# Der linearzeit MST-Algorithmus

Der schnellste Algorithmus für das MST/ MSF Problem

Max Springenberg

Proseminar: Randomisierte Algorithmen, TU Dortmund

# Motivation

# "the fastest"

Borůvka, Kruskal, Prim	$O(m \log(n))$	(deterministisch)
Chazelle	$O(m \log(\beta(m, n)))$	(deterministisch)
MST	O(m+n)	(randomisiert)

1

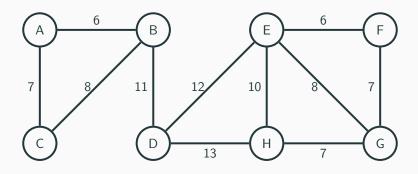
### "the fastest"

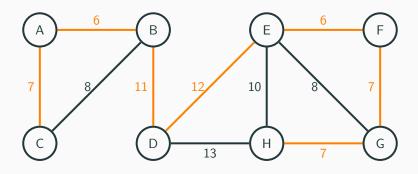
```
Borůvka, Kruskal, Prim O(m \log(n)) (deterministisch)
Chazelle O(m \log(\beta(m,n))) (deterministisch)
MST O(m+n) (randomisiert)
```

"For many applications, a randomized algorithm is the simplest algorithm available, or the fastest, or both."[1]

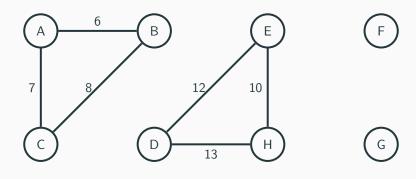
1

Was wollen wir erreichen?

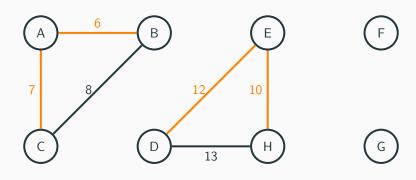




# MSF



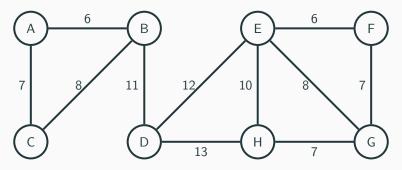
# MSF



# *F*-leicht/-schwer

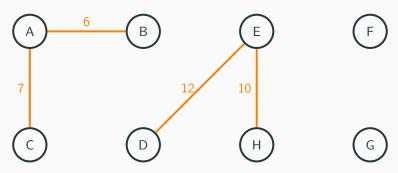
## Teaser: *F*-schwer

Sei G:



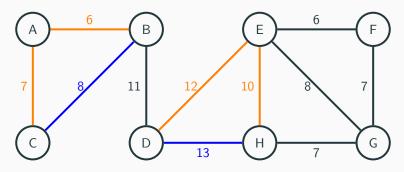
## Teaser: *F*-schwer

Sei F:



### **Teaser:** *F*-schwer

Dann ist etwas an diesen Kanten besonders.



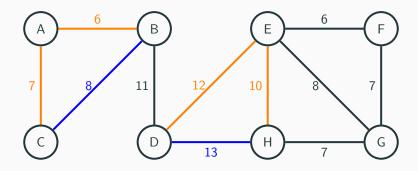
# F-leicht/-schwer

Sei 
$$e = \{u, v\}$$
,  $P_e$  in  $F$ ,  $w$  von  $G$ 

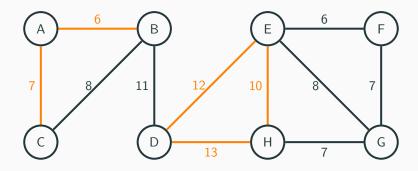
$$w_F(e) = egin{cases} \infty & , u \text{ und } v \text{ in verschiedenen Komponenten} \\ max\{w(P_e(e))\} & , \text{ sonst} \end{cases}$$

F-schwer: 
$$w(e) > w_F(e)$$

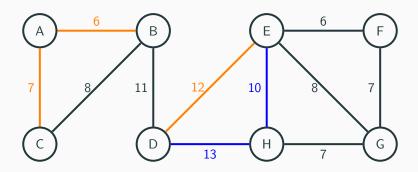
F-leicht: 
$$w(e) \le w_F(e)$$



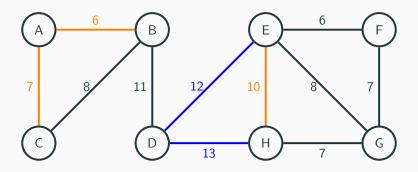
Zyklus D,E,H,D $\mbox{\ensuremath{\cancel{\uptilde}}}$ 



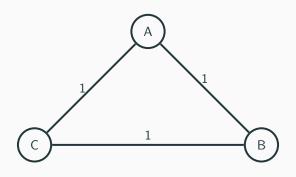




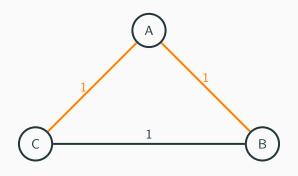




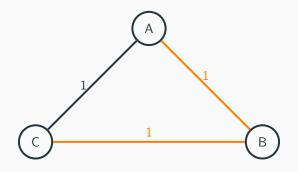
 $G_{w_1}$ :



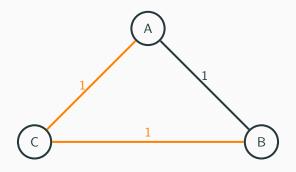
 $G_{w_1}$ , MST F:



 $G_{w_1}$ , MST F:



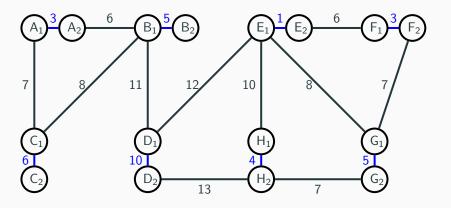
 $G_{w_1}$ , MST F:



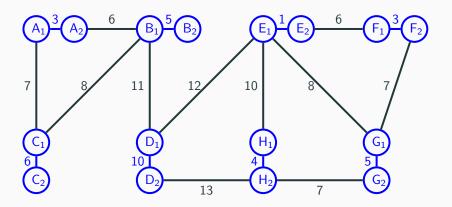
Borůvka Phasen

- 1. Kontraktierende Kanten markieren
- 2. Verbundene Komponenten bestimmen
- 3. Verbundene Komponenten durch einzelne Knoten ersetzen
- 4. Selbstschleifen entfernen

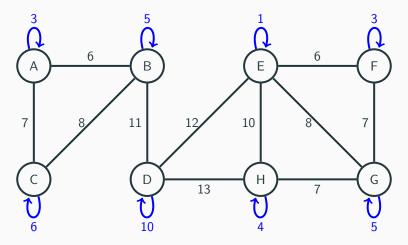
### 1. Kontraktierende Kanten markieren



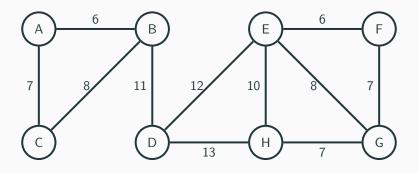
### 2. Verbundene Komponenten bestimmen



3. Verbundene Komponenten durch einzelne Knoten ersetzen



### 4. Selbstschleifen entfernen



9

### Reduktion der Knoten

• Minimale Komponente: zwei Knoten, eine Kante

### Reduktion der Knoten

- Minimale Komponente: zwei Knoten, eine Kante
- Maximale Anzahl minimaler Komponenten: n/2

### Reduktion der Knoten

- Minimale Komponente: zwei Knoten, eine Kante
- Maximale Anzahl minimaler Komponenten: n/2
- Maximale Anzahl an Knoten nach Borůvka-Phase: n/2

Randomisierte Stichproben

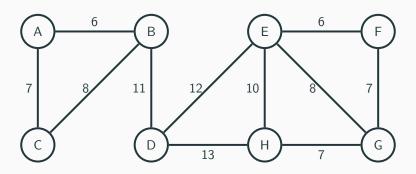


Wirf eine Münze!

Quelle: https://melbournechapter.net/explore/coin-flip-clipart/

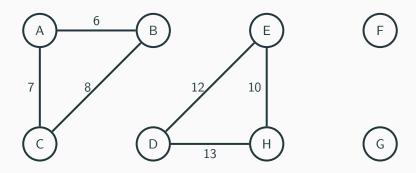
# Kanten "würfeln"

 $\boldsymbol{G}$  :

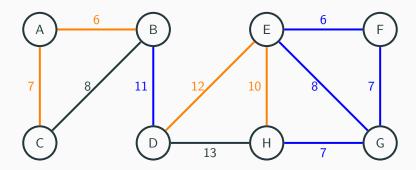


## Kanten "würfeln"





# Kanten "würfeln"



Lemma 10.19 (vereinfacht)

Für den MSF F von G(p), wobei  $p \in (0,1]$  erwarten wir nicht mehr als n/p F-leichte Kanten in G.

### Lemma 10.19 (vereinfacht)

Für den MSF F von G(p), wobei  $p \in (0,1]$  erwarten wir nicht mehr als n/p F-leichte Kanten in G.

#### Beweisidee:

• Seien die Kanten von G aufsteigend sortiert

$$e_1,\ldots,e_{m_G},\ w(e_1)\leq\ldots\leq w(e_{m_G})$$

### Lemma 10.19 (vereinfacht)

Für den MSF F von G(p), wobei  $p \in (0,1]$  erwarten wir nicht mehr als n/p F-leichte Kanten in G.

- Seien die Kanten von G aufsteigend sortiert
- Sei  $F = (V_G, \emptyset)$

### Lemma 10.19 (vereinfacht)

Für den MSF F von G(p), wobei  $p \in (0,1]$  erwarten wir nicht mehr als n/p F-leichte Kanten in G.

- Seien die Kanten von G aufsteigend sortiert
- Sei  $F = (V_G, \emptyset)$
- Konstruiere G(p) nach der Kantenreihenfolge

### Lemma 10.19 (vereinfacht)

Für den MSF F von G(p), wobei  $p \in (0,1]$  erwarten wir nicht mehr als n/p F-leichte Kanten in G.

- Seien die Kanten von G aufsteigend sortiert
- Sei  $F = (V_G, \emptyset)$
- Konstruiere G(p) nach der Kantenreihenfolge
- Ist die betrachtete Kante F-leicht und in verschiedenen Komponenten wird sie in F aufgenommen

• Wann wird die nächste Kante hinzugenommen?

• Wann wird die nächste F-leichte Kante hinzugenommen?

• Wann wird die nächste F-leichte Kante hinzugenommen?

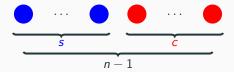
- Wann wird die nächste F-leichte Kante hinzugenommen?
- Wie oft "würfeln"?

- Wann wird die nächste F-leichte Kante hinzugenommen?
- Wie oft "würfeln"? 1/p

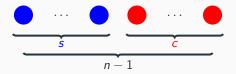
- Wann wird die nächste F-leichte Kante hinzugenommen?
- Wie oft "würfeln"? 1/p
- Letzte Phase:  $s \leq n-1, s \in \mathbb{N}$

ullet Differenz der Phasen c=(n-1)-s

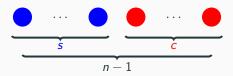
• Differenz der Phasen c = (n-1) - s



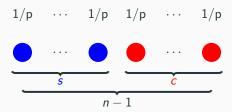
- Differenz der Phasen c = (n-1) s
- weitere c-Phasen, impliziert: erwartet mehr F-leichte Kanten in G



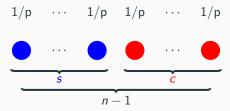
- Differenz der Phasen c = (n-1) s
- weitere c-Phasen, impliziert: erwartet mehr F-leichte Kanten in G
- n-1 Phasen/ Erfolge

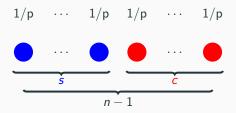


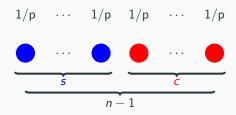
- Differenz der Phasen c = (n-1) s
- weitere c-Phasen, impliziert: erwartet mehr F-leichte Kanten in G
- n-1 Phasen/ Erfolge



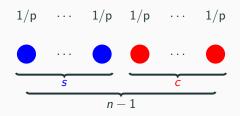
- Differenz der Phasen c = (n-1) s
- weitere c-Phasen, impliziert: erwartet mehr F-leichte Kanten in G
- n-1 Phasen/ Erfolge
- Erfolgswahrscheinlichkeit p, impiziert: negative Binomialverteilung







 $X_{np} \stackrel{def}{=}$  negative Binomialverteilung, Parameter n-1,p  $X_{sp} \stackrel{def}{=}$  negative Binomialverteilung, Parameter s,p



 $X_{np} \stackrel{def}{=}$  negative Binomialverteilung, Parameter n-1,p  $X_{sp} \stackrel{def}{=}$  negative Binomialverteilung, Parameter s,p  $X_{np}$  dominiert  $X_{sp}$ , mit:

Für alle 
$$z \in \mathbb{R}$$
:  $\Pr[X_{np} > z] \ge \Pr[X_{sp} > z]$  oder auch:  $n/p > (n-1)/p = E[X_{np}] \ge E[X_{sp}] = s/p$ 

**Der MST-Algorithmus** 

Data: Graph G

**Result:** Approximation eines MST/ MSF in  ${\it G}$ 

Data: Graph G

**Result:** Approximation eines MST/ MSF in *G* 

3 Borůvka-Phasen

1:  $G_1, C \leftarrow$  **Wenn** G leer oder Borůvka-Phasen terminieren:

return F = C

Data: Graph G

**Result:** Approximation eines MST/ MSF in *G* 

3 Borůvka-Phasen

1:  $G_1, C \leftarrow$  **Wenn** G leer oder Borůvka-Phasen terminieren:

return 
$$F = C$$

2: 
$$G_2 \leftarrow G_1(p = 0, 5)$$

Data: Graph G

**Result:** Approximation eines MST/ MSF in *G* 

3 Borůvka-Phasen

1:  $G_1, C \leftarrow$  **Wenn** G leer oder Borůvka-Phasen terminieren:

return 
$$F = C$$

- 2:  $G_2 \leftarrow G_1(p=0,5)$
- 3:  $F_2 \leftarrow MST(G_2)$

Data: Graph G

Result: Approximation eines MST/ MSF in G

3 Borůvka-Phasen

1:  $G_1, C \leftarrow Wenn G$  leer oder Borůvka-Phasen terminieren:

return 
$$F = C$$

- 2:  $G_2 \leftarrow G_1(p=0,5)$
- 3:  $F_2 \leftarrow MST(G_2)$
- 4:  $G_3 \leftarrow (V_{G_1}, E_{G_1} E_{F_2 heavy})$

Data: Graph G

**Result:** Approximation eines MST/ MSF in *G* 

3 Borůvka-Phasen

1:  $G_1, C \leftarrow Wenn G$  leer oder Borůvka-Phasen terminieren:

return 
$$F = C$$

- 2:  $G_2 \leftarrow G_1(p=0,5)$
- 3:  $F_2 \leftarrow MST(G_2)$
- 4:  $G_3 \leftarrow (V_{G_1}, E_{G_1} E_{F_2 heavy})$
- 5:  $F_3 \leftarrow MST(G_3)$

Data: Graph G

**Result:** Approximation eines MST/ MSF in *G* 

3 Borůvka-Phasen

1:  $G_1, C \leftarrow Wenn G$  leer oder Borůvka-Phasen terminieren:

return 
$$F = C$$

2: 
$$G_2 \leftarrow G_1(p=0,5)$$

3: 
$$F_2 \leftarrow MST(G_2)$$

4: 
$$G_3 \leftarrow (V_{G_1}, E_{G_1} - E_{F_2-heavy})$$

5: 
$$F_3 \leftarrow MST(G_3)$$

6: **return** 
$$F = C \cup F_3$$

# Laufzeit: Überblick

$$G_1, C \leftarrow egin{array}{c} & ext{Wenn } G ext{ leer} \\ & ext{oder Borůvka-Phasen terminieren:} \\ & ext{return } F = C \end{array}$$
 $G_2 \leftarrow G_1(p=0,5)$ 
 $F_2 \leftarrow MST(G_2)$ 
 $G_3 \leftarrow (V_{G_1}, E_{G_1} - E_{F_2 - heavy})$ 
 $F_3 \leftarrow MST(G_3)$ 
 $ext{return } F = C \cup F_3$ 

# Laufzeit: Überblick

$$O(n+m)$$
  $G_1, C \leftarrow$  Wenn  $G$  leer oder Borůvka-Phasen terminieren: return  $F = C$ 

$$O(n+m)$$
  $G_2 \leftarrow G_1(p=0,5)$   $F_2 \leftarrow MST(G_2)$   $O(n+m)$   $G_3 \leftarrow (V_{G_1}, E_{G_1} - E_{F_2-heavy})$   $F_3 \leftarrow MST(G_3)$ 

$$O(n+m)$$
 return  $F=C\cup F_3$ 

# Laufzeit: Überblick

3 Borůvka-Phasen

$$O(n+m)$$
  $G_1, C \leftarrow$  Wenn  $G$  leer oder Borůvka-Phasen terminieren: return  $F = C$ 

$$O(n+m) \quad G_2 \leftarrow G_1(p=0,5)$$

? 
$$F_2 \leftarrow MST(G_2)$$

$$O(n+m)$$
  $G_3 \leftarrow (V_{G_1}, E_{G_1} - E_{F_2-heavy})$ 

? 
$$F_3 \leftarrow MST(G_3)$$

$$O(n+m)$$
 return  $F=C\cup F_3$ 

$$T(m,n) \le ? + ? + c(m+n)$$
  
, mit  $c \in \mathbb{N}$  konstant

$$T(m,n) \le ? + ? + c(m+n)$$
  
, mit  $c \in \mathbb{N}$  konstant

$$G_1 \mid n_{G_1} = n_G/8, m_{G_1} = m_G$$

$$T(m,n) \leq ? + ? + c(m+n)$$
  
, mit  $c \in \mathbb{N}$  konstant

$$G_1$$
  $n_{G_1} = n_G/8, m_{G_1} = m_G$   
 $G_2$   $n_{G_2} = n_G/8, m_{G_2} = m_G/2$ 

$$T(m, n) \le T(n/8, m/2) + ? + c(m + n)$$
  
, mit  $c \in \mathbb{N}$  konstant

$$G_1$$
  $n_{G_1} = n_G/8, m_{G_1} = m_G$   
 $G_2$   $n_{G_2} = n_G/8, m_{G_2} = m_G/2$ 

$$T(m, n) \le T(n/8, m/2) + ? + c(m + n)$$
  
, mit  $c \in \mathbb{N}$  konstant

$$G_1$$
  $n_{G_1} = n_G/8, m_{G_1} = m_G$   
 $G_2$   $n_{G_2} = n_G/8, m_{G_2} = m_G/2$   
 $G_3$   $n_{G_3} = \frac{n_G/8}{0.5}, m_{G_3} = m_G/2$ 

$$T(m, n) \le T(n/8, m/2) + T(n/8, n/4) + c(m+n)$$
  
, mit  $c \in \mathbb{N}$  konstant

$$G_1$$
  $n_{G_1} = n_G/8, m_{G_1} = m_G$   
 $G_2$   $n_{G_2} = n_G/8, m_{G_2} = m_G/2$   
 $G_3$   $n_{G_3} = n_G/4, m_{G_3} = m_G/2$ 

$$T(m, n) \le T(n/8, m/2) + T(n/8, n/4) + c(m+n)$$

$$\le (T(n/8^2, m/2^2) + T(n/8^2, \frac{2n}{8^2}) + c(n/8 + m/2))$$

$$+ (T(n/8^2, \frac{n/4}{2}) + T(n/8^2, \frac{2n}{8^2}) + c(n/8 + n/4))$$

$$+ c(n+m)$$
. mit  $c \in \mathbb{N}$  konstant

$$\begin{split} T(m,n) &\leq \mathsf{T}(\mathsf{n}/8,\ \mathsf{m}/2) + \mathsf{T}(\mathsf{n}/8,\ \mathsf{n}/4) + c(m+n) \\ &\leq (T(n/8^2,m/2^2) + T(n/8^2,\frac{2n}{8^2}) \\ &+ T(n/8^2,\frac{n/4}{2}) + T(n/8^2,\frac{2n}{8^2}) \\ &+ c(n/8+n/4) + c(n/8+m/2)) + c(n+m) \end{split}$$

$$T(m, n) \le T(n/8, m/2) + T(n/8, n/4) + c(m+n)$$
  
 $\le (T(n/8^2, m/2^2) + T(n/8^2, \frac{2n}{8^2})$   
 $+ T(n/8^2, \frac{n/4}{2}) + T(n/8^2, \frac{2n}{8^2})$   
 $+ c(n/2 + m/2)) + c(n+m)$   
. mit  $c \in \mathbb{N}$  konstant

$$T(m, n) \leq T(n/8, m/2) + T(n/8, n/4) + c(m+n)$$

$$\leq (T(n/8^2, m/2^2) + T(n/8^2, \frac{2n}{8^2})$$

$$+ T(n/8^2, \frac{n/4}{2}) + T(n/8^2, \frac{2n}{8^2})$$

$$+ c(n/2 + m/2)) + c(n+m)$$

$$\leq c(n+m) \cdot \sum_{i=0}^{\infty} (1/2)^i$$

, mit  $c \in \mathbb{N}$  konstant

$$T(m, n) \le T(n/8, m/2) + T(n/8, n/4) + c(m+n)$$

$$\le (T(n/8^2, m/2^2) + T(n/8^2, \frac{2n}{8^2})$$

$$+ T(n/8^2, \frac{n/4}{2}) + T(n/8^2, \frac{2n}{8^2})$$

$$+ c(n/2 + m/2)) + c(n+m)$$

$$\le c(n+m) \cdot \sum_{i=0}^{\infty} (1/2)^i$$

$$= 2 \cdot c(n+m)$$
. mit  $c \in \mathbb{N}$  konstant

19

• F-leichte Kanten als Gütekriterium

- F-leichte Kanten als Gütekriterium
- MSF F von G(p), mit n/p F-leichten Kanten in G

- F-leichte Kanten als Gütekriterium
- MSF F von G(p), mit n/p F-leichten Kanten in G
- Wissen von anderen Algorithmen verwenden

- F-leichte Kanten als Gütekriterium
- MSF F von G(p), mit n/p F-leichten Kanten in G
- Wissen von anderen Algorithmen verwenden
- Auch sukzessive, rekursive Aufrufe können effizient sein

#### Literatur



[1] Motwani, R., Raghavan, P.: Randomized Algorithms. Cambridge : Cambridge University Press 1995, Preface, Kapitel 10.3.