

Wahrscheinlichkeitsrechnung und mathematische Statistik für Informatiker

Vorlesung im Wintersemester 2018/19
an der TU Dortmund

Jun.-Prof. Dr. Andreas Groll

WiSe 18/19, Fakultät Statistik, TU Dortmund

Einleitung

1.1 WRUMS für Informatiker

Jun.-Prof. Dr. Andreas Groll

Mathegebäude, Raum 216a

E-mail: groll@statistik.tu-dortmund.de

- Vorlesung

- ▶ Termin: Do 08:30 - 10:00
- ▶ Hörsaal: HG II - HS3

1.1 WRUMS für Informatiker

Jun.-Prof. Dr. Andreas Groll

Mathegebäude, Raum 216a

E-mail: groll@statistik.tu-dortmund.de

- Vorlesung

- ▶ Termin: Do 08:30 - 10:00
- ▶ Hörsaal: HG II - HS3

Hendrik van der Wurp

Mathegebäude, Raum 226

E-mail: vanderwurp@statistik.tu-dortmund.de

- Übung (2 Gruppen)

- ▶ Termin: Do 18:00 - 19:30 (i.d.R. alle 2 Wochen)
- ▶ Gruppe 1: ab 18.10.2018
- ▶ Gruppe 2: ab 25.10.2018
- ▶ Raum: EF50 - HS1

1.1 WRUMS für Informatiker

Jun.-Prof. Dr. Andreas Groll

Mathegebäude, Raum 216a

E-mail: groll@statistik.tu-dortmund.de

- Vorlesung

- ▶ Termin: Do 08:30 - 10:00
- ▶ Hörsaal: HG II - HS3

Hendrik van der Wurp

Mathegebäude, Raum 226

E-mail: vanderwurp@statistik.tu-dortmund.de

- Übung (2 Gruppen)

- ▶ Termin: Do 18:00 - 19:30 (i.d.R. alle 2 Wochen)
- ▶ Gruppe 1: ab 18.10.2018
- ▶ Gruppe 2: ab 25.10.2018
- ▶ Raum: EF50 - HS1

- Klausurtermine

- ▶ Klausur: Mo (18.02.2019)
16-18 Uhr, Räume: Audimax & EF50 - HS3 & Mathe E28 & Mathe E29
- ▶ Nachklausur: Fr (29.03.2019)
8-10 Uhr, Räume: Audimax & Mathe E28 & Mathe E29

1.1 WRUMS für Informatiker

Jun.-Prof. Dr. Andreas Groll

Mathegebäude, Raum 216a

E-mail: groll@statistik.tu-dortmund.de

- Vorlesung

- ▶ Termin: Do 08:30 - 10:00
- ▶ Hörsaal: HG II - HS3

Hendrik van der Wurp

Mathegebäude, Raum 226

E-mail: vanderwurp@statistik.tu-dortmund.de

- Übung (2 Gruppen)

- ▶ Termin: Do 18:00 - 19:30 (i.d.R. alle 2 Wochen)
- ▶ Gruppe 1: ab 18.10.2018
- ▶ Gruppe 2: ab 25.10.2018
- ▶ Raum: EF50 - HS1

- Klausurtermine

- ▶ Klausur: Mo (18.02.2019)
16-18 Uhr, Räume: Audimax & EF50 - HS3 & Mathe E28 & Mathe E29
- ▶ Nachklausur: Fr (29.03.2019)
8-10 Uhr, Räume: Audimax & Mathe E28 & Mathe E29

- Voraussetzung für Klausur

Regelmäßige Teilnahme Ü,
selbstständige Bearbeitung der
Übungsaufgaben

1.1 WRUMS für Informatiker

Jun.-Prof. Dr. Andreas Groll

Mathegebäude, Raum 216a

E-mail: groll@statistik.tu-dortmund.de

- Vorlesung

- ▶ Termin: Do 08:30 - 10:00
- ▶ Hörsaal: HG II - HS3

Hendrik van der Wurp

Mathegebäude, Raum 226

E-mail: vanderwurp@statistik.tu-dortmund.de

- Übung (2 Gruppen)

- ▶ Termin: Do 18:00 - 19:30 (i.d.R. alle 2 Wochen)
- ▶ Gruppe 1: ab 18.10.2018
- ▶ Gruppe 2: ab 25.10.2018
- ▶ Raum: EF50 - HS1

- Klausurtermine

- ▶ Klausur: Mo (18.02.2019)
16-18 Uhr, Räume: Audimax & EF50 - HS3 & Mathe E28 & Mathe E29
- ▶ Nachklausur: Fr (29.03.2019)
8-10 Uhr, Räume: Audimax & Mathe E28 & Mathe E29

- Voraussetzung für Klausur

Regelmäßige Teilnahme Ü,
selbstständige Bearbeitung der
Übungsaufgaben

- Moodle

Website: [https://moodle.tu-dortmund.de/
course/view.php?id=13183](https://moodle.tu-dortmund.de/course/view.php?id=13183)

Passwort: wrums1819

1.2 Übersicht

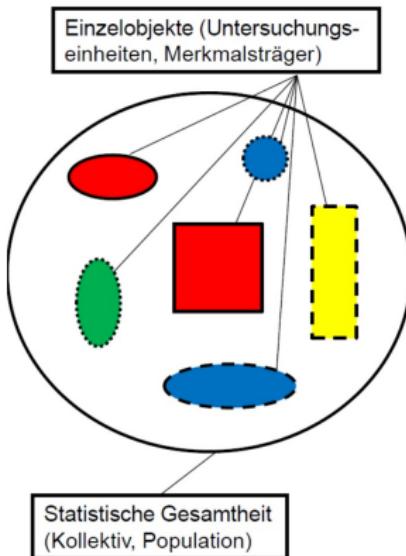
- Motivation
- Merkmale und Datentypen
- Univariate Daten
 - ▶ Tabellarische und grafische Darstellung
- Statistische Kennzahlen
 - ▶ für die Lage
 - ▶ für die Streuung
- Bivariate Daten
 - ▶ Tabellarische und grafische Darstellung
 - ▶ Zusammenhangsmaße
 - ▶ Lineare Regression
- Mengentheoretische Grundlagen
- Wahrscheinlichkeitsmaße und -räume
- Zufallsvariablen und deren Verteilungen
- Wichtige Wahrscheinlichkeitsverteilungen
- Bedingte Wahrscheinlichkeiten und stochastische Unabhängigkeit
- Erwartungswert und Varianz
- Weitere wahrscheinlichkeitstheoretische Kennzahlen
- Markoffketten
- Statistische Tests
 - ▶ Normalverteilung
 - ▶ Test bei nicht-normalverteilten Daten

1.3 Motivation

- Statistische Methoden spielen in der Informatik an vielen Stellen eine große Rolle
- Beispiele:
 - ▶ Laufzeiten von Algorithmen mit stochastischem Input
 - ▶ Stochastische Algorithmen
 - ▶ Spieltheorie
 - ▶ Ausfälle von Datenverbindungen oder Hardwarekomponenten
 - ▶ Automatische Übersetzung
 - ▶ Assoziationsregeln, Bilderkennung, Signalanalyse
 - ▶ Statistische Lernverfahren
- Diese Vorlesung behandelt nicht alle diese Themen, sondern die dazu notwendigen statistischen Grundlagen.

Univariate Daten

2.1 Merkmale und Datentypen



Merkmal	Merkmalsausprägungen	Wertebereich
Form	Ellipse, Ellipse, Ellipse, Rechteck, Rechteck, Ellipse	{Ellipse, Rechteck}
Farbe	Rot, Blau, Grün, Rot, Gelb, Blau	{Blau, Gelb, Grün, Rot}
Linienart	Durchgängig, Gepunktet, Gepunktet, Durchgängig, Gestrichelt, Gestrichelt	{Gepunktet, Gestrichelt, Durchgängig}
Breite in cm	2, 1, 1, 2, 1, 3	$(0, \infty)$
Höhe in cm	1, 1, 2, 2, 3, 1	$(0, \infty)$

2.1 Merkmale und Datentypen

Datentypen

Skalentyp mögliche Aussagen Im Beispiel

qualitativ

Nominal	Gleich / Verschieden	Farbe, Form (binär, dichotom)
Ordinal	Größer / Kleiner	Linienart

quantitativ / metrisch

Intervall	Differenzen gleich / verschieden	(Breite, Höhe)
Verhältnis	Verhältnisse gleich / verschieden	Breite, Höhe

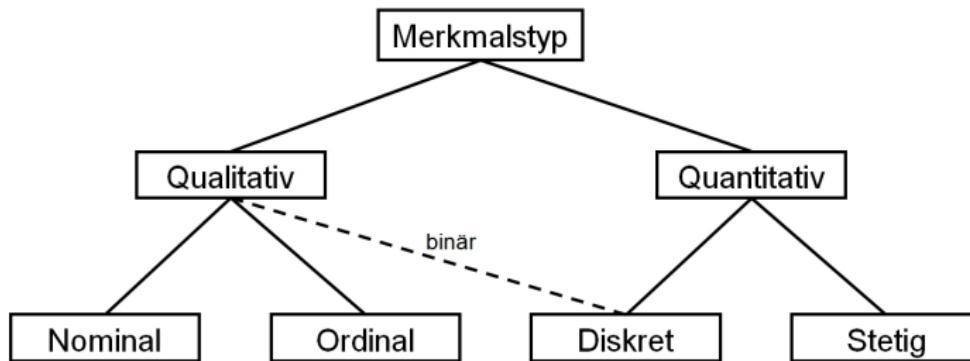
2.1 Merkmale und Datentypen

Datentypen

Datentyp	Anzahl der Ausprägungen	Im Beispiel
Diskret	Endlich <i>oder</i> abzählbar unendlich viele	Form Breite, Höhe (wenn grob bemessen)
Stetig	Überabzählbar viele	Breite, Höhe (wenn beliebig fein bemessen)

2.1 Merkmale und Datentypen

Datentypen



- Qualitativ heißt immer diskret
- Skalenniveau wird von links nach rechts immer höher

2.1 Merkmale und Datentypen

- Unter Inkaufnahme von Informationsverlust können Merkmale in andere Skalenniveaus überführt und entsprechend analysiert werden
 - ▶ stetig in diskret (runden, genaue Werte gehen verloren)
 - ▶ diskret quantitativ in ordinal (Abstände gehen verloren)
 - ▶ ordinal in nominal (Ordnung geht verloren)
- Dieses Vorgehen kann generell auch sinnvoll sein (z.B. bei Linearitätsverletzung)

2.2 Tabellarische und grafische Darstellung von univariaten Daten

Qualitative Daten

$M_N = \{e_1, \dots, e_N\}$ Population bestehend aus Objekten e_1, \dots, e_N

X Nominales bzw. ordinales Merkmal

$x \in W_X$ Merkmalsausprägungen von X

$W_X = \{x(j) \mid j = 1, \dots, J\} = \{x(1), \dots, x(J)\}$ Wertebereich von X mit Merkmalsausprägungen $x(j)$, $j = 1, \dots, J$

$D_N = \{x_n \mid n = 1, \dots, N\} = \{x_1, \dots, x_N\}$ Urliste aus der Messung von X in der Population M_N , d.h. $x_n = X(e_n)$, $n = 1, \dots, N$

$x(1) < x(2) < \dots < x(J)$ falls X ordinal

2.2 Tabellarische und grafische Darstellung von univariaten Daten

Qualitative Daten: Beispiel **Bearbeitungen von Softwareaufgaben**

Bearbeitung	Bearbeiter(in)	Aufgabe	Version	Anzahl Clicks	Bearbeitungszeit
e ₁	Kai	Export	1.1	14	8.0
e ₂	Kai	Verknüpfung	1.2	12	4.9
e ₃	Miriam	Export	1.1	12	6.6
e ₄	Tina	Verknüpfung	1.2	13	3.2
e ₅	Oliver	Export	2.0	17	3.9
e ₆	Tina	Export	1.2	11	4.5
e ₇	Tina	Verknüpfung	1.2	14	6.1
e ₈	Miriam	Export	1.2	10	3.7
e ₉	Miriam	Export	1.2	10	4.2
e ₁₀	Oliver	Abfrage	1.1	18	8.5
e ₁₁	Oliver	Verknüpfung	2.0	16	3.6
e ₁₂	Oliver	Abfrage	2.0	15	3.7

2.2 Tabellarische und grafische Darstellung von univariaten Daten

Qualitative Daten: Beispiel **Bearbeitungen von Softwareaufgaben**

Bearbeitung	Bearbeiter(in)	Aufgabe	Version	Anzahl Clicks	Bearbeitungszeit
e ₁	Kai	Export	1.1	14	8.0
e ₂	Kai	Verknüpfung	1.2	12	4.9
e ₃	Miriam	Export	1.1	12	6.6
e ₄	Tina	Verknüpfung	1.2	13	3.2
e ₅	Oliver	Export	2.0	17	3.9
e ₆	Tina	Export	1.2	11	4.5
e ₇	Tina	Verknüpfung	1.2	14	6.1
e ₈	Miriam	Export	1.2	10	3.7
e ₉	Miriam	Export	1.2	10	4.2
e ₁₀	Oliver	Abfrage	1.1	18	8.5
e ₁₁	Oliver	Verknüpfung	2.0	16	3.6
e ₁₂	Oliver	Abfrage	2.0	15	3.7

Objekte

2.2 Tabellarische und grafische Darstellung von univariaten Daten

Qualitative Daten: Beispiel **Bearbeitungen von Softwareaufgaben**

Bearbeitung	Bearbeiter(in)	Aufgabe	Version	Anzahl Clicks	Bearbeitungszeit
e ₁	Kai	Export	1.1	14	8.0
e ₂	Kai	Verknüpfung	1.2	12	4.9
e ₃	Miriam	Export	1.1	12	6.6
e ₄	Tina	Verknüpfung	1.2	13	3.2
e ₅	Oliver	Export	2.0	17	3.9
e ₆	Tina	Export	1.2	11	4.5
e ₇	Tina	Verknüpfung	1.2	14	6.1
e ₈	Miriam	Export	1.2	10	3.7
e ₉	Miriam	Export	1.2	10	4.2
e ₁₀	Oliver	Abfrage	1.1	18	8.5
e ₁₁	Oliver	Verknüpfung	2.0	16	3.6
e ₁₂	Oliver	Abfrage	2.0	15	3.7

5 Variablen

2.2 Tabellarische und grafische Darstellung von univariaten Daten

Qualitative Daten: Beispiel **Bearbeitungen von Softwareaufgaben**

Bearbeitung	Bearbeiter(in)	Aufgabe	Version	Anzahl Clicks	Bearbeitungszeit
e ₁	Kai	Export	1.1	14	8.0
e ₂	Kai	Verknüpfung	1.2	12	4.9
e ₃	Miriam	Export	1.1	12	6.6
e ₄	Tina	Verknüpfung	1.2	13	3.2
e ₅	Oliver	Export	2.0	17	3.9
e ₆	Tina	Export	1.2	11	4.5
e ₇	Tina	Verknüpfung	1.2	14	6.1
e ₈	Miriam	Export	1.2	10	3.7
e ₉	Miriam	Export	1.2	10	4.2
e ₁₀	Oliver	Abfrage	1.1	18	8.5
e ₁₁	Oliver	Verknüpfung	2.0	16	3.6
e ₁₂	Oliver	Abfrage	2.0	15	3.7

Qualitative Daten

2.2 Tabellarische und grafische Darstellung von univariaten Daten

Qualitative Daten: Beispiel Bearbeitungen von Softwareaufgaben

Bearbeitung	Bearbeiter(in)	Aufgabe	Version	Anzahl Clicks	Bearbeitungszeit
e ₁	Kai	Export	1.1	14	8.0
e ₂	Kai	Verknüpfung	1.2	12	4.9
e ₃	Miriam	Export	1.1	12	6.6
e ₄	Tina	Verknüpfung	1.2	13	3.2
e ₅	Oliver	Export	2.0	17	3.9
e ₆	Tina	Export	1.2	11	4.5
e ₇	Tina	Verknüpfung	1.2	14	6.1
e ₈	Miriam	Export	1.2	10	3.7
e ₉	Miriam	Export	1.2	10	4.2
e ₁₀	Oliver	Abfrage	1.1	18	8.5
e ₁₁	Oliver	Verknüpfung	2.0	16	3.6
e ₁₂	Oliver	Abfrage	2.0	15	3.7

D_{N;1}, N=12

X₁ = Bearbeiter(in)

W_{X1} = {Kai, Miriam, Oliver, Tina}

J₁ = 4

2.2 Tabellarische und grafische Darstellung von univariaten Daten

Qualitative Daten: Beispiel **Bearbeitungen von Softwareaufgaben**

Bearbeitung	Bearbeiter(in)	Aufgabe	Version	Anzahl Clicks	Bearbeitungszeit
e ₁	Kai	Export	1.1	14	8.0
e ₂	Kai	Verknüpfung	1.2	12	4.9
e ₃	Miriam	Export	1.1	12	6.6
e ₄	Tina	Verknüpfung	1.2	13	3.2
e ₅	Oliver	Export	2.0	17	3.9
e ₆	Tina	Export	1.2	11	4.5
e ₇	Tina	Verknüpfung	1.2	14	6.1
e ₈	Miriam	Export	1.2	10	3.7
e ₉	Miriam	Export	1.2	10	4.2
e ₁₀	Oliver	Abfrage	1.1	18	8.5
e ₁₁	Oliver	Verknüpfung	2.0	16	3.6
e ₁₂	Oliver	Abfrage	2.0	15	3.7

D_{N,2}, N=12

X₂ = Aufgabe

W_{X2} = {Abfrage, Export, Verknüpfung}

J₂ = 3

2.2 Tabellarische und grafische Darstellung von univariaten Daten

Qualitative Daten: Beispiel Bearbeitungen von Softwareaufgaben

Bearbeitung	Bearbeiter(in)	Aufgabe	Version	Anzahl Clicks	Bearbeitungszeit
e ₁	Kai	Export	1.1	14	8.0
e ₂	Kai	Verknüpfung	1.2	12	4.9
e ₃	Miriam	Export	1.1	12	6.6
e ₄	Tina	Verknüpfung	1.2	13	3.2
e ₅	Oliver	Export	2.0	17	3.9
e ₆	Tina	Export	1.2	11	4.5
e ₇	Tina	Verknüpfung	1.2	14	6.1
e ₈	Miriam	Export	1.2	10	3.7
e ₉	Miriam	Export	1.2	10	4.2
e ₁₀	Oliver	Abfrage	1.1	18	8.5
e ₁₁	Oliver	Verknüpfung	2.0	16	3.6
e ₁₂	Oliver	Abfrage	2.0	15	3.7

$D_{N,3}, N=12$
 $X_3 = \text{Version}$
 $W_{X_3} = \{1.1, 1.2, 2.0\}, 1.1 < 1.2 < 2.0$
 $J_3 = 3$

2.2 Tabellarische und grafische Darstellung von univariaten Daten

Qualitative Daten: Deskriptive Auswertung

Absolute Häufigkeit N_j von $x(j)$: $N_j = N[x(j)] = \sum_{i=1}^N d_i(j)$, mit $d_i(j) := I_{x(e_i)=x(j)}$

Damit gilt $\sum_{j=1}^J N_j = N$

$x_1(1)$ Kai	$x_1(2)$ Miriam	$x_1(3)$ Oliver	$x_1(4)$ Tina	Σ
2	3	4	3	12

i	$X_1(e_i)$	$d_{11}(1)$	$d_{11}(2)$	$d_{11}(3)$	$d_{11}(4)$
1	Kai	1	0	0	0
2	Kai	1	0	0	0
3	Miriam	0	1	0	0
4	Tina	0	0	0	1
5	Oliver	0	0	1	0
6	Tina	0	0	0	1
7	Tina	0	0	0	1
8	Miriam	0	1	0	0
9	Miriam	0	1	0	0
10	Oliver	0	0	1	0
11	Oliver	0	0	1	0
12	Oliver	0	0	1	0
Σ		2	3	4	3

2.2 Tabellarische und grafische Darstellung von univariaten Daten

Qualitative Daten: Deskriptive Auswertung

Relative Häufigkeit f_j von $x(j)$: $f_j = \frac{N_j}{N}$

Damit gilt $\sum_{j=1}^J f_j = 1$

$x_1(1)$ Kai	$x_1(2)$ Miriam	$x_1(3)$ Oliver	$x_1(4)$ Tina	Σ
2/12 ≈ 0.17	3/12 $= 0.25$	4/12 ≈ 0.33	3/12 $= 0.25$	12/12 $= 1$

i	$X_1(e_i)$	$d_{11}(1)$	$d_{11}(2)$	$d_{11}(3)$	$d_{11}(4)$
1	Kai	1	0	0	0
2	Kai	1	0	0	0
3	Miriam	0	1	0	0
4	Tina	0	0	0	1
5	Oliver	0	0	1	0
6	Tina	0	0	0	1
7	Tina	0	0	0	1
8	Miriam	0	1	0	0
9	Miriam	0	1	0	0
10	Oliver	0	0	1	0
11	Oliver	0	0	1	0
12	Oliver	0	0	1	0
$\Sigma/12$		0.17	0.25	0.33	0.25

2.2 Tabellarische und grafische Darstellung von univariaten Daten

Qualitative Daten: Deskriptive Auswertung

Tabellarische Darstellung absoluter und relativer Häufigkeiten

Ausprägung	Absolute Häufigkeit	Relative Häufigkeit
$x(1)$	N_1	$f_1 = N_1/N$
\vdots	\vdots	\vdots
$x(J)$	N_J	$f_J = N_J/N$
	$\sum_{j=1}^J N_j = N$	$\sum_{j=1}^J f_j = 1$

2.2 Tabellarische und grafische Darstellung von univariaten Daten

Qualitative Daten: Deskriptive Auswertung

Tabellarische Darstellung absoluter und relativer Häufigkeiten

Bearbeiter(in)		
Ausprägung	Absolute Häufigkeit	Relative Häufigkeit
Kai	2	0.17
Miriam	3	0.25
Oliver	4	0.33
Tina	3	0.25
	12	1

Aufgabe		
Ausprägung	Absolute Häufigkeit	Relative Häufigkeit
Abfrage	2	0.17
Export	6	0.5
Verknüpfung	4	0.33
	12	1

Version		
Ausprägung	Absolute Häufigkeit	Relative Häufigkeit
1.1	3	0.25
1.2	6	0.5
2.0	3	0.25
	12	1

2.2 Tabellarische und grafische Darstellung von univariaten Daten

Quantitativ diskrete Daten

$M_N = \{e_1, \dots, e_N\}$ Population bestehend aus Objekten e_1, \dots, e_N

X Quantitatives Merkmal

$x \in W_X$ Merkmalsausprägungen von X

$W_X = \{x(j) \mid j = 1, \dots, J\}$ Wertebereich von X mit
 $= \{x(1), \dots, x(J)\}$ Merkmalsausprägungen $x(j)$, $j = 1, \dots, J$

$D_N = \{x_n \mid n = 1, \dots, N\}$ Urliste aus der Messung von X in der
 $= \{x_1, \dots, x_N\}$ Population M_N , d.h. $x_n = X(e_n)$, $n = 1, \dots, N$

2.2 Tabellarische und grafische Darstellung von univariaten Daten

Quantitativ diskrete Daten: Beispiel **Bearbeitungen von Softwareaufgaben**

Bearbeitung	Bearbeiter(in)	Aufgabe	Version	Anzahl Clicks	Bearbeitungszeit
e ₁	Kai	Export	1.1	14	8.0
e ₂	Kai	Verknüpfung	1.2	12	4.9
e ₃	Miriam	Export	1.1	12	6.6
e ₄	Tina	Verknüpfung	1.2	13	3.2
e ₅	Oliver	Export	2.0	17	3.9
e ₆	Tina	Export	1.2	11	4.5
e ₇	Tina	Verknüpfung	1.2	14	6.1
e ₈	Miriam	Export	1.2	10	3.7
e ₉	Miriam	Export	1.2	10	4.2
e ₁₀	Oliver	Abfrage	1.1	18	8.5
e ₁₁	Oliver	Verknüpfung	2.0	16	3.6
e ₁₂	Oliver	Abfrage	2.0	15	3.7

 $D_{N,4}, N=12$ $X_4 = \text{Anzahl Clicks}$ $W_{X4} = \{0, 1, \dots, 10, 11, 12, 13, 14, 15, 16, 17, 18, \dots, \infty\}$ $J_4 = \infty$

2.2 Tabellarische und grafische Darstellung von univariaten Daten

Quantitativ diskrete Daten: Deskriptive Auswertung

Absolute Häufigkeit N_j und **relative Häufigkeit** f_j analog zu qualitativen Daten

Relative Summenhäufigkeit $s_j = \sum_{k=1}^j f_k = \frac{\#\{x_n | x_n \leq x(j)\}}{N}$

Ausprägung	Absolute Häufigkeit	Relative Häufigkeit	Relative Summenhäufigkeit
$x(1)$	N_1	$f_1 = N_1/N$	f_1
$x(2)$	N_2	$f_2 = N_2/N$	$f_1 + f_2$
\vdots	\vdots	\vdots	\vdots
$x(J-1)$	N_{J-1}	$f_{J-1} = N_{J-1}/N$	$f_1 + \dots + f_{J-1}$
$x(J)$	N_J	$f_J = N_J/N$	$f_1 + \dots + f_J = 1$
	$\sum_{j=1}^J N_j = N$	$\sum_{j=1}^J f_j = 1$	

2.2 Tabellarische und grafische Darstellung von univariaten Daten

Quantitativ diskrete Daten: Deskriptive Auswertung

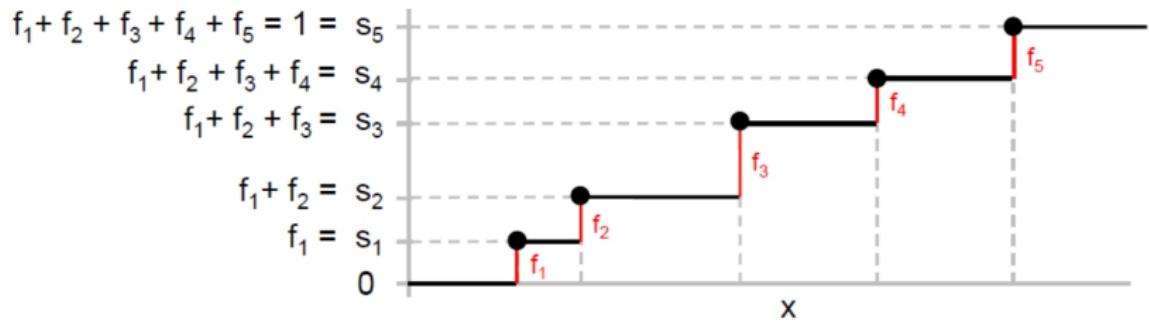
Anzahl Clicks			
Ausprägung	Absolute Häufigkeit	Relative Häufigkeit	Relative Summenhäufigkeit
0 - 9	0	0	0
10	2	0.167	0.167
11	1	0.083	0.25
12	2	0.167	0.417
13	1	0.083	0.5
14	2	0.167	0.667
15	1	0.083	0.75
16	1	0.083	0.833
17	1	0.083	0.917
18	1	0.083	1
19 - ∞	0	0	1
	12	1	

2.2 Tabellarische und grafische Darstellung von univariaten Daten

Quantitativ diskrete Daten: Deskriptive Auswertung

Grafische Darstellung: **Empirische Verteilungsfunktion**

$$F_N(X) = \begin{cases} 0 & , \text{ falls } x < x(1) \\ s_j = \sum_{k=1}^j f_k, \text{ mit } j = \max\{\tilde{j} | x(\tilde{j}) \leq x\} & , \text{ falls } x(1) \leq x \end{cases}$$



2.2 Tabellarische und grafische Darstellung von univariaten Daten

Quantitativ stetige Daten:

$$M_N = \{e_1, \dots, e_N\}$$

Population bestehend aus Objekten e_1, \dots, e_N

$$X$$

Quantitatives Merkmal

$$x \in W_X$$

Merkmalsausprägungen von X

$$W_X = (-\infty, \infty) = \bigcup_{j=1}^J K_j$$

Klassierter (kategorisierter) Wertebereich von X

$$K_j = (v_{j-1}, v_j], \quad j = 1, \dots, J - 1$$

Merkmalsklassen mit Klassengrenzen

$$K_J = (v_{J-1}, v_J)$$

$-\infty = v_0 < v_1 < \dots < v_{J-1} < v_J = \infty$

$$\begin{aligned} D_N &= \{x_n | n = 1, \dots, N\} \\ &= \{x_1, \dots, x_N\} \end{aligned}$$

Urliste aus der Messung von X in der Population M_N , d.h. $x_n = X(e_n)$, $n = 1, \dots, N$

2.2 Tabellarische und grafische Darstellung von univariaten Daten

Quantitativ stetige Daten: Beispiel **Bearbeitungen von Softwareaufgaben**

Bearbeitung	Bearbeiter(in)	Aufgabe	Version	Anzahl Clicks	Bearbeitungszeit
e ₁	Kai	Export	1.1	14	8.0
e ₂	Kai	Verknüpfung	1.2	12	4.9
e ₃	Miriam	Export	1.1	12	6.6
e ₄	Tina	Verknüpfung	1.2	13	3.2
e ₅	Oliver	Export	2.0	17	3.9
e ₆	Tina	Export	1.2	11	4.5
e ₇	Tina	Verknüpfung	1.2	14	6.1
e ₈	Miriam	Export	1.2	10	3.7
e ₉	Miriam	Export	1.2	10	4.2
e ₁₀	Oliver	Abfrage	1.1	18	8.5
e ₁₁	Oliver	Verknüpfung	2.0	16	3.6
e ₁₂	Oliver	Abfrage	2.0	15	3.7

$D_{N;5}, N = 12$

X_5 = Bearbeitungszeit

$$W_{X_5} = (-\infty, \infty) = (-\infty, 4] \cup (4, 5] \cup \dots \cup (7, 8] \cup (8, \infty) = (-\infty, 4] \cup \left(\bigcup_{j=1}^4 (j+3, j+4] \right) \cup (8, \infty)$$

$J_5 = 6$

2.2 Tabellarische und grafische Darstellung von univariaten Daten

Quantitativ stetige Daten: Deskriptive Auswertung

Klassierte Häufigkeitsverteilung

Klasse K_j	Absolute Häufigkeit	Relative Häufigkeit	Relative Summenhäufigkeit
$K_1 = (v_0, v_1]$	$N(K_1)$	$f(K_1) = N(K_1)/N$	$f(K_1)$
$K_2 = (v_1, v_2]$	$N(K_2)$	$f(K_2) = N(K_2)/N$	$f(K_1) + f(K_2)$
\vdots	\vdots	\vdots	\vdots
$K_{J-1} = (v_{J-2}, v_{J-1}]$	$N(K_{J-1})$	$f(K_{J-1}) = N(K_{J-1})/N$	$f(K_1) + \dots + f(K_{J-1})$
$K_J = (v_{J-1}, v_J)$	$N(K_J)$	$f(K_J) = N(K_J)/N$	$f(K_1) + \dots + f(K_J) = 1$
	$\sum_{j=1}^J N(K_j) = N$	$\sum_{j=1}^J f(K_j) = 1$	

$$N(K_j) = \#\{x | x \in K_j\} = \#\{x | v_{j-1} < x \leq v_j\}$$

2.2 Tabellarische und grafische Darstellung von univariaten Daten

Quantitativ stetige Daten: Deskriptive Auswertung

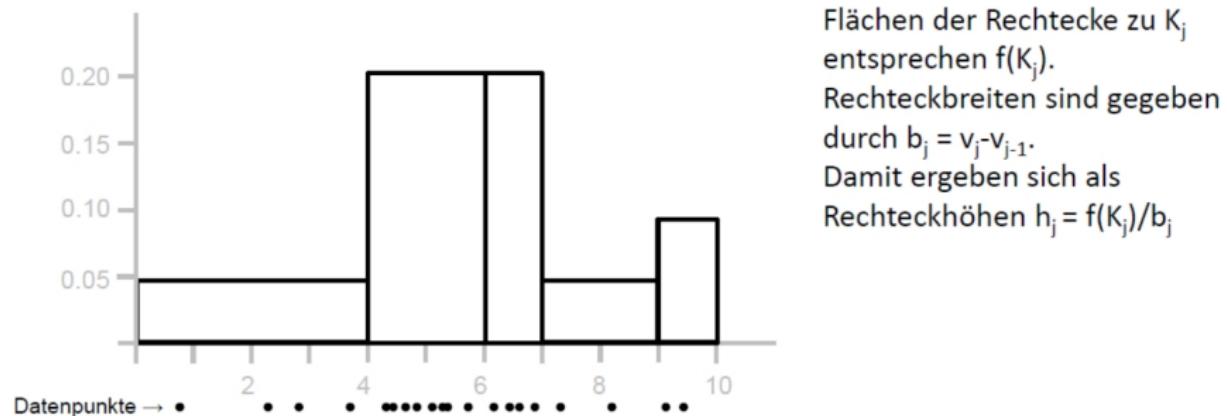
Bearbeitungszeit			
Klasse	Absolute Häufigkeit	Relative Häufigkeit	Relative Summenhäufigkeit
$K_1 = (-\infty, 4]$	5	0.417	0.417
$K_2 = (4, 5]$	3	0.250	0.667
$K_3 = (5, 6]$	0	0.000	0.667
$K_4 = (6, 7]$	2	0.167	0.833
$K_5 = (7, 8]$	1	0.083	0.917
$K_6 = (8, \infty)$	1	0.083	1
	12	1	

2.2 Tabellarische und grafische Darstellung von univariaten Daten

Quantitativ stetige Daten: Deskriptive Auswertung

Grafische Darstellung: **Histogramm**

Aufbauend auf klassierter Häufigkeitsverteilung, allerdings $v_0 \neq -\infty$ und $v_J \neq \infty$

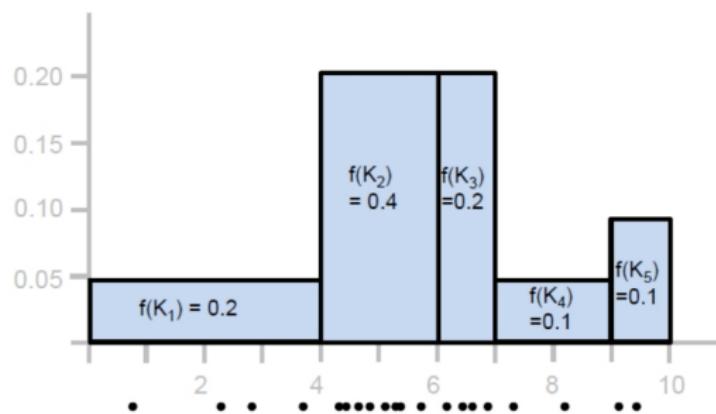


2.2 Tabellarische und grafische Darstellung von univariaten Daten

Quantitativ stetige Daten: Deskriptive Auswertung

Grafische Darstellung: **Histogramm**

Aufbauend auf klassierter Häufigkeitsverteilung, allerdings $v_0 \neq -\infty$ und $v_J \neq \infty$



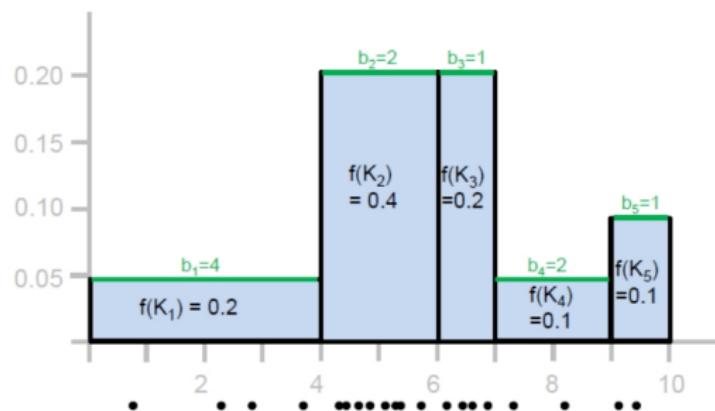
Flächen der Rechtecke zu K_j entsprechen $f(K_j)$.
Rechteckbreiten sind gegeben durch $b_j = v_j - v_{j-1}$.
Damit ergeben sich als Rechteckhöhen $h_j = f(K_j)/b_j$

2.2 Tabellarische und grafische Darstellung von univariaten Daten

Quantitativ stetige Daten: Deskriptive Auswertung

Grafische Darstellung: **Histogramm**

Aufbauend auf klassierter Häufigkeitsverteilung, allerdings $v_0 \neq -\infty$ und $v_J \neq \infty$



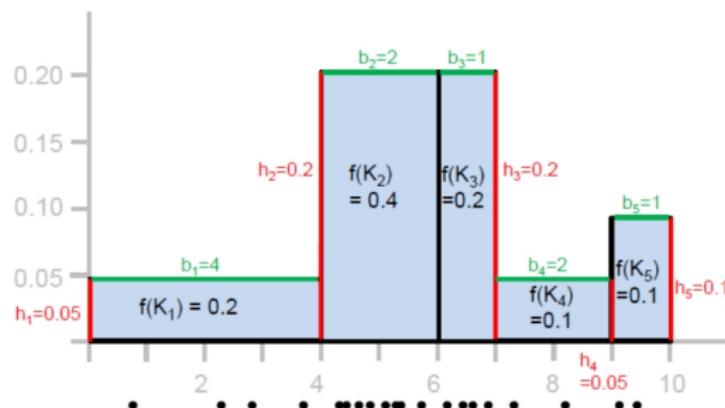
Flächen der Rechtecke zu K_j entsprechen f(K_j).
Rechteckbreiten sind gegeben durch b_j = v_j - v_{j-1}.
Damit ergeben sich als Rechteckhöhen h_j = f(K_j) / b_j

2.2 Tabellarische und grafische Darstellung von univariaten Daten

Quantitativ stetige Daten: Deskriptive Auswertung

Grafische Darstellung: **Histogramm**

Aufbauend auf klassierter Häufigkeitsverteilung, allerdings $v_0 \neq -\infty$ und $v_J \neq \infty$



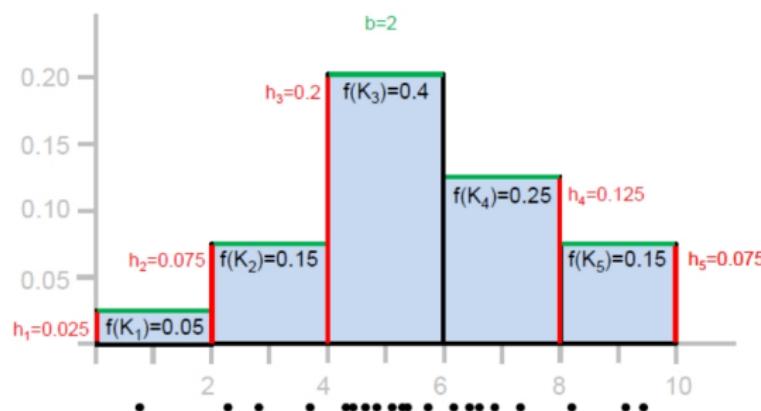
Flächen der Rechtecke zu K_j entsprechen $f(K_j)$.
Rechteckbreiten sind gegeben durch $b_j = v_j - v_{j-1}$.
Damit ergeben sich als Rechteckhöhen $h_j = f(K_j) / b_j$

2.2 Tabellarische und grafische Darstellung von univariaten Daten

Quantitativ stetige Daten: Deskriptive Auswertung

Grafische Darstellung: **Histogramm**

Üblicherweise gleiche Klassenbreiten



Flächen der Rechtecke zu K_j entsprechen $f(K_j)$.
Rechteckbreiten sind gegeben durch $b = v_j - v_{j-1}$.
Damit ergeben sich als Rechteckhöhen $h_j = f(K_j)/b$

2.2 Tabellarische und grafische Darstellung von univariaten Daten

Quantitativ stetige Daten: Deskriptive Auswertung

Grafische Darstellung: **Histogramm**

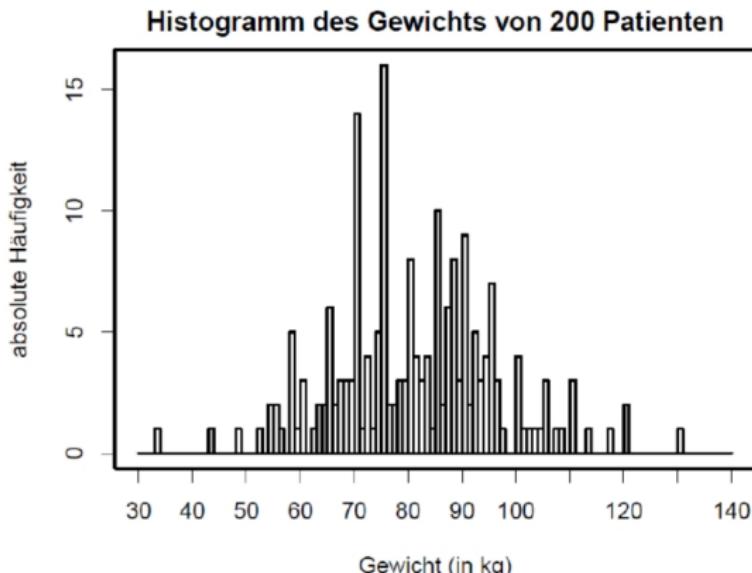
- Beispiel Patientendaten: Gewicht (in kg); NA: fehlender Wert (Not Available)
→ Zufällige Auswahl des Gewichts von 200 Patienten:

85	70	75	70	92	88	68	101	74	80	87	68	95	33	75	117
105	88	76	82	107	92	87	91	83	80	85	95	75	60	85	75
73	58	93	70	100	94	100	75	80	85	87	43	90	92	89	NA
100	96	58	72	77	83	48	74	90	58	78	75	56	70	75	70
67	95	74	88	70	68	66	102	72	74	113	72	81	75	55	60
75	90	71	93	NA	94	75	89	90	80	52	90	105	90	82	80
83	80	89	70	67	92	108	58	75	75	110	85	58	74	93	97
65	83	110	87	81	64	103	120	65	85	79	95	110	70	90	85
94	88	88	130	70	69	78	100	88	86	85	76	60	79	90	88
104	69	96	59	75	NA	75	66	70	86	80	65	94	72	62	75
105	91	79	88	80	85	69	87	54	96	70	82	70	95	78	95
95	84	70	90	65	67	85	NA	92	87	63	120	65	55	65	81
NA	54	81	63	64	77	70	75								

2.2 Tabellarische und grafische Darstellung von univariaten Daten

Grafische Darstellung: **Histogramm**

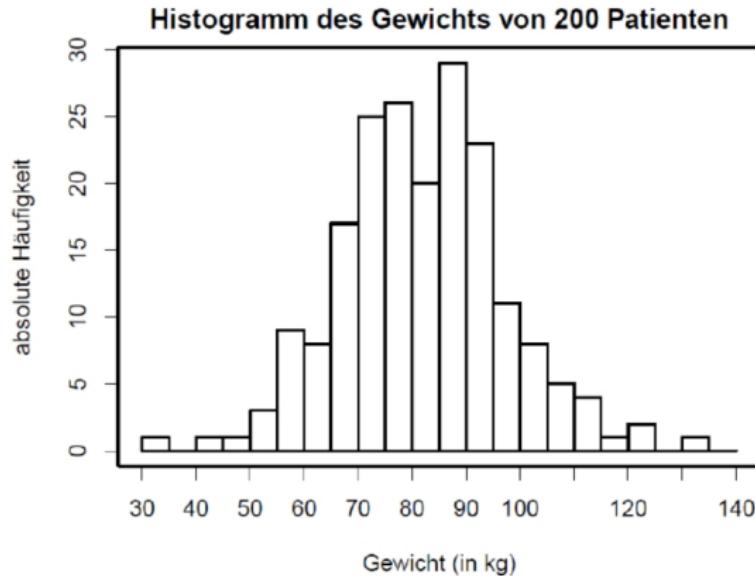
- Patientendaten: Klassenbreite 1 kg führt zu unruhigem Bild, auffällig: Häufungen bei Vielfachen von 5 kg



2.2 Tabellarische und grafische Darstellung von univariaten Daten

Grafische Darstellung: **Histogramm**

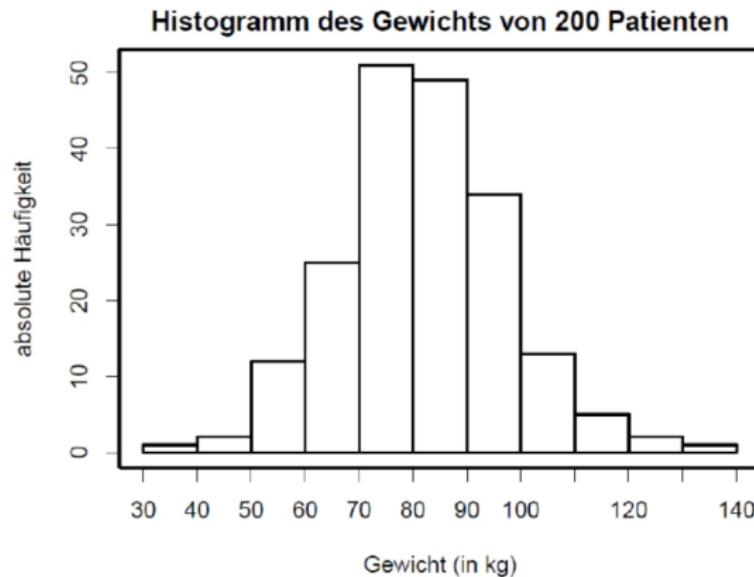
- Patientendaten: Klassenbreite 5 kg



2.2 Tabellarische und grafische Darstellung von univariaten Daten

Grafische Darstellung: **Histogramm**

- Patientendaten: Klassenbreite 10 kg



2.2 Tabellarische und grafische Darstellung von univariaten Daten

- Bei qualitativen Merkmalen ist ein sogenanntes **Stabdiagramm (Balkendiagramm)** etabliert
 - ▶ Pro Merkmalsausprägung wird ein schmaler Stab (Balken) mit der absoluten oder relativen Häufigkeit über dem Merkmalswert gezeichnet
 - ▶ Merkmalsausprägungen werden für qualitative Merkmale gleichabständig auf der x-Achse gezeichnet
 - ▶ Stäbe sind immer (im Gegensatz zu Kästen beim Histogramm) voneinander separiert!
- Zur Visualisierung von Klassenanteilen an einer Gesamtheit wird häufig ein **Kuchen- bzw. Kreis-Diagramm** verwendet.
 - ▶ Dabei wird ein Kreis so in Sektoren aufgeteilt, dass die Sektorflächen proportional zu den absoluten (bzw. relativen) Häufigkeiten sind
 - ▶ Kreissegmente (Winkel) sind viel schlechter vergleichbar als Stäbe/Balken, deshalb besser Stabdiagramme verwenden!

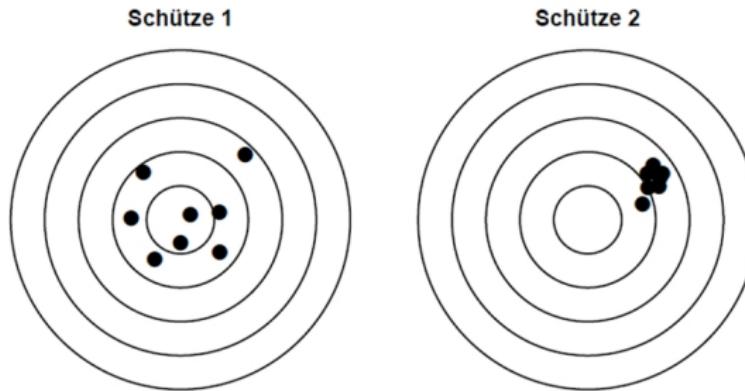
Statistische Kennzahlen

3.1 Statistische Kennzahlen für die Lage

- Nach der passenden grafischen Darstellung der Werte eines Merkmals, nun (algebraische) Charakterisierungen der Verteilung solcher Werte.
- Ziel ist es, die Verteilung durch möglichst wenige Maßzahlen zu beschreiben.
 - ① **Wo liegt die Mitte der Werte?**
Repräsentative Charakterisierung einer Verteilung durch eine Zahl: **Lagemaß**
 - ② **Wie streuen die Werte um die Mitte?**
Charakterisierung der Größe der Unsicherheit (=Streuung) der Merkmalswerte: **Streuungsmaß**
- Später: Vergleich verschiedener Gesamtheiten miteinander mit Hilfe der Maßzahlen

3.1 Statistische Kennzahlen für die Lage

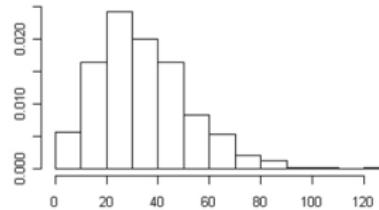
- Beispiel: Welcher Schütze schießt besser?



- Schütze 1: Lage gut, Streuung schlecht
- Schütze 2: Lage schlecht, Streuung gut

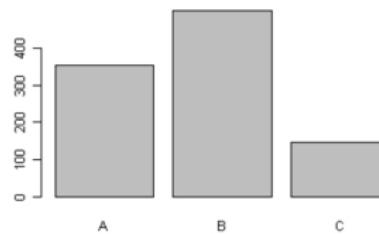
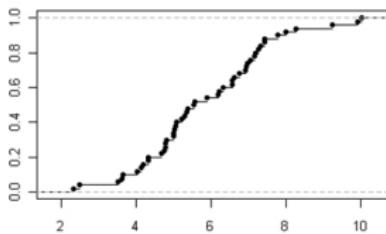
3.1 Statistische Kennzahlen für die Lage

Bisher: geringe Informationsverdichtung durch Verteilungsbeschreibung



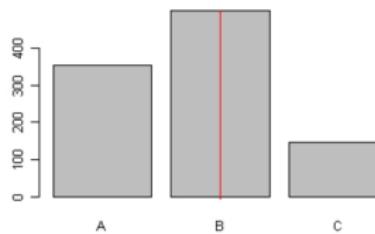
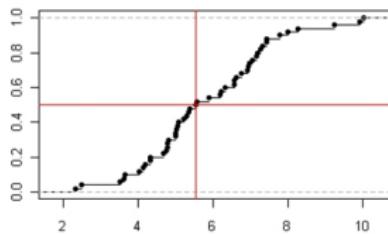
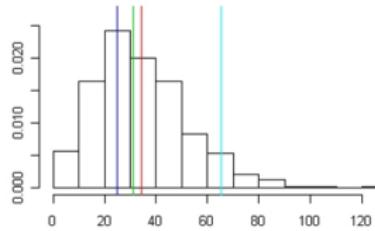
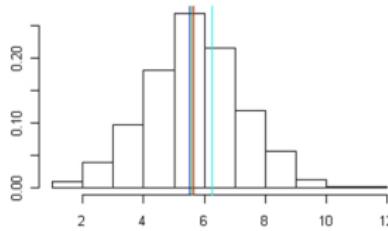
Beispiel

- Histogramm
- Empirische Verteilungsfunktion
- Stabdiagramm



3.1 Statistische Kennzahlen für die Lage

Bisher: geringe Informationsverdichtung durch Verteilungsbeschreibung
Jetzt: stärkere Zusammenfassung der Daten auf ihr „Zentrum“



Farbige Linien
repräsentieren das
Zentrum

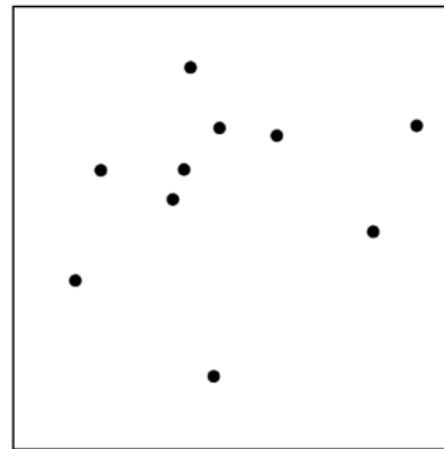
3.1 Statistische Kennzahlen für die Lage

Bisher: geringe Informationsverdichtung durch Verteilungsbeschreibung

Jetzt: stärkere Zusammenfassung der Daten auf ihr „Zentrum“

Unterschiedliche Definitionen von „Zentrum“.

Allgemein: repräsentative Merkmalsausprägung, von der alle beobachteten Werte möglichst wenig abweichen



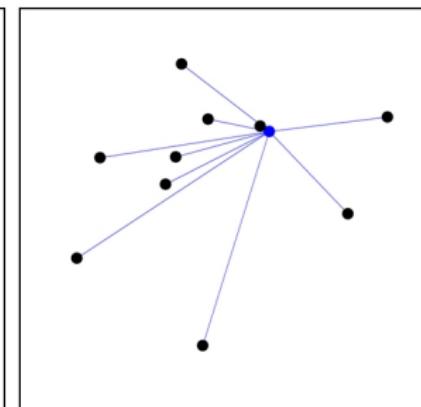
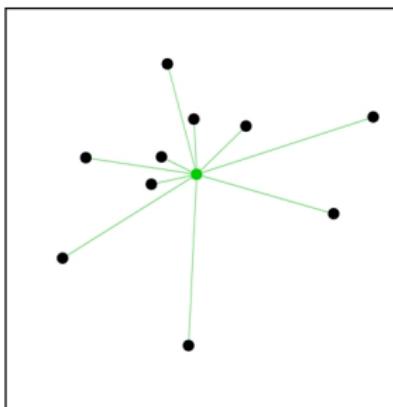
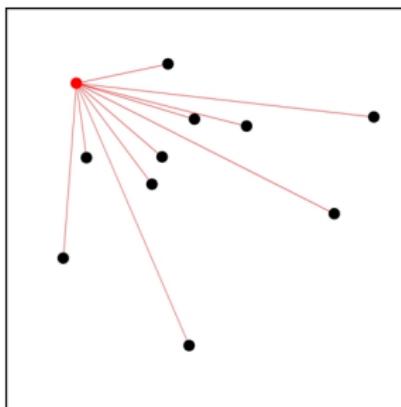
3.1 Statistische Kennzahlen für die Lage

Bisher: geringe Informationsverdichtung durch Verteilungsbeschreibung

Jetzt: stärkere Zusammenfassung der Daten auf ihr „Zentrum“

Unterschiedliche Definitionen von „Zentrum“.

Allgemein: repräsentative Merkmalsausprägung, von der alle beobachteten Werte möglichst wenig abweichen



3.1 Statistische Kennzahlen für die Lage

- Charakterisierung der Merkmalswerte auf einer Gesamtheit durch eine einzige Zahl: Lagemaße
- **Lagemaß = „Mitte der Merkmalswerte“**
- Auswahl des geeigneten Lagemaßes hängt vom Skalenniveau ab
- Wichtigste Beispiele
 - ▶ **Arithmetisches Mittel:** Klassischer Mittelwert
 - ★ Reagiert am empfindlichsten auf „Ausreißer“, d.h. wenn für die Verteilung einige ungewöhnlich große oder kleine Werte vorliegen
 - ▶ **Median:** Zentralwert, mittlerer Wert in der geordneten Stichprobe
 - ★ Liegt nicht unbedingt in der Mitte der Merkmalswerte, ist aber dennoch oft ein guter „Repräsentant“
 - ★ Ist nicht unbedingt eindeutig
 - ▶ **Modalwert:** Häufigster Wert in der Stichprobe
 - ★ Ist nicht unbedingt eindeutig
 - ★ Bei stetigen Merkmalen meist erst nach Klassierung geeignet

3.1 Statistische Kennzahlen für die Lage

Lagemaße:

Arithmetisches Mittel = Mittelwert (mean)

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Median = „Zentralwert“ = 50%-Wert: med_x

Der Median ist derjenige Wert, für den 50% der Merkmalswerte größer oder gleich und 50% kleiner oder gleich sind.

Der Median ist der mittlere Wert der Rangliste:

$$\text{med}_x := \begin{cases} x_{\left(\frac{n+1}{2}\right)} & n \text{ ungerade} \\ \frac{x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)}}{2} & n \text{ gerade} \end{cases}$$

Modalwert / Modus = häufigster Wert: mod_x

Der Modalwert ist derjenige Merkmalswert, der am häufigsten vorkommt.

3.1 Statistische Kennzahlen für die Lage

- p -Quantil $Q_p = \tilde{x}_p$
 - ▶ Verallgemeinerung des Medians (50%-Wert) auf beliebige Prozentzahlen (100%-Werte)
 - ▶ Nützliche Mittel zur Beschreibung einer Rangliste $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$

Ein **p -Quantil** Q_p , $p \in [0, 1]$, ist eine Zahl, für die $100 \cdot p\%$ der Merkmalswerte einer Gesamtheit kleiner oder gleich sind und $100 \cdot (1 - p)\%$ größer oder gleich.

Genauer könnte man für Q_p z.B. Folgendes fordern:

$Q_p \geq$ größtem Merkmalswert einer Gesamtheit, der $\geq 100 \cdot p\%$ der Merkmalswerte ist und

$Q_p \leq$ nächstgrößerem Merkmalswert der Gesamtheit, also

$$x_{(\lfloor np \rfloor)} \leq Q_p \leq x_{(\lfloor np \rfloor + 1)}.$$

3.1 Statistische Kennzahlen für die Lage

Die folgende Berechnungsmethode für Quantile entspricht der obigen Berechnung des Medians.

p -Quantil Berechnung: „Standard“ (Nicht in R, dort type = 2 wählen.)

$$Q_p := \begin{cases} x_{(j)}, & j := \lceil np \rceil, \text{ } np \text{ nicht ganzzahlig} \\ \frac{x_{(j)} + x_{(j+1)}}{2}, & j := np, \text{ } np \text{ ganzzahlig} \end{cases}$$

Bezeichnung

- Anstelle von **p -Quantil** sagt man auch **$100 \cdot p\%$ -Perzentil** oder **($1-p$)-Fraktil**.
- 0.25- bzw. 0.75-Quantile heißen auch unteres bzw. oberes **Quartil**: unteres Quartil $q_4 = 0.25$ -Quantil; oberes Quartil $q^4 = 0.75$ -Quantil.

3.1 Statistische Kennzahlen für die Lage

- Nominale Daten

- ▶ Gesucht: x^* , für das Abweichung zwischen x^* und x_1, \dots, x_N minimal ist
- ▶ Mit nominellen Ausprägungen kann keine sinnvolle Abweichung berechnet werden
- ▶ Dummykodierung führt auf den Modalwert $x(j^*)$

i	x_i
1	A
2	C
:	:
N	B

i	x_i	$d_i(1)$	$d_i(2)$	$d_i(3)$
1	A	1	0	0
2	C	0	0	1
:	:	:	:	:
N	B	0	1	0
\sum		N_1	N_2	N_3

3.1 Statistische Kennzahlen für die Lage

Nominale Daten

Modalwert

Beispiel Bearbeitung von Softwareaufgaben

Die Modalwerte lauten

$$x_1(j^*) = \text{Oliver}$$

$$x_2(j^*) = \text{Export}$$

$$x_3(j^*) = 1.2$$

Bearbeiter(in)		
Ausprägung	Absolute Häufigkeit	Relative Häufigkeit
Kai	2	0.17
Miriam	3	0.25
Oliver	4	0.33
Tina	3	0.25
	12	1

Aufgabe		
Ausprägung	Absolute Häufigkeit	Relative Häufigkeit
Abfrage	2	0.17
Export	6	0.5
Verknüpfung	4	0.33
	12	1

Version		
Ausprägung	Absolute Häufigkeit	Relative Häufigkeit
1.1	3	0.25
1.2	6	0.5
2.0	3	0.25
	12	1

3.1 Statistische Kennzahlen für die Lage

Ordinale Daten

x_1, \dots, x_N

$x_i \in W_X, i = 1, \dots, N$

$W_X = \{x(j) | j = 1, \dots, J\} = \{x(1), \dots, x(J)\}$

$x(1) < x(2) < \dots < x(J)$

Urliste x_1, \dots, x_N

Geordnete Liste $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(N)}$

$$x_{(k)} = x_{i_k}$$

i	x_i
1	$x(3)$
2	$x(2)$
3	$x(1)$
4	$x(1)$
5	$x(3)$

k	$x_{(k)}$
1	$x(1)$
2	$x(1)$
3	$x(2)$
4	$x(3)$
5	$x(3)$

Geordnete Liste \rightarrow

mit $i_k = \min[\arg\min_{i^*} (x_{i^*} | i^* \in \{1, \dots, N\} \setminus \{i_1, \dots, i_{k-1}\})], k = 1, \dots, N$

$x_{(k)}$ wird k -ter **Rangwert** genannt, erster und letzter Rangwert $x_{(1)}$ und $x_{(N)}$ heißen **Minimum** und **Maximum**.

3.1 Statistische Kennzahlen für die Lage

Ordinale Daten

x_1, \dots, x_N

$x_i \in W_X, i = 1, \dots, N$

$W_X = \{x(j) | j = 1, \dots, J\} = \{x(1), \dots, x(J)\}$

$x(1) < x(2) < \dots < x(J)$

$x_{(k)}$ wird k -ter **Rangwert** genannt, erster und letzter Rangwert $x_{(1)}$ und $x_{(n)}$ heißen Minimum und Maximum.

i	x_i	$R(x_i)$
1	$x(3)$	4.5
2	$x(2)$	3
3	$x(1)$	1.5
4	$x(1)$	1.5
5	$x(3)$	4.5

↑ Ränge

$$R(x_i) = \frac{1}{\#K^*} \sum_{k^* \in K^*} k^* \text{ mit } K^* = \{k^* | x_{(k^*)} = x_i\}$$

$R(x_i)$ ist der **Rang** von x_i

k	$x_{(k)}$
1	$x(1)$
2	$x(1)$
3	$x(2)$
4	$x(3)$
5	$x(3)$

3.1 Statistische Kennzahlen für die Lage

Ordinale Daten

Beispiel Bearbeitungen von Softwareaufgaben

i	Version _i
1	1.1
2	1.2
3	1.1
4	1.2
5	2.0
6	1.2
7	1.2
8	1.2
9	1.2
10	1.1
11	2.0
12	2.0

Geordnete
Liste →

k	Version _(k)
1	1.1
2	1.1
3	1.1
4	1.2
5	1.2
6	1.2
7	1.2
8	1.2
9	1.2
10	2.0
11	2.0
12	2.0

Ränge →

$$\frac{1}{3} \sum_{s=1}^3 s = 2$$

$$\frac{1}{6} \sum_{s=4}^9 s = 6.5$$

$$\frac{1}{3} \sum_{s=10}^{12} s = 11$$

i	Version _i	R(Version _i)
1	1.1	2
2	1.2	6.5
3	1.1	2
4	1.2	6.5
5	2.0	11
6	1.2	6.5
7	1.2	6.5
8	1.2	6.5
9	1.2	6.5
10	1.1	2
11	2.0	11
12	2.0	11

3.1 Statistische Kennzahlen für die Lage

Quantitative Daten

x_1, \dots, x_N

$x_i \in W_X, i = 1, \dots, N$

$W_X = \{x(j) | j = 1, \dots, J\} = \{x(1), \dots, x(J)\}$

bzw. $W_X = (-\infty, \infty)$

Der Median minimiert die Summe der absoluten Abweichungen

$$\Delta_a(x) = \sum_{i=1}^N |x_i - x|$$

Der Mittelwert minimiert die Summe der quadratischen Abweichungen

$$\Delta(x) = \sum_{i=1}^N (x_i - x)^2$$

3.1 Statistische Kennzahlen für die Lage

Quantitative Daten

Generell gilt: $\Delta(x) = \sum_{i=1}^N (x_i - x)^2$ ist minimal für $x = \bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$

Beweis $\forall x \in \mathbb{R}$:

$$\begin{aligned}\Delta(x) &= \sum_{i=1}^N (x_i - x)^2 = \sum_{i=1}^N [(x_i - \bar{x}) + (\bar{x} - x)]^2 \\ &= \sum_{i=1}^N (x_i - \bar{x})^2 + 2(\bar{x} - x) \underbrace{\sum_{i=1}^N (x_i - \bar{x})}_{=0 \text{ (*)}} + \underbrace{\sum_{i=1}^N (\bar{x} - x)^2}_{=N(\bar{x}-x)^2} \\ &= \Delta(\bar{x}) + \underbrace{N(\bar{x}-x)^2}_{\geq 0} \geq \Delta(\bar{x})\end{aligned}$$

$$(*) \sum_{i=1}^N (x_i - \bar{x}) = \sum_{i=1}^N \left(x_i - \frac{1}{N} \sum_{l=1}^N x_l \right) = \sum_{i=1}^N x_i - \frac{1}{N} \sum_{i=1}^N \sum_{l=1}^N x_l = \sum_{i=1}^N x_i - \frac{1}{N} N \sum_{l=1}^N x_l = 0$$

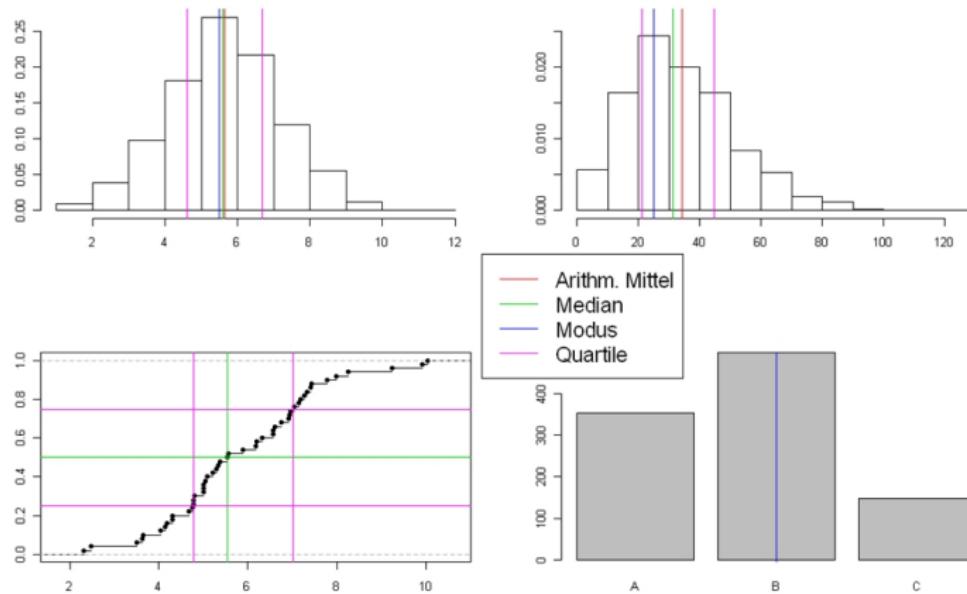
3.1 Statistische Kennzahlen für die Lage

Zusammenfassung: Welche Maßzahlen sind bei welchem Skalenniveau geeignet?

Skalenniveau → ↓ Lagemaß	Nominal	Ordinal	Quantitativ
Modus			- Informationsverlust – Nur für klassierte Daten
Median			+ Robust - Informationsverlust - Hohe Streubreite
Arithmetisches Mittel	 – Nur für J = 2		- Ausreißeranfällig + Informationsnutzung + Geringe Streubreite

3.2 Statistische Kennzahlen für die Streuung

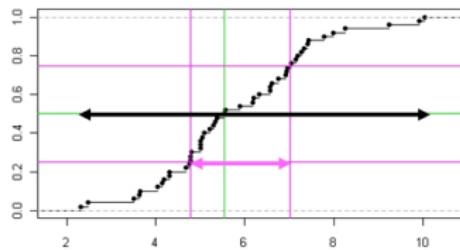
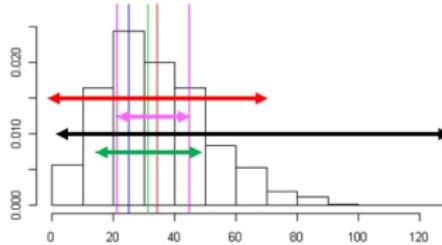
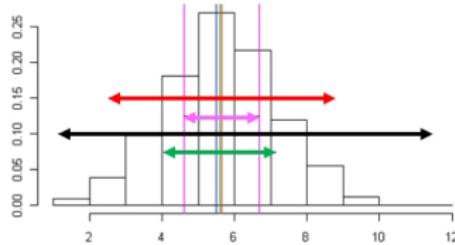
Bisher: Beschreibung von Häufigkeitsverteilung und Lage



3.2 Statistische Kennzahlen für die Streuung

Bisher: Beschreibung von Häufigkeitsverteilung und Lage

Jetzt: Beschreibung der mittleren Variation um die Lage



Allgemein: Streuung desto höher,
je schlechter sich konkrete Werte
vorhersagen lassen.

3.2 Statistische Kennzahlen für die Streuung

Streuungsmaße:

empirische Varianz und Standardabweichung

- Varianz: „Durchschnitt“ der quadrierten Abweichungen vom arithmetischen Mittel

$$\text{var}_x = s_x^2 := \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{(n-1)} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

- Standardabweichung: Wurzel aus der Varianz

$$s_x := \sqrt{\text{var}_x}$$

Interquartilsabstand (interquartile range)

$$\text{qd}_x := q^4 - q_1$$

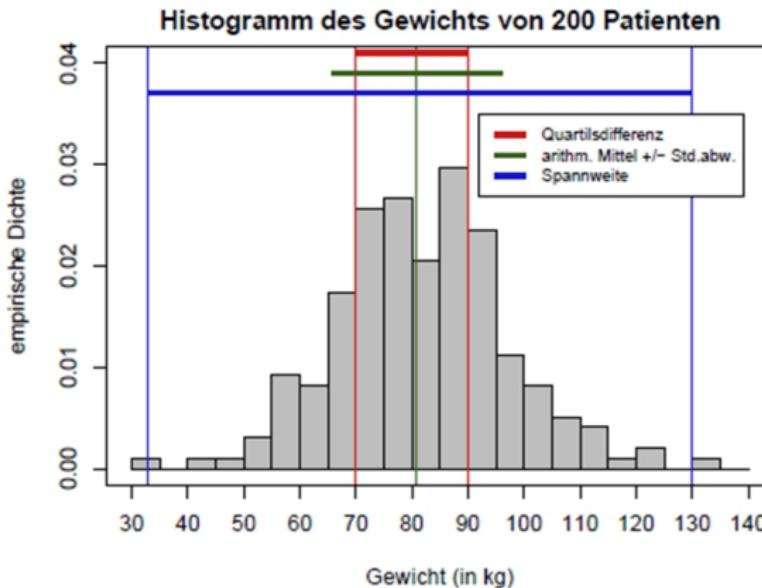
Spannweite (range)

$$R_x := \max(x) - \min(x) = x_{(n)} - x_{(1)}$$

3.2 Statistische Kennzahlen für die Streuung

- Beispiel 1: Gewicht von 200 Patienten

$$s_x = 15.14 \text{ kg}, \quad qd_x = 20 \text{ kg}, \quad R_x = 97 \text{ kg}$$



3.2 Statistische Kennzahlen für die Streuung

Streuungsmaße:

Variationskoeffizient (relative Standardabweichung)

$$v_x := \frac{s_x}{\bar{x}}$$

Mittlere absolute Medianabweichung MD

(von „Mean Deviation from the Median“)

$$md_x := \frac{1}{n} \sum_{i=1}^n |x_i - \text{med}_x|$$

Mediane absolute Medianabweichung MAD

(von „Median Absolute Deviation“)

$$\text{mad}_x := \text{med}(|x_i - \text{med}_x|)$$

3.2 Statistische Kennzahlen für die Streuung

Nominale Daten

x_1, \dots, x_N

$x_i \in W_X, i = 1, \dots, N$

$W_X = \{x(j) | j = 1, \dots, J\}$
 $= \{x(1), \dots, x(J)\}$

Rechnen nur sinnvoll mit
 Dummyvariablen bzw. Häufigkeiten

i	x_i
1	A
2	C
\vdots	\vdots
N	B

i	x_i	$d_i(1)$	$d_i(2)$	$d_i(3)$
1	A	1	0	0
2	C	0	0	1
\vdots	\vdots	\vdots	\vdots	\vdots
N	B	0	1	0
\sum		N_1	N_2	N_3

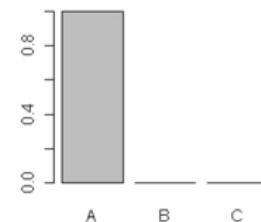
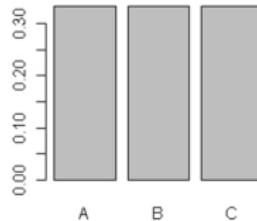
3.2 Statistische Kennzahlen für die Streuung

Nominale Daten

Allgemein: Streuung ist desto höher, je schlechter sich konkrete Werte vorhersagen lassen.

Nominale Merkmalsausprägungen lassen sich um so besser vorhersagen, je häufiger eine bestimmte Kategorie vorkommt.

Geringste Streuung , falls es ein j gibt mit $f_j = 1$. \rightarrow



\leftarrow Höchste Streuung , falls $f_j = 1/J$, $j=1,\dots,J$.

3.2 Statistische Kennzahlen für die Streuung

Nominale Daten

Geringe Streuung, falls es ein j gibt mit $f_j = 1$.

Höchste Streuung, falls $f_j = 1/J$, $j = 1, \dots, J$

D entspricht dem Anteil von Paaren mit unterschiedlichen Merkmalsausprägungen an allen aus der Urliste bildbaren Beobachtungspaaren:

Simpson's D

$$D = \frac{\#\{(i, k) \in \{1, \dots, N\} \times \{1, \dots, N\} | x_i \neq x_k\}}{N^2}$$

$$D = 1 - \sum_{j=1}^J f_j^2$$

Beispiel

i	x _i
1	A
2	B
3	A
4	C

$$\begin{aligned} D &= 1 - \left(\frac{2^2 + 1^2 + 1^2}{4^2} \right) = 1 - \frac{6}{16} = \frac{5}{8} \\ &= \frac{\#\{(1,2), (1,4), (2,1), (2,3), (2,4), (3,2), (3,4), (4,1), (4,2), (4,3)\}}{4^2} \end{aligned}$$

3.2 Statistische Kennzahlen für die Streuung

Nominale Daten

Geringste Streuung, falls es ein j gibt mit $f_j = 1$.

Höchste Streuung, falls $f_j = 1/J$, $j = 1, \dots, J$.

Simpson's D

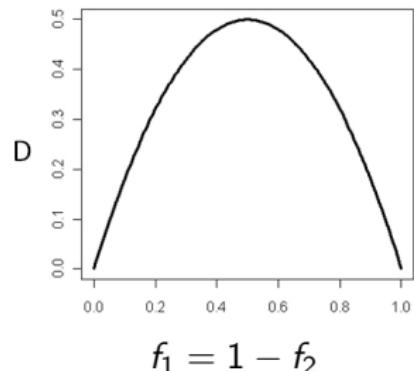
$$D = 1 - \sum_{j=1}^J f_j^2$$

$$0 \leq D \leq 1 - \frac{1}{J}$$

$D = 0$ für $\max[(f_1, \dots, f_J)] = 1$

$D = 1 - \frac{1}{J}$ für $f_1 = \dots = f_J = \frac{1}{J}$

Beispiel $J = 2$



3.2 Statistische Kennzahlen für die Streuung

Nominale Daten

Geringste Streuung, falls es ein j gibt mit $f_j = 1$.

Höchste Streuung, falls $f_j = 1/J$, $j = 1, \dots, J$.

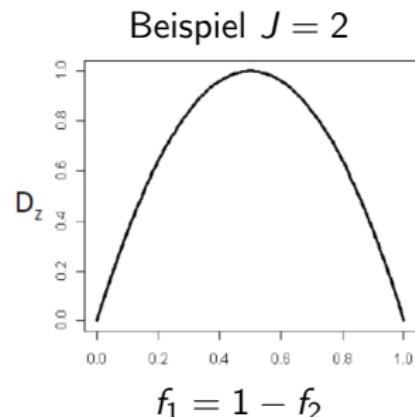
Simpson's D_z (Normierte Version)

$$D_z = \frac{J(1 - \sum_{j=1}^J f_j^2)}{J-1}$$

$$0 \leq D_z \leq 1$$

$D_z = 0$ für $\max[(f_1, \dots, f_J)] = 1$

$D_z = 1$ für $f_1 = \dots = f_J = \frac{1}{J}$



3.2 Statistische Kennzahlen für die Streuung

Nominale Daten

Informationstheorie: Ein Ereignis liefert desto mehr Information, je geringer seine Eintrittswahrscheinlichkeit ist.

Kodierung der Elementarereignisse in Bits, Beispiel **Kaffeebestellung**

1. Bit: 0 = Tasse 1 = Kännchen
2. Bit 0 = Schwarz 1 = mit Milch
3. Bit: 0 = Süßstoff 1 = Zucker

8 mögliche Bestellungen: 000, 001, 010, 011, 100, 101, 110, 111

Beträgt die Wahrscheinlichkeit einer Teilmenge dieser Bestellungen $p = 1/8$, wird genau eine Bestellung ausgewählt und man erhält Information über alle $3 = -\log_2(1/8)$ Bits, falls die Teilmenge ausgewählt wird.

Wird dagegen die Menge möglicher Bestellungen auf 50%, z.B. alle Bestellungen mit Kännchen eingegrenzt, also $p = 1/4$, so erhält man Information über $2 = -\log_2(1/4)$ Bits.

3.2 Statistische Kennzahlen für die Streuung

Nominale Daten

Die Information einer Merkmalsausprägung $x(j)$ in Bits kann also allgemein definiert werden durch $-\log_2(f_j)$.

Der Informationsgehalt des gesamten Merkmals x ergibt sich durch die **Entropie** genannte erwartete Information $H(x)$ von x :

$$H(x) = - \sum_{j=1}^J f_j \log_2(f_j)$$

Beispiel **Kaffeebestellung**: Sei x_F die Antwort auf eine bestimmte Frage F



F = „Möchten Sie Ihren Kaffee mit Milch und Zucker?“

$$x_F(0) = \text{„Nein“}, x_F(1) = \text{„Ja“}, f_1 = 6/8, f_2 = 2/8,$$

$$H(x_F) = -(6/8) \cdot \log_2(6/8) - (2/8) \cdot \log_2(2/8) = 0.8113$$

3.2 Statistische Kennzahlen für die Streuung

Nominale Daten

Entropie von x : $H(x) = - \sum_{j=1}^J f_j \log_2(f_j)$ Beispiel **Kaffeebestellung**



F = „Möchten Sie Ihren Kaffee mit Milch und Zucker?“

$$x_F(0) = \text{„Nein“}, x_F(1) = \text{„Ja“}, f_1 = 6/8, f_2 = 2/8, H(x_F) = \boxed{0.8113}$$



F = „Möchten Sie Ihren Kaffee in der Tasse?“

$$x_F(0) = \text{„Nein“}, x_F(1) = \text{„Ja“}, f_1 = 4/8, f_2 = 4/8,$$

$$H(x_F) = -(4/8) \cdot \log_2(4/8) - (4/8) \cdot \log_2(4/8) = \boxed{1}$$

3.2 Statistische Kennzahlen für die Streuung

- Entropie gibt also die Information an, die man im Mittel durch Kenntnis der tatsächlichen Ausprägung erhält, wenn man vorher nur die Verteilung kannte. Ist diese hoch, konnte man den Wert vorher schlecht vorhersagen \Rightarrow hohe Streuung.
- Ist der Informationszugewinn gering, konnte man vorher schon gut prognostizieren.
- Beispiel „Wer wird Millionär“
 - ▶ Kandidat ist sicher = geringe Streuung, keine weitere Information durch Joker
 - ▶ Kandidat ist unsicher = hohe Streuung, erhofft Informationsgewinn durch Publikumsjoker
 - ▶ Ist hier die Streuung hoch, weiterer Informationsgewinn durch Einzelbefragungsjoker

3.2 Statistische Kennzahlen für die Streuung

Nominale Daten

Entropie von x :
$$H(x) = - \sum_{j=1}^J f_j \cdot \log_2(f_j)$$

Die Entropie ist ein sinnvolles Maß für die Streuung, denn sie erfüllt die Forderungen:

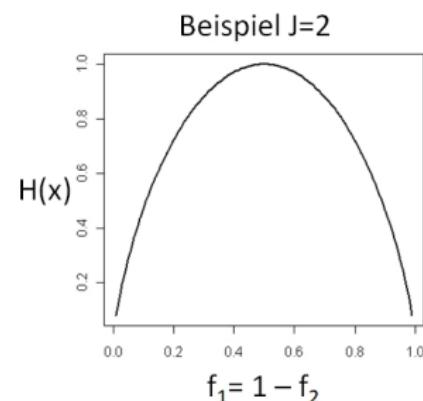
Geringe Streuung, falls es ein j gibt mit $f_j = 1$.

Höchste Streuung, falls $f_j = 1/J$, $j = 1, \dots, J$.

$$0 < H(x) \leq \log_2(J)$$

$$\lim[H(x)] = 0 \text{ für } \max[(f_1, \dots, f_J)] \rightarrow 1$$

$$H(x) = \log_2(J) \text{ für } f_1 = \dots = f_J = \frac{1}{J}$$



3.2 Statistische Kennzahlen für die Streuung

Nominale Daten

Normierte Entropie von x : $H_n(x) = - \sum_{j=1}^J f_j \cdot \frac{\log_2(f_j)}{\log_2(J)}$

Die Entropie ist ein sinnvolles Maß für die Streuung, denn sie erfüllt die Forderungen:

Geringe Streuung, falls es ein j gibt mit $f_j = 1$.

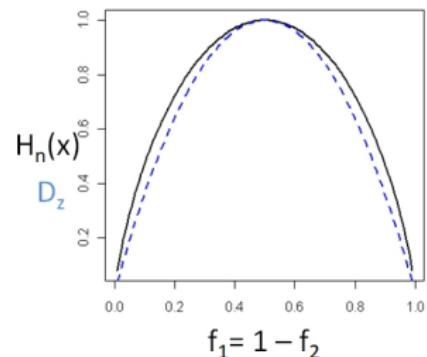
Höchste Streuung, falls $f_j = 1/J$, $j = 1, \dots, J$.

$$0 < H_n(x) \leq 1$$

$$\lim[H_n(x)] = 0 \text{ für } \max[(f_1, \dots, f_J)] \rightarrow 1$$

$$H_n(x) = 1 \text{ für } f_1 = \dots = f_J = \frac{1}{J}$$

Beispiel $J=2$



3.2 Statistische Kennzahlen für die Streuung

Nominale Daten: Beispiel Bearbeitungen von Softwareaufgaben

Merkmal	D _z	H _{n(x)}
Bearbeiter(in)	$4/3 \cdot (1 - 0.17^2 - 0.25^2 - 0.33^2 - 0.25^2)$ = 0.9815	$[-0.17 \cdot \log_2(0.17) - 0.25 \cdot \log_2(0.25) - 0.33 \cdot \log_2(0.33) - 0.25 \cdot \log_2(0.25)] / \log_2(4)$ = 0.9796
Aufgabe	$3/2 \cdot (1 - 0.17^2 - 0.5^2 - 0.33^2)$ = 0.9167	$[-0.17 \cdot \log_2(0.17) - 0.5 \cdot \log_2(0.5) - 0.33 \cdot \log_2(0.33)] / \log_2(3)$ = 0.9206
Version	$3/2 \cdot (1 - 0.25^2 - 0.5^2 - 0.25^2)$ = 0.9375	$[-0.25 \cdot \log_2(0.25) - 0.5 \cdot \log_2(0.5) - 0.25 \cdot \log_2(0.25)] / \log_2(3)$ = 0.9464

Bearbeiter(in)		
Aus-prägung	Absolute Häufigkeit	Relative Häufigkeit
Kai	2	0.17
Miriam	3	0.25
Oliver	4	0.33
Tina	3	0.25
	12	1

Aufgabe		
Ausprägung	Absolute Häufigkeit	Relative Häufigkeit
Abfrage	2	0.17
Export	6	0.5
Verknüpfung	4	0.33
	12	1

Version		
Aus-prägung	Absolute Häufigkeit	Relative Häufigkeit
1.1	3	0.25
1.2	6	0.5
2.0	3	0.25
	12	1

3.2 Statistische Kennzahlen für die Streuung

Ordinale Daten

x_1, \dots, x_N

$x_i \in W_x, i = 1, \dots, N$

$W_x = \{x(j) | j = 1, \dots, J\} = \{x(1), \dots, x(J)\}$

$x(1) < x(2) < \dots < x(J)$

i	x_i
1	$x(3)$
2	$x(2)$
3	$x(1)$
4	$x(1)$
5	$x(3)$

k	$x(k)$
1	$x(1)$
2	$x(1)$
3	$x(2)$
4	$x(3)$
5	$x(3)$

Simpson's D und $H(x)$ sind anwendbar, allerdings wird die Information der Kategorienordnung nicht genutzt.

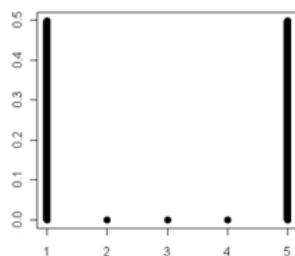
Geordnete Liste
→

3.2 Statistische Kennzahlen für die Streuung

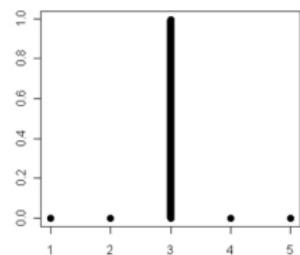
Ordinale Daten

Allgemein: Streuung desto höher, je schlechter konkrete Werte sich vorhersagen lassen.

Werte lassen sich umso besser vorhersagen, je stärker sie sich um den Median verdichten.



Geringste Streuung für $N(\tilde{x}_{0.5}) = N \rightarrow$



← Höchste Streuung für $N(\tilde{x}_0) = N(\tilde{x}_1) = N/2$

Nicht mehr höchste Streuung bei ausgeglichener Belegung, da die Kategorien unterschiedlich weit von der Mitte entfernt sind. Höchste Streuung bei maximaler Entfernung zur Mitte, also bei gleichmäßiger Konzentration an Minimum und Maximum.

3.2 Statistische Kennzahlen für die Streuung

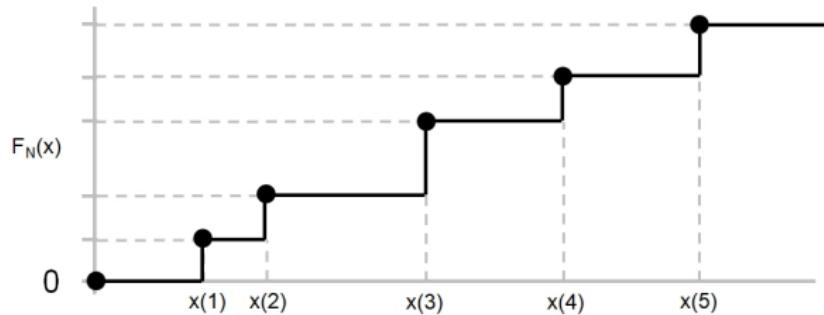
Ordinale Daten

Geringe Streuung für $N(\tilde{x}_{0.5}) = N$

Höchste Streuung für $N(\tilde{x}_0) = N(\tilde{x}_1) = N/2$

Dispersionsindex nach Leti

$$D_L = \sum_{j=1}^{J-1} F_N[x(j)] \cdot (1 - F_N[x(j)])$$



3.2 Statistische Kennzahlen für die Streuung

Ordinale Daten

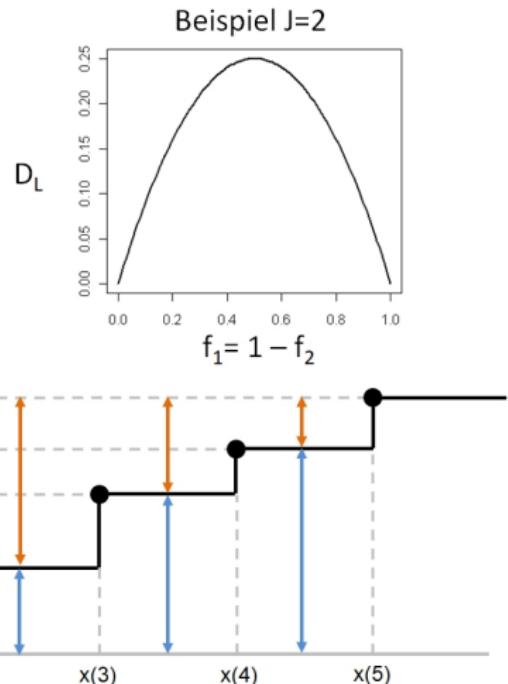
Geringe Streuung für $N(\tilde{x}_{0.5}) = N$

Höchste Streuung für $N(\tilde{x}_0) = N(\tilde{x}_1) = N/2$

Dispersionsindex nach Leti

$$D_L = \sum_{j=1}^{J-1} F_N[x(j)] \cdot (1 - F_N[x(j)])$$

$$0 \leq D_L \leq \frac{J-1}{4}$$



3.2 Statistische Kennzahlen für die Streuung

Ordinale Daten

Geringe Streuung für $N(\tilde{x}_{0.5}) = N$

Höchste Streuung für $N(\tilde{x}_0) = N(\tilde{x}_1) = N/2$

Normierter Dispersionsindex nach Leti

$$D_{LZ} = \frac{4}{J-1} \sum_{j=1}^{J-1} F_N[x(j)] \cdot (1 - F_N[x(j)])$$

$$0 \leq D_{LZ} \leq 1$$

Für $J = 2$ gilt $D_Z = D_{LZ}$,
d.h. normierte Versionen von
Simpson und Leti sind
äquivalent.

Beweis:

$$\begin{aligned} D_{LZ} &= \\ &= \frac{4}{2-1} \sum_{j=1}^1 F_N[x(j)](1 - F_N[x(j)]) \\ &= 4 \cdot (f_1(1-f_1)) = 2 \cdot (2f_1 - 2f_1^2) \\ &= 2(1 - f_1^2 - 1 + 2f_1 - f_1^2) \\ &= 2(1 - [f_1^2 + (1 - f_1)^2]) \\ &= 2\left(1 - \sum_{j=1}^2 f_j^2\right) \\ &= \frac{2\left(1 - \sum_{j=1}^2 f_j^2\right)}{2-1} = D_Z \quad \square \end{aligned}$$

3.2 Statistische Kennzahlen für die Streuung

Quantitative Daten

x_1, \dots, x_N

$x_i \in W_x, i = 1, \dots, N$

$W_x = \{x(j) | j = 1, \dots, J\} = \{x(1), \dots, x(J)\}$

bzw. $W_x = (-\infty, \infty)$

Allgemein: Streuung desto höher, je schlechter konkrete Werte sich vorhersagen lassen.

Werte lassen sich umso besser vorhersagen, je stärker sie sich um das jeweilige Lagemaß verdichten.

3.2 Statistische Kennzahlen für die Streuung

Quantitative Daten

Werte lassen sich umso besser vorhersagen, je stärker sie sich um das jeweilige Lagemaß verdichten.

Lagemaß: Arithmetisches Mittel

Streuungsmaß:

Varianz (mittlere quadratische Abweichung)

$$s_x^2 = \frac{1}{N-1} \sum_{n=1}^N (x_n - \bar{x})^2 \quad (\text{bzw. } d_x^2 = \frac{1}{N} \sum_{n=1}^N (x_n - \bar{x})^2)$$

Standardabweichung

$$s = \sqrt{s_x^2} = \sqrt{\frac{1}{N-1} \sum_{n=1}^N (x_n - \bar{x})^2}$$

3.2 Statistische Kennzahlen für die Streuung

Quantitative Daten

Von Streuungsparametern abgeleitete Größen für verhältnisskalierte Merkmale

Quartilskoeffizient

$$Q_{\text{koeff}} = \frac{2Q}{\tilde{x}_{0.25} + \tilde{x}_{0.75}} = \frac{2(\tilde{x}_{0.75} - \tilde{x}_{0.25})}{\tilde{x}_{0.25} + \tilde{x}_{0.75}} = (\tilde{x}_{0.75} - \tilde{x}_{0.25}) \Big/ \left(\frac{\tilde{x}_{0.25} + \tilde{x}_{0.75}}{2} \right)$$

Variationskoeffizient

$$V_x = \frac{s_x}{\bar{x}}$$

3.2 Statistische Kennzahlen für die Streuung

Quantitative Daten: Berechnung der Varianz aus Häufigkeitsverteilung

$$s_x^2 = \frac{N}{N-1} \sum_{j=1}^J f_j \cdot [x(j) - \sum_{k=1}^J f_k \cdot x(k)]^2 = \frac{N}{N-1} \sum_{j=1}^J f_j \cdot (x(j) - \bar{x})^2$$

Beweis:

$$\begin{aligned} s_x^2 &= \frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})^2 = \frac{1}{N-1} \sum_{i=1}^N (x_{(i)} - \bar{x})^2 = \frac{(x_{(1)} - \bar{x})^2}{N-1} + \dots + \frac{(x_{(N)} - \bar{x})^2}{N-1} \\ &= \underbrace{\frac{(x(1) - \bar{x})^2}{N-1} + \dots + \frac{(x(1) - \bar{x})^2}{N-1}}_{f_1 \cdot N\text{-mal}} + \dots + \underbrace{\frac{(x(J) - \bar{x})^2}{N-1} + \dots + \frac{(x(J) - \bar{x})^2}{N-1}}_{f_J \cdot N\text{-mal}} \\ &= \frac{N}{N-1} f_1 \cdot (x(1) - \bar{x})^2 + \dots + \frac{N}{N-1} f_J \cdot (x(J) - \bar{x})^2 = \frac{N}{N-1} \sum_{j=1}^J f_j \cdot (x(j) - \bar{x})^2 \quad \square \end{aligned}$$

3.2 Statistische Kennzahlen für die Streuung

Quantitative Daten: Varianz von Lineartransformationen

$$y = ax + b \Rightarrow s_y^2 = a^2 s_x^2$$

Beweis:

$$\begin{aligned} s_y^2 &= \frac{1}{N-1} \sum_{n=1}^N (y_n - \bar{y})^2 = \frac{1}{N-1} \sum_{n=1}^N [ax_n + b - (a\bar{x} + b)]^2 \\ &= \frac{1}{N-1} \sum_{n=1}^N (ax_n - a\bar{x})^2 \\ &= a^2 \frac{1}{N-1} \sum_{n=1}^N (x_n - \bar{x})^2 = \boxed{a^2 s_x^2} \quad \square \end{aligned}$$

$$\bar{y} = \overline{ax + b} = \frac{1}{N} \sum_{n=1}^N (ax_n + b) = a \frac{1}{N} \sum_{n=1}^N x_n + \frac{bN}{N} = a\bar{x} + b$$

3.2 Statistische Kennzahlen für die Streuung

Quantitative Daten: **Verschiebungssatz von Steiner**

$$d_x^2 = \left(\frac{1}{N} \sum_{n=1}^N (x_n - b)^2 \right) \quad \text{speziell für } b = 0 : d_x^2 = \bar{x^2} - \bar{x}^2$$

Beweis:

$$\begin{aligned} d_x^2 &= \frac{1}{N} \sum_{n=1}^N (x_n - \bar{x})^2 = \frac{1}{N} \sum_{n=1}^N [(x_n - b) + (b - \bar{x})]^2 \\ &= \frac{1}{N} \sum_{n=1}^N [(x_n - b)^2 + 2(x_n - b)(b - \bar{x}) + (b - \bar{x})^2] \\ &= \frac{1}{N} \sum_{n=1}^N (x_n - b)^2 + 2(b - \bar{x}) \frac{1}{N} \sum_{n=1}^N (x_n - b) + \frac{1}{N} \sum_{n=1}^N (b - \bar{x})^2 \\ &= \frac{1}{N} \sum_{n=1}^N (x_n - b)^2 - 2(\bar{x} - b)^2 + (\bar{x} - b)^2 = \boxed{\frac{1}{N} \sum_{n=1}^N (x_n - b)^2 - (\bar{x} - b)^2} \quad \square \end{aligned}$$

3.2 Statistische Kennzahlen für die Streuung

Quantitative Daten: Beispiel **Bearbeitungen von Softwareaufgaben**

$$\begin{aligned}
 s_{x_4}^2 &= \frac{2 \cdot (10 - 13.5)^2 + 1 \cdot (11 - 13.5)^2 + 2 \cdot (12 - 13.5)^2}{11} \\
 &\quad + \frac{1 \cdot (13 - 13.5)^2 + 2 \cdot (14 - 13.5)^2 + 1 \cdot (15 - 13.5)^2}{11} \\
 &\quad + \frac{1 \cdot (16 - 13.5)^2 + 1 \cdot (17 - 13.5)^2 + 1 \cdot (18 - 13.5)^2}{11} \\
 &= 7
 \end{aligned}$$

$$V_4 = \frac{\sqrt{7}}{13.5} = 0.196$$

$$\bar{x}_4 = 13.5$$

k	Anzahl Clicks _(k)
1	10
2	10
3	11
4	12
5	12
6	13
7	14
8	14
9	15
10	16
11	17
12	18

$$Q_{\text{koeff};4} = \frac{2 \cdot 4}{11.5 + 15.5} = 0.296$$

$$\tilde{x}_{4;0.25} = 11.5$$

$$Q_4 = 4$$

$$R_4 = 8$$

$$\tilde{x}_{4;0.75} = 15.5$$

3.2 Statistische Kennzahlen für die Streuung

Quantitative Daten: Beispiel **Bearbeitungen von Softwareaufgaben**

$$\begin{aligned}s_{x_5}^2 &= \frac{(3.2 - 5.075)^2 + (3.6 - 5.075)^2 + 2 \cdot (3.7 - 5.075)^2}{11} \\&+ \frac{(3.9 - 5.075)^2 + (4.2 - 5.075)^2 + (4.5 - 5.075)^2}{11} \\&+ \frac{(4.9 - 5.075)^2 + (6.1 - 5.075)^2 + (6.6 - 5.075)^2}{11} \\&+ \frac{(8.0 - 5.075)^2 + (8.5 - 5.075)^2}{11} = 3.24\end{aligned}$$

$$\bar{x}_5 = 5.075$$

$$V_5 = \frac{\sqrt{3.24}}{5.075} = 0.355$$

k	Bearbeitungszeit _(k)
1	3.2
2	3.6
3	3.7
4	3.7
5	3.9
6	4.2
7	4.5
8	4.9
9	6.1
10	6.6
11	8.0
12	8.5

$$Q_{\text{koeff};5} = \frac{2 \cdot 2.65}{3.7 + 6.35} = 0.527$$

$$\tilde{x}_{5;0.25} = 3.7$$

$$Q_5 = 2.65$$

$$R_5 = 5.3$$

$$\tilde{x}_{5;0.75} = 6.35$$

3.2 Statistische Kennzahlen für die Streuung

Zusammenfassung: Welche Maßzahlen sind bei welchem Skalenniveau geeignet?

Skalenniveau → ↓ Streuungsmaß	Nominal	Ordinal	Quantitativ
Simpson's D/ Entropie		– Informationsverlust	– Nur für klassierte Daten
Leti's D	– Nur für J = 2		– Nur für klassierte Daten
MAD/ Spannweite/ Quartilsdifferenz		– Geringe Aussagekraft für kleine J	+ Robust – Informationsverlust – Hohe Streubreite
Varianz/ Standardabweichung Variationskoeffizient	– Nur für J = 2		– Ausreißeranfälligkeit + Informationsnutzung + Geringe Streubreite

Bivariate Daten

4.1 Bivariate Daten: Tabellarische und grafische Darstellungen

Bisher: Betrachtung einzelner Merkmale X

Jetzt: Betrachtung von Merkmalspaaren (X, Y)

Bearbeitung	Bearbeiter(in)	Aufgabe	Version	Anzahl Clicks	Bearbeitungszeit
e ₁	Kai	Export	1.1	14	8.0
e ₂	Kai	Verknüpfung	1.2	12	4.9
e ₃	Miriam	Export	1.1	12	6.6
e ₄	Tina	Verknüpfung	1.2	13	3.2
e ₅	Oliver	Export	2.0	17	3.9
e ₆	Tina	Export	1.2	11	4.5
e ₇	Tina	Verknüpfung	1.2	14	6.1
e ₈	Miriam	Export	1.2	10	3.7
e ₉	Miriam	Export	1.2	10	4.2
e ₁₀	Oliver	Abfrage	1.1	18	8.5
e ₁₁	Oliver	Verknüpfung	2.0	16	3.6
e ₁₂	Oliver	Abfrage	2.0	15	3.7

X=Aufgabe

Y=Anzahl Clicks

4.1 Bivariate Daten: Tabellarische und grafische Darstellungen

Nominale Daten

Univariante Urlisten:

$$x_1, \dots, x_N$$

$$y_1, \dots, y_N$$

Univariante Wertebereiche:

$$x_i \in W_X, y_i \in W_Y, i = 1, \dots, N$$

$$\begin{aligned} W_X &= \{x(j) | j = 1, \dots, J\} = \\ &\{x(1), \dots, x(J)\} \end{aligned}$$

$$\begin{aligned} W_Y &= \{Y(k) | k = 1, \dots, K\} = \\ &\{y(1), \dots, y(K)\} \end{aligned}$$

i	x _i	y _i
1	A	D
2	C	E
...	...	
N	B	E

Bivariate Urliste:

$$(x_1, y_1), \dots, (x_N, y_N)$$

Bivariater Wertebereich:

$$\begin{aligned} (x_i, y_i) &\in W_{XY} = W_X \times W_Y = \\ &\{(x[1], y[1]), \dots, (x[1], y[K]), (x[2], y[1]), \\ &\dots, (x[J], y[K])\} \end{aligned}$$

4.1 Bivariate Daten: Tabellarische und grafische Darstellungen

Nominale Daten

$$x_1, \dots, x_N; y_1, \dots, y_N \\ x_i \in W_X, y_i \in W_Y$$

$$(x_1, y_1), \dots, (x_N, y_N) \\ (x_i, y_i) \in W_{XY} = W_X \times W_Y$$

$$d_i(j) = I_{x(e_i)=x(j)} \\ r_i(k) = I_{y(e_i)=y(k)}$$

i	x _i	y _i
1	A	D
2	C	E
...	...	
N	B	E

Dummykodierung →

i	x _i	y _i	d _i (1)	d _i (2)	d _i (3)	r _i (1)	r _i (2)
1	A	D	1	0	0	1	0
2	C	E	0	0	1	0	1
...
N	B	E	0	1	0	0	1
Σ			N _{1•}	N _{2•}	N _{3•}	N _{•1}	N _{•2}

4.1 Bivariate Daten: Tabellarische und grafische Darstellungen

Nominale Daten

Häufigkeitsverteilung eines bivariaten Merkmals

$$(x_i, y_i) \in W_{XY} = W_X \times W_Y, i = 1, \dots, N$$

$$W_{XY} = \{(x[j], y[k]) | j = 1, \dots, J; k = 1, \dots, K\}$$

$$= \left\{ \begin{array}{ccc} (x[1], y[1]) & \dots & (x[1], y[K]) \\ (x[2], y[1]) & \dots & (x[2], y[K]) \\ \vdots & \ddots & \vdots \\ (x[J], y[1]) & \dots & (x[J], y[K]) \end{array} \right\}$$

4.1 Bivariate Daten: Tabellarische und grafische Darstellungen

Nominale Daten

Gemeinsame absolute Häufigkeitsverteilung von x und y

$$N_{jk} = N((x[j], y[k])), \quad j = 1, \dots, J; k = 1, \dots, K$$

$$\begin{pmatrix} N_{11} & \dots & N_{1K} \\ N_{21} & \dots & N_{2K} \\ \vdots & \ddots & \vdots \\ N_{J1} & \dots & N_{JK} \end{pmatrix}$$

Gemeinsame relative Häufigkeitsverteilung von x und y

$$f_{jk} = \frac{N_{jk}}{N}, \quad j = 1, \dots, J; k = 1, \dots, K$$

$$\begin{pmatrix} f_{11} & \dots & f_{1k} \\ f_{21} & \dots & f_{2k} \\ \vdots & \ddots & \vdots \\ f_{j1} & \dots & f_{jk} \end{pmatrix}$$

4.1 Bivariate Daten: Tabellarische und grafische Darstellungen

Nominale Daten: Häufigkeitsverteilung eines bivariaten Merkmals

i	x _i	y _i	d _i (1)	d _i (2)	d _i (3)	r _i (1)	r _i (2)
1	A	D	1	0	0	1	0
2	C	E	0	0	1	0	1
...
N	B	E	0	1	0	0	1
Σ			$N_{1\bullet}$	$N_{2\bullet}$	$N_{3\bullet}$	$N_{\bullet 1}$	$N_{\bullet 2}$

$$\begin{aligned}
 N_{jk} &= N((x[j], y[k])) \\
 &= \sum_{i \in \{I | r_i(k) = 1\}} d_i(j) = \sum_{i \in \{I | d_i(j) = 1\}} r_i(k) \\
 &= \sum_{i=1}^N d_i(j) \cdot r_i(k)
 \end{aligned}$$

$$\begin{aligned}
 N_{j\bullet} &= \sum_{i=1}^N d_i(j) = \sum_{i \in \{I | r_i(1) = 1\}} d_i(j) + \sum_{i \in \{I | r_i(2) = 1\}} d_i(j) + \dots + \sum_{i \in \{I | r_i(K) = 1\}} d_i(j) \\
 &= \sum_{k=1}^K \sum_{l=1}^N d_l(j) \cdot r_l(k) = \sum_{k=1}^K N_{jk}
 \end{aligned}$$

4.1 Bivariate Daten: Tabellarische und grafische Darstellungen

Nominale Daten: Darstellung einer bivariaten Häufigkeitsverteilung

Kontingenztafel

Absolute Häufigkeiten

		Y				
		y(1)	y(2)	...	y(K)	Σ
X	x(1)	N_{11}	N_{12}	...	N_{1K}	$N_{1\cdot}$
	x(2)	N_{21}	N_{22}	...	N_{2K}	$N_{2\cdot}$

	x(J)	N_{J1}	N_{J2}	...	N_{JK}	$N_{J\cdot}$
Σ		$N_{\cdot 1}$	$N_{\cdot 2}$...	$N_{\cdot K}$	N

$$N_{j\cdot} = \sum_{k=1}^K N_{jk}$$

$$N_{\cdot k} = \sum_{j=1}^J N_{jk}$$

$$N = \sum_{j=1}^J \sum_{k=1}^K N_{jk}$$

4.1 Bivariate Daten: Tabellarische und grafische Darstellungen

Nominale Daten: Darstellung einer bivariaten Häufigkeitsverteilung

Kontingenztafel

Gemeinsame absolute Häufigkeitsverteilung von X und Y

		Y				
		y(1)	y(2)	...	y(K)	Σ
X	x(1)	N_{11}	N_{12}	...	N_{1K}	$N_{1\cdot}$
	x(2)	N_{21}	N_{22}	...	N_{2K}	$N_{2\cdot}$

	x(J)	N_{J1}	N_{J2}	...	N_{JK}	$N_{J\cdot}$
Σ		$N_{\cdot 1}$	$N_{\cdot 2}$...	$N_{\cdot K}$	N

$$N_{j\cdot} = \sum_{k=1}^K N_{jk}$$

$$N_{\cdot k} = \sum_{j=1}^J N_{jk}$$

$$N = \sum_{j=1}^J \sum_{k=1}^K N_{jk}$$

4.1 Bivariate Daten: Tabellarische und grafische Darstellungen

Nominale Daten: Darstellung einer bivariaten Häufigkeitsverteilung

Kontingenztafel

		Y				
		y(1)	y(2)	...	y(K)	Σ
X	x(1)	N_{11}	N_{12}	...	N_{1K}	$N_{1\cdot}$
	x(2)	N_{21}	N_{22}	...	N_{2K}	$N_{2\cdot}$

	x(J)	N_{J1}	N_{J2}	...	N_{JK}	$N_{J\cdot}$
Σ		$N_{\cdot 1}$	$N_{\cdot 2}$...	$N_{\cdot K}$	N

Absolute Randhäufigkeitsverteilung von X

Absolute Randhäufigkeitsverteilung von Y

4.1 Bivariate Daten: Tabellarische und grafische Darstellungen

Nominale Daten: Darstellung einer bivariaten Häufigkeitsverteilung

Kontingenztafel

		Y				Σ
		y(1)	y(2)	...	y(K)	
X	x(1)	N_{11}/N	N_{12}/N	...	N_{1K}/N	$N_{1\cdot}/N$
	x(2)	N_{21}/N	N_{22}/N	...	N_{2K}/N	$N_{2\cdot}/N$

	x(J)	N_{J1}/N	N_{J2}/N	...	N_{JK}/N	$N_{J\cdot}/N$
Σ	$N_{\cdot 1}/N$	$N_{\cdot 2}/N$...	$N_{\cdot K}/N$	N/N	

4.1 Bivariate Daten: Tabellarische und grafische Darstellungen

Nominale Daten: Darstellung einer bivariaten Häufigkeitsverteilung

Kontingenztafel

Relative Häufigkeiten

		Y				
		y(1)	y(2)	...	y(K)	Σ
X	x(1)	f_{11}	f_{12}	...	f_{1K}	$f_{1\cdot}$
	x(2)	f_{21}	f_{22}	...	f_{2K}	$f_{2\cdot}$

	x(J)	f_{J1}	f_{J2}	...	f_{JK}	$f_{J\cdot}$
Σ		$f_{\cdot 1}$	$f_{\cdot 2}$...	$f_{\cdot K}$	1

$$f_{\cdot k} = \sum_{j=1}^J f_{jk}$$

$$f_{j\cdot} = \sum_{k=1}^K f_{jk}$$

$$1 = \sum_{j=1}^J \sum_{k=1}^K f_{jk}$$

4.1 Bivariate Daten: Tabellarische und grafische Darstellungen

Nominale Daten: Darstellung einer bivariaten Häufigkeitsverteilung

Kontingenztafel

Gemeinsame relative Häufigkeitsverteilung f_{XY} von X und Y

		Y				Σ
		y(1)	y(2)	...	y(K)	
X	x(1)	f_{11}	f_{12}	...	f_{1K}	$f_{1\cdot}$
	x(2)	f_{21}	f_{22}	...	f_{2K}	$f_{2\cdot}$

	x(J)	f_{J1}	f_{J2}	...	f_{JK}	$f_{J\cdot}$
	Σ	$f_{\cdot 1}$	$f_{\cdot 2}$...	$f_{\cdot K}$	1

$$f_{XY} = \{f_{jk} \mid j=1, \dots, J; k=1, \dots, K\}$$

$$f_{j\cdot} = \sum_{k=1}^K f_{jk}$$

$$f_{\cdot k} = \sum_{j=1}^J f_{jk}$$

$$1 = \sum_{j=1}^J \sum_{k=1}^K f_{jk}$$

4.1 Bivariate Daten: Tabellarische und grafische Darstellungen

Nominale Daten: Darstellung einer bivariaten Häufigkeitsverteilung

Kontingenztafel

		Y					$f_{x\bullet} = \{f_{j\bullet} \mid j = 1, \dots, J\}$
		y(1)	y(2)	...	y(K)	Σ	
X	x(1)	f_{11}	f_{12}	...	f_{1K}	$f_{1\cdot}$	Relative Randhäufigkeitsverteilung $f_{x\bullet}$ von X
	x(2)	f_{21}	f_{22}	...	f_{2K}	$f_{2\cdot}$	
	
	x(J)	f_{J1}	f_{J2}	...	f_{JK}	$f_{J\cdot}$	
Σ		$f_{\cdot 1}$	$f_{\cdot 2}$...	$f_{\cdot K}$	1	
Relative Randhäufigkeitsverteilung $f_{\cdot Y}$ von Y							$f_{\cdot Y} = \{f_{\cdot k} \mid k = 1, \dots, K\}$

4.1 Bivariate Daten: Tabellarische und grafische Darstellungen

Nominale Daten: Darstellung einer bivariaten Häufigkeitsverteilung

Kontingenztafel

Wie lautet die Verteilung von Y im Teildatensatz, für den $X = x(2)$ gilt?

		Y				
		y(1)	y(2)	...	y(K)	Σ
X	x(1)					
	x(2)	N_{21}	N_{22}	...	N_{2K}	$N_{2\cdot}$
...						
x(J)						

Dieser Datensatz hat Umfang N_2 .
Absolute Häufigkeitsverteilung:

$$N_{y;k|2} = N_{2k}, \quad k=1, \dots, K$$

4.1 Bivariate Daten: Tabellarische und grafische Darstellungen

Nominale Daten: Darstellung einer bivariaten Häufigkeitsverteilung

Kontingenztafel

Wie lautet die Verteilung von Y im Teildatensatz, für den $X = x(2)$ gilt?

		Y				
		y(1)	y(2)	...	y(K)	Σ
X	x(1)					
	x(2)	$N_{21}/N_{2\bullet}$	$N_{22}/N_{2\bullet}$...	$N_{2K}/N_{2\bullet}$	$N_{2\bullet}/N_{2\bullet}$
	...					
	x(J)					

Dieser Datensatz hat Umfang N_2 .

Relative Häufigkeitsverteilung:

$$f_{y;k|2} = N_{y;2k}/N_{2\bullet} = f_{2k}/f_{2\bullet}, \quad k=1,\dots,K$$

4.1 Bivariate Daten: Tabellarische und grafische Darstellungen

Nominale Daten: Darstellung einer bivariaten Häufigkeitsverteilung

Kontingenztafel

Bedingte Verteilung von Y gegeben X , d.h. von $Y|X = k$

		Y				Σ
		y(1)	y(2)	...	y(K)	
X	x(1)	$f_{11}/f_{1\bullet}$	$f_{12}/f_{1\bullet}$...	$f_{1K}/f_{1\bullet}$	1
	x(2)	$f_{21}/f_{2\bullet}$	$f_{22}/f_{2\bullet}$...	$f_{2K}/f_{2\bullet}$	1

	x(J)	$f_{J1}/f_{J\bullet}$	$f_{J2}/f_{J\bullet}$...	$f_{JK}/f_{J\bullet}$	1
	Σ					J

Bedingte Verteilung
von Y gegeben $X=x(2)$

$$f_{y;k|2} = f_{2k}/f_{2\bullet}$$

4.1 Bivariate Daten: Tabellarische und grafische Darstellungen

Nominale Daten: Darstellung einer bivariaten Häufigkeitsverteilung

Kontingenztafel

		Y				Σ
		y(1)	y(2)	...	y(K)	
X	x(1)	$f_{11}/f_{1\bullet}$	$f_{12}/f_{1\bullet}$...	$f_{1K}/f_{1\bullet}$	1
	x(2)	$f_{21}/f_{2\bullet}$	$f_{22}/f_{2\bullet}$...	$f_{2K}/f_{2\bullet}$	1

	x(J)	$f_{J1}/f_{J\bullet}$	$f_{J2}/f_{J\bullet}$...	$f_{JK}/f_{J\bullet}$	1
Σ						J

Bedingte Verteilung
 $f_{Y|X}$ von Y gegeben X

$$f_{y;klj} = f_{jk}/f_{j\bullet}$$

$$f_{Y|X} = \{f_{y;klj} \mid j=1, \dots, J; k=1, \dots, K\}$$

Bedingte Verteilung
 $f_{X|Y}$ von X gegeben Y

$$f_{x;jlk} = f_{jk}/f_{\bullet k}$$

$$f_{X|Y} = \{f_{x;jlk} \mid j=1, \dots, J; k=1, \dots, K\}$$

4.1 Bivariate Daten: Tabellarische und grafische Darstellungen

Nominale Daten: Beispiel **Bearbeitungen von Softwareaufgaben**

Be-arbeiter(in)	Aufgabe
Kai	Export
Kai	Verknüpfung
Miriam	Export
Tina	Verknüpfung
Oliver	Export
Tina	Export
Tina	Verknüpfung
Miriam	Export
Miriam	Export
Oliver	Abfrage
Oliver	Verknüpfung
Oliver	Abfrage

Absolute Häufigkeiten

		Aufgabe			Σ
		Abfrage	Export	Verknüpfung	
Bear-bei-ter(in)	Kai	0	1	1	2
	Miriam	0	3	0	3
	Oliver	2	1	1	4
	Tina	0	1	2	3
	Σ	2	6	4	12

4.1 Bivariate Daten: Tabellarische und grafische Darstellungen

Nominale Daten: Beispiel **Bearbeitungen von Softwareaufgaben**

Be-arbeiter(in)	Aufgabe
Kai	Export
Kai	Verknüpfung
Miriam	Export
Tina	Verknüpfung
Oliver	Export
Tina	Export
Tina	Verknüpfung
Miriam	Export
Miriam	Export
Oliver	Abfrage
Oliver	Verknüpfung
Oliver	Abfrage

Relative Häufigkeiten

		Aufgabe			Σ
		Abfrage	Export	Verknüpfung	
Bear-bei-ter(in)	Kai	0	1/12	1/12	2/12
	Miriam	0	3/12	0	3/12
	Oliver	2/12	1/12	1/12	4/12
	Tina	0	1/12	2/12	3/12
	Σ	2/12	6/12	4/12	1

4.1 Bivariate Daten: Tabellarische und grafische Darstellungen

Nominale Daten: Beispiel **Bearbeitungen von Softwareaufgaben**

Bearbeiter(in)	Aufgabe
Kai	Export
Kai	Verknüpfung
Miriam	Export
Tina	Verknüpfung
Oliver	Export
Tina	Export
Tina	Verknüpfung
Miriam	Export
Miriam	Export
Oliver	Abfrage
Oliver	Verknüpfung
Oliver	Abfrage

Relative Häufigkeiten Aufgabe bedingt auf Bearbeiter(in)

		Aufgabe			Σ
		Abfrage	Export	Verknüpfung	
Bearbeiter(in)	Kai	0	1/2	1/2	1
	Miriam	0	1	0	1
	Oliver	2/4	1/4	1/4	1
	Tina	0	1/3	2/3	1
	Σ				4

4.1 Bivariate Daten: Tabellarische und grafische Darstellungen

Nominale Daten: Beispiel **Bearbeitungen von Softwareaufgaben**

Bearbeiter(in)	Aufgabe
Kai	Export
Kai	Verknüpfung
Miriam	Export
Tina	Verknüpfung
Oliver	Export
Tina	Export
Tina	Verknüpfung
Miriam	Export
Miriam	Export
Oliver	Abfrage
Oliver	Verknüpfung
Oliver	Abfrage

Relative Häufigkeiten Bearbeiter(in) bedingt auf Aufgabe

		Aufgabe			Σ
		Abfrage	Export	Verknüpfung	
Bearbeiter(in)	Kai	0	1/6	1/4	
	Miriam	0	1/2	0	
	Oliver	1	1/6	1/4	
	Tina	0	1/6	1/2	
Σ		1	1	1	3

4.1 Bivariate Daten: Tabellarische und grafische Darstellungen

Nominale Daten: Beispiel in R:

Überlebende der Titanic

Der **Mosaikplot**

Code in R:

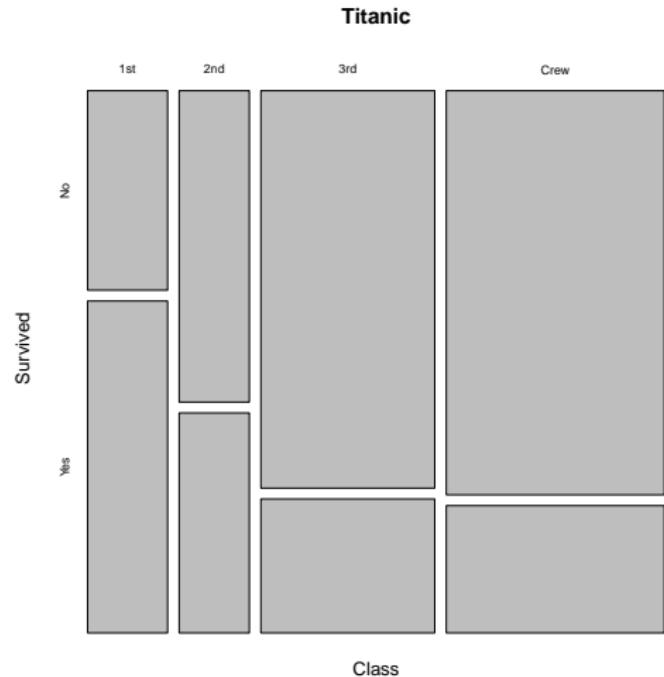
```
mosaicplot(~ Class + Survived,  
          data = Titanic)
```

Rechteckbreiten entsprechen $f_{\bullet c}$

Rechteckhöhen entsprechen $f_{s|c}$

Rechteckflächen entsprechen

$$f_{sc} = f_{s|c} \cdot f_{\bullet c}$$



4.1 Bivariate Daten: Tabellarische und grafische Darstellungen

Nominale Daten: Beispiel in R:

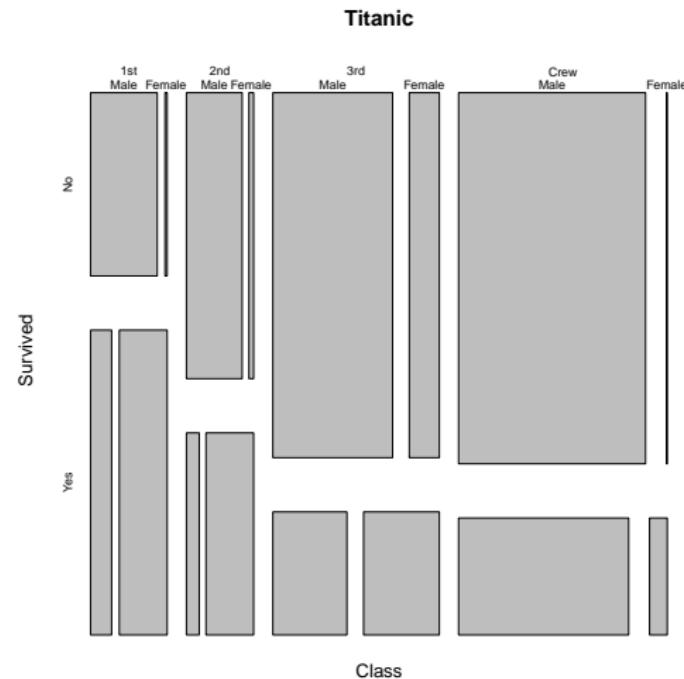
Überlebende der Titanic

Der **Mosaikplot**

Code in R:

```
mosaicplot(~ Class + Survived +  
Sex, data = Titanic)
```

Zusätzliche Einteilung der Flächen nach Geschlecht



4.1 Bivariate Daten: Tabellarische und grafische Darstellungen

Ordinale Daten:

- Kontingenztafeln und Mosaikplots mit geordneten Kategorien

Quantitative Daten:

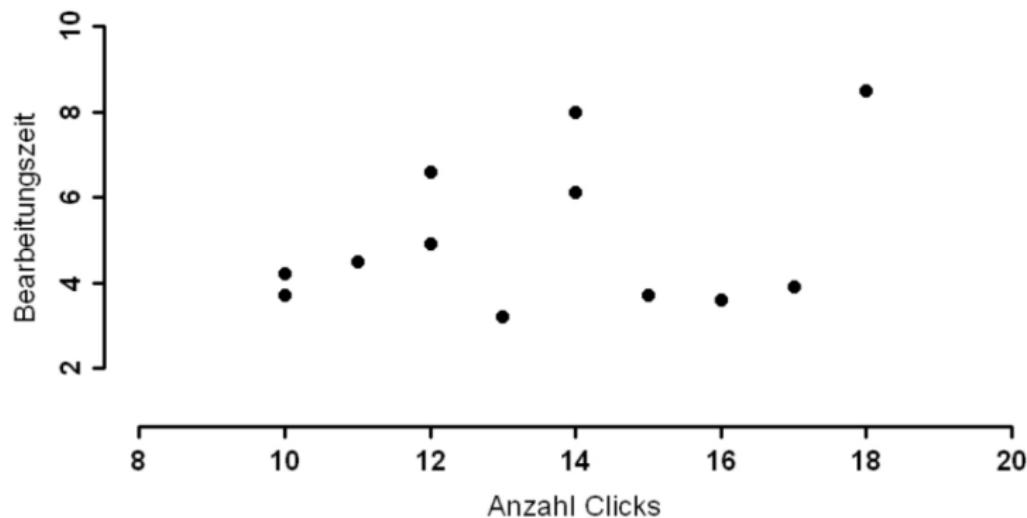
- Kontingenztafeln und Mosaikplots mit klassierten Daten
- Streudiagramme!

4.1 Bivariate Daten: Tabellarische und grafische Darstellungen

Quantitative Daten: Beispiel **Bearbeitungen von Softwareaufgaben**

Streudiagramm

Darstellung der Punktpaare (x_i, y_i) in einem kartesischen Koordinatensystem

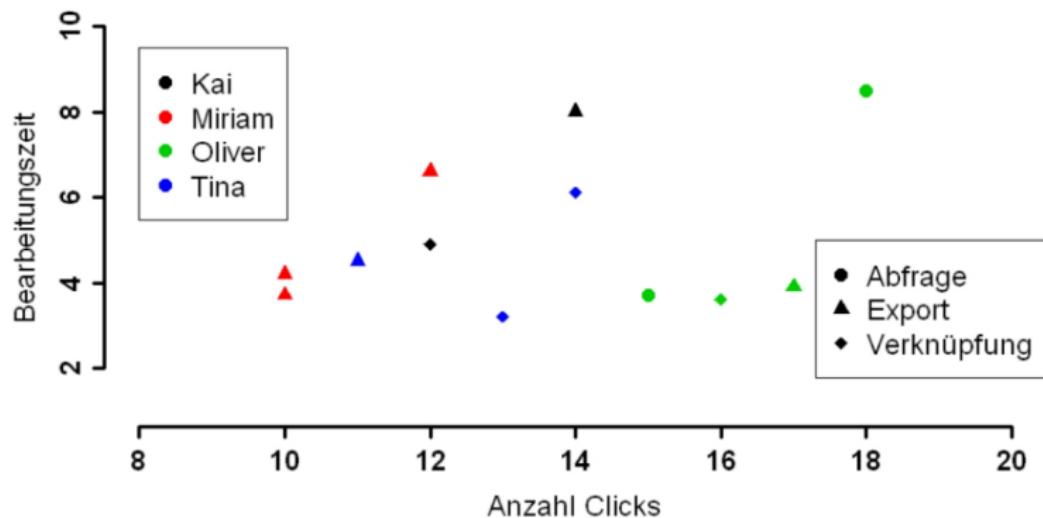


4.1 Bivariate Daten: Tabellarische und grafische Darstellungen

Quantitative Daten: Beispiel **Bearbeitungen von Softwareaufgaben**

Streudiagramm

Darstellung der Punktepaare (x_i, y_i) in einem kartesischen Koordinatensystem



4.2 Bivariate Daten: Zusammenhangsmaße

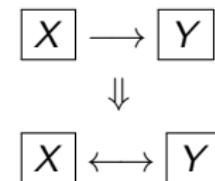
- Erinnerung: Allgemeine Eigenschaft der Streuung univariater Daten: Streuung von X desto höher, je schlechter sich konkrete Werte vorhersagen lassen.
 - ▶ Bisher: Vorhersage der Werte von X durch einzelne Lageparameter.
 - ▶ Jetzt: **Vorhersage der Werte von Y unter Verwendung der Werte von X .**
- Allgemein: Zusammenhang (= **Korrelation**) zwischen X und Y desto größer, je besser sich der Wert von Y unter Kenntnis des Werts von X vorhersagen lässt (oder umgekehrt).
- **Wichtige Unterscheidung**
 - ▶ **Korrelation** bedeutet nicht notwendig **Kausalität** (Beziehung zwischen *Ursache* und *Wirkung* oder *Aktion* und *Reaktion*)

4.2 Bivariate Daten: Zusammenhangsmaße

Korrelation und Kausalität

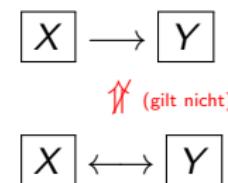
Es gilt:

X ist Ursache von $Y \Rightarrow X$ und Y korrelieren



Aber:

X und Y korrelieren $\not\Rightarrow X$ ist Ursache von Y



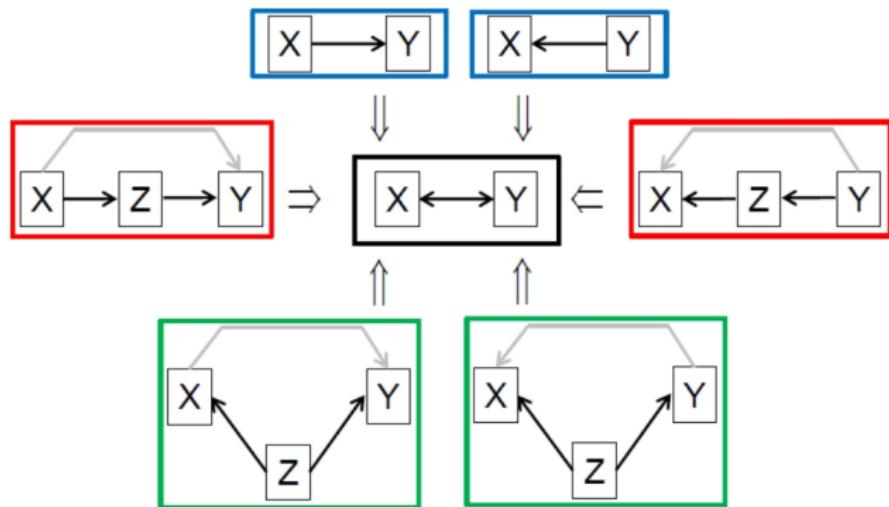
4.2 Bivariate Daten: Zusammenhangsmaße

Korrelation und Kausalität

X ist Ursache von $Y \Rightarrow X$ und Y korrelieren

X und Y korrelieren $\not\Rightarrow X$ ist Ursache von Y

Verschiedene
Korrelationsquellen
möglich



4.2 Bivariate Daten: Zusammenhangsmaße

Nominale Daten

Zusammenhang (=Korrelation) zwischen X und Y desto größer, je besser sich der Wert von Y unter Kenntnis des Werts von X vorhersagen lässt (oder umgekehrt).

	Y				
	$y(1)$	$y(2)$	\dots	$y(K)$	Σ
$x(1)$	$f_{y;1 1}$	$f_{y;2 1}$	\dots	$f_{y;K 1}$	1
$x(2)$	$f_{y;1 2}$	$f_{y;2 2}$	\dots	$f_{y;K 2}$	1
\dots	\dots	\dots	\dots	\dots	\dots
$x(J)$	$f_{y;1 J}$	$f_{y;2 J}$	\dots	$f_{y;K J}$	1
	$f_{\cdot 1}$	$f_{\cdot 2}$	\dots	$f_{\cdot K}$	

Wert von Y lässt sich bei Kenntnis von X umso besser vorhersagen, je stärker die bedingte Verteilung $f_{Y|X}$ von Y gegeben X von der Randverteilung $f_{\cdot Y}$ von Y abweicht.

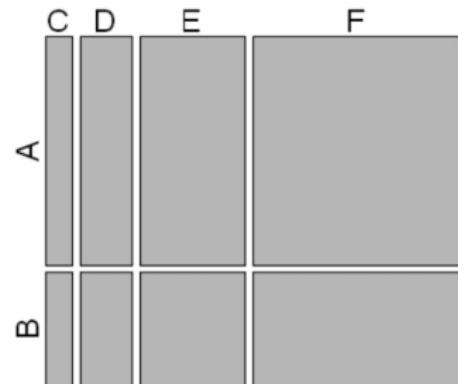
4.2 Bivariate Daten: Zusammenhangsmaße

Nominale Daten

Wert von Y lässt sich bei Kenntnis von X umso besser vorhersagen, je stärker die bedingte Verteilung $f_{Y|X}$ von Y gegeben X von der Randverteilung $f_{\bullet Y}$ von Y abweicht.

	Y				
	$y(1)$	$y(2)$	\dots	$y(K)$	Σ
$x(1)$	$f_{\bullet 1}$	$f_{\bullet 2}$	\dots	$f_{\bullet K}$	1
$x(2)$	$f_{\bullet 1}$	$f_{\bullet 2}$	\dots	$f_{\bullet K}$	1
\dots	\dots	\dots	\dots	\dots	\dots
$x(J)$	$f_{\bullet 1}$	$f_{\bullet 2}$	\dots	$f_{\bullet K}$	1
	$f_{\bullet 1}$	$f_{\bullet 2}$	\dots	$f_{\bullet K}$	

Zusammenhang minimal, falls
 $f_{y;k|j} = f_{\bullet j}$ für alle $j \in \{1, \dots, J\}$
und $k \in \{1, \dots, K\}$



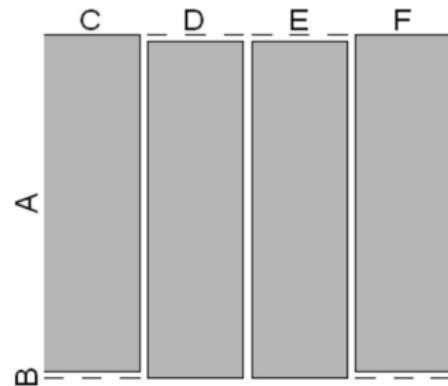
4.2 Bivariate Daten: Zusammenhangsmaße

Nominale Daten

Wert von Y lässt sich bei Kenntnis von X umso besser vorhersagen, je stärker die bedingte Verteilung $f_{Y|X}$ von Y gegeben X von der Randverteilung $f_{\bullet Y}$ von Y abweicht.

	Y				
	$y(1)$	$y(2)$	\dots	$y(K)$	Σ
$x(1)$	0	1	\dots	0	1
$x(2)$	0	0	\dots	1	1
\dots	\dots	\dots	\dots	\dots	\dots
$x(J)$	1	0	\dots	0	1
	$f_{\bullet 1}$	$f_{\bullet 2}$	\dots	$f_{\bullet K}$	

Zusammenhang maximal, falls es für alle $j \in \{1, \dots, J\}$ ein $k \in \{1, \dots, K\}$ mit $f_{y;k|j} = 1$ gibt



4.2 Bivariate Daten: Zusammenhangsmaße

Nominale Daten

Wert von Y lässt sich bei Kenntnis von X umso besser vorhersagen, je stärker die bedingte Verteilung $f_{Y|X}$ von Y gegeben X von der Randverteilung $f_{\bullet Y}$ von Y abweicht.

	Y					
	$y(1)$	$y(2)$	\dots	$y(K)$	Σ	
X	$x(1)$	$f_{y;1 1}$	$f_{y;2 1}$	\dots	$f_{y;K 1}$	1
	$x(2)$	$f_{y;1 2}$	$f_{y;2 2}$	\dots	$f_{y;K 2}$	1
	\dots	\dots	\dots	\dots	\dots	\dots
	$x(J)$	$f_{y;1 J}$	$f_{y;2 J}$	\dots	$f_{y;K J}$	1
		$f_{\bullet 1}$	$f_{\bullet 2}$	\dots	$f_{\bullet K}$	

Ein Maß, dass desto größer wird, je größer die Abweichung der bedingten Verteilung $f_{Y|X}$ von der Randverteilung $f_{\bullet Y}$ ist, ist also ein sinnvolles Zusammenhangsmaß.

4.2 Bivariate Daten: Zusammenhangsmaße

Nominale Daten

Ein Maß, dass desto größer wird, je größer die Abweichung der bedingten Verteilung $f_{Y|X}$ von der Randverteilung $Y_{\bullet Y}$ ist, ist also ein sinnvolles Zusammenhangsmaß.

	Y				
	y(1)	y(2)	...	y(K)	Σ
x(1)	$f_{0;11}$	$f_{0;12}$...	$f_{0;1K}$	$f_{1\bullet}$
x(2)	$f_{0;21}$	$f_{0;22}$...	$f_{0;2K}$	$f_{2\bullet}$
...
x(J)	$f_{0;J1}$	$f_{0;J2}$...	$f_{0;JK}$	$f_{J\bullet}$
Σ	$f_{\bullet 1}$	$f_{\bullet 2}$...	$f_{\bullet K}$	1

Wären bedingte und Randverteilung identisch, so würde ein Anteil von von $f_{0;jk} = f_{\bullet k} \cdot f_{j\bullet}$ an den N Daten in Kategorie $(x(j), y(k))$ fallen.

Dieser Fall wird als **empirische Unabhängigkeit** von X und Y bezeichnet.

4.2 Bivariate Daten: Zusammenhangsmaße

Nominale Daten

Ein Maß, dass desto größer wird, je größer die Abweichung der bedingten Verteilung $f_{Y|X}$ von der Randverteilung $Y \bullet Y$ ist, ist also ein sinnvolles Zusammenhangsmaß.

	Y				
	y(1)	y(2)	...	y(K)	Σ
x(1)	v_{11}	v_{12}	...	v_{1K}	$N_{1\bullet}$
x(2)	v_{21}	v_{22}	...	v_{2K}	$N_{2\bullet}$
...
x(J)	v_{J1}	v_{J2}	...	v_{JK}	$N_{J\bullet}$
Σ	$N_{\bullet 1}$	$N_{\bullet 2}$...	$N_{\bullet K}$	N

Somit würden bei Unabhängigkeit

$$v_{jk} = f_{\bullet k} \cdot f_{j\bullet} \cdot N = \frac{N_{\bullet k} \cdot N_{j\bullet} \cdot N}{N \cdot N} = \frac{N_{\bullet k} \cdot N_{j\bullet}}{N}$$

Beobachtungen in Kategorie $(x(j), x(k))$ erwartet.

4.2 Bivariate Daten: Zusammenhangsmaße

Nominale Daten Je größer die beobachteten Anzahlen N_{jk} von den erwarteten v_{jk} abweichen, desto mehr unterscheiden sich bedingte und Randverteilungen. Ein Maß, dass auf der quadratischen Abweichung der erwarteten von den beobachteten Häufigkeiten basiert, ist die **χ^2 -Größe**

$$\chi^2 = \sum_{j=1}^J \sum_{k=1}^K \frac{(N_{jk} - v_{jk})^2}{v_{jk}}, \quad v_{jk} = \frac{N_{j\bullet} N_{\bullet k}}{N}$$

		Y				Σ
		$y(1)$	$y(2)$...	$y(K)$	
X	$x(1)$	$(N_{11}-v_{11})^2$	$(N_{12}-v_{12})^2$...	$(N_{1K}-v_{1K})^2$	$N_{1\bullet}$
	$x(2)$	$(N_{21}-v_{21})^2$	$(N_{22}-v_{22})^2$...	$(N_{2K}-v_{2K})^2$	$N_{2\bullet}$

	$x(J)$	$(N_{J1}-v_{J1})^2$	$(N_{J2}-v_{J2})^2$...	$(N_{JK}-v_{JK})^2$	$N_{J\bullet}$
Σ		$N_{\bullet 1}$	$N_{\bullet 2}$...	$N_{\bullet K}$	N

4.2 Bivariate Daten: Zusammenhangsmaße

Nominale Daten: die χ^2 -Größe

$$\chi^2 = \sum_{j=1}^J \sum_{k=1}^K \frac{(N_{jk} - v_{jk})^2}{v_{jk}}, \quad v_{jk} = \frac{N_{j\bullet} N_{\bullet k}}{N}$$

Die χ^2 -Größe erfüllt die Forderung, desto größer zu werden, je größer die Abweichung der bedingten Verteilung $f_{Y|X}$ von der Randverteilung f_Y ist.

$$\begin{aligned} \boxed{\chi^2} &= \sum_{j=1}^J \sum_{k=1}^K \frac{\left(N_{jk} - \frac{N_{j\bullet} N_{\bullet k}}{N}\right)^2 N}{N_{j\bullet} N_{\bullet k}} = \sum_{j=1}^J \sum_{k=1}^K \frac{(f_{jk} N - f_{j\bullet} f_{\bullet k} N)^2}{f_{j\bullet} f_{\bullet k} N} \\ &= \sum_{j=1}^J \sum_{k=1}^K \frac{N(f_{jk} - f_{j\bullet} f_{\bullet k})^2}{f_{j\bullet} f_{\bullet k}} = \sum_{j=1}^J \sum_{k=1}^K \frac{N f_{j\bullet}^2 \left(\frac{f_{jk}}{f_{j\bullet}} - f_{\bullet k}\right)^2}{f_{j\bullet} f_{\bullet k}} \\ &= \boxed{\sum_{j=1}^J \sum_{k=1}^K \frac{N f_{j\bullet} (f_{y;k|j} - f_{\bullet k})^2}{f_{\bullet k}}} \end{aligned}$$

4.2 Bivariate Daten: Zusammenhangsmaße

Nominale Daten: die χ^2 -Größe

$$\chi^2 = \sum_{j=1}^J \sum_{k=1}^K \frac{(N_{jk} - v_{jk})^2}{v_{jk}} = N \left(\sum_{j=1}^J \sum_{k=1}^K \frac{N_{jk}^2}{N_{j\bullet} N_{\bullet k}} - 1 \right), \quad v_{jk} = \frac{N_{j\bullet} N_{\bullet k}}{N}$$

Es gilt: $0 \leq \chi^2 \leq N(\min\{J, K\} - 1)$

Beweis:

$0 \leq \chi^2$ klar wegen $N_{j\bullet} > 0, N_{\bullet k} > 0, (N_{jk} - v_{jk})^2 \geq 0$

$0 = \chi^2$, wenn $N_{jk} = v_{jk}$, d.h. wenn alle bedingten Häufigkeiten den unter Unabhängigkeit erwarteten Häufigkeiten entsprechen.

4.2 Bivariate Daten: Zusammenhangsmaße

Nominale Daten: die χ^2 -Größe

$$\chi^2 = \sum_{j=1}^J \sum_{k=1}^K \frac{(N_{jk} - v_{jk})^2}{v_{jk}} = N \left(\sum_{j=1}^J \sum_{k=1}^K \frac{N_{jk}^2}{N_{j\bullet} N_{\bullet k}} - 1 \right), \quad v_{jk} = \frac{N_{j\bullet} N_{\bullet k}}{N}$$

Wann gilt: $\boxed{\chi^2 = N(\min\{J, K\} - 1)}$?

Beweisskizze: Sei o.B.d.A. $K \leq J$.

Dann gilt für alle $k = 1, \dots, K$ und $j = 1, \dots, J$ mit $N_{jk} > 0$:

$$\sum_{j=1}^J \sum_{k=1}^K \frac{N_{jk}^2}{N_{j\bullet} N_{\bullet k}} = K \Leftrightarrow \frac{N_{jk}}{N_{j\bullet}} = 1 \quad \text{für ein } k_j,$$

d.h. χ^2 wird maximal, wenn es zu jedem j ein k_j mit $f_{y;k_j|j} = 1$ gibt.

4.2 Bivariate Daten: Zusammenhangsmaße

Nominale Daten: die χ^2 -Größe

$$\chi^2 = \sum_{j=1}^J \sum_{k=1}^K \frac{(N_{jk} - v_{jk})^2}{v_{jk}} = N \left(\sum_{j=1}^J \sum_{k=1}^K \frac{N_{jk}^2}{N_{j\bullet} N_{\bullet k}} - 1 \right), \quad v_{jk} = \frac{N_{j\bullet} N_{\bullet k}}{N}$$

Es gilt: $0 \leq \chi^2 \leq N(\min\{J, K\} - 1)$

(Korrigierter) Kontingenzkoeffizient nach Pearson:

$$C = \sqrt{\frac{\chi^2}{\chi^2 + N \min\{J, K\} - 1}} \in [0, 1]$$

Eliminiert Abhängigkeit des Koeffizienten vom Stichprobenumfang N und von der Dimension $\min\{J, K\}$.

4.2 Bivariate Daten: Zusammenhangsmaße

Nominale Daten: Beispiel Bearbeitungen von Softwareaufgaben

 N_{jk}

b		Aufgabe			Σ
		Abfrage	Export	Verknüpfung	
Bearbei- ter(in)	Kai	0	1	1	2
	Miriam	0	3	0	3
	Oliver	2	1	1	4
	Tina	0	1	2	3
	Σ	2	6	4	12

4.2 Bivariate Daten: Zusammenhangsmaße

Nominale Daten: Beispiel Bearbeitungen von Softwareaufgaben

V_{jk}

		Aufgabe			Σ
		Abfrage	Export	Verknüpfung	
Bearbei- ter(in)	Kai	0 $2 \cdot 2 / 12 = 1/3$	1 $2 \cdot 6 / 12 = 1$	1 $2 \cdot 4 / 12 = 2/3$	2
	Miriam	0 $3 \cdot 2 / 12 = 1/2$	3 $3 \cdot 6 / 12 = 3/2$	0 $3 \cdot 4 / 12 = 1$	3
	Oliver	2 $4 \cdot 2 / 12 = 2/3$	1 $4 \cdot 6 / 12 = 2$	1 $4 \cdot 4 / 12 = 4/3$	4
	Tina	0 $3 \cdot 2 / 12 = 1/2$	1 $3 \cdot 6 / 12 = 3/2$	2 $3 \cdot 4 / 12 = 1$	3
	Σ	2	6	4	12

4.2 Bivariate Daten: Zusammenhangsmaße

Nominale Daten: Beispiel Bearbeitungen von Softwareaufgaben

$$(N_{jk} - v_{jk})^2$$

		Aufgabe			Σ
		Abfrage	Export	Verknüpfung	
Bearbei- ter(in)	Kai	0 $(0-1/3)^2=1/9$	1 $(1-1)^2=0$	1 $(1-2/3)^2=1/9$	2
	Miriam	0 $(0-1/2)^2=1/4$	3 $(3-3/2)^2=9/4$	0 $(0-1)^2=1$	3
	Oliver	2 $(2-2/3)^2=16/9$	1 $(1-2)^2=1$	1 $(1-4/3)^2=1/9$	4
	Tina	0 $(0-1/2)^2=1/4$	1 $(1-3/2)^2=1/4$	2 $(2-1)^2=1$	3
	Σ	2	6	4	12

4.2 Bivariate Daten: Zusammenhangsmaße

Nominale Daten: Beispiel Bearbeitungen von Softwareaufgaben

$$(N_{jk} - v_{jk})^2 / v_{jk}$$

		Aufgabe			Σ
		Abfrage	Export	Verknüpfung	
Bearbei- ter(in)	Kai	0 $1 \cdot 3 / (9 \cdot 1) = 1/3$	1 $0/1=0$	1 $1 \cdot 3 / (9 \cdot 2) = 1/6$	2
	Miriam	0 $1 \cdot 2 / (4 \cdot 1) = 1/2$	3 $9 \cdot 2 / (4 \cdot 3) = 3/2$	0 $1/1=1$	3
	Oliver	2 $16 \cdot 3 / (9 \cdot 2) = 8/3$	1 $1/2$	1 $1 \cdot 3 / (9 \cdot 4) = 1/12$	4
	Tina	0 $1 \cdot 2 / (4 \cdot 1) = 1/2$	1 $1 \cdot 2 / (4 \cdot 3) = 1/6$	2 $1/1=1$	3
	Σ	2	6	4	12

4.2 Bivariate Daten: Zusammenhangsmaße

Nominale Daten: Beispiel **Bearbeitungen von Softwareaufgaben**

$$\begin{aligned}\chi^2 &= \sum_{j=1}^J \sum_{k=1}^K \frac{(N_{jk} - v_{jk})^2}{v_{jk}} \\ &= \frac{1}{12}(4 + 6 + 32 + 6 + 0 + 18 + 6 + 2 + 2 + 12 + 1 + 12) = \frac{101}{12} \approx 8.417\end{aligned}$$

$$(N_{jk} - v_{jk})^2 / v_{jk}$$

		Aufgabe			Σ
		Abfrage	Export	Verknüpfung	
Bearbei- ter(in)	Kai	1/3	0	1/6	2
	Miriam	1/2	3/2	1	3
	Oliver	8/3	1/2	1/12	4
	Tina	1/2	1/6	1	3
Σ		2	6	4	12

4.2 Bivariate Daten: Zusammenhangsmaße

Nominale Daten: Beispiel Bearbeitungen von Softwareaufgaben

$$\chi^2 = \frac{101}{12}, \quad C = \sqrt{\frac{\chi^2}{\chi^2 + N} \frac{\min\{J, K\}}{\min\{J, K\} - 1}} = \sqrt{\frac{101 \cdot 12}{12 \cdot 245} \cdot \frac{3}{2}} = \sqrt{\frac{303}{490}} \approx 0.786$$

$$(N_{jk} - v_{jk})^2 / v_{jk}$$

		Aufgabe			Σ
		Abfrage	Export	Verknüpfung	
Bearbei- ter(in)	Kai	1/3	0	1/6	2
	Miriam	1/2	3/2	1	3
	Oliver	8/3	1/2	1/12	4
	Tina	1/2	1/6	1	3
	Σ	2	6	4	12

4.2 Bivariate Daten: Zusammenhangsmaße

Ordinale Daten

Allgemein: Zusammenhang (=Korrelation) zwischen Y und X desto größer, je besser sich der Wert von Y unter Kenntnis des Werts von X vorhersagen lässt (oder umgekehrt).

Wert von Y lässt sich bei Kenntnis von X umso besser vorhersagen, je mehr ein hoher Wert von X einen hohen Wert von Y impliziert (**positiver Zusammenhang**) bzw. je mehr ein hoher Wert von X einen niedrigen Wert von Y impliziert (**negativer Zusammenhang**).

Ein sinnvolles Zusammenhangsmaß für ordinale Daten sollte also im Absolutwert hoch sein, wenn hohe **Ränge** von X mit hohen bzw. niedrigen **Rängen** von Y einhergehen und niedrig, wenn Paare von hohen und hohen, hohen und niedrigen, niedrigen und hohen sowie niedrigen und niedrigen **X- und Y-Rängen** in gleichem Maße auftreten.

4.2 Bivariate Daten: Zusammenhangsmaße

Quantitative Daten

Allgemein: Zusammenhang (=Korrelation) zwischen Y und X desto größer, je besser sich der Wert von Y unter Kenntnis des Werts von X vorhersagen lässt (oder umgekehrt).

Wert von Y lässt sich bei Kenntnis von X umso besser vorhersagen, je mehr ein hoher **Wert** von X einen hohen **Wert** von Y impliziert (positiver Zusammenhang) bzw. je mehr ein hoher **Wert** von X einen niedrigen **Wert** von Y impliziert (negativer Zusammenhang).

Ein sinnvolles Zusammenhangsmaß für ordinale Daten sollte also im Absolutwert hoch sein, wenn hohe **Werte** von X mit hohen bzw. niedrigen **Werten** von Y einhergehen und niedrig, wenn Paare von hohen und hohen, hohen und niedrigen, niedrigen und hohen sowie niedrigen und niedrigen **X- und Y-Werten** in gleichem Maße auftreten.

4.2 Bivariate Daten: Zusammenhangsmaße

Quantitative Daten

Allgemein: Zusammenhang (=Korrelation) zwischen Y und X desto größer, je besser sich der Wert von Y unter Kenntnis des Werts von X vorhersagen lässt (oder umgekehrt).

$$\text{Kovarianz: } s_{xy} = \frac{1}{N-1} \sum_{n=1}^N (x_n - \bar{x})(y_n - \bar{y})$$

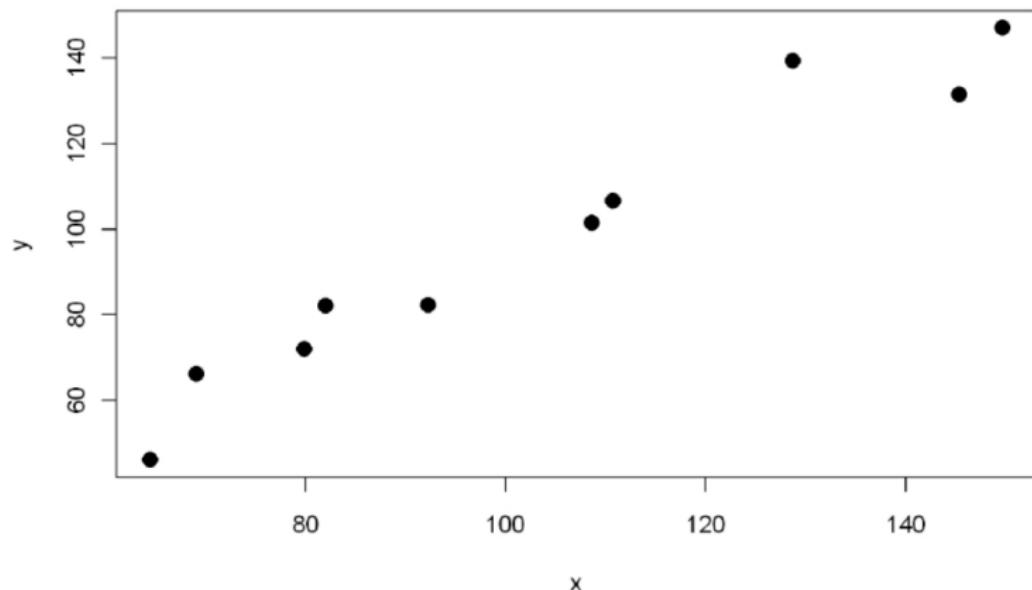
$s_{xy} > 0$, wenn hohe Werte von X in hohem Maße mit hohen Werten von Y einhergehen (Positive Korrelation)

$s_{xy} < 0$, wenn hohe Werte von X in hohem Maße mit niedrigen Werten von Y einhergehen (Negative Korrelation)

$s_{xy} = 0$, wenn hohe Werte von X in gleichem Maße mit hohen Werten wie mit niedrigen Werten von Y einhergehen (Unkorreliertheit)

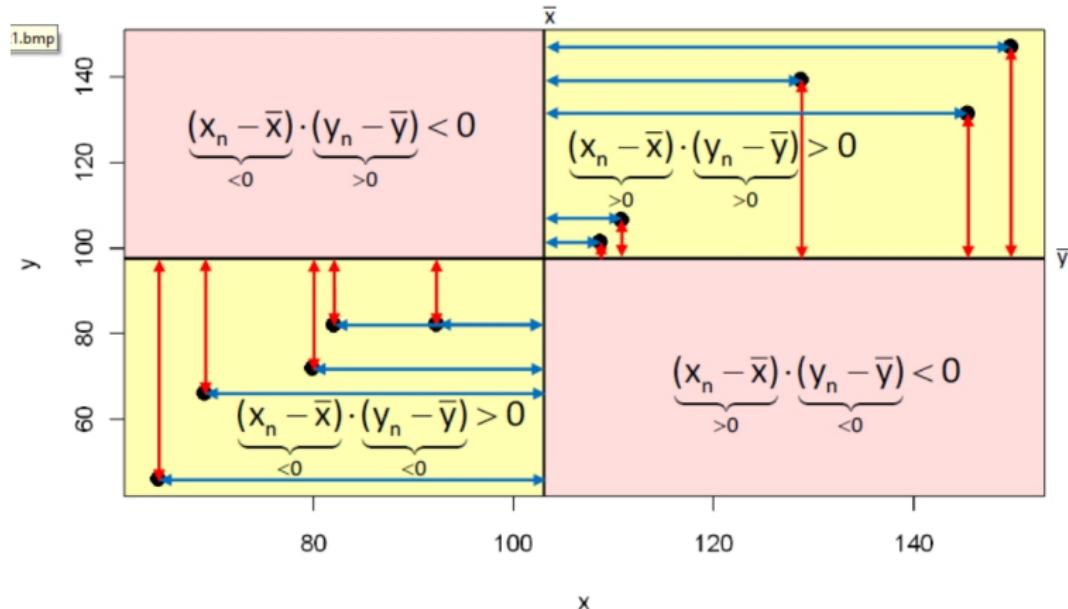
4.2 Bivariate Daten: Zusammenhangsmaße

Quantitative Daten: Kovarianz: $s_{xy} = \frac{1}{N-1} \sum_{n=1}^N (x_n - \bar{x})(y_n - \bar{y})$



4.2 Bivariate Daten: Zusammenhangsmaße

Quantitative Daten: Kovarianz: $s_{xy} = \frac{1}{N-1} \sum_{n=1}^N (x_n - \bar{x})(y_n - \bar{y})$



4.2 Bivariate Daten: Zusammenhangsmaße

Quantitative Daten:

Kovarianz:

$$s_{xy} = \frac{1}{N-1} \sum_{n=1}^N (x_n - \bar{x})(y_n - \bar{y}) = \frac{1}{N-1} \left(\sum_{n=1}^N x_n y_n - N \bar{x} \bar{y} \right) = \frac{N}{N-1} (\bar{xy} - \bar{x} \cdot \bar{y})$$

Beweis analog zu Beweis von $d_x^2 = \bar{x^2} - \bar{x}^2$:

$$\begin{aligned} s_{xy}^2 &= \frac{1}{N-1} \sum_{n=1}^N (x_n - \bar{x})(y_n - \bar{y}) = \frac{1}{N-1} \sum_{n=1}^N (x_n y_n - x_n \bar{y} - \bar{x} y_n + \bar{x} \cdot \bar{y}) \\ &= \frac{1}{N-1} \sum_{n=1}^N x_n y_n - \frac{1}{N-1} \left(\sum_{n=1}^N x_n \right) \bar{y} - \bar{x} \frac{1}{N-1} \left(\sum_{n=1}^N y_n \right) + \frac{N}{N-1} \bar{x} \cdot \bar{y} \\ &= \frac{N}{N-1} \bar{xy} - \frac{N}{N-1} \bar{x} \cdot \bar{y} - \frac{N}{N-1} \bar{x} \cdot \bar{y} + \frac{N}{N-1} \bar{x} \cdot \bar{y} = \boxed{\frac{N}{N-1} (\bar{xy} - \bar{x} \cdot \bar{y})} \quad \square \end{aligned}$$

4.2 Bivariate Daten: Zusammenhangsmaße

Quantitative Daten: Kovarianz: $-s_x s_y \leq s_{xy} \leq s_x s_y$

Beweis: Spezialfall der Cauchy-Schwarz-Ungleichung:

Für $(a_n, b_n) \in \mathbb{R}^2$ gilt:

$$\left(\sum_{n=1}^N a_n b_n \right)^2 \leq \sum_{n=1}^N a_n^2 \cdot \sum_{n=1}^N b_n^2 \implies \left(\sum_{n=1}^N (x_n - \bar{x})(y_n - \bar{y}) \right)^2 \leq \sum_{n=1}^N (x_n - \bar{x})^2 \cdot \sum_{n=1}^N (y_n - \bar{y})^2$$

$$\Leftrightarrow -\sqrt{\sum_{n=1}^N (x_n - \bar{x})^2 \cdot \sum_{n=1}^N (y_n - \bar{y})^2} \leq \left(\sum_{n=1}^N (x_n - \bar{x})(y_n - \bar{y}) \right) \leq \sqrt{\sum_{n=1}^N (x_n - \bar{x})^2 \cdot \sum_{n=1}^N (y_n - \bar{y})^2}$$

$$\Leftrightarrow -\sqrt{\frac{\sum_{n=1}^N (x_n - \bar{x})^2}{N-1}} \sqrt{\frac{\sum_{n=1}^N (y_n - \bar{y})^2}{N-1}} \leq \frac{\left(\sum_{n=1}^N (x_n - \bar{x})(y_n - \bar{y}) \right)}{N-1} \leq \sqrt{\frac{\sum_{n=1}^N (x_n - \bar{x})^2}{N-1}} \sqrt{\frac{\sum_{n=1}^N (y_n - \bar{y})^2}{N-1}}$$

$$\Leftrightarrow -s_x s_y \leq s_{xy} \leq s_x s_y \quad \square$$

4.2 Bivariate Daten: Zusammenhangsmaße

Quantitative Daten: Korrelationskoeffizient nach Bravais-Pearson

$$r_{xy} = \frac{s_{xy}}{s_x s_y} \quad -s_x s_y \leq s_{xy} \leq s_x s_y \implies -1 \leq r_{xy} \leq 1$$

Gleichheitsbedingung bei der Cauchy-Schwarz-Ungleichung:

Für $(a_n, b_n) \in \mathbb{R}^2$ gilt:

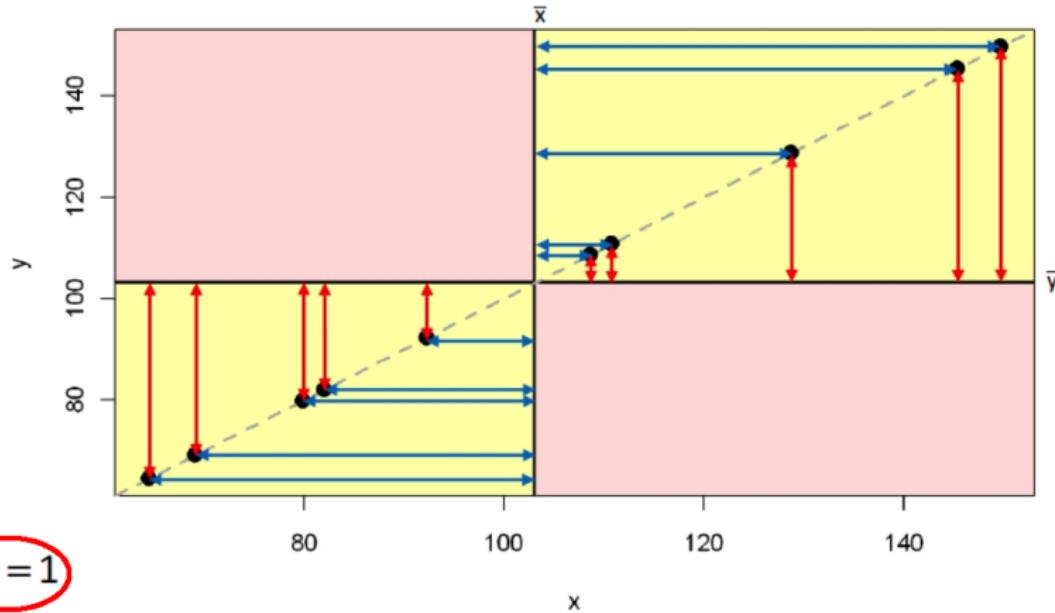
$$\left(\sum_{n=1}^N a_n b_n \right)^2 = \sum_{n=1}^N a_n^2 \cdot \sum_{n=1}^N b_n^2 \Leftrightarrow \text{es gibt eine Konstante } d \text{ mit } b_n = d \cdot a_n \forall n$$

$$\begin{aligned} \implies r_{xy} \in \{-1, 1\} &\Leftrightarrow (y_n - \bar{y}) = d \cdot (x_n - \bar{x}) \\ &\Leftrightarrow y_n = c + d \cdot x_n \quad \text{mit } c = \bar{y} - d \bar{x} \end{aligned}$$

Das heißt, $|r_{xy}|$ ist genau dann 1, wenn alle x_n und y_n auf einer Geraden liegen.

4.2 Bivariate Daten: Zusammenhangsmaße

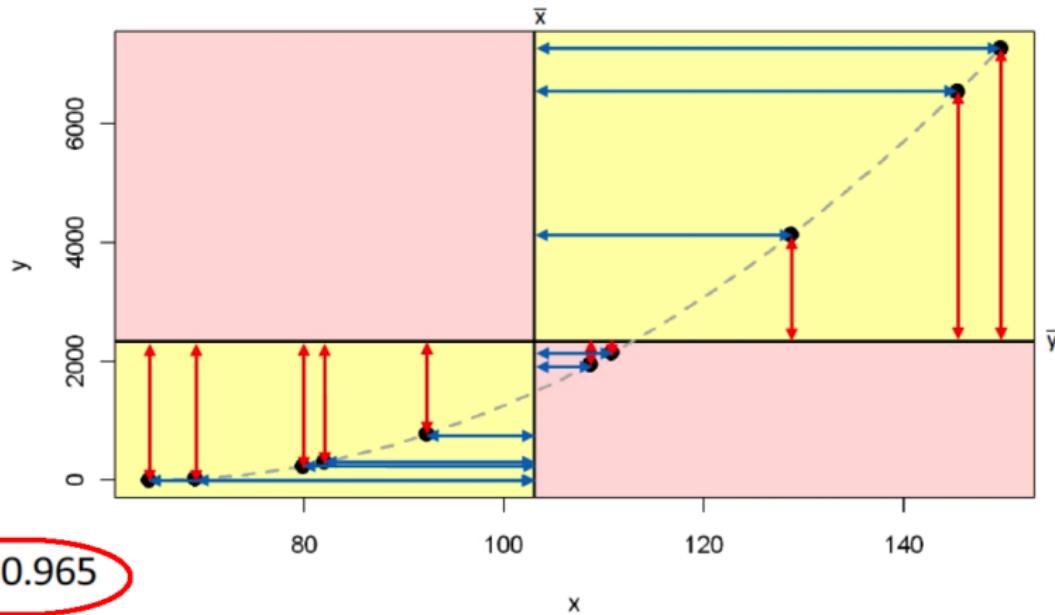
Quantitative Daten: Kovarianz: $s_{xy} = \frac{1}{N-1} \sum_{n=1}^N (x_n - \bar{x})(c + dx_n - c + d\bar{x})$



4.2 Bivariate Daten: Zusammenhangsmaße

Quantitative Daten: Korrelationskoeffizient nach Bravais-Pearson

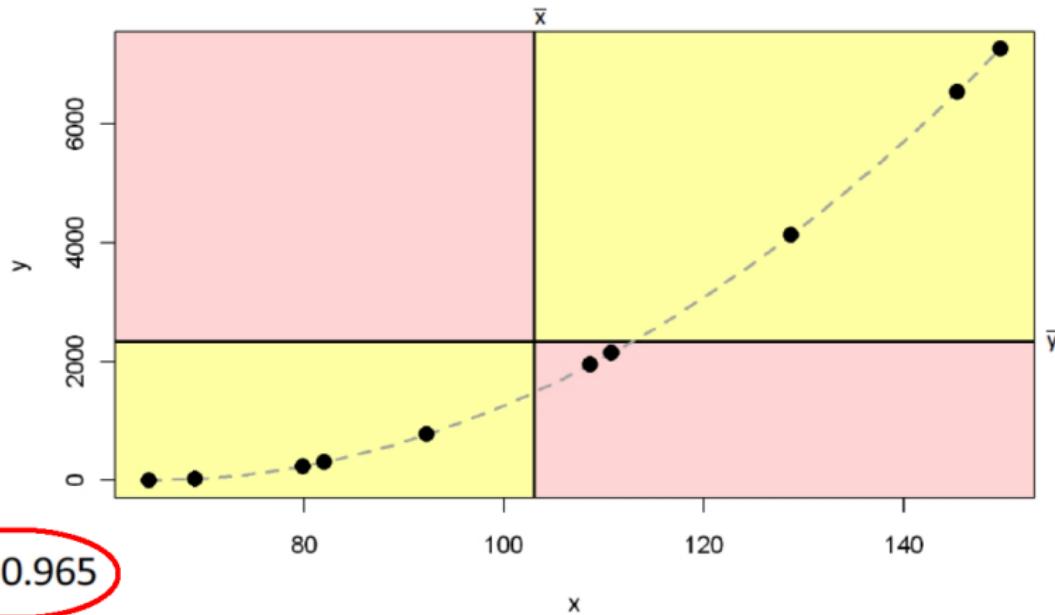
Nicht-linearer monotoner Zusammenhang



4.2 Bivariate Daten: Zusammenhangsmaße

Ordinal/Quantitative Daten: Nicht-linearer monotoner Zusammenhang

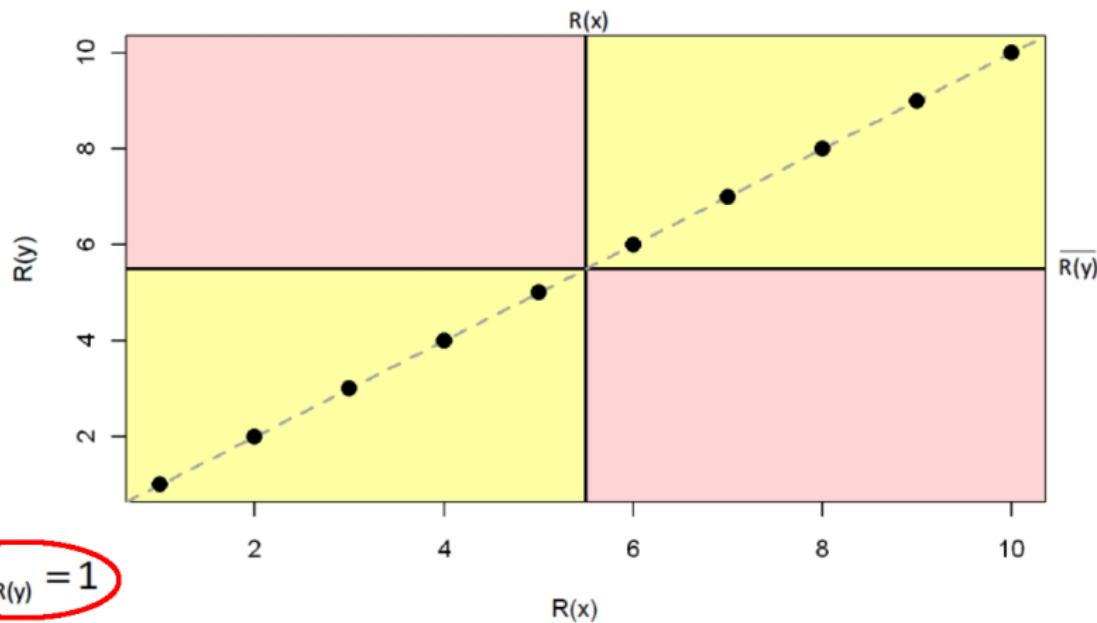
Übergang zu Rängen



4.2 Bivariate Daten: Zusammenhangsmaße

Ordinal/Quantitative Daten: Nicht-linearer monotoner Zusammenhang

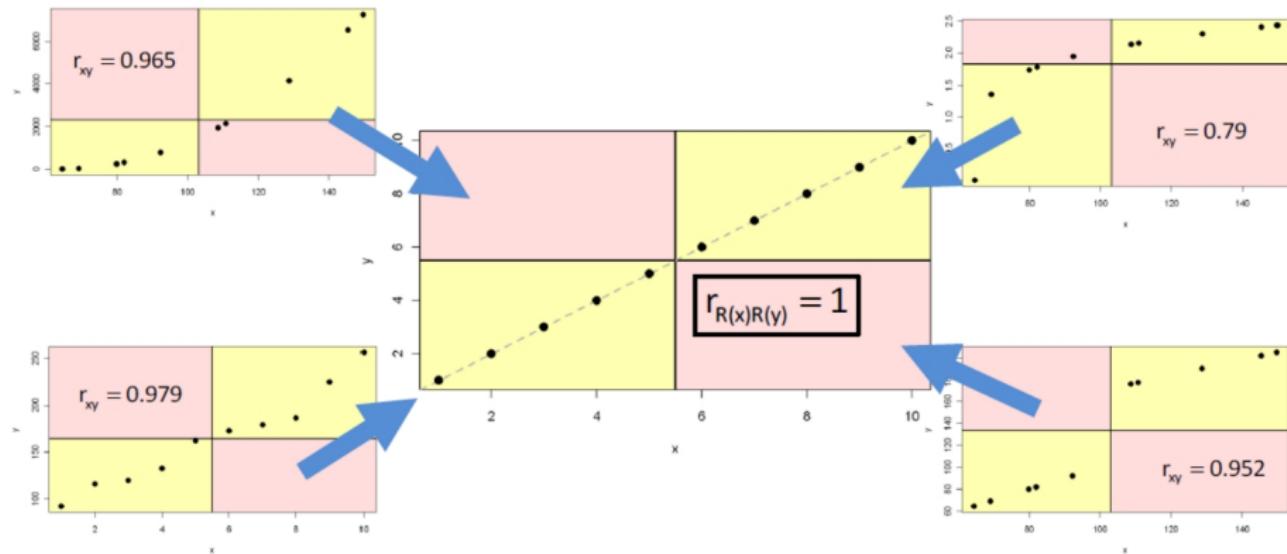
Übergang zu Rängen



4.2 Bivariate Daten: Zusammenhangsmaße

Ordinalale/Quantitative Daten

Absolute Korrelation von Rängen bei monotonem Zusammenhang immer 1



4.2 Bivariate Daten: Zusammenhangsmaße

Ordinale/Quantitative Daten

Falls X und Y mindestens ordinale Skalenniveau haben, so wird der Bravais-Pearson-Korrelationskoeffizient der Ränge $R(X)$ und $R(Y)$ von X und Y der **Spearman'sche Rangkorrelationskoeffizient** r_{xy}^{Sp} von X und Y genannt:

$$r_{xy}^{\text{Sp}} = r_{R(X)R(Y)} = \frac{s_{R(X)R(Y)}}{s_{R(X)}s_{R(Y)}} = \frac{\sum_{n=1}^N (R(x_n) - \overline{R(x)}) (R(y_n) - \overline{R(y)})}{\sqrt{\sum_{n=1}^N (R(x_n) - \overline{R(x)})^2 \sum_{n=1}^N (R(y_n) - \overline{R(y)})^2}}$$

4.2 Bivariate Daten: Zusammenhangsmaße

Ordinale/Quantitative Daten

Spearmanscher Rangkorrelationskoeffizient

Falls keine Bindungen auftreten, d.h. $R(x_j) \neq R(x_k)$ und $R(y_j) \neq R(y_k)$ für alle $j \neq k$, so gilt:

$$r_{xy}^{\text{Sp}} = 1 - \frac{6}{N(N^2 - 1)} \sum_{n=1}^N (R(x_n) - R(y_n))^2$$

Beweisansatz:

$$\sum_{n=1}^N R(x_n) = \sum_{n=1}^N R(y_n) = \sum_{n=1}^N n = \frac{N(N+1)}{2}$$

$$\text{und } \sum_{n=1}^N R(x_n)^2 = \sum_{n=1}^N R(y_n)^2 = \sum_{n=1}^N n^2 = \frac{N(N+1)(2N+1)}{6}$$

4.2 Bivariate Daten: Zusammenhangsmaße

Ordinale/Quantitative Daten: Beispiel Bearbeitungen von Softwareaufgaben

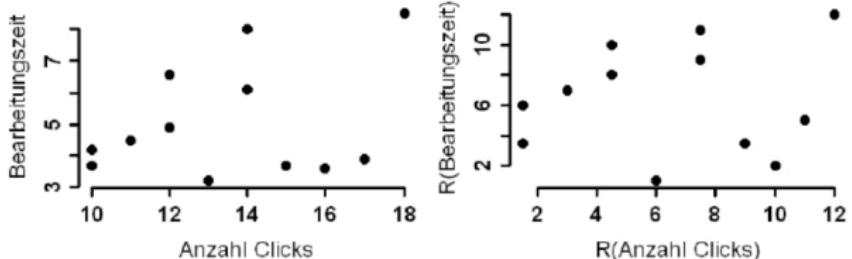
Anzahl Clicks	
Rang	
14	7.5
12	4.5
12	4.5
13	6
17	11
11	3
14	7.5
10	1.5
10	1.5
18	12
16	10
15	9
Bearbeitungszeit	
Rang	
8.0	11
4.9	8
6.6	10
3.2	1
3.9	5
4.5	7
6.1	9
3.7	3.5
4.2	6
8.5	12
3.6	2
3.7	3.5

$$\bar{x}_4 = 13.5$$

$$s_{x_4}^2 = 7$$

$$\bar{x}_5 = 5.075$$

$$s_{x_5}^2 = 3.24$$



$$r_{x_4 x_5} = [(0.5 \cdot 2.925) + (-1.5 \cdot -0.175) + (-1.5 \cdot 1.525) + (-0.5 \cdot -1.875) + (3.5 \cdot -1.175) + (-2.5 \cdot -0.575) + (0.5 \cdot 1.025) + (-3.5 \cdot -1.375) + (-3.5 \cdot -0.875) + (4.5 \cdot 3.425) + (2.5 \cdot -1.475) + (1.5 \cdot -1.375)] / (11 \cdot \sqrt{7 \cdot 3.24}) = 0.301$$

$$r_{x_4 x_5}^{Sp} = [(1 \cdot 4.5) + (-2 \cdot 1.5) + (-2 \cdot 3.5) + (-0.5 \cdot -5.5) + (4.5 \cdot -1.5) + (-3.5 \cdot 0.5) + (1 \cdot 2.5) + (-5 \cdot -3) + (-5 \cdot -0.5) + (5.5 \cdot 5.5) + (3.5 \cdot -4.5) + (2.5 \cdot -3)] / (39.4525) = 0.111$$

4.3 Bivariate Daten: Lineare Regression

Korrelation und Linearität:

Der Korrelationskoeffizient ist auch deshalb so beliebt, weil er ein *Maß für die Linearität eines Zusammenhangs* darstellt.

- Es gilt $r_{xy} = 1$, genau wenn die Punkte (x_i, y_i) auf einer Geraden liegen, und es gilt $r_{xy} = 0$, wenn keine lineare Beziehung besteht.
- Um den Grad der Linearität eines Zusammenhangs quantifizieren zu können, ist es notwendig, sich auf ein Optimalitätskriterium zu einigen, nach dem man eine „optimal an die Punkte angepasste Gerade“ bestimmt.
- Das beliebteste Kriterium ist das Prinzip der Kleinsten Quadrate, nach dem die Gerade so bestimmt wird, dass die Quadratsumme derjenigen Abstände der Punkte von der Geraden minimal werden, die senkrecht zu der x -Achse gemessen werden.

4.3 Bivariate Daten: Lineare Regression

Quantitative Daten: Erinnerung

Allgemein: Zusammenhang (=Korrelation) zwischen Y und X desto größer, je besser sich der Wert von Y unter Kenntnis des Werts von X **vorhersagen** lässt (oder umgekehrt).

Bravais-Pearson-Korrelationskoeffizient misst linearen Zusammenhang.

Wie lässt sich der lineare Zusammenhang zur Vorhersage nutzen?

4.3 Bivariate Daten: Lineare Regression

Quantitative Daten

$$|r_{xy}| = 1 \Leftrightarrow y_n = c + dx_n \text{ für } n=1, \dots, N$$

Für beliebiges (j, k) mit $j \neq k$:

$$y_j = c + dx_j$$

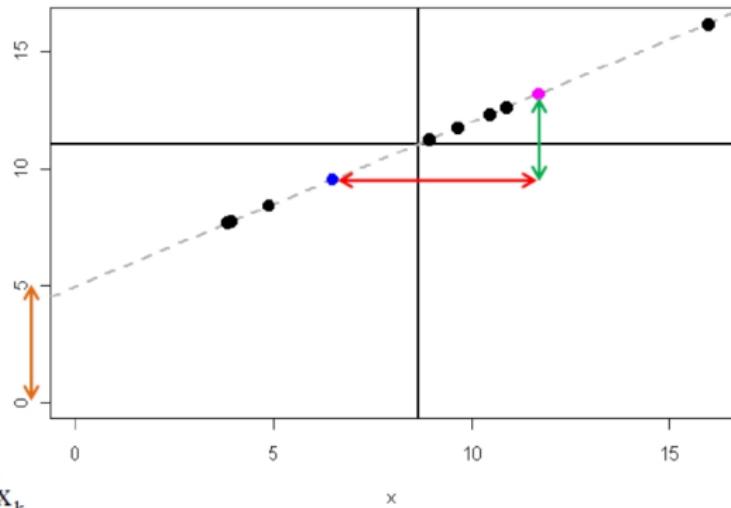
$$y_k = c + dx_k$$

$$\begin{aligned} \Rightarrow y_j - y_k &= (c + dx_j) - (c + dx_k) \\ &= d(x_j - x_k) \end{aligned}$$

$$\Leftrightarrow d = \frac{(y_j - y_k)}{(x_j - x_k)}$$

$$y_k = c + dx_k$$

$$\begin{aligned} \Leftrightarrow c &= y_k - dx_k \\ &= y_k - \frac{(y_j - y_k)}{(x_j - x_k)} x_k \end{aligned}$$



Perfekte Vorhersage durch Einsetzen in die Gleichung.

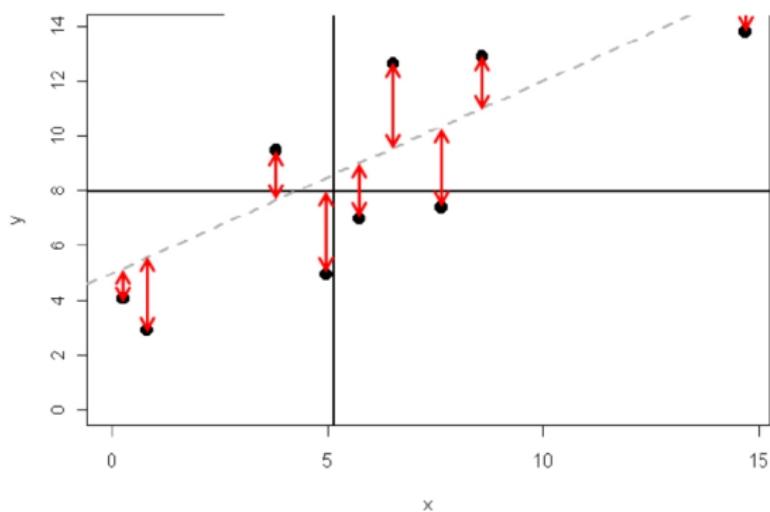
4.3 Bivariate Daten: Lineare Regression

Quantitative Daten

$$0 < |r_{xy}| < 1 \Leftrightarrow y_n = [c + dx_n] + \boxed{\epsilon_n} \text{ für } n=1, \dots, N$$

Vorhersagefehler

$$\boxed{\epsilon_n} = y_n - [c + dx_n]$$



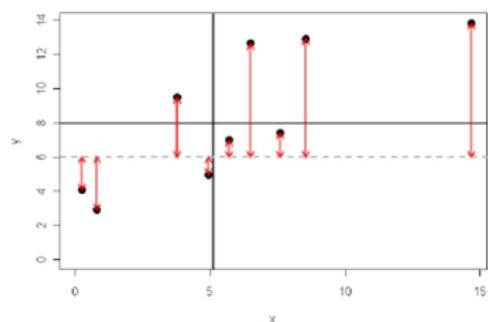
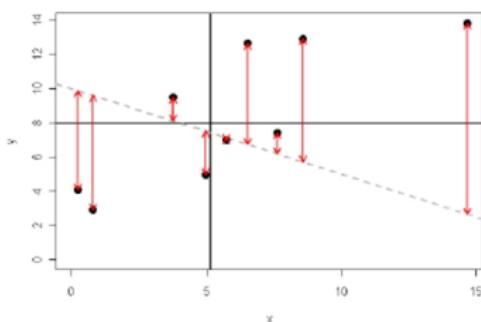
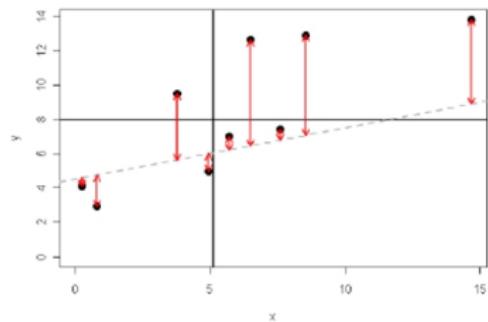
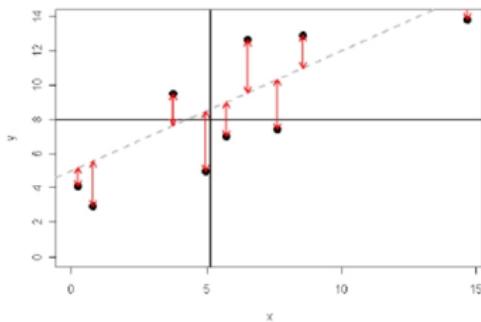
4.3 Bivariate Daten: Lineare Regression

Quantitative Daten: Methode der kleinsten Quadrate

Koeffizienten c und d so bestimmen, dass Fehlerquadratsumme

$$Q(c, d) = \sum_{n=1}^N \varepsilon_n^2$$

minimal wird.



4.3 Bivariate Daten: Lineare Regression

Quantitative Daten: Methode der kleinsten Quadrate

Die Fehlerquadratsumme $Q(c, d) = \sum_{n=1}^N (Y_n - c - dx_n)^2$ ist minimal für

$$d = \frac{s_{xy}}{s_x^2} \quad \text{und} \quad c = \bar{y} - \frac{s_{xy}}{s_x^2} \bar{x}$$

Beweis:

$$\frac{\partial}{\partial c} Q(c, d) = \sum_{n=1}^N 2(c + dx_n - y_n) = 2Nc + 2dN\bar{x} - 2N\bar{y} \stackrel{!}{=} 0 \Leftrightarrow c + d\bar{x} - \bar{y} = 0$$

$$\frac{\partial}{\partial d} Q(c, d) = \sum_{n=1}^N 2(c + dx_n - y_n)x_n = 2Nc\bar{x} + 2d \sum_{n=1}^N x_n^2 - 2 \sum_{n=1}^N x_n y_n \stackrel{!}{=} 0$$

$$\Leftrightarrow cN\bar{x} + d \sum_{n=1}^N x_n^2 - \sum_{n=1}^N x_n y_n = 0$$

4.3 Bivariate Daten: Lineare Regression

Beweis (Fortsetzung)

$$(1) c + d\bar{x} - \bar{y} = 0 \Leftrightarrow c = \bar{y} - d\bar{x} \quad (2) cN\bar{x} + d \sum_{n=1}^N x_n^2 - \sum_{n=1}^N x_n y_n = 0$$

$$(1) \text{ in } (2) (\bar{y} - d\bar{x})N\bar{x} + d \sum_{n=1}^N x_n^2 - \sum_{n=1}^N x_n y_n = 0$$

$$\Leftrightarrow d \left(\sum_{n=1}^N x_n^2 - N\bar{x}^2 \right) = \sum_{n=1}^N x_n y_n - N\bar{x} \cdot \bar{y}$$

$$\Leftrightarrow d = \frac{\sum_{n=1}^N x_n y_n - N\bar{x} \cdot \bar{y}}{\left(\sum_{n=1}^N x_n^2 - N\bar{x}^2 \right)} = \frac{\frac{N}{N-1}(\bar{xy} - \bar{x} \cdot \bar{y})}{\frac{N}{N-1} \left(\frac{1}{N} \sum_{n=1}^N x_n^2 - \bar{x}^2 \right)} = \frac{s_{xy}}{s_x^2} \quad (3)$$

$$(3) \text{ in } (1) c = \bar{y} - \frac{s_{xy}}{s_x^2} \bar{x}$$

4.3 Bivariate Daten: Lineare Regression

Quantitative Daten: Methode der kleinsten Quadrate

Beweis (Fortsetzung)

$$\frac{\partial}{\partial c} Q(c, d) = 2Nc + 2dN\bar{x} - 2N\bar{y}, \quad \frac{\partial}{\partial d} Q(c, d) = 2Nc\bar{x} + 2d \sum_{n=1}^N x_n^2 - 2 \sum_{n=1}^N x_n y_n$$

$$\frac{\partial^2}{\partial c \partial c} Q(c, d) = 2N, \quad \frac{\partial^2}{\partial c \partial d} Q(c, d) = 2 \sum_{n=1}^N x_n, \quad \frac{\partial^2}{\partial d \partial d} Q(c, d) = 2 \sum_{n=1}^N x_n^2$$

$$\det \begin{bmatrix} 2N & 2 \sum_{n=1}^N x_n \\ 2 \sum_{n=1}^N x_n & 2 \sum_{n=1}^N x_n^2 \end{bmatrix} = 4N \sum_{n=1}^N x_n^2 - 4 \left(\sum_{n=1}^N x_n \right)^2 = 4(N-1)Ns_x^2 > 0 \quad \square$$

4.3 Bivariate Daten: Lineare Regression

Quantitative Daten: Methode der kleinsten Quadrate

Je größer die absolute Korrelation, desto kleiner die Fehlerquadratsumme

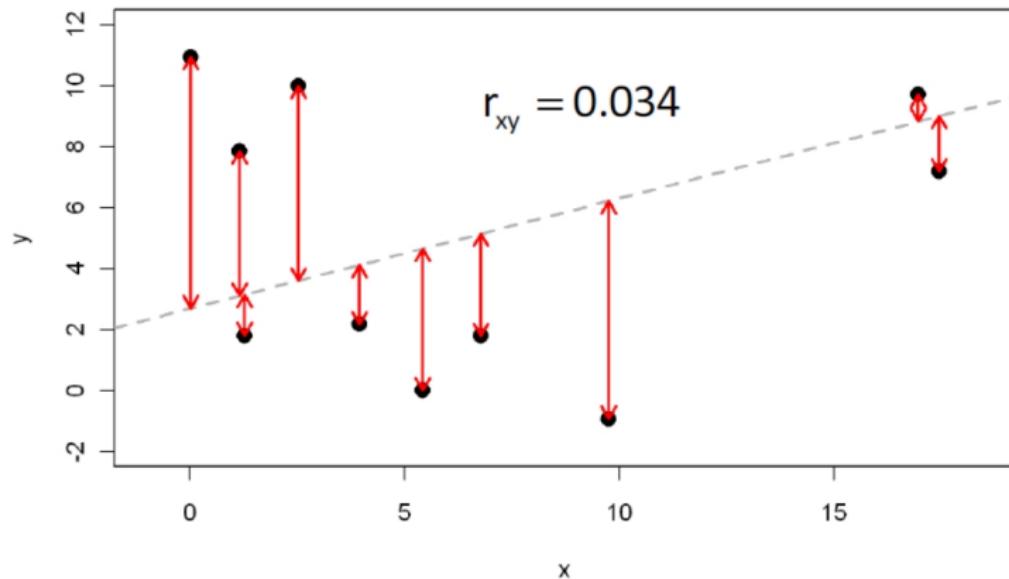
$$d = \frac{s_{xy}}{s_x^2} \text{ und } c = \bar{y} - \frac{s_{xy}}{s_x^2} \bar{x}$$

$$\begin{aligned} \sum_{n=1}^N \varepsilon_n^2 &= \sum_{n=1}^N \left(y_n - \left(\bar{y} - \frac{s_{xy}}{s_x^2} \bar{x} \right) - \frac{s_{xy}}{s_x^2} x_n \right)^2 = \sum_{n=1}^N \left(y_n - \left(\bar{y} - r_{xy} \frac{s_y}{s_x} \bar{x} \right) - r_{xy} \frac{s_y}{s_x} x_n \right)^2 \\ &= \sum_{n=1}^N \left((y_n - \bar{y}) - r_{xy} \frac{s_y}{s_x} (x_n - \bar{x}) \right)^2 \\ &= \sum_{n=1}^N \left((y_n - \bar{y})^2 - 2r_{xy} \frac{s_y}{s_x} (y_n - \bar{y})(x_n - \bar{x}) + \left(r_{xy} \frac{s_y}{s_x} \right)^2 (x_n - \bar{x})^2 \right) \\ &= (N-1) \cdot \left(s_y^2 - 2r_{xy} \frac{s_y}{s_x} s_{xy} + \left(r_{xy} \frac{s_y}{s_x} \right)^2 s_x^2 \right) = (N-1) \cdot (s_y^2 - 2r_{xy}^2 s_y^2 + r_{xy}^2 s_y^2) \\ &= (N-1) \cdot (s_y^2 - r_{xy}^2 s_y^2) \quad \square \end{aligned}$$

4.3 Bivariate Daten: Lineare Regression

Quantitative Daten: **Methode der kleinsten Quadrate**

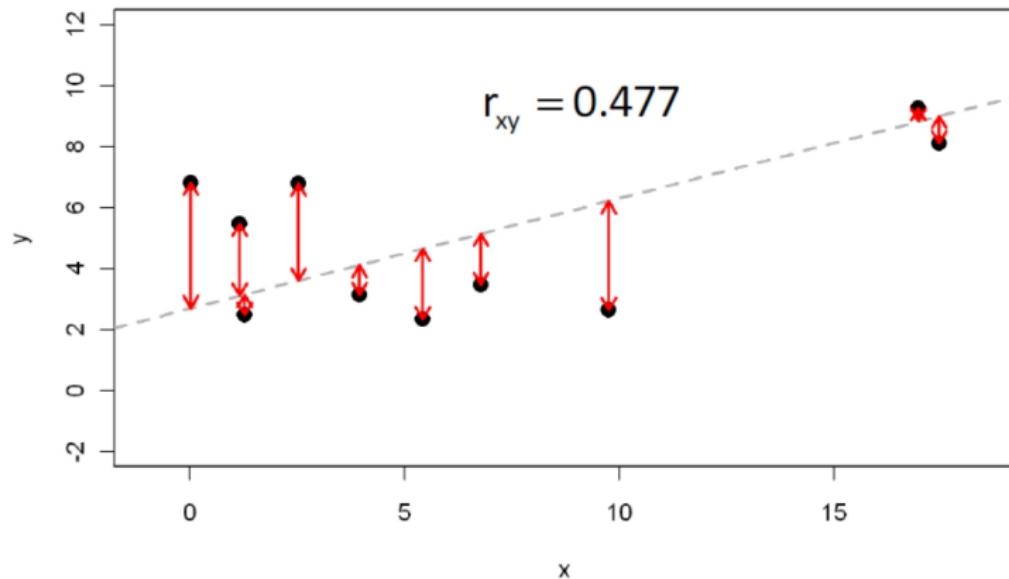
Je größer die absolute Korrelation, desto kleiner die Fehlerquadratsumme



4.3 Bivariate Daten: Lineare Regression

Quantitative Daten: **Methode der kleinsten Quadrate**

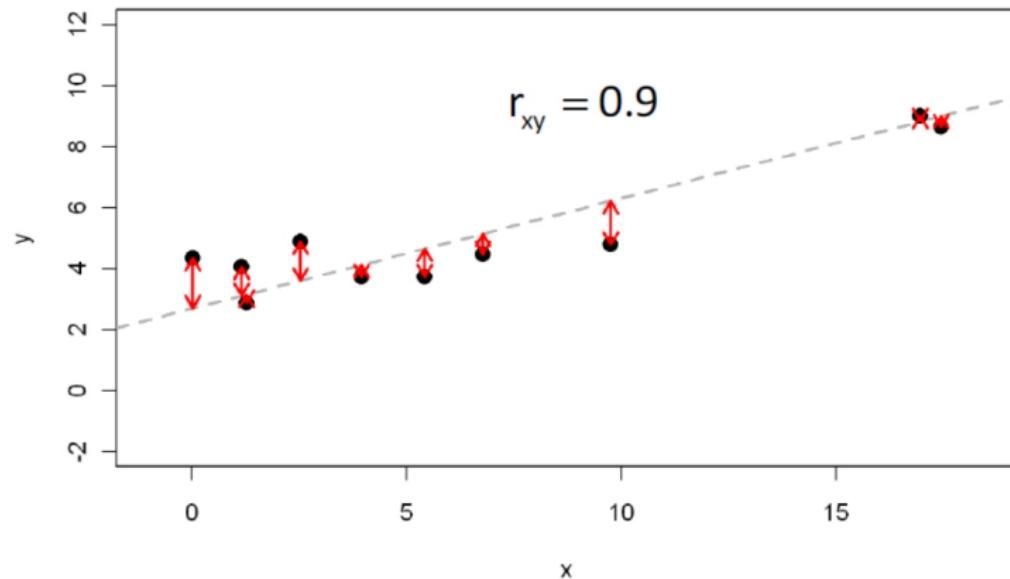
Je größer die absolute Korrelation, desto kleiner die Fehlerquadratsumme



4.3 Bivariate Daten: Lineare Regression

Quantitative Daten: **Methode der kleinsten Quadrate**

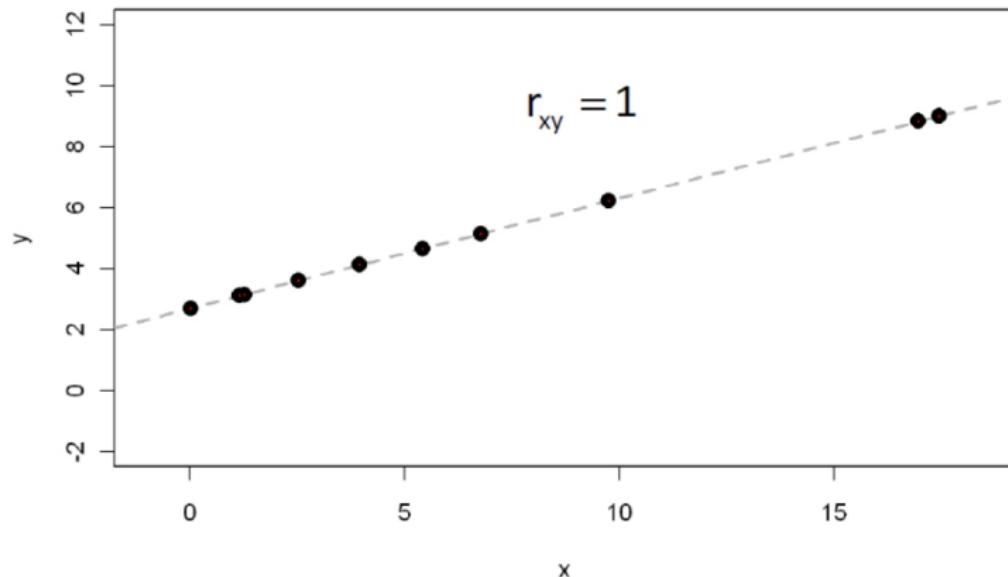
Je größer die absolute Korrelation, desto kleiner die Fehlerquadratsumme



4.3 Bivariate Daten: Lineare Regression

Quantitative Daten: **Methode der kleinsten Quadrate**

Je größer die absolute Korrelation, desto kleiner die Fehlerquadratsumme



4.3 Bivariate Daten: Lineare Regression

Quantitative Daten: Beispiel Bearbeitungen von Softwareaufgaben

Anzahl Clicks	Bearbeitungszeit	$c+dx_4$	ϵ
14	8.0	5.177	2.823
12	4.9	4.768	0.132
12	6.6	4.768	1.832
13	3.2	4.973	-1.773
17	3.9	5.791	-1.891
11	4.5	4.564	-0.064
14	6.1	5.177	0.922
10	3.7	4.359	-0.659
10	4.2	4.359	-0.159
18	8.5	5.995	2.505
16	3.6	5.586	-1.986
15	3.7	5.382	-1.682

$$\bar{x}_4 = 13.5$$

$$S_{x_4}^2 = 7$$

$$\bar{x}_5 = 5.075$$

$$S_{x_5}^2 = 3.24$$

$$r_{x_4x_5} = 0.301$$

$$x_5 = c + dx_4 + \epsilon$$

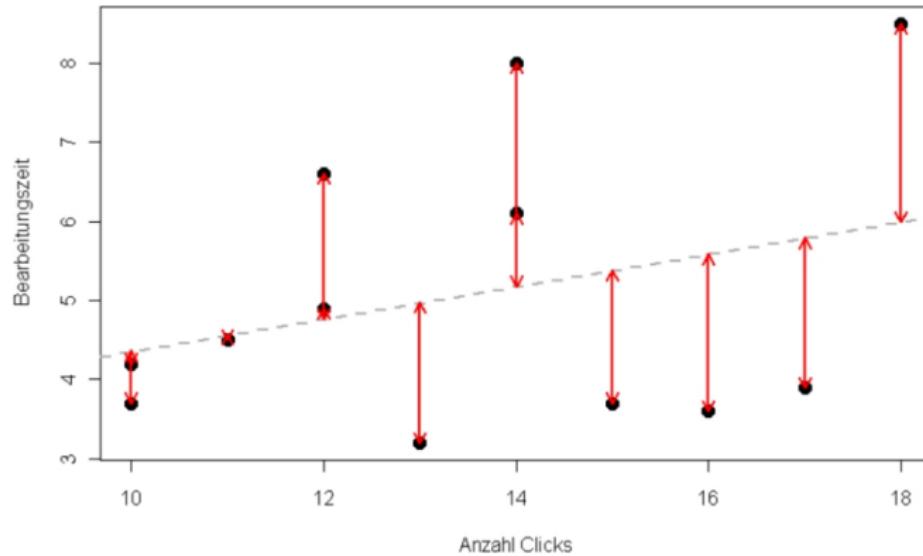
$$\begin{aligned}
 c &= \bar{x}_5 - r_{x_4x_5} \frac{s_{x_5}}{s_{x_4}} \bar{x}_4 \\
 &= 5.075 - 0.301 \sqrt{\frac{3.24}{7}} 13.5 \\
 &= 2.314
 \end{aligned}$$

$$\begin{aligned}
 d &= r_{x_4x_5} \frac{s_{x_5}}{s_{x_4}} = 0.301 \sqrt{\frac{3.24}{7}} \\
 &= 0.205
 \end{aligned}$$

4.3 Bivariate Daten: Lineare Regression

Quantitative Daten: Beispiel **Bearbeitungen von Softwareaufgaben**

$$x_5 = 2.314 + 0.205x_4 + \varepsilon$$



4.3 Bivariate Daten: Lineare Regression

Zusammenfassung

Skalenniveau → ↓Zusammenhangsmaß	Nominal	Ordinal	Quantitativ
χ^2 -Größe/ Kontingenzkoeffizient nach Pearson		 – Informationsverlust	 – Nur für klassierte Daten
Rangkorrelationskoeffizient nach Spearman	 – Nur für J = 2		 + Robust + Allg. Zusammenhang – Informationsverlust
Korrelationskoeff. nach Bravais-Pearson/lin. Regr.	 – Nur für J = 2		 – Ausreißeranfälligkeit – Lin. Zusammenhang + Informationsnutzung

Wahrscheinlichkeitstheorie

5.0 Wahrscheinlichkeitstheorie

Wahrscheinlichkeitstheorie

- Teilgebiet der Mathematik, dass sich mit Wahrscheinlichkeiten und der Analyse zufälliger Prozesse beschäftigt
- Mathematische Abstraktion von nicht-deterministischen Ereignissen

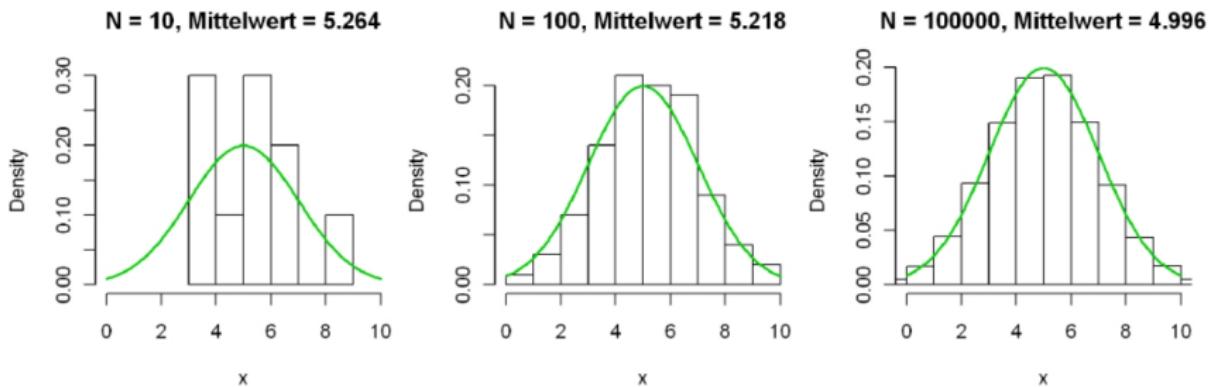
Unterscheidung von Empirie und Theorie

- Bisher: reine Beschreibung von Lage, Streuung und Zusammenhang von Daten ohne Berücksichtigung ihrer Entstehung
- Jetzt: Interpretation der Daten als Realisationen von Zufallsvariablen und Beschreibung von deren Wahrscheinlichkeitsverteilungen
- Auf Basis dieser Wahrscheinlichkeitsverteilungen lassen sich dann Aussagen über nicht betrachtete oder zukünftige Daten machen

5.0 Beschreibung des Zufalls

Vergleich unterschiedlich großer Stichproben aus der gleichen Wahrscheinlichkeitsverteilung

Beispiel Normalverteilung: Gesetz der großen Zahlen



5.1 Mengentheoretische Grundlagen

Elementare Begriffe

Zufallsexperiment Datenerhebungsprozess mit nicht vorhersagbarem Ausgang

Ergebnis ω Elementarer Ausgang eines Zufallsexperiments

Grundraum Ω Menge aller möglichen Ergebnisse
 $\Omega = \{\omega | \omega \text{ ist Ergebnis des Zufallsexperiments}\}$

Ereignis A Menge von Ergebnissen, d.h. Teilmenge von Ω

Elementarereignis Einelementiges Ereignis

5.1 Mengentheoretische Grundlagen

Beispiel

Zufallsexperiment Einfacher Würfelwurf

Ergebnisse $\omega_1 = 1, \omega_2 = 2, \omega_3 = 3, \omega_4 = 4, \omega_5 = 5, \omega_6 = 6$

Grundraum $\Omega = \{1, 2, 3, 4, 5, 6\}$

Ereignisse $A = \{2, 4, 6\}, B = \{1, 3, 5\}, C = \{1, 2, 3, 4, 5\},$
 $D = \{3, 4, 5, 6\}, E = \{2, 3, 5\}, F = \{1, 2, 3, 4, 5, 6\} = \Omega$

Elementarereignisse $\{1\}, \{2\}, \{3\}, \{4\}, \{5\}, \{6\}$

5.1 Mengentheoretische Grundlagen

Beispiele

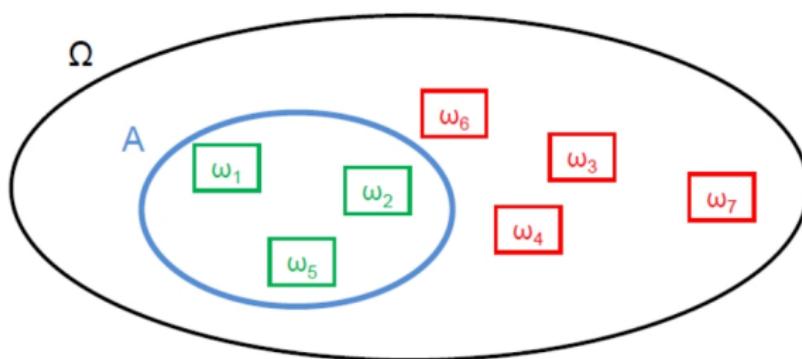
Experiment	Grundraum Ω	Ergebnis ω
Roulette	$\{0, 1, \dots, 36\}$	Zahlenfeld der Kugel
Würfeln: Warten auf 6	$\mathbb{N} \cup \{\infty\}$	Anzahl Würfe bis zur ersten 6
6 aus 49	$\{(\omega_1, \dots, \omega_6) \mid 1 \leq \omega_1 < \dots < \omega_6 \leq 49\}$	Geordnete Nummern der gezogenen Kugeln
Einzelne Serveranfrage	$[t_{\min}, t_{\max}]$	Anfragezeitpunkt t
Mausaktivität	$\{\omega : [t_{\min}, t_{\max}] \rightarrow (1, \dots, 600) \times (1, \dots, 800) \times \{0, 1, 2\}\}$	Koordinaten und Clickzustand (nicht, links, rechts) des Mauszeigers zu jeder Zeit
Wartezeit bis zur nächsten Serveranfrage	$[0, \infty)$	Zeit zwischen zwei Anfragen

5.1 Mengentheoretische Grundlagen

Bezeichnungen

$$\omega \in A$$

Ergebnis ω ist im Ereignis A enthalten

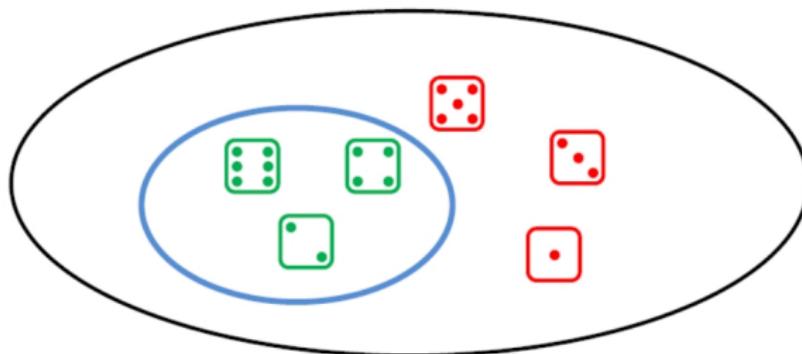


5.1 Mengentheoretische Grundlagen

Bezeichnungen: Beispiel Würfelwurf

$$2 \in \{2, 4, 6\}$$

Augenzahl 2 ist gerade Zahl



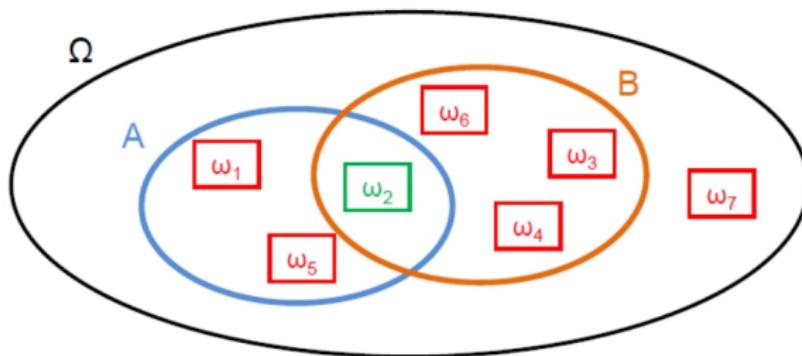
5.1 Mengentheoretische Grundlagen

Bezeichnungen

Schnittereignis zweier Mengen

$$A \cap B = \{\omega \in \Omega \mid \omega \in A \text{ und } \omega \in B\}$$

Ergebnis ω ist in Ereignis A **und** Ereignis B enthalten



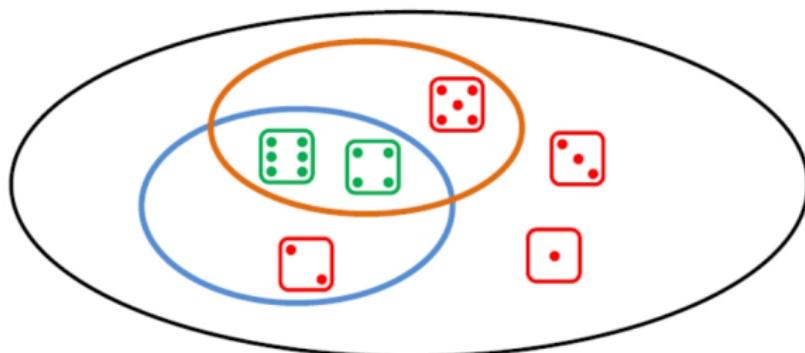
5.1 Mengentheoretische Grundlagen

Bezeichnungen: Beispiel Würfelwurf

Schnittereignis zweier Mengen

$$4 \in \{2, 4, 6\} \cap \{4, 5, 6\}$$

Augenzahl 4 ist gerade Zahl und größer als 3



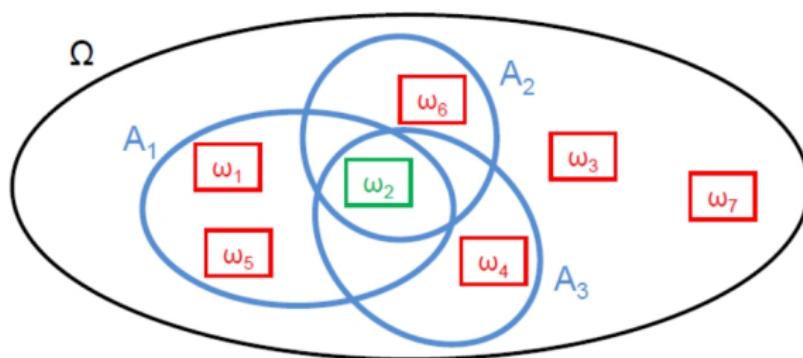
5.1 Mengentheoretische Grundlagen

Bezeichnungen

Schnittereignis beliebig vieler Mengen

$$\bigcap_{i \in I} A_i = \{\omega \in \Omega \mid \omega \in A_i \text{ für } i \in I\}$$

Ergebnis ω ist in allen Ereignissen A_i enthalten



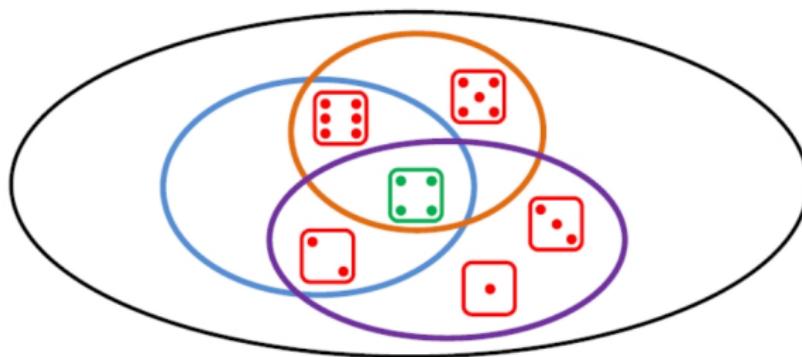
5.1 Mengentheoretische Grundlagen

Bezeichnungen: Beispiel Würfelwurf

Schnittereignis beliebig vieler Mengen

$$4 \in \{2, 4, 6\} \cap \{4, 5, 6\} \cap \{1, 2, 3, 4\}$$

Augenzahl 4 ist **gerade Zahl** und **größer als 3** und **kleiner als 5**



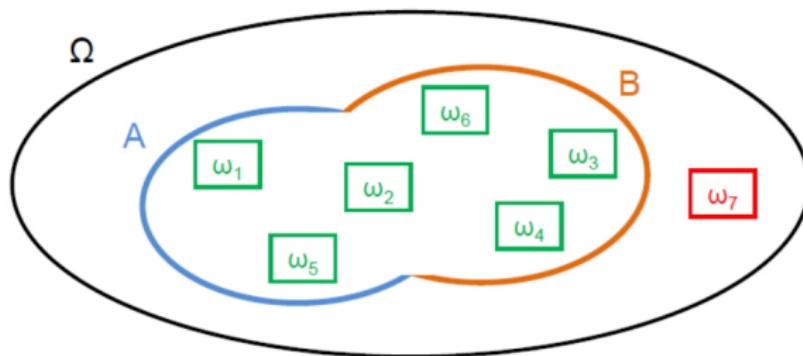
5.1 Mengentheoretische Grundlagen

Bezeichnungen

Vereinigungseignis zweier Mengen

$$A \cup B = \{\omega \in \Omega | \omega \in A \text{ und/oder } \omega \in B\}$$

Ergebnis **ω** ist in Ereignis **A** **und/oder** Ereignis **B** enthalten



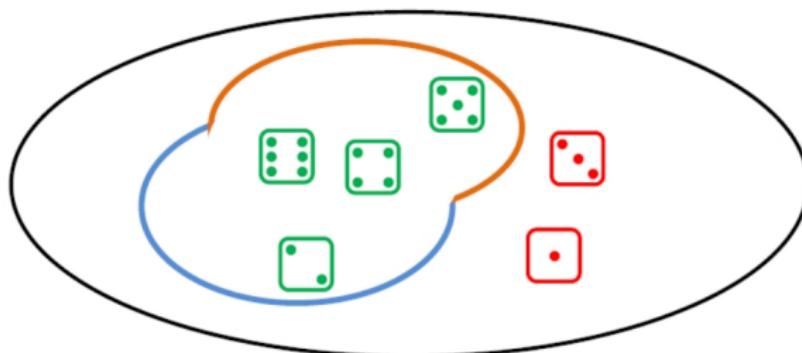
5.1 Mengentheoretische Grundlagen

Bezeichnungen: Beispiel Würfelwurf

Vereinigungssereignis zweier Mengen

$$2 \in \{2, 4, 6\} \cup \{4, 5, 6\}$$

Augenzahl 2 ist gerade Zahl



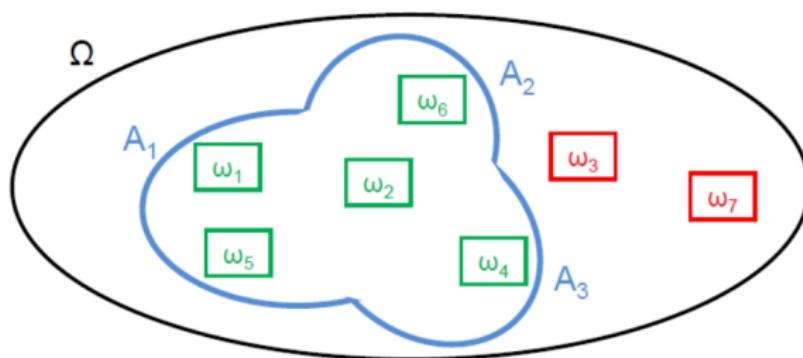
5.1 Mengentheoretische Grundlagen

Bezeichnungen

Vereinigungseignis beliebig vieler Mengen

$$\bigcup_{i \in I} = \{\omega \in \Omega \mid \omega \in A_i \text{ für mindestens ein } i \in I\}$$

Ergebnis ω ist in mindestens einem A_i enthalten



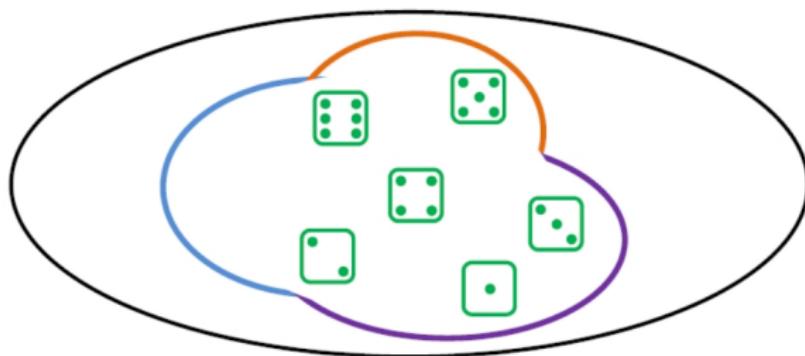
5.1 Mengentheoretische Grundlagen

Bezeichnungen: Beispiel Würfelwurf

Vereinigungseignis beliebig vieler Mengen

$$5 \in \{2, 4, 6\} \cup \{4, 5, 6\} \cup \{1, 2, 3, 4\}$$

Augenzahl 5 ist größer als 3



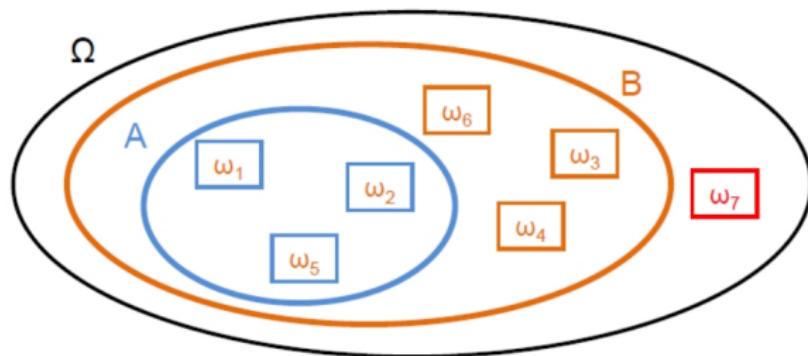
5.1 Mengentheoretische Grundlagen

Bezeichnungen

Teilereignis

$$A \subset B \text{ (bzw. } A \subseteq B)$$

Ereignis A ist in Ereignis B enthalten, aus Ereignis A folgt Ereignis B



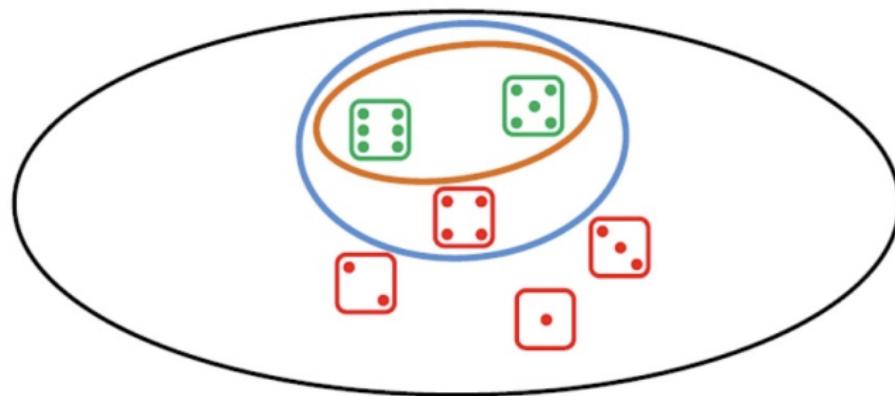
5.1 Mengentheoretische Grundlagen

Bezeichnungen: Beispiel Würfelwurf

Teilereignis

$$\{5, 6\} \subset \{4, 5, 6\}$$

Augenzahl 5 ist größer als 4 und damit auch größer als 3.



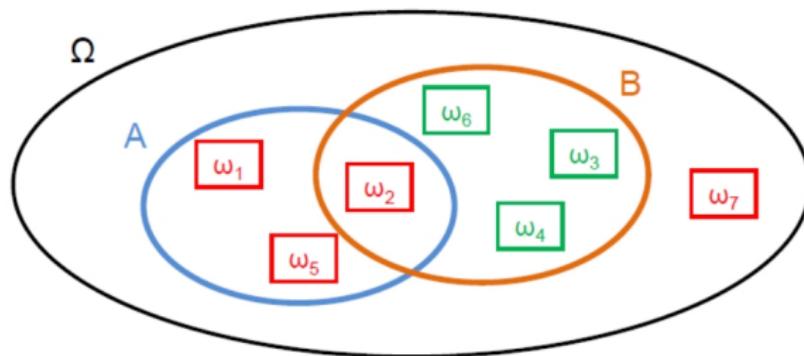
5.1 Mengentheoretische Grundlagen

Bezeichnungen

Differenzereignis

$$B \setminus A = \{\omega \in \Omega \mid \omega \in B \text{ und } \omega \notin A\}$$

Ergebnis ω ist in Ereignis B , aber nicht in Ereignis A enthalten



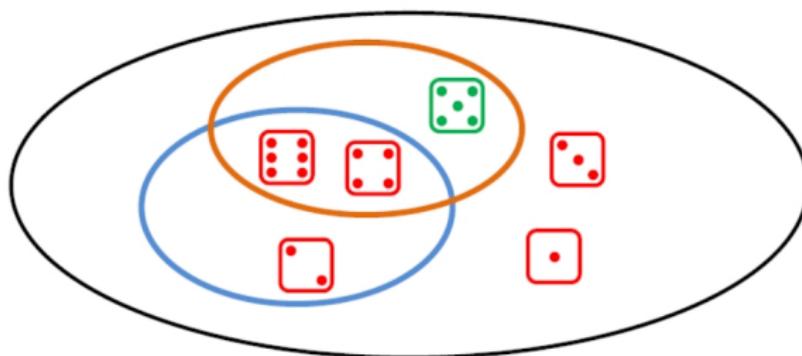
5.1 Mengentheoretische Grundlagen

Bezeichnungen: Beispiel Würfelwurf

Differenzereignis

$$5 \in \{4, 5, 6\} \setminus \{2, 4, 6\}$$

Augenzahl 5 ist größer als 3, aber nicht gerade Zahl



5.1 Mengentheoretische Grundlagen

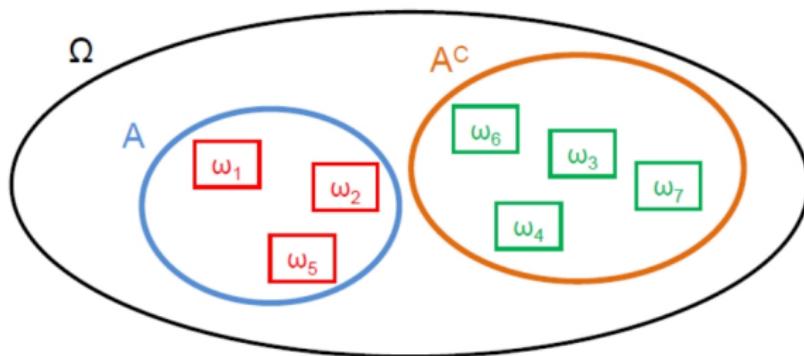
Bezeichnungen

Komplementärereignis

$$A^c = \Omega \setminus A = \{\omega \in \Omega | \omega \notin A\}$$

Ergebnis ω ist in Ereignis A^c enthalten \Leftrightarrow Ergebnis ω ist nicht in Ereignis A enthalten

Das Ereignis A^c heißt **Komplement** bzw. **Gegenereignis** von bzw. zu A



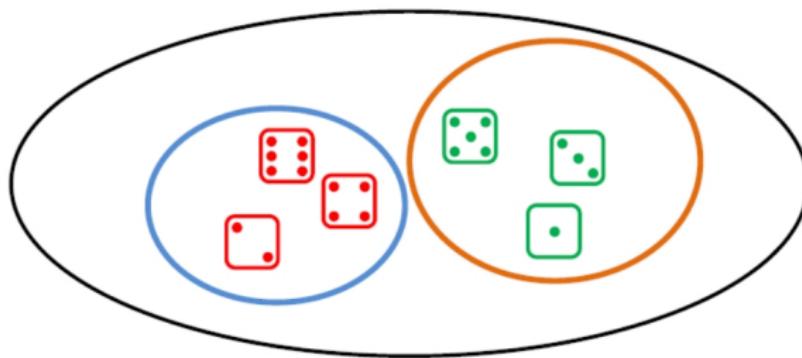
5.1 Mengentheoretische Grundlagen

Bezeichnungen: Beispiel Würfelwurf

Komplementärereignis

$$5 \in \{2, 4, 6\}^c$$

Augenzahl 5 ist nicht gerade Zahl



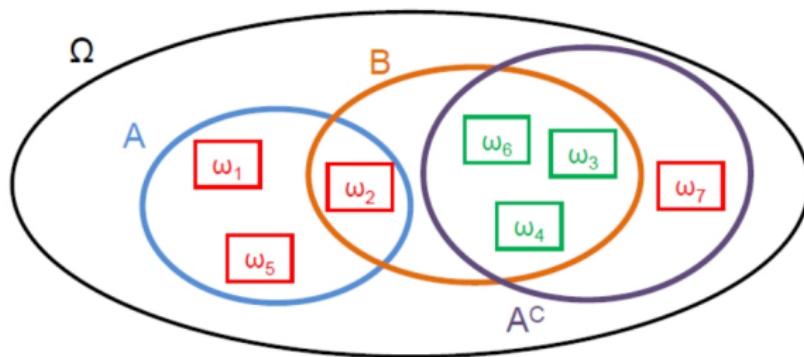
5.1 Mengentheoretische Grundlagen

Regeln

Differenzereignis und Komplementärereignis

$$B \setminus A = \{\omega \in \Omega \mid \omega \in B \text{ und } \omega \notin A\} = B \cap A^c = B \setminus (A \cap B)$$

Ergebnis ω ist in Ereignis B , aber nicht in Ereignis A enthalten

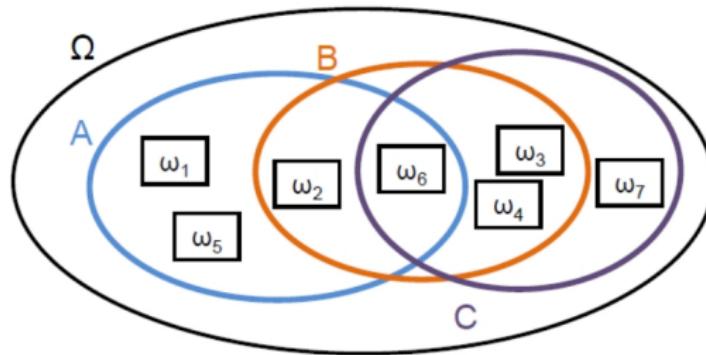


5.1 Mengentheoretische Grundlagen

Regeln

Distributivgesetz

$$(A \cup B) \cap C = (A \cap C) \cup (B \cap C)$$

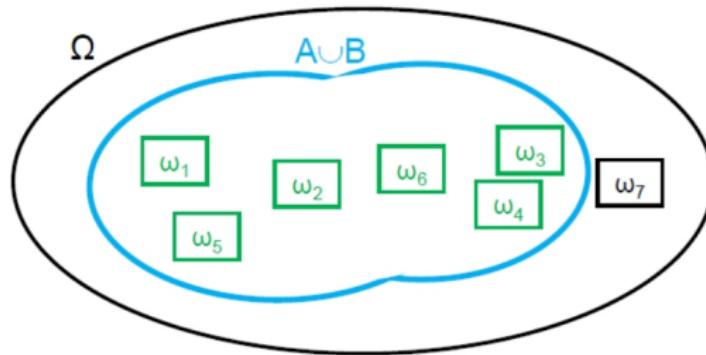


5.1 Mengentheoretische Grundlagen

Regeln

Distributivgesetz

$$(A \cup B) \cap C = (A \cap C) \cup (B \cap C)$$

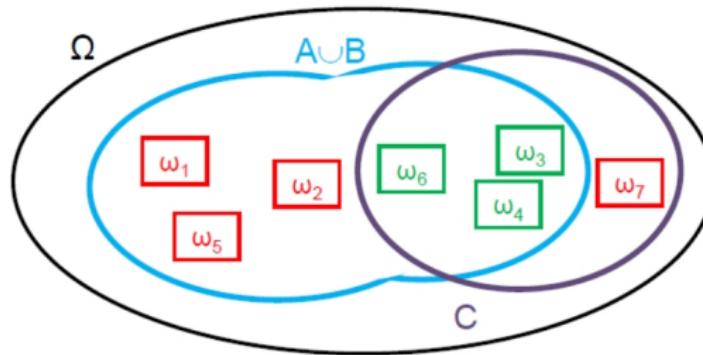


5.1 Mengentheoretische Grundlagen

Regeln

Distributivgesetz

$$(A \cup B) \cap C = (A \cap C) \cup (B \cap C)$$

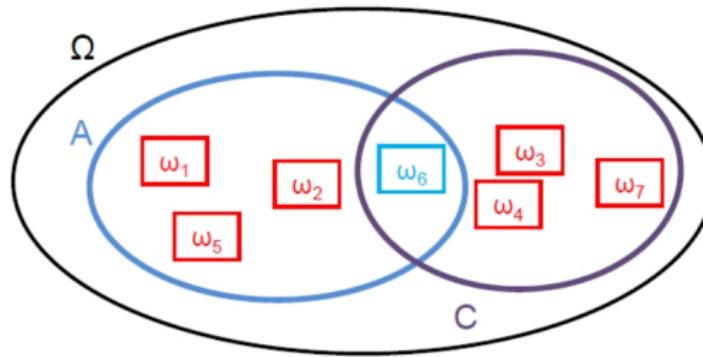


5.1 Mengentheoretische Grundlagen

Regeln

Distributivgesetz

$$(A \cup B) \cap C = (A \cap C) \cup (B \cap C)$$

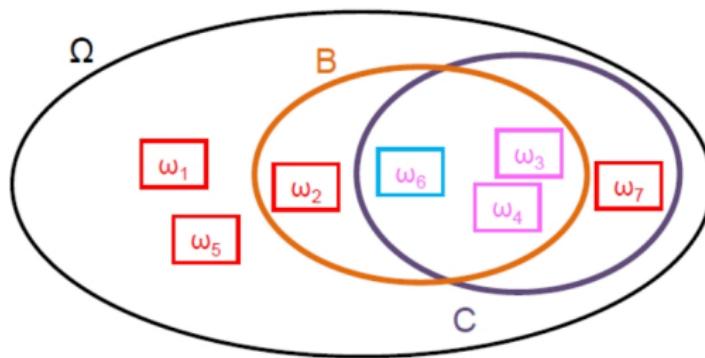


5.1 Mengentheoretische Grundlagen

Regeln

Distributivgesetz

$$(A \cup B) \cap C = (A \cap C) \cup (B \cap C)$$

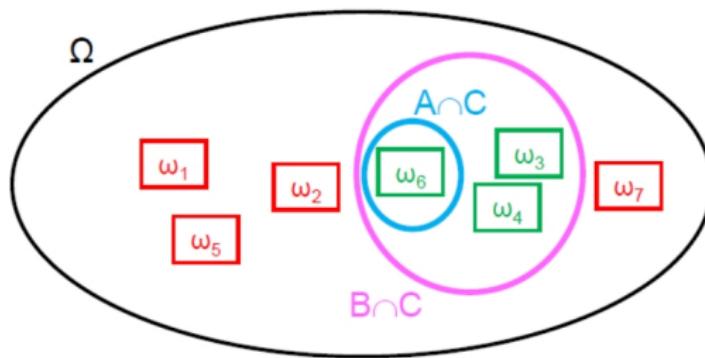


5.1 Mengentheoretische Grundlagen

Regeln

Distributivgesetz

$$(A \cup B) \cap C = (A \cap C) \cup (B \cap C)$$

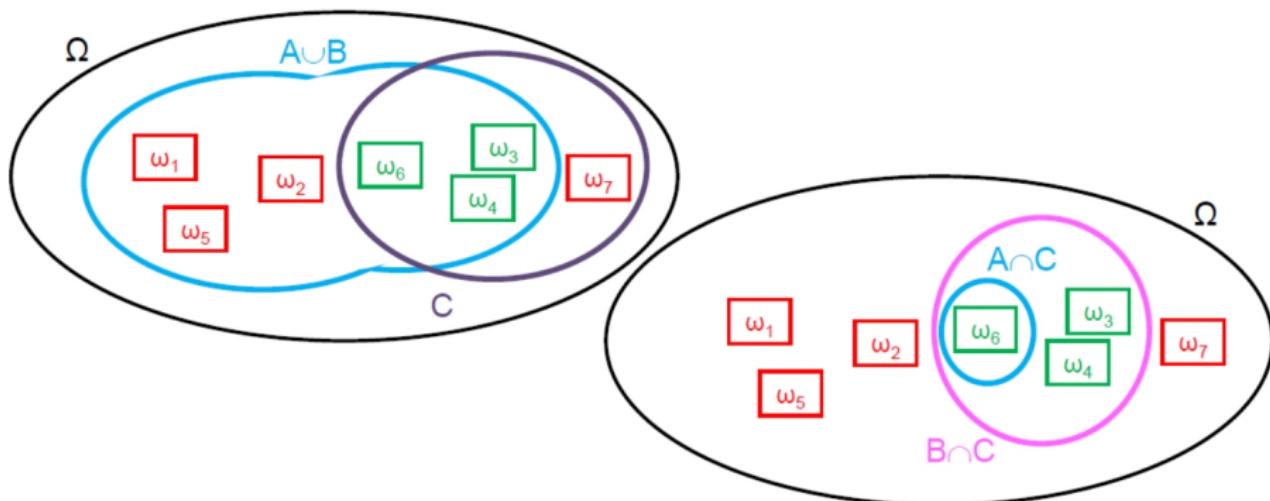


5.1 Mengentheoretische Grundlagen

Regeln

Distributivgesetz

$$(A \cup B) \cap C = (A \cap C) \cup (B \cap C)$$

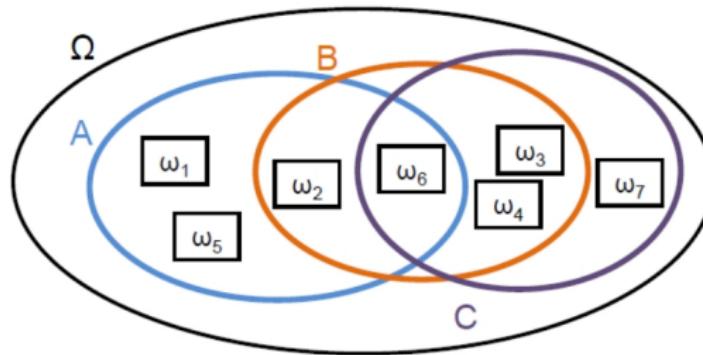


5.1 Mengentheoretische Grundlagen

Regeln

Distributivgesetz

$$(A \cap B) \cup C = (A \cup C) \cap (B \cup C)$$

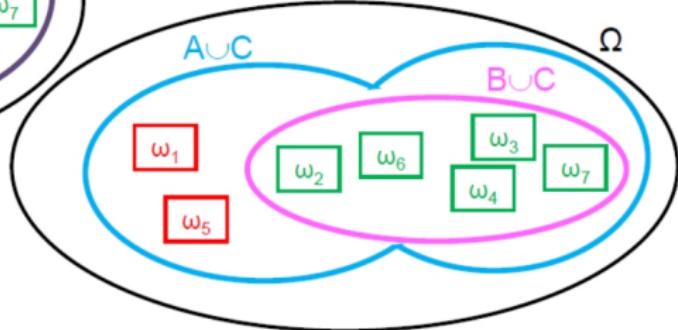
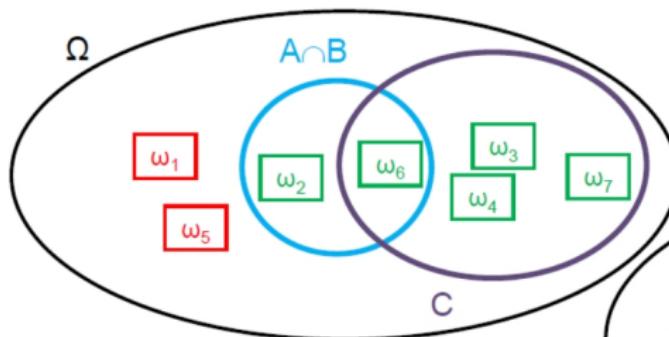


5.1 Mengentheoretische Grundlagen

Regeln

Distributivgesetz

$$(A \cap B) \cup C = (A \cup C) \cap (B \cup C)$$

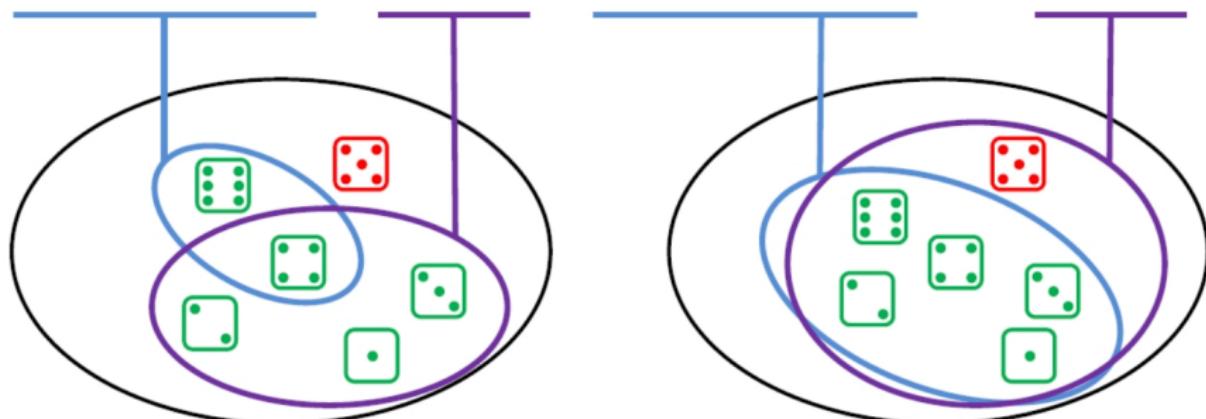


5.1 Mengentheoretische Grundlagen

Regeln: Beispiel Würfelwurf

Distributivgesetz

$$(\{2,4,6\} \cap \{4,5,6\}) \cup \{1,2,3,4\} = (\{2,4,6\} \cup \{1,2,3,4\}) \cap (\{4,5,6\} \cup \{1,2,3,4\})$$

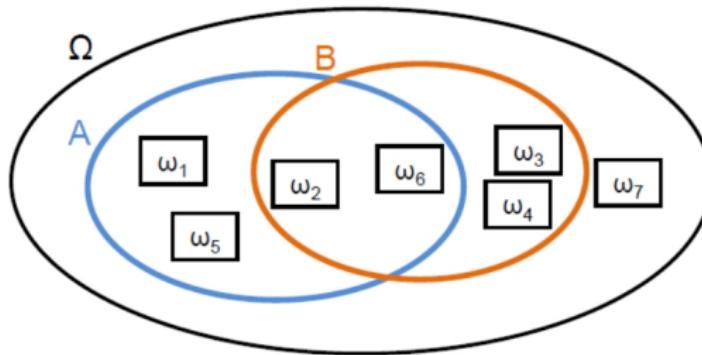


5.1 Mengentheoretische Grundlagen

Regeln

Regeln von de Morgan

$$(A \cap B)^c = A^c \cup B^c, \quad (A \cup B)^c = A^c \cap B^c$$

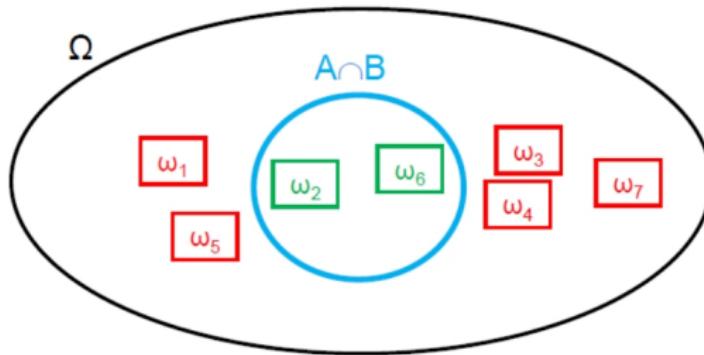


5.1 Mengentheoretische Grundlagen

Regeln

Regeln von de Morgan

$$(A \cap B)^c = A^c \cup B^c$$

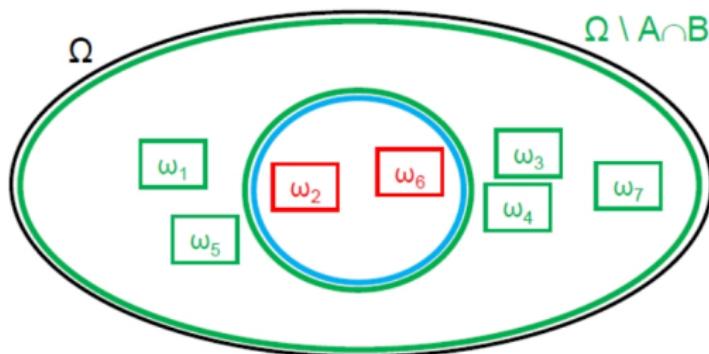


5.1 Mengentheoretische Grundlagen

Regeln

Regeln von de Morgan

$$(A \cap B)^c = A^c \cup B^c$$

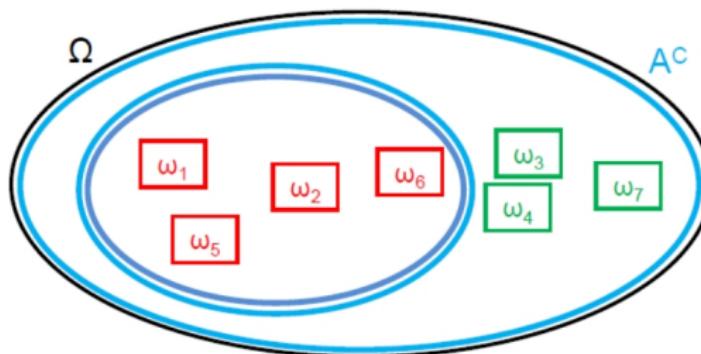


5.1 Mengentheoretische Grundlagen

Regeln

Regeln von de Morgan

$$(A \cap B)^c = A^c \cup B^c$$

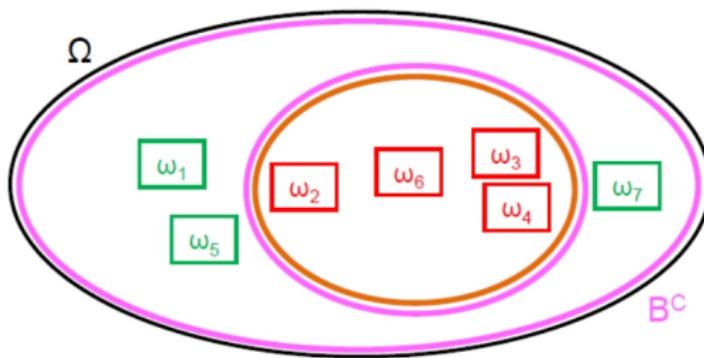


5.1 Mengentheoretische Grundlagen

Regeln

Regeln von de Morgan

$$(A \cap B)^c = A^c \cup B^c$$

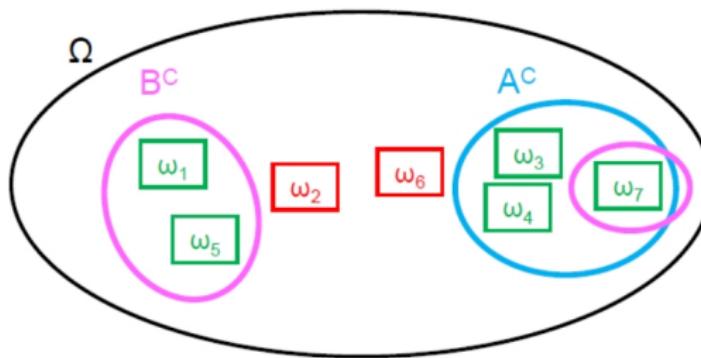


5.1 Mengentheoretische Grundlagen

Regeln

Regeln von de Morgan

$$(A \cap B)^c = A^c \cup B^c$$

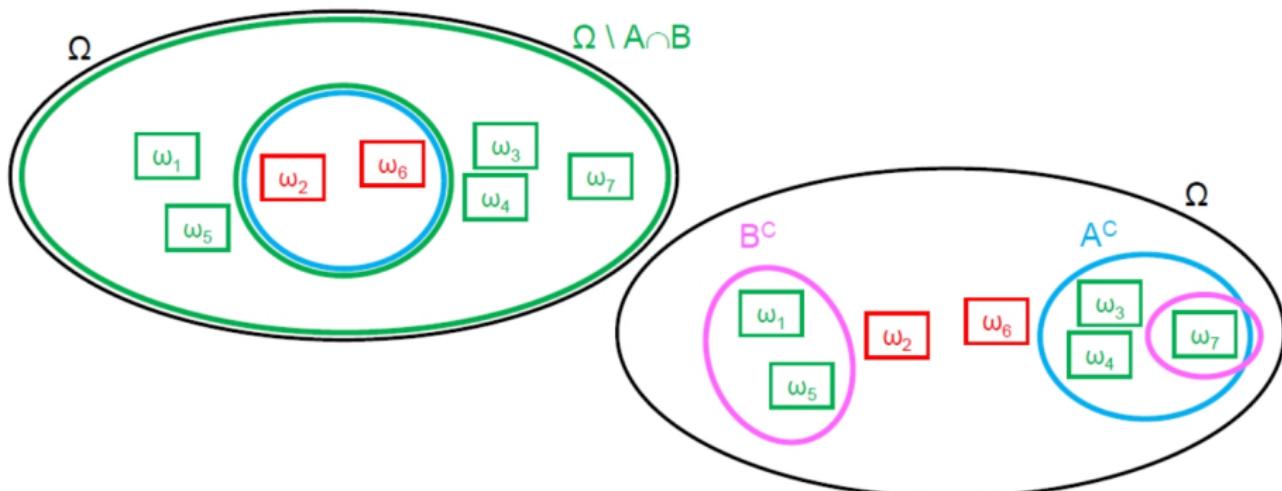


5.1 Mengentheoretische Grundlagen

Regeln

Regeln von de Morgan

$$(A \cap B)^c = A^c \cup B^c$$

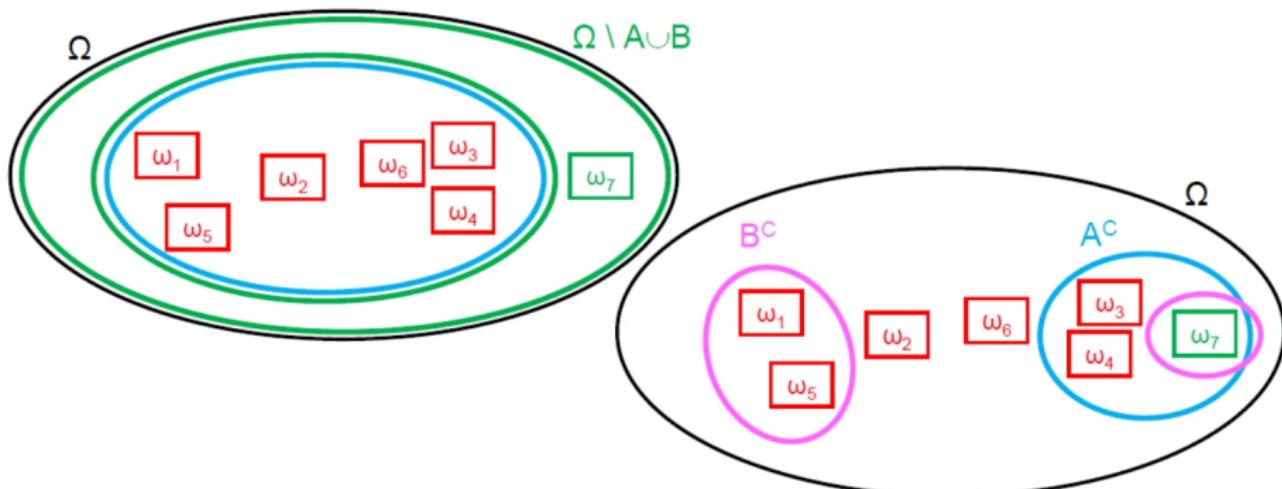


5.1 Mengentheoretische Grundlagen

Regeln

Regeln von de Morgan

$$(A \cup B)^c = A^c \cap B^c$$



5.1 Mengentheoretische Grundlagen

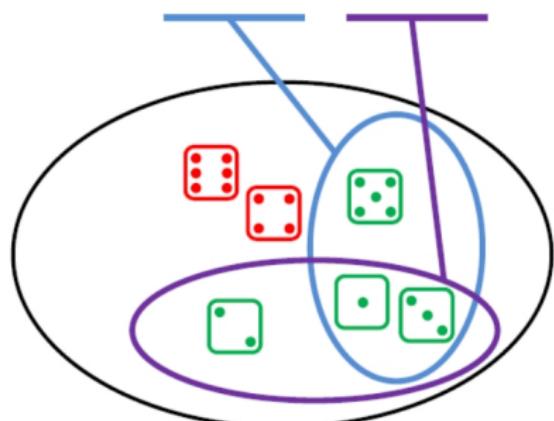
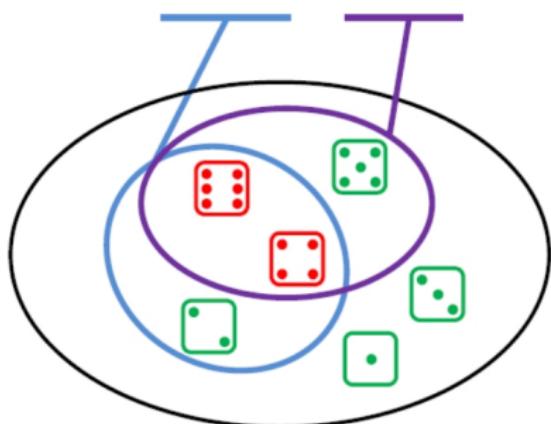
Regeln: Beispiel Würfelwurf

Regeln von de Morgan

$$(\{2,4,6\} \cap \{4,5,6\})^c$$

=

$$\{2,4,6\}^c \cup \{4,5,6\}^c$$



5.1 Mengentheoretische Grundlagen

Beispiel Mausaktivität

Ereignisbeispiele

$$A \supset \{\omega_1, \omega_3, \omega_4\}$$

„Letzter Click auf LU“

$$B \supset \{\omega_3, \omega_4\}$$

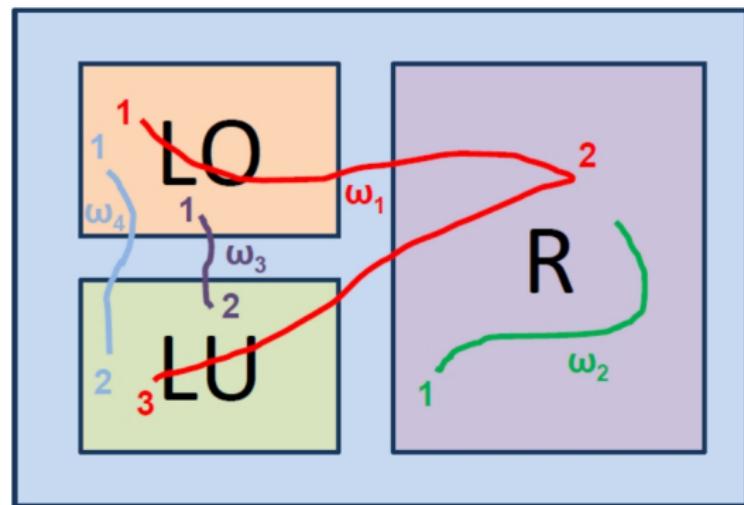
„Mauszeiger immer in linker Hälfte“

$$C \supset \{\omega_2\}$$

„Nur einmal geklickt“

$$D \supset \{\omega_1, \omega_2\}$$

„R wurde geklickt“



5.1 Mengentheoretische Grundlagen

Zusammenfassung Bezeichnungen

Mathematische Schreibweise	Ausformulierte Schreibweise
$\omega \in A$	Ergebnis ω ist in Ereignis A enthalten
$A \cap B$	Schnittereignis: Menge aller Ergebnisse, die in A und B enthalten sind
$A \cap B = \emptyset$	A und B sind disjunkt: es gibt kein Ergebnis, das in A und B enthalten ist
$A \cup B$	Vereinigungsergebnis: Menge aller Ergebnisse, die in A und/oder B enthalten sind
$A \subseteq B$	A ist Teilereignis von B : Alle in A enthaltenen Ergebnisse sind auch in B enthalten
$B \setminus A$	Differenzereignis: Menge der Ergebnisse, die in B , aber nicht in A enthalten sind
$A^c = \Omega \setminus A$	Komplementärereignis: Menge aller Ergebnisse, die nicht in A enthalten sind

5.1 Mengentheoretische Grundlagen

Zusammenfassung Regeln

Mathematische Schreibweise	Ausformulierte Schreibweise
$(A \cup B) \cap C = (A \cap B) \cup (B \cap C)$	Distributivgesetze Die Schnittmenge einer zwei Mengen A und B vereinigenden Menge mit einer weiteren Menge C ist gleich der Vereinigung der beiden aus C und jeweils einer der beiden Mengen A und B gebildeten Schnittmengen.
$(A \cap B) \cup C = (A \cup C) \cap (B \cup C)$	Die Vereinigung der Schnittmenge zweier Mengen A und B mit einer weiteren Menge C ist gleich der Schnittmenge der beiden aus C und jeweils einer der beiden Mengen A und B gebildeten Vereinigungen

5.1 Mengentheoretische Grundlagen

Zusammenfassung Regeln

Mathematische Schreibweise	Ausformulierte Schreibweise
$(A \cap B)^c = A^c \cup B^c$	Regeln von de Morgan Das Komplementärereignis der Schnittmenge zweier Mengen ist gleich der Vereinigung der Komplementärereignisse der zwei Mengen.
$(A \cup B)^c = A^c \cap B^c$	Das Komplementärereignis der Vereinigung zweier Mengen ist gleich der Schnittmenge der Komplementärereignisse der zwei Mengen

5.2 Wahrscheinlichkeitsmaße, Wahrscheinlichkeitsräume

Zuletzt: Interpretation von Daten als Realisationen von Zufallsvariablen.

Mengentheoretische Grundlagen zur Ordnung von Ergebnissen und Ereignissen

Ergebnis und Ereignis $\omega \in A$	Teilereignis $A \subseteq B$	Vereinigungseignis $A \cup B$
Schnittereignis $A \cap B$	Differenzereignis $B \setminus A$	Distributivgesetze $(A \cup B) \cap C = (A \cap C) \cup (B \cap C)$ $(A \cap B) \cup C = (A \cup C) \cap (B \cup C)$
Disjunkte Ereignisse $A \cap B = \emptyset$	Komplementärereignis $A^c = \Omega \setminus A$	Regeln von de Morgan $(A \cap B)^c = A^c \cup B^c$ $(A \cup B)^c = A^c \cap B^c$

Jetzt: Zuordnung von Wahrscheinlichkeiten zu Ergebnissen und Ereignissen

5.2 Wahrscheinlichkeitsmaße, Wahrscheinlichkeitsräume

Kolmogorov-Axiome, Wahrscheinlichkeitsmaß

Seien Ω ein Grundraum und \mathcal{A} die Menge aller Ereignisse über Ω . Dann heißt die Abbildung

$$P : \mathcal{A} \rightarrow [0, 1], \quad A \mapsto P(A),$$

ein **Wahrscheinlichkeitsmaß**, falls sie folgende Eigenschaften (**Kolmogorov-Axiome**) besitzt:

- ① $0 \leq P(A) \leq 1$ für jedes Ereignis $A \in \mathcal{A}$
- ② $P(\Omega) = 1$
- ③ $P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$ für alle paarweise disjunkten Ereignisse $A_i \in \mathcal{A}$

Der Wert $P(A)$ für ein Ereignis A heißt **Wahrscheinlichkeit** von A .

Das Tripel (Ω, \mathcal{A}, P) heißt **Wahrscheinlichkeitsraum**

5.2 Wahrscheinlichkeitsmaße, Wahrscheinlichkeitsräume

Kolmogorov-Axiome, Wahrscheinlichkeitsmaß: Beispiel Würfelwurf

$$\Omega = \{1, 2, 3, 4, 5, 6\}$$

$$\mathcal{A} = \left\{ \emptyset, \{1\}, \{2\}, \{3\}, \{4\}, \{5\}, \{6\}, \right. \\ \{1, 2\}, \{1, 3\}, \{1, 4\}, \{1, 5\}, \{1, 6\}, \{2, 3\}, \{2, 4\}, \{2, 5\}, \{2, 6\}, \{3, 4\}, \{3, 5\}, \{3, 6\}, \\ \{4, 5\}, \{4, 6\}, \{5, 6\}, \{1\}, \\ \{1, 2, 3\}, \{1, 2, 4\}, \{1, 2, 5\}, \{1, 2, 6\}, \{1, 3, 4\}, \{1, 3, 5\}, \{1, 3, 6\}, \{1, 4, 5\}, \{1, 4, 6\}, \{1, 5, 6\}, \\ \{2, 3, 4\}, \{2, 3, 5\}, \{2, 3, 6\}, \{2, 4, 5\}, \{2, 4, 6\}, \{2, 5, 6\}, \{3, 4, 5\}, \{3, 4, 6\}, \{3, 5, 6\}, \{4, 5, 6\}, \\ \{1, 2, 3, 4\}, \{1, 2, 3, 5\}, \{1, 2, 3, 6\}, \{1, 2, 4, 5\}, \{1, 2, 4, 6\}, \{1, 2, 5, 6\}, \{1, 2, 5, 6\}, \{1, 3, 4, 5\}, \\ \{1, 3, 4, 6\}, \{1, 3, 5, 6\}, \{1, 4, 5, 6\}, \{2, 3, 4, 5\}, \{2, 3, 4, 6\}, \{2, 4, 5, 6\}, \{3, 4, 5, 6\}, \\ \{1, 2, 3, 4, 5\}, \{1, 2, 3, 4, 6\}, \{1, 2, 4, 5, 6\}, \{1, 3, 4, 5, 6\}, \{2, 3, 4, 5, 6\}, \\ \left. \{1, 2, 3, 4, 5, 6\} \right\}$$

$$P(\{1\}) = P(\{2\}) = P(\{3\}) = P(\{4\}) = P(\{5\}) = P(\{6\}) = 1/6$$

5.2 Wahrscheinlichkeitsmaße, Wahrscheinlichkeitsräume

Kolmogorov-Axiome, Wahrscheinlichkeitsmaß: Beispiel Würfelwurf
(Fortsetzung)

① $0 \leq P(A) \leq 6/6 = 1$ für alle $A \in \mathcal{A}$

② $P(\Omega) = 1$

③ $P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$ für alle paarw. disj. Ereignisse $A_i \in \mathcal{A}$,

insb. für $A_i = \{i\}$, $i = 1, \dots, 6$, $A_i = \emptyset$, $i > 6$: $P\left(\bigcup_{i=1}^{\infty} \{i\}\right) = P\left(\bigcup_{i=1}^6 \{i\}\right)$

$$= P(\Omega) = \sum_{i=1}^6 P(i) = 6/6 = 1$$

5.2 Wahrscheinlichkeitsmaße, Wahrscheinlichkeitsräume

Kolmogorov-Axiome, Wahrscheinlichkeitsmaß:

Beispiel Mausaktivität, interpolierte x-Position des Mauszeigers zu stetiger Zeit t

$$\Omega = [1, 800]$$

$$\mathcal{A} = \left\{ \emptyset, \{(a, b) | a \in \Omega, b \in \Omega, a \leq b\}, \left\{ \bigcup_{c=1}^2 (a_c, b_c) | a_c \in \Omega, b_c \in \Omega, a_c \leq b_c \right\}, \dots, \right. \\ \left. \left\{ \bigcup_{c=1}^{\infty} (a_c, b_c) | a_c \in \Omega, b_c \in \Omega, a_c \leq b_c \right\}, \{[a, b]|\dots\}, \dots \{([a, b]|\dots\}, \{([a, b]|\dots\}, \dots \right\}$$

$$P([a, b]) = (b - a)/799, \quad a \leq b$$

5.2 Wahrscheinlichkeitsmaße, Wahrscheinlichkeitsräume

Kolmogorov-Axiome, Wahrscheinlichkeitsmaß:

Beispiel Mausaktivität, interpolierte x -Position des Mauszeigers zu stetiger Zeit t (Fortsetzung)

① $0 \leq P(A) \leq 799/799 = 1$ für alle $A \in \mathcal{A}$

② $P(\Omega) = 1$

③ $P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$ für alle paarw. disj. Ereignisse $A_i \in \mathcal{A}$,

z.B. für

$$A_1 = 1, A_2 = (1, 400), A_3 = 400, A_4 = (400, 800), A_5 = 800, A_i = \emptyset, i > 5 :$$

$$\begin{aligned} P\left(\bigcup_{i=1}^{\infty} A_i\right) &= P(1 \cup (1, 400) \cup 400 \cup (400, 800) \cup 800) = P(\Omega) = \sum_{i=1}^5 P(i) \\ &= \frac{0+399+0+400+0}{799} = 1 \end{aligned}$$

5.2 Wahrscheinlichkeitsmaße, Wahrscheinlichkeitsräume

Eigenschaften von Wahrscheinlichkeitsmaßen

$P : \mathcal{A} \rightarrow [0, 1], \quad A \mapsto P(A)$

- ① $0 \leq P(A) \leq 1$ für jedes Ereignis $A \in \mathcal{A}$
- ② $P(\Omega) = 1$
- ③ $P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$ für alle paarweise disjunkten Ereignisse $A_i \in \mathcal{A}$

(i) $A \cap B = \emptyset \Rightarrow P(A \cup B) = P(A) + P(B)$

Beweis:

Setze $A_1 = A, A_2 = B, A_i = \emptyset$, für $i > 2$

$$\begin{aligned}
 P(A \cup B) &= P\left(\bigcup_{i=1}^{\infty} A_i\right) \stackrel{3.}{=} \sum_{i=1}^{\infty} P(A_i) = P(A_1) + \sum_{i=2}^{\infty} P(A_i) \\
 &= P(A_1) + \left(\bigcup_{i=2}^{\infty} A_i\right) = \boxed{P(A) + P(B)} \quad \square
 \end{aligned}$$

5.2 Wahrscheinlichkeitsmaße, Wahrscheinlichkeitsräume

Eigenschaften von Wahrscheinlichkeitsmaßen

$P : \mathcal{A} \rightarrow [0, 1], \quad A \mapsto P(A)$

- ① $0 \leq P(A) \leq 1$ für jedes Ereignis $A \in \mathcal{A}$
- ② $P(\Omega) = 1$
- ③ $P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$ für alle paarweise disjunkten Ereignisse $A_i \in \mathcal{A}$

(ii) $A \subseteq B \Rightarrow P(B \setminus A) = P(B) - P(A)$

Beweis:

$$P(B) = P((B \setminus A) \cup A) \stackrel{(i)}{=} P(B \setminus A) + P(A) \Rightarrow P(B \setminus A) = P(B) - P(A) \quad \square$$

5.2 Wahrscheinlichkeitsmaße, Wahrscheinlichkeitsräume

Eigenschaften von Wahrscheinlichkeitsmaßen

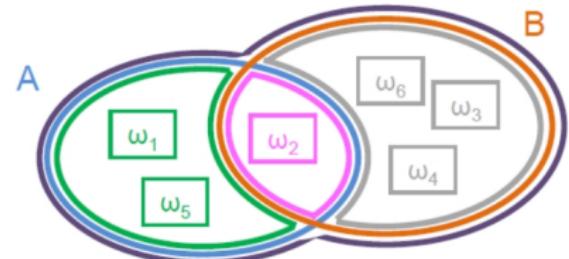
$P : \mathcal{A} \rightarrow [0, 1], \quad A \mapsto P(A)$

- ① $0 \leq P(A) \leq 1$ für jedes Ereignis $A \in \mathcal{A}$
- ② $P(\Omega) = 1$
- ③ $P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$ für alle paarweise disjunkten Ereignisse $A_i \in \mathcal{A}$

$$\boxed{\text{(iii)} \quad P(A \cup B) = P(A) + P(B) - P(A \cap B)}$$

Beweis:

$$A \cup B = [A \setminus (A \cap B)] \cup [B \setminus (A \cap B)] \cup [A \cap B]$$



5.2 Wahrscheinlichkeitsmaße, Wahrscheinlichkeitsräume

Eigenschaften von Wahrscheinlichkeitsmaßen

Beweis: (Fortsetzung)

$$A \cup B = [A \setminus (A \cap B)] \cup [B \setminus (A \cap B)] \cup [A \cap B]$$

$$\Rightarrow P([A \cup B]) = P([A \setminus (A \cap B)] \cup [B \setminus (A \cap B)] \cup [A \cap B])$$

$$\stackrel{(i)}{=} P([A \setminus (A \cap B)]) + P([B \setminus (A \cap B)]) + P(A \cap B)$$

$$\stackrel{(ii)}{=} P(A) - P(A \cap B) + P(B) - P(A \cap B) + P(A \cap B)$$

$$= P(A) + P(B) - P(A \cap B) \quad \square$$

5.2 Wahrscheinlichkeitsmaße, Wahrscheinlichkeitsräume

Eigenschaften von Wahrscheinlichkeitsmaßen

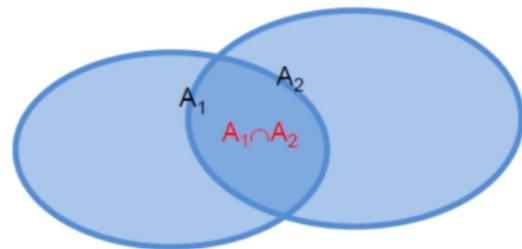
(iii) $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

(iv) **Poincaré-Sylvesterformel**

$$P\left(\bigcup_{n=1}^N A_n\right) = \sum_{m=1}^N (-1)^{m+1} \sum_{1 \leq n_1 < \dots < n_m \leq N} P(A_{n_1} \cap \dots \cap A_{n_m})$$

Am Beispiel $N = 2$:

$$\begin{aligned} P(A_1 \cup A_2) &= (-1)^{1+1} \cdot P(A_1) + (-1)^{1+1} \cdot P(A_2) + (-1)^{2+1} \cdot P(A_1 \cap A_2) \\ &= \boxed{P(A_1)} + \boxed{P(A_2)} - \boxed{P(A_1 \cap A_2)} \end{aligned}$$



5.2 Wahrscheinlichkeitsmaße, Wahrscheinlichkeitsräume

Eigenschaften von Wahrscheinlichkeitsmaßen

(iii) $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

(iv) **Poincaré-Sylvesterformel**

$$P\left(\bigcup_{n=1}^N A_n\right) = \sum_{m=1}^N (-1)^{m+1} \sum_{1 \leq n_1 < \dots < n_m \leq N} P(A_{n_1} \cap \dots \cap A_{n_m})$$

Für $N = 3$:

$$\begin{aligned} P(A_1 \cup A_2 \cup A_3) &= (-1)^{1+1} \cdot P(A_1) + (-1)^{1+1} \cdot P(A_2) + (-1)^{1+1} \cdot P(A_3) \\ &\quad + (-1)^{2+1} \cdot P(A_1 \cap A_2) + (-1)^{2+1} \cdot P(A_1 \cap A_3) + (-1)^{2+1} \cdot P(A_2 \cap A_3) \\ &\quad + (-1)^{3+1} \cdot P(A_1 \cap A_2 \cap A_3) \\ &= P(A_1) + P(A_2) + P(A_3) - P(A_1 \cap A_2) - P(A_1 \cap A_3) - P(A_2 \cap A_3) \\ &\quad + P(A_1 \cap A_2 \cap A_3) \end{aligned}$$

5.2 Wahrscheinlichkeitsmaße, Wahrscheinlichkeitsräume

Eigenschaften von Wahrscheinlichkeitsmaßen

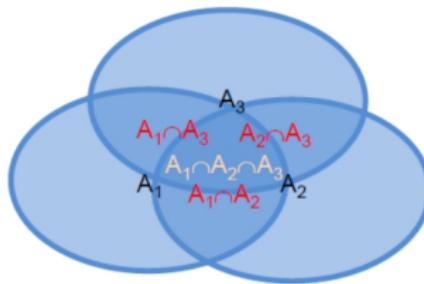
(iii) $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

(iv) **Poincaré-Sylvesterformel**

$$P\left(\bigcup_{n=1}^N A_n\right) = \sum_{m=1}^N (-1)^{m+1} \sum_{1 \leq n_1 < \dots < n_m \leq N} P(A_{n_1} \cap \dots \cap A_{n_m})$$

Für $N = 3$: $P(A_1 \cup A_2 \cup A_3) =$

$$\boxed{P(A_1)} + \boxed{P(A_2)} + \boxed{P(A_3)} - \boxed{P(A_1 \cap A_2)} - \boxed{P(A_1 \cap A_3)} - \boxed{P(A_2 \cap A_3)} \\ + \boxed{P(A_1 \cap A_2 \cap A_3)}$$



5.2 Wahrscheinlichkeitsmaße, Wahrscheinlichkeitsräume

Eigenschaften von Wahrscheinlichkeitsmaßen

$P : \mathcal{A} \rightarrow [0, 1]$, $A \mapsto P(A)$

- ① $0 \leq P(A) \leq 1$ für jedes Ereignis $A \in \mathcal{A}$
- ② $P(\Omega) = 1$
- ③ $P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$ für alle paarweise disjunkten Ereignisse $A_i \in \mathcal{A}$

$$\text{(v)} \quad P(A^c) = 1 - P(A)$$

Beweis:

$$P(A^c) = P(\Omega \setminus A) \stackrel{(ii)}{=} P(\Omega) - P(A) = \boxed{1 - P(A)} \quad \square$$

5.2 Wahrscheinlichkeitsmaße, Wahrscheinlichkeitsräume

Eigenschaften von Wahrscheinlichkeitsmaßen

$P : \mathcal{A} \rightarrow [0, 1]$, $A \mapsto P(A)$

- ① $0 \leq P(A) \leq 1$ für jedes Ereignis $A \in \mathcal{A}$
- ② $P(\Omega) = 1$
- ③ $P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$ für alle paarweise disjunkten Ereignisse $A_i \in \mathcal{A}$

(vi) $P(\emptyset) = 0$

Beweis:

$$P(\emptyset) = P(\Omega^c) \stackrel{(v)}{=} 1 - P(\Omega) = 0 \quad \square$$

5.2 Wahrscheinlichkeitsmaße, Wahrscheinlichkeitsräume

Eigenschaften von Wahrscheinlichkeitsmaßen

$P : \mathcal{A} \rightarrow [0, 1]$, $A \mapsto P(A)$

- ① $0 \leq P(A) \leq 1$ für jedes Ereignis $A \in \mathcal{A}$
- ② $P(\Omega) = 1$
- ③ $P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$ für alle paarweise disjunkten Ereignisse $A_i \in \mathcal{A}$

(vii) $A \subseteq B \Rightarrow P(A) \leq P(B)$

Beweis:

$$\begin{aligned} A \subseteq B &\Rightarrow P(B \setminus A) = P(B) - P(A) \\ &\Rightarrow P(A) = P(B) - \underbrace{P(B \setminus A)}_{\geq 0} \leq P(B) \quad \square \end{aligned}$$

5.2 Wahrscheinlichkeitsmaße, Wahrscheinlichkeitsräume

Diskreter Wahrscheinlichkeitsraum

Seien $\Omega = \{\omega_1, \omega_2, \dots\}$ ein **endlicher** oder **abzählbarer unendlicher** Grundraum und P ein Wahrscheinlichkeitsmaß auf Ω . Dann heißt (Ω, \mathcal{A}, P) **diskreter Wahrscheinlichkeitsraum**.

Für beliebiges Ereignis $A \in \mathcal{A}$ gilt dann nach (i):

$$P(A) = P\left(\bigcup_{i:\omega_i \in A} \{\omega_i\}\right) = \sum_{i:\omega_i \in A} P(\{\omega_i\})$$

Laplace-Raum

Treten die Elemente von endlichem $\Omega = \{\omega_1, \dots, \omega_{|\Omega|}\}$ aus einem diskreten Wahrscheinlichkeitsraum (Ω, \mathcal{A}, P) alle mit der selben Wahrscheinlichkeit auf, d.h. gilt $P(\{\omega_i\}) = 1/|\Omega|$ für $i = 1, \dots, |\Omega|$, so wird (Ω, \mathcal{A}, P) auch **Laplace-Raum** genannt und die Wahrscheinlichkeit für ein Ereignis $A \in \mathcal{A}$ kann durch $P(A) = |A|/|\Omega|$ angegeben werden.

5.2 Wahrscheinlichkeitsmaße, Wahrscheinlichkeitsräume

Eigenschaften von Wahrscheinlichkeitsmaßen; Diskreter

Wahrscheinlichkeitsraum: Beispiel: *Bearbeitungen von Softwareaufgaben*

Bearbeitung	Bearbeiter(in)	Aufgabe	Version
e ₁	Kai	Export	1.1
e ₂	Kai	Verknüpfung	1.2
e ₃	Miriam	Export	1.1
e ₄	Tina	Verknüpfung	1.2
e ₅	Oliver	Export	2.0
e ₆	Tina	Export	1.2
e ₇	Tina	Verknüpfung	1.2
e ₈	Miriam	Export	1.2
e ₉	Miriam	Export	1.2
e ₁₀	Oliver	Abfrage	1.1
e ₁₁	Oliver	Verknüpfung	2.0
e ₁₂	Oliver	Abfrage	2.0

Zufällige Auswahl einer Bearbeitung

→ Ergebnis $\omega \in \{e_1, \dots, e_{12}\} = \Omega$

Elementarwahrscheinlichkeiten

$$P(\{e_i\}) = 1/12, i = 1, \dots, 12$$

Ereignisse

- ① Bearbeiter männlich

$$A_1 = \{e_1, e_2, e_5, e_{10}, e_{11}, e_{12}\}$$

- ② Gestellte Aufgabe Export

$$A_2 = \{e_1, e_3, e_5, e_6, e_8, e_9\}$$

- ③ Verwendete Version 2.0

$$A_3 = \{e_5, e_{11}, e_{12}\}$$

5.2 Wahrscheinlichkeitsmaße, Wahrscheinlichkeitsräume

Eigenschaften von Wahrscheinlichkeitsmaßen

- (i) $A \cap B = \emptyset \Rightarrow P(A \cup B) = P(A) + P(B)$ (v) $P(A^c) = 1 - P(A)$
- (ii) $A \subseteq B \Rightarrow P(B \setminus A) = P(B) - P(A)$ (vi) $P(\emptyset) = 0$
- (iii) $P(A \cup B) = P(A) + P(B) - P(A \cap B)$ (vii) $A \subseteq B \Rightarrow P(A) \leq P(B)$
- (iv) $P\left(\bigcup_{n=1}^N A_n\right) = \sum_{m=1}^N (-1)^{m+1} \sum_{1 \leq n_1 < \dots < n_m \leq N} P(A_{n_1} \cap \dots \cap A_{n_m})$

$$\omega \in \{e_1, \dots, e_{12}\} = \Omega$$

$$P(\{e_i\}) = 1/12, i = 1, \dots, 12$$

$$A_1 = \{e_1, e_2, e_5, e_{10}, e_{11}, e_{12}\}$$

$$A_2 = \{e_1, e_3, e_5, e_6, e_8, e_9\}$$

$$A_3 = \{e_5, e_{11}, e_{12}\}$$

5.2 Wahrscheinlichkeitsmaße, Wahrscheinlichkeitsräume

Eigenschaften von Wahrscheinlichkeitsmaßen

- | | |
|--|--|
| (i) $A \cap B = \emptyset \Rightarrow P(A \cup B) = P(A) + P(B)$ | (v) $P(A^c) = 1 - P(A)$ |
| (ii) $A \subseteq B \Rightarrow P(B \setminus A) = P(B) - P(A)$ | (vi) $P(\emptyset) = 0$ |
| (iii) $P(A \cup B) = P(A) + P(B) - P(A \cap B)$ | (vii) $A \subseteq B \Rightarrow P(A) \leq P(B)$ |
| (iv) $P\left(\bigcup_{n=1}^N A_n\right) = \sum_{m=1}^N (-1)^{m+1} \sum_{1 \leq n_1 < \dots < n_m \leq N} P(A_{n_1} \cap \dots \cap A_{n_m})$ | |

$$\omega \in \{e_1, \dots, e_{12}\} = \Omega$$

$$P(\{e_i\}) = 1/12, i = 1, \dots, 12$$

$$A_1 = \{e_1, e_2, e_5, e_{10}, e_{11}, e_{12}\}$$

$$A_2 = \{e_1, e_3, e_5, e_6, e_8, e_9\}$$

$$A_3 = \{e_5, e_{11}, e_{12}\}$$

$$\begin{aligned}
 P(A_1) &= P(\{e_1\} \cup \{e_2\} \cup \{e_5\} \cup \{e_{10}\} \cup \{e_{11}\} \cup \{e_{12}\}) \\
 &= P(\{e_1\}) + P(\{e_2\}) + P(\{e_5\}) \\
 &\quad + P(\{e_{10}\}) + P(\{e_{11}\}) + P(\{e_{12}\}) = 6/12 = 1/2 \\
 P(A_2) &= P(\{e_1\} \cup \{e_3\} \cup \{e_5\} \cup \{e_6\} \cup \{e_8\} \cup \{e_9\}) \\
 &= P(\{e_1\}) + P(\{e_3\}) + P(\{e_5\}) \\
 &\quad + P(\{e_6\}) + P(\{e_8\}) + P(\{e_9\}) = 6/12 = 1/2 \\
 P(A_3) &= P(\{e_5\} \cup \{e_{11}\} \cup \{e_{12}\}) \\
 &= P(\{e_5\}) + P(\{e_{11}\}) + P(\{e_{12}\}) = 3/12 = 1/4
 \end{aligned}$$

5.2 Wahrscheinlichkeitsmaße, Wahrscheinlichkeitsräume

Eigenschaften von Wahrscheinlichkeitsmaßen

$$(i) A \cap B = \emptyset \Rightarrow P(A \cup B) = P(A) + P(B) \quad (v) P(A^c) = 1 - P(A)$$

$$(ii) A \subseteq B \Rightarrow P(B \setminus A) = P(B) - P(A) \quad (vi) P(\emptyset) = 0$$

$$(iii) P(A \cup B) = P(A) + P(B) - P(A \cap B) \quad (vii) A \subseteq B \Rightarrow P(A) \leq P(B)$$

$$(iv) P\left(\bigcup_{n=1}^N A_n\right) = \sum_{m=1}^N (-1)^{m+1} \sum_{1 \leq n_1 < \dots < n_m \leq N} P(A_{n_1} \cap \dots \cap A_{n_m})$$

$$\omega \in \{e_1, \dots, e_{12}\} = \Omega \\ P\{\{e_i\}\} = 1/12, i = 1, \dots, 12$$

$$A_1 = \{e_1, e_2, e_5, e_{10}, e_{11}, e_{12}\}$$

$$A_2 = \{e_1, e_3, e_5, e_6, e_8, e_9\}$$

$$A_3 = \{e_5, e_{11}, e_{12}\}$$

$$P(A_1) = 1/2$$

$$P(A_2) = 1/2$$

$$P(A_3) = 1/4$$

Wahrscheinlichkeit für eine Bearbeitung, die von einem Mann mit einer anderen Version als 2.0 durchgeführt wurde

$$A_3 = \{e_5, e_{11}, e_{12}\} \subset \{e_1, e_2, e_5, e_{10}, e_{11}, e_{12}\} = A_1 \\ \Rightarrow (ii) P(A_1 \setminus A_3) = P(A_1) - P(A_3) = 1/2 - 1/4 = 1/4 \\ \Rightarrow (vii) 1/4 = P(A_3) \leq P(A_1) = 1/2$$

5.2 Wahrscheinlichkeitsmaße, Wahrscheinlichkeitsräume

Eigenschaften von Wahrscheinlichkeitsmaßen

- (i) $A \cap B = \emptyset \Rightarrow P(A \cup B) = P(A) + P(B)$
- (ii) $A \subseteq B \Rightarrow P(B \setminus A) = P(B) - P(A)$
- (iii) $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
- (v) $P(A^c) = 1 - P(A)$
- (vi) $P(\emptyset) = 0$
- (vii) $A \subseteq B \Rightarrow P(A) \leq P(B)$

$$(iv) P\left(\bigcup_{n=1}^N A_n\right) = \sum_{m=1}^N (-1)^{m+1} \sum_{1 \leq n_1 < \dots < n_m \leq N} P(A_{n_1} \cap \dots \cap A_{n_m})$$

$$\omega \in \{e_1, \dots, e_{12}\} = \Omega$$

$$P(\{e_i\}) = 1/12, i = 1, \dots, 12$$

$$A_1 = \{e_1, e_2, e_5, e_{10}, e_{11}, e_{12}\}$$

$$A_2 = \{e_1, e_3, e_5, e_6, e_8, e_9\}$$

$$A_3 = \{e_5, e_{11}, e_{12}\}$$

$$P(A_1) = 1/2$$

$$P(A_2) = 1/2$$

$$P(A_3) = 1/4$$

Wahrscheinlichkeit für eine Bearbeitung, die Aufgabe Export hatte und/oder von einem Mann durchgeführt wurde

$$\begin{aligned}
 P(A_1 \cup A_2) &= P(A_1) + P(A_2) - P(A_1 \cap A_2) \\
 &= 1/2 + 1/2 - P(\{e_1, e_2, e_5, e_{10}, e_{11}, e_{12}\} \cap \{e_1, e_3, e_5, e_6, e_8, e_9\}) \\
 &= 1 - P(\{e_1, e_5\}) = 1 - P(\{e_1\} \cup \{e_5\}) \\
 &= 1 - (P(\{e_1\}) + P(\{e_5\})) = 1 - 2/12 \\
 &= 10/12 = 5/6
 \end{aligned}$$

5.2 Wahrscheinlichkeitsmaße, Wahrscheinlichkeitsräume

Eigenschaften von Wahrscheinlichkeitsmaßen

- (i) $A \cap B = \emptyset \Rightarrow P(A \cup B) = P(A) + P(B)$
- (v) $P(A^c) = 1 - P(A)$
- (ii) $A \subseteq B \Rightarrow P(B \setminus A) = P(B) - P(A)$
- (vi) $P(\emptyset) = 0$
- (iii) $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
- (vii) $A \subseteq B \Rightarrow P(A) \leq P(B)$

(iv) $P\left(\bigcup_{n=1}^N A_n\right) = \sum_{m=1}^N (-1)^{m+1} \sum_{1 \leq n_1 < \dots < n_m \leq N} P(A_{n_1} \cap \dots \cap A_{n_m})$

$$\omega \in \{e_1, \dots, e_{12}\} = \Omega$$

$$P(\{e_i\}) = 1/12, i = 1, \dots, 12$$

$$A_1 = \{e_1, e_2, e_5, e_{10}, e_{11}, e_{12}\}$$

$$A_2 = \{e_1, e_3, e_5, e_6, e_8, e_9\}$$

$$A_3 = \{e_5, e_{11}, e_{12}\}$$

$$P(A_1) = 1/2$$

$$P(A_2) = 1/2$$

$$P(A_3) = 1/4$$

W'keit für eine Bearbeitung, die Aufgabe Export hatte und/oder von einem Mann und /oder mit Version 2.0 durchgeführt wurde

$$\begin{aligned}
 & P(A_1 \cup A_2 \cup A_3) \\
 &= P(A_1) + P(A_2) + P(A_3) - P(A_1 \cap A_2) - P(A_1 \cap A_3) \\
 &\quad - P(A_2 \cap A_3) + P(A_1 \cap A_2 \cap A_3) \\
 &= 1/2 + 1/2 - 1/4 - P(\{e_1, e_5\}) - P(\{e_5, e_{11}, e_{12}\}) \\
 &\quad - P(\{e_5\}) + P(\{e_5\}) \\
 &= 15/12 - 2/12 - 3/12 - 1/12 + 1/12 = 10/12 = 5/6
 \end{aligned}$$

5.2 Wahrscheinlichkeitsmaße, Wahrscheinlichkeitsräume

Eigenschaften von Wahrscheinlichkeitsmaßen

- (i) $A \cap B = \emptyset \Rightarrow P(A \cup B) = P(A) + P(B)$
- (ii) $A \subseteq B \Rightarrow P(B \setminus A) = P(B) - P(A)$
- (iii) $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
- (iv) $P\left(\bigcup_{n=1}^N A_n\right) = \sum_{m=1}^N (-1)^{m+1} \sum_{1 \leq n_1 < \dots < n_m \leq N} P(A_{n_1} \cap \dots \cap A_{n_m})$
- (v) $P(A^c) = 1 - P(A)$
- (vi) $P(\emptyset) = 0$
- (vii) $A \subseteq B \Rightarrow P(A) \leq P(B)$

$$\omega \in \{e_1, \dots, e_{12}\} = \Omega$$

$$P(\{e_i\}) = 1/12, i = 1, \dots, 12$$

$$A_1 = \{e_1, e_2, e_5, e_{10}, e_{11}, e_{12}\}$$

$$A_2 = \{e_1, e_3, e_5, e_6, e_8, e_9\}$$

$$A_3 = \{e_5, e_{11}, e_{12}\}$$

$$P(A_1) = 1/2$$

$$P(A_2) = 1/2$$

$$P(A_3) = 1/4$$

W'keit für eine Bearbeitung, die weder Aufgabe Export hatte noch von einem Mann noch mit Version 2.0 durchgeführt wurde

$$\text{Mit (v): } P([A_1 \cup A_2 \cup A_3]^c) = 1 - P(A_1 \cup A_2 \cup A_3)$$

$$= 1 - 5/6 = 1/6$$

$$\begin{aligned} \text{Mit de Morgan: } P([A_1 \cup A_2 \cup A_3]^c) &= P(A_1^c \cap A_2^c \cap A_3^c) \\ &= P(\{e_3, e_4, e_6, e_7, e_8, e_9\} \cap \{e_2, e_4, e_7, e_{10}, e_{11}, e_{12}\}) \\ &\quad \cap \{e_1, e_2, e_3, e_4, e_6, e_7, e_8, e_9, e_{10}\}) \\ &= P(\{e_4, e_7\}) = 2/12 = 1/6 \end{aligned}$$

5.2 Wahrscheinlichkeitsmaße, Wahrscheinlichkeitsräume

Eigenschaften von Wahrscheinlichkeitsmaßen

$$(i) A \cap B = \emptyset \Rightarrow P(A \cup B) = P(A) + P(B) \quad (v) P(A^c) = 1 - P(A)$$

$$(ii) A \subseteq B \Rightarrow P(B \setminus A) = P(B) - P(A) \quad (vi) P(\emptyset) = 0$$

$$(iii) P(A \cup B) = P(A) + P(B) - P(A \cap B) \quad (vii) A \subseteq B \Rightarrow P(A) \leq P(B)$$

$$(iv) P\left(\bigcup_{n=1}^N A_n\right) = \sum_{m=1}^N (-1)^{m+1} \sum_{1 \leq n_1 < \dots < n_m \leq N} P(A_{n_1} \cap \dots \cap A_{n_m})$$

$$\omega \in \{e_1, \dots, e_{12}\} = \Omega \\ P(\{e_i\}) = 1/12, i = 1, \dots, 12$$

$$A_1 = \{e_1, e_2, e_5, e_{10}, e_{11}, e_{12}\} \\ A_2 = \{e_1, e_3, e_5, e_6, e_8, e_9\} \\ A_3 = \{e_5, e_{11}, e_{12}\}$$

$$P(A_1) = 1/2 \\ P(A_2) = 1/2 \\ P(A_3) = 1/4$$

W'keit für eine Bearbeitung, die mit Version 2.0 von einer Frau durchgeführt wurde

$$P(A_1^c \cap A_3) = P(\{e_3, e_4, e_6, e_7, e_8, e_9\} \cap \{e_5, e_{11}, e_{12}\}) \\ = P(\emptyset) = 0$$

Zufallsvariablen und deren Verteilung

6.0 Zufallsvariablen und deren Verteilung

Erinnerung

Zufallsexperiment	Datenerhebungsprozess mit nicht vorhersagbarem Ausgang
Ergebnis ω	Elementarer Ausgang eines Zufallsexperiments
Grundraum Ω	Menge aller möglichen Ergebnisse $\Omega = \{\omega \mid \omega \text{ ist Ergebnis des Zufallsexperiments}\}$

Zufallsvariable

Eine Abbildung, die jedem Ergebnis eines Zufallsexperiments eine reelle Zahl zuordnet, wird **Zufallsvariable (ZV)** genannt. Ein konkreter Wert $x = X(\omega)$ heißt **Realisation** der Zufallsvariable X .

$$X : \Omega \rightarrow \mathbb{R} \quad \omega \mapsto X(\omega)$$

6.0 Zufallsvariablen und deren Verteilung

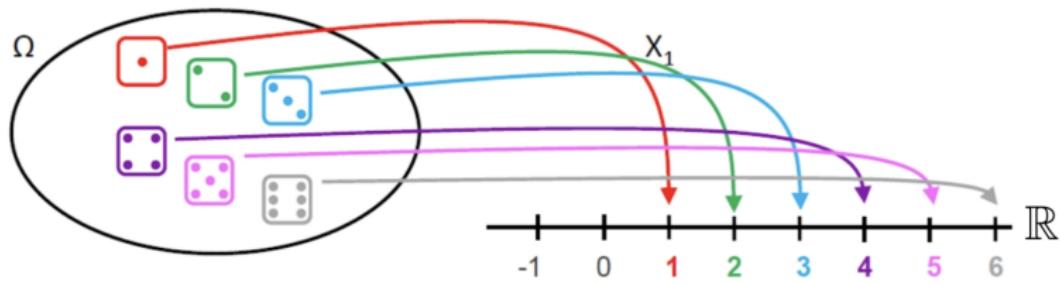
Zufallsvariable

Eine Abbildung, die jedem Ergebnis eines Zufallsexperiments eine reelle Zahl zuordnet, wird **Zufallsvariable** genannt. Ein konkreter Wert $x = X(\omega)$ heißt **Realisation** der Zufallsvariable X .

$$X : \Omega \rightarrow \mathbb{R} \quad \omega \mapsto X(\omega)$$

Beispiel Würfelwurf

Zufallsvariable Augenzahl: $X_1(\omega) = \omega$



6.0 Zufallsvariablen und deren Verteilung

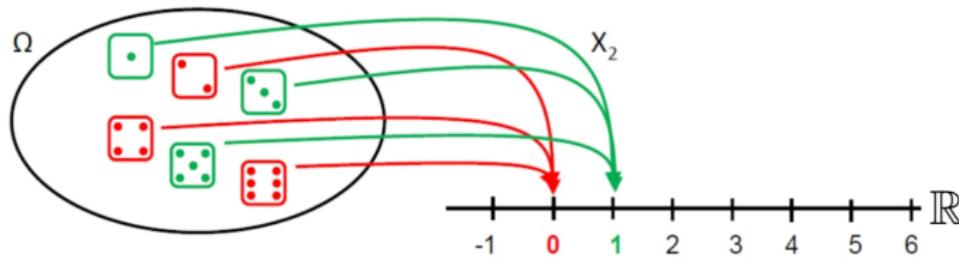
Zufallsvariable

Eine Abbildung, die jedem Ergebnis eines Zufallsexperiments eine reelle Zahl zuordnet, wird **Zufallsvariable** genannt. Ein konkreter Wert $x = X(\omega)$ heißt **Realisation** der Zufallsvariable X .

$$X : \Omega \rightarrow \mathbb{R} \quad \omega \mapsto X(\omega)$$

Beispiel Würfelwurf: $X_2(\omega_i) = 1$, falls i -ter Wurf Kopf, $X_2(\omega_i) = 0$ sonst

Zufallsvariable Gerade/Ungerade: $X_2(\omega) \in \{0, 1\}$



6.0 Zufallsvariablen und deren Verteilung

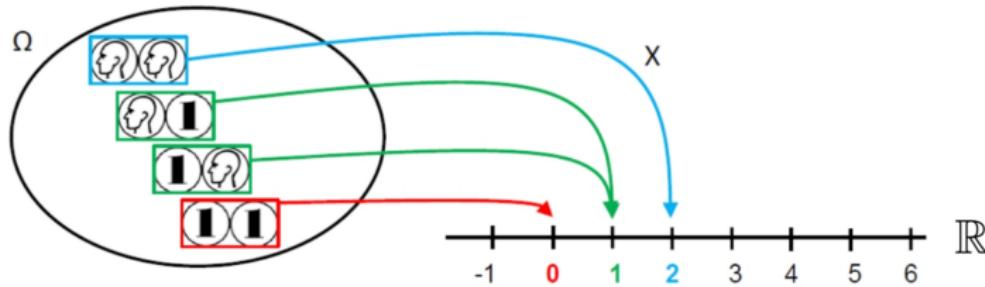
Zufallsvariable

Eine Abbildung, die jedem Ergebnis eines Zufallsexperiments eine reelle Zahl zuordnet, wird **Zufallsvariable** genannt. Ein konkreter Wert $x = X(\omega)$ heißt **Realisation** der Zufallsvariable X .

$$X : \Omega \rightarrow \mathbb{R} \quad \omega \mapsto X(\omega)$$

Beispiel zweifacher Münzwurf

Zufallsvariable Anzahl Kopf: $X((\omega_1, \omega_2)) = \omega_1 + \omega_2$



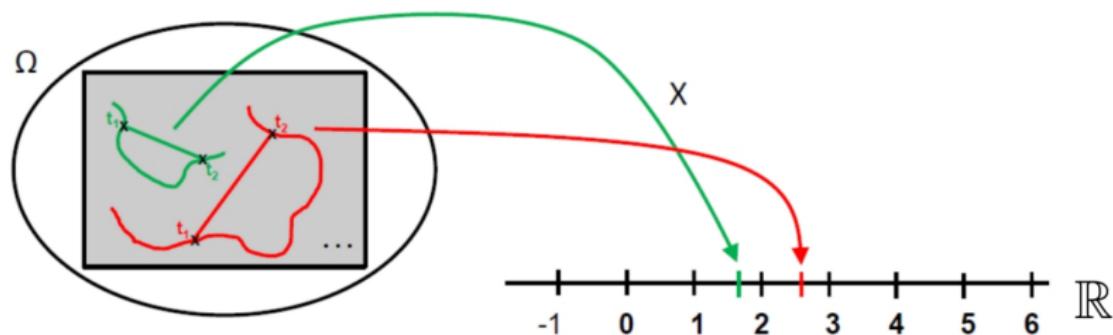
6.0 Zufallsvariablen und deren Verteilung

Beispiel Mausaktivität: $\omega(t) = [x(t), y(t), c(t)]$

ZV: Distanz zwischen ersten 2 Mausclicks

$$X(\omega) = \sqrt{[x(t_2) - x(t_1)]^2 + [y(t_2) - y(t_1)]^2}$$

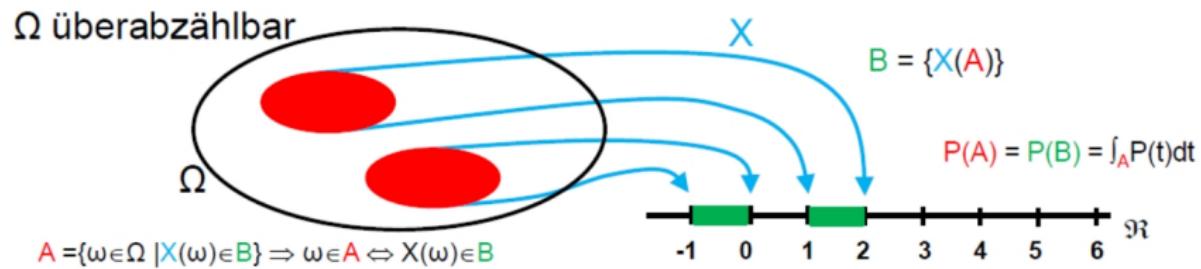
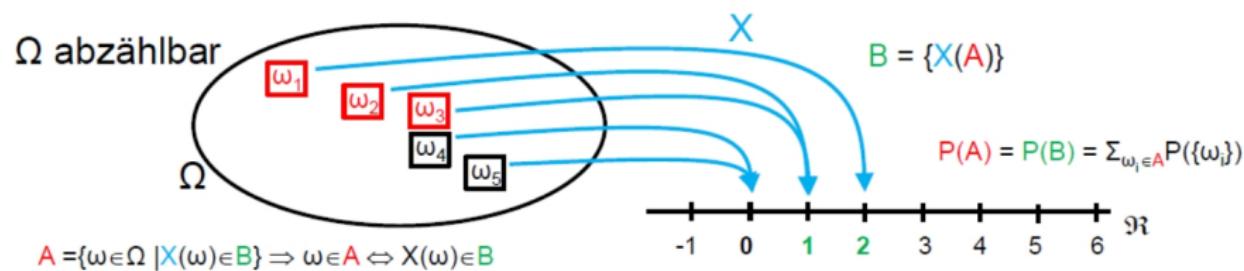
$$t_1 = \min(t | c(t) > 0) \quad t_2 = \min(t | c(t) > 0, t > t_1)$$



6.0 Zufallsvariablen und deren Verteilungen

Verteilung eindimensionaler Zufallsvariablen

Die durch die Zufallsvariable definierte Abbildung von beliebigem Grundraum Ω auf die reellen Zahlen erlaubt die Zuordnung von Wahrscheinlichkeiten zu Teilmengen von \mathbb{R} .



6.0 Zufallsvariablen und deren Verteilung

Verteilung eindimensionaler Zufallsvariablen

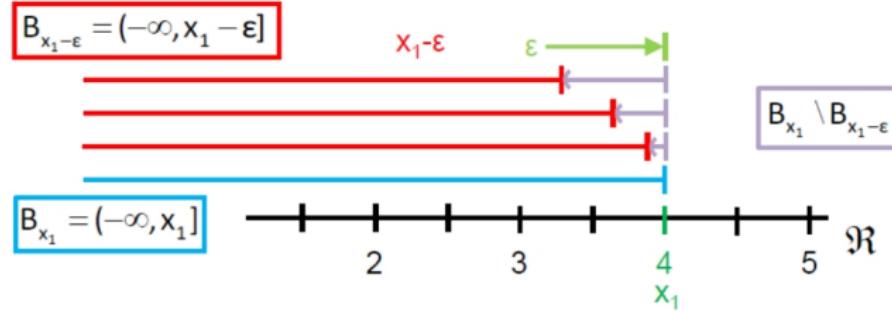
Die **Wahrscheinlichkeitsverteilung** oder kurz **Verteilung** einer Zufallsvariablen X ist definiert durch

$$P^X(B) = P(X \in B) = P(\{\omega \in \Omega | X(\omega) \in B\}), B \subseteq \mathbb{R}$$

Diese Verteilung ist eindeutig definiert, wenn $P^X(B_x)$ für jedes Intervall der Form $B_x = (-\infty, x]$ bekannt ist:

$$B = \{x_1\} = \lim_{\epsilon \downarrow 0} (\{B_{x_1} \setminus B_{x_1 - \epsilon}\}) \Rightarrow P^X(B) = \lim_{\epsilon \downarrow 0} [P^X(B_{x_1}) - P^X(B_{x_1 - \epsilon})],$$

da $B_{x_1 - \epsilon} \subset B_{x_1}$



6.0 Zufallsvariablen und deren Verteilung

Verteilung eindimensionaler Zufallsvariablen

Die **Wahrscheinlichkeitsverteilung** oder kurz **Verteilung** einer Zufallsvariablen X ist definiert durch

$$P^X(B) = P(X \in B) = P(\{\omega \in \Omega | X(\omega) \in B\}), B \subseteq \mathbb{R}$$

Diese Verteilung ist eindeutig definiert, wenn $P^X(B_x)$ für jedes Intervall der Form $B_x = (-\infty, x]$ bekannt ist:

$$\boxed{B = \{x_1\}} = \lim_{\epsilon \downarrow 0} (\{B_{x_1} \setminus B_{x_1 - \epsilon}\}) \Rightarrow P^X(B) = \lim_{\epsilon \downarrow 0} [P^X(B_{x_1}) - P^X(B_{x_1 - \epsilon})],$$

da $B_{x_1 - \epsilon} \subset B_{x_1}$

$$x_1 \neq \dots \neq x_k : \boxed{B = \{x_1, \dots, x_k\}} = \bigcup_{i=1}^k \lim_{\epsilon \downarrow 0} (\{B_{x_i} \setminus B_{x_i - \epsilon}\})$$

$$\Rightarrow P^X(B) = \sum_{i=1}^k \lim_{\epsilon \downarrow 0} [P^X(B_{x_i}) - P^X(B_{x_i - \epsilon})]$$

6.0 Zufallsvariablen und deren Verteilung

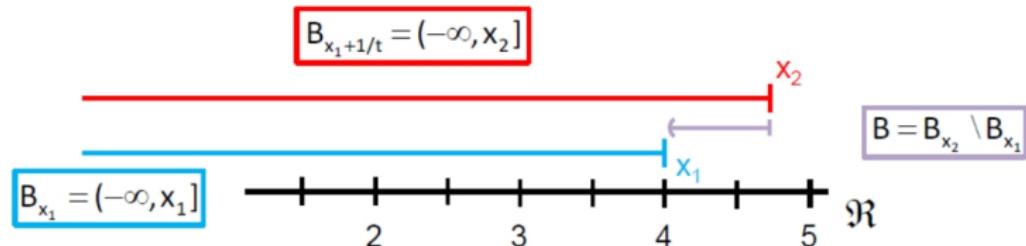
Verteilung eindimensionaler Zufallsvariablen

Die **Wahrscheinlichkeitsverteilung** oder kurz **Verteilung** einer Zufallsvariablen X ist definiert durch

$$P^X(B) = P(X \in B) = P(\{\omega \in \Omega | X(\omega) \in B\}), B \subseteq \mathbb{R}$$

Diese Verteilung ist eindeutig definiert, wenn $P^X(B_x)$ für jedes Intervall der Form $B_x = (-\infty, x]$ bekannt ist:

$$x_1 < x_2 : B = (x_1, x_2] = B_{x_2} \setminus B_{x_1} \Rightarrow P^X(B) = P^X(B_{x_2}) - P^X(B_{x_1}), \text{ da } B_{x_1} \subset B_{x_2}$$



6.0 Zufallsvariablen und deren Verteilung

Verteilung eindimensionaler Zufallsvariablen

Wahrscheinlichkeitsverteilung: $P^X(B) = P(X \in B) = P(\{\omega \in \Omega | X(\omega) \in B\})$, $B \subseteq \mathbb{R}$

→ eindeutig definiert, wenn $P^X(B_x)$ für jedes Intervall der Form $B_x = (-\infty, x]$ bekannt:

$$\boxed{B = \{x_1\}} = \lim_{\epsilon \downarrow 0} (\{B_{x_1} \setminus B_{x_1 - \epsilon}\}) \Rightarrow P^X(B) = \lim_{\epsilon \downarrow 0} [P^X(B_{x_1}) - P^X(B_{x_1 - \epsilon})],$$

da $B_{x_1 - \epsilon} \subset B_{x_1}$

$$x_1 \neq \dots \neq x_k : \boxed{B = \{x_1, \dots, x_k\}} = \bigcup_{i=1}^k \lim_{\epsilon \downarrow 0} (\{B_{x_i} \setminus B_{x_i - \epsilon}\})$$

$$\Rightarrow P^X(B) = \sum_{i=1}^k \lim_{\epsilon \downarrow 0} [P^X(B_{x_i}) - P^X(B_{x_i - \epsilon})]$$

$$x_1 < x_2 : \boxed{B = (x_1, x_2]} = B_{x_2} \setminus B_{x_1} \Rightarrow P^X(B) = P^X(B_{x_2}) - P^X(B_{x_1}), \text{ da } B_{x_1} \subset B_{x_2}$$

Beliebige Ereignisse lassen sich dann aus den halboffenen Intervallen durch Schnitte und Vereinigungen konstruieren.

6.0 Zufallsvariablen und deren Verteilung

Verteilung eindimensionaler Zufallsvariablen

Die Funktion $F = F^X : \mathbb{R} \rightarrow [0, 1]$ mit

$$F(x) = P^X((-\infty, x]) = P(X \leq x) = P(\{\omega \in \Omega | X(\omega) \leq x\}), \quad x \in \mathbb{R}$$

wird **Verteilungsfunktion** genannt.

Die Entsprechung der Verteilungsfunktion in der deskriptiven Statistik ist die empirische Verteilungsfunktion, bei der an die Stelle von Wahrscheinlichkeiten kumulierte relative Häufigkeiten treten.

$$F_N(x) = \begin{cases} 0 & \text{falls } x < x(1) \\ s_j = \frac{\#\{x_n | x_n \leq x(j)\}}{N} \text{ mit } j = \max\{\tilde{j} | x(\tilde{j}) \leq x\} & \text{falls } x(1) \leq x \end{cases}$$

$$= \frac{\#\{x_n | x_n \leq x\}}{N}$$

6.0 Zufallsvariablen und deren Verteilung

Verteilung eindimensionaler Zufallsvariablen

$F = F^X : \mathbb{R} \rightarrow [0, 1]$ mit

$$F(x) = P^X((-\infty, x]) = P(X \leq x) = P(\{\omega \in \Omega | X(\omega) \leq x\}), \quad x \in \mathbb{R}$$

Eigenschaften der Verteilungsfunktion

$$(A) \lim_{x \rightarrow -\infty} F(x) = 0, \quad \lim_{x \rightarrow \infty} F(x) = 1$$

Beweis:

$$\begin{aligned} \lim_{x \rightarrow -\infty} F(x) &= \lim_{x \rightarrow -\infty} P(\{\omega \in \Omega | X(\omega) \in (-\infty, x] \cap \mathbb{R}\}) \\ &= P(\{\omega \in \Omega | X(\omega) \in \{-\infty\} \cap \mathbb{R}\}) = P(\{\omega \in \Omega | X(\omega) = \emptyset\}) \\ &\stackrel{(*)}{=} P(\emptyset) = 0 \quad (*) \quad [\omega \in \Omega \Rightarrow X(\omega) \in \mathbb{R}] \Leftrightarrow [X(\omega) \notin \mathbb{R} \Rightarrow \omega \notin \Omega] \end{aligned}$$

$$\begin{aligned} \lim_{x \rightarrow \infty} F(x) &= \lim_{x \rightarrow \infty} P(\{\omega \in \Omega | X(\omega) \in (-\infty, x] \cap \mathbb{R}\}) \\ &= P(\{\omega \in \Omega | X(\omega) \in \mathbb{R}\}) = P(\Omega) = 1 \quad \square \end{aligned}$$

6.0 Zufallsvariablen und deren Verteilung

Verteilung eindimensionaler Zufallsvariablen

$F = F^X : \mathbb{R} \rightarrow [0, 1]$ mit

$$F(X) = P^X((-\infty, x]) = P(X \leq x) = P(\{\omega \in \Omega | X(\omega) \leq x\}), \quad x \in \mathbb{R}$$

Eigenschaften der Verteilungsfunktion

(A) $\lim_{x \rightarrow -\infty} F(x) = 0, \quad \lim_{x \rightarrow \infty} F(x) = 1$

(B) $x < y \Rightarrow F(x) < F(y)$

Beweis:

$$F(x) = P(A) \text{ mit } A = \{\omega \in \Omega | X(\omega) \leq x\}$$

$$F(y) = P(B) \text{ mit } B = \{\omega \in \Omega | X(\omega) \leq y\}$$

$$\boxed{x < y} \Rightarrow A \subseteq B \Rightarrow P(A) \leq P(B) \Leftrightarrow \boxed{F(x) \leq F(y)}$$

6.0 Zufallsvariablen und deren Verteilung

Verteilung eindimensionaler Zufallsvariablen

$F = F^X : \mathbb{R} \rightarrow [0, 1]$ mit

$$F(X) = P^X((-\infty, x]) = P(X \leq x) = P(\{\omega \in \Omega | X(\omega) \leq x\}), \quad x \in \mathbb{R}$$

Eigenschaften der Verteilungsfunktion

(A) $\lim_{x \rightarrow -\infty} F(x) = 0, \quad \lim_{x \rightarrow \infty} F(x) = 1$

(C) $\lim_{x \downarrow z} F(x) = F(z)$

(B) $x < y \Rightarrow F(x) < F(y)$

Beweis:

Setze $A_n = \{\omega \in \Omega | X(\omega) \in (-\infty, z + 1/n]\}, \quad A_0 = \Omega$

$$\Rightarrow A = \bigcap_{n=1}^{\infty} A_n = \{\omega \in \Omega | X(\omega) \in (-\infty, z]\}, \quad A_n \subset A_{n-1}, \quad A_{n-1}^c \subset A_n^c, \quad n = 1, 2, \dots$$

6.0 Zufallsvariablen und deren Verteilung

Beweis (Fortsetzung)

$$\begin{aligned} F(z) &= P(A) = P\left(\bigcap_{n=1}^{\infty} A_n\right) = 1 - P\left(\bigcup_{n=1}^{\infty} A_n^c\right) = 1 - \sum_{n=1}^{\infty} P(A_n^c \setminus A_{n-1}^c) \\ &= 1 - \lim_{N \uparrow \infty} \sum_{n=1}^N P(A_n^c \setminus A_{n-1}^c) = 1 - \lim_{N \uparrow \infty} P(A_N^c) = \lim_{N \uparrow \infty} P(A_N) \\ &= \boxed{\lim_{x \downarrow z} F(x)} \quad \square \end{aligned}$$

6.0 Zufallsvariablen und deren Verteilung

Verteilung eindimensionaler Zufallsvariablen

$F = F^X : \mathbb{R} \rightarrow [0, 1]$ mit

$$F(x) = P^X((-\infty, x]) = P(X \leq x) = P(\{\omega \in \Omega | X(\omega) \leq x\}), \quad x \in \mathbb{R}$$

Eigenschaften der Verteilungsfunktion

$$(A) \lim_{x \rightarrow -\infty} F(x) = 0, \quad \lim_{x \rightarrow \infty} F(x) = 1 \quad (C) \lim_{x \downarrow z} F(x) = F(z)$$

$$(B) x < y \Rightarrow F(x) < F(y)$$

$$(D) P(a < X \leq b) = F(b) - F(a)$$

Beweis:

Setze $A = \{\omega \in \Omega | X(\omega) \in (-\infty, a]\}$ und $B = \{\omega \in \Omega | X(\omega) \in (-\infty, b]\}$

$$\begin{aligned} \Rightarrow P(a < X \leq b) &= P(\{\omega \in \Omega | X(\omega) \in (a, b]\}) = P(B \setminus A) \underset{A \subseteq B}{=} P(B) - P(A) \\ &= P(X \leq b) - P(X \leq a) = F(b) - F(a) \quad \square \end{aligned}$$

6.0 Zufallsvariablen und deren Verteilung

Verteilung eindimensionaler Zufallsvariablen

$F = F^X : \mathbb{R} \rightarrow [0, 1]$ mit

$$F(x) = P^X((-\infty, x]) = P(X \leq x) = P(\{\omega \in \Omega | X(\omega) \leq x\}), \quad x \in \mathbb{R}$$

Eigenschaften der Verteilungsfunktion

- | | |
|--|---|
| (A) $\lim_{x \rightarrow -\infty} F(x) = 0$, $\lim_{x \rightarrow \infty} F(x) = 1$ | (C) $\lim_{x \downarrow z} F(x) = F(z)$ |
| (B) $x < y \Rightarrow F(x) < F(y)$ | (D) $P(a < X \leq b) = F(b) - F(a)$ |
| (E) $P(X > a) = 1 - F(a)$ | |

Beweis:

Setze $A = \{\omega \in \Omega | X(\omega) \leq a\} \Rightarrow A^c = \{\omega \in \Omega | X(\omega) > a\}$

$$\Rightarrow P(X > a) = P(A^c) = 1 - P(A) = \boxed{1 - F(a)} \quad \square$$

6.0 Zufallsvariablen und deren Verteilung

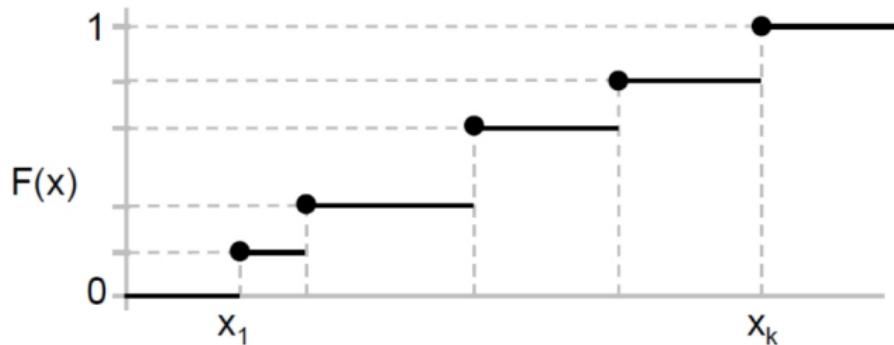
Verteilung eindimensionaler Zufallsvariablen

Spezialfall diskrete Verteilungsfunktion (Ω abzählbar)

$\Omega = \{\omega_1, \dots, \omega_n\} \Rightarrow X \in \{x_1, \dots, x_k\}$ mit $-\infty < x_1 < \dots < x_k < \infty$, $k \leq n$

$F = F^X : \mathbb{R} \rightarrow [0, 1]$ mit

$F(x) = P^X((-\infty, x]) = P(X \leq x) = P(\{\omega \in \Omega | X(\omega) \leq x\})$, $x \in \mathbb{R}$



6.0 Zufallsvariablen und deren Verteilung

Verteilung eindimensionaler Zufallsvariablen

Spezialfall diskrete Verteilungsfunktion (Ω abzählbar)

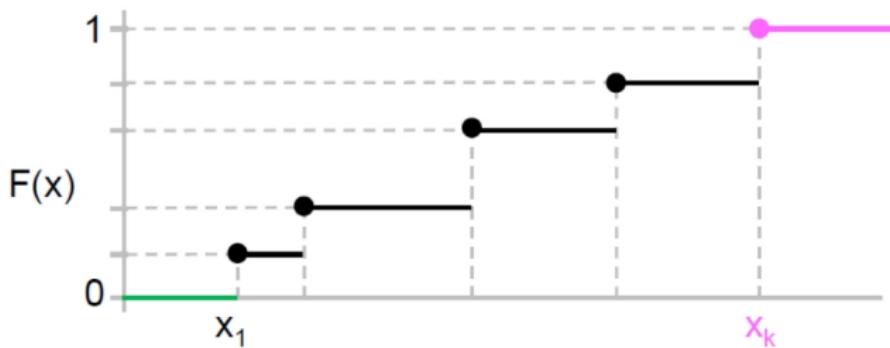
$\Omega = \{\omega_1, \dots, \omega_n\} \Rightarrow X \in \{x_1, \dots, x_k\}$ mit $-\infty < x_1 < \dots < x_k < \infty$, $k \leq n$

(A) $\lim_{x \rightarrow -\infty} F(x) = 0$, $\lim_{x \rightarrow +\infty} F(x) = 1$

$$F(x) = P(A_x) \text{ mit } A_x = \{\omega \in \Omega \mid X(\omega) \in (-\infty, x] \cap \{x_1, \dots, x_k\}\}$$

$$x < x_1 \Rightarrow A_x = \emptyset \Rightarrow P(A_x) = 0$$

$$x \geq x_k \Rightarrow A_x = \Omega \Rightarrow P(A_x) = 1$$



6.0 Zufallsvariablen und deren Verteilung

Verteilung eindimensionaler Zufallsvariablen

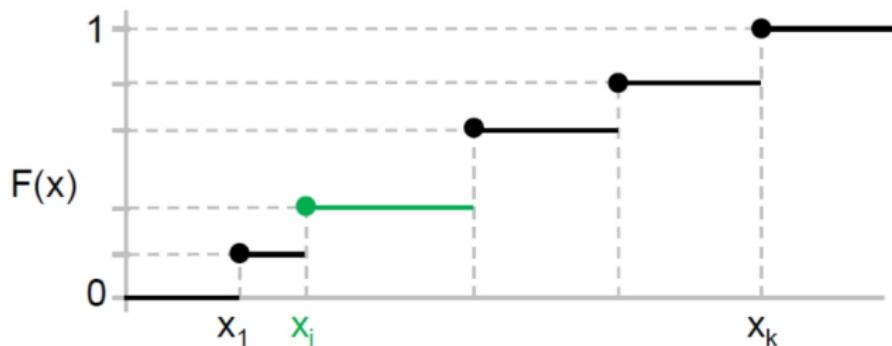
Spezialfall diskrete Verteilungsfunktion (Ω abzählbar)

$$\Omega = \{\omega_1, \dots, \omega_n\} \Rightarrow X \in \{x_1, \dots, x_k\} \text{ mit } -\infty < x_1 < \dots < x_k < \infty, k \leq n$$

(C) $\lim_{x \downarrow z} F(x) = F(z)$

$$F(x) = P(A_x) \text{ mit } A_x = \{\omega \in \Omega \mid X(\omega) \in (-\infty, x] \cap \{x_1, \dots, x_k\}\}$$

$$\begin{aligned} i=1, \dots, n-1: x_i \leq x < x_{i+1} &\Rightarrow A_x = \{\omega \in \Omega \mid X(\omega) \in \{x_1, \dots, x_i\}\} \\ &\Rightarrow P(A_x) = F(x_i) \end{aligned}$$



6.0 Zufallsvariablen und deren Verteilung

Verteilung eindimensionaler Zufallsvariablen

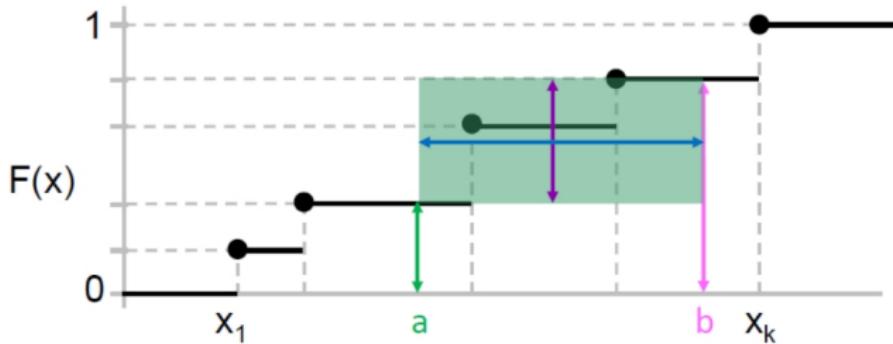
Spezialfall diskrete Verteilungsfunktion (Ω abzählbar)

$\Omega = \{\omega_1, \dots, \omega_n\} \Rightarrow X \in \{x_1, \dots, x_k\}$ mit $-\infty < x_1 < \dots < x_k < \infty$, $k \leq n$

$$(D) P(a < X \leq b) = F(b) - F(a)$$

$$A_b \setminus A_a = \{\omega \in \Omega \mid X(\omega) \in \{x_1, \dots, x_k\}, a < X(\omega) \leq b\}$$

$$P(a < X \leq b) = P(A_b \setminus A_a) = F(b) - F(a)$$



6.0 Zufallsvariablen und deren Verteilung

Verteilung eindimensionaler Zufallsvariablen

Spezialfall diskrete Verteilungsfunktion (Ω abzählbar)

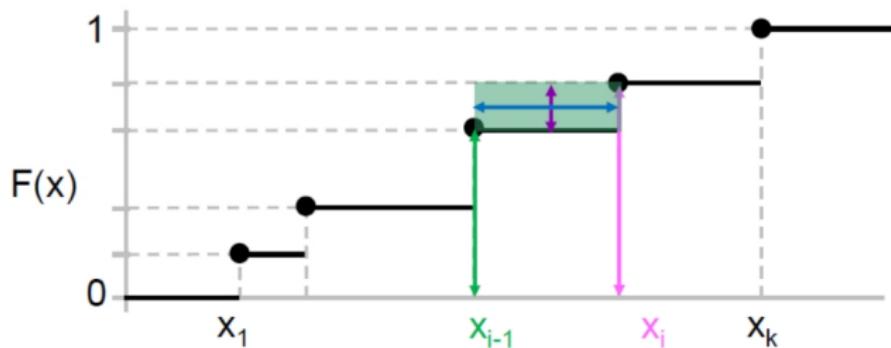
$\Omega = \{\omega_1, \dots, \omega_n\} \Rightarrow X \in \{x_1, \dots, x_k\}$ mit $-\infty < x_1 < \dots < x_k < \infty$, $k \leq n$

$$(D) \quad i=1, \dots, n: P(x_{i-1} < X \leq x_i)$$

$$(x_0 = -\infty)$$

$$A_{x_i} \setminus A_{x_{i-1}} = \{\omega \in \Omega \mid X(\omega) \in \{x_i\}\}$$

$$P(x_{i-1} < X \leq x_i) = P(A_{x_i} \setminus A_{x_{i-1}}) = P(X = x_i) = p_i$$



6.0 Zufallsvariablen und deren Verteilung

Verteilung eindimensionaler Zufallsvariablen

Spezialfall diskrete Verteilungsfunktion (Ω abzählbar)

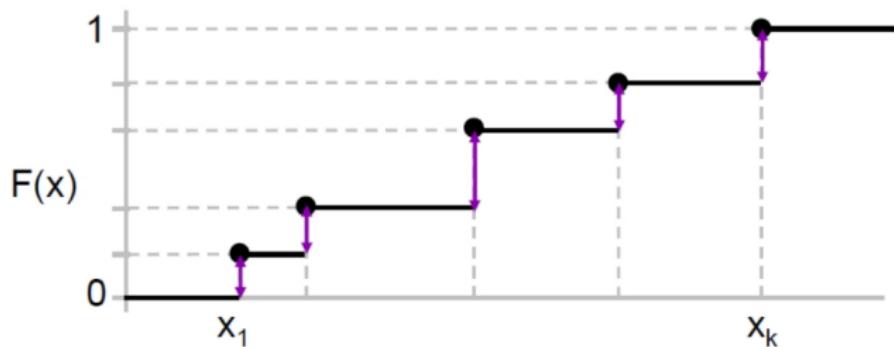
$\Omega = \{\omega_1, \dots, \omega_n\} \Rightarrow X \in \{x_1, \dots, x_k\}$ mit $-\infty < x_1 < \dots < x_k < \infty$, $k \leq n$

$$(D) \ i=1, \dots, n: P(x_{i-1} < X \leq x_i)$$

$$(x_0 = -\infty)$$

$$A_{x_i} \setminus A_{x_{i-1}} = \{\omega \in \Omega \mid X(\omega) \in \{x_i\}\}$$

$$P(x_{i-1} < X \leq x_i) = P(A_{x_i} \setminus A_{x_{i-1}}) = P(X = x_i) = p(x_i)$$



6.0 Zufallsvariablen und deren Verteilung

Verteilung eindimensionaler Zufallsvariablen

Spezialfall diskrete Verteilungsfunktion (Ω abzählbar)

$$\Omega = \{\omega_1, \dots, \omega_n\} \Rightarrow X \in \{x_1, \dots, x_k\} \text{ mit } -\infty < x_1 < \dots < x_k < \infty, k \leq n$$

Die Funktion: $p : \mathbb{R} \rightarrow [0, 1]$ mit $p(x) = P(X = x)$ heißt **Zähldichte von X** .



6.0 Zufallsvariablen und deren Verteilung

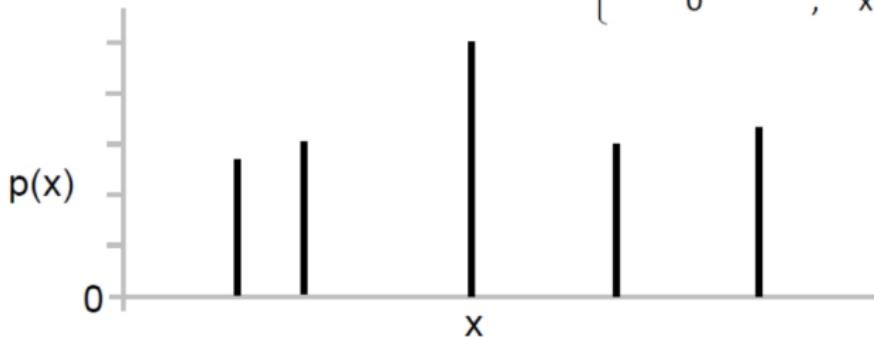
Verteilung eindimensionaler Zufallsvariablen

Spezialfall diskrete Verteilungsfunktion (Ω abzählbar)

$\Omega = \{\omega_1, \dots, \omega_n\} \Rightarrow X \in \{x_1, \dots, x_k\}$ mit $-\infty < x_1 < \dots < x_k < \infty$, $k \leq n$

Die Funktion: $p : \mathbb{R} \rightarrow [0, 1]$ mit $p(x) = P(X = x)$ heißt **Zähldichte von X**.

$$p(x) = \begin{cases} F(x_i) - F(x_{i-1}) & , \quad x \cap \{x_1, \dots, x_k\} = \{x_i\} \\ 0 & , \quad x \cap \{x_1, \dots, x_k\} = \emptyset \end{cases}$$



6.0 Zufallsvariablen und deren Verteilung

Verteilung eindimensionaler Zufallsvariablen, diskrete Verteilungsfunktion

Beispiel: Anzahl Kopf beim **5-fachen Münzwurf**

Zähldichte

x	0	1	2	3	4	5
$A_x = \{\omega \in \Omega \mid X(\omega) = x\}$						
$p(x) = P(X=x)$ $= A_x / \Omega $	1/32	5/32	10/32	10/32	5/32	1/32

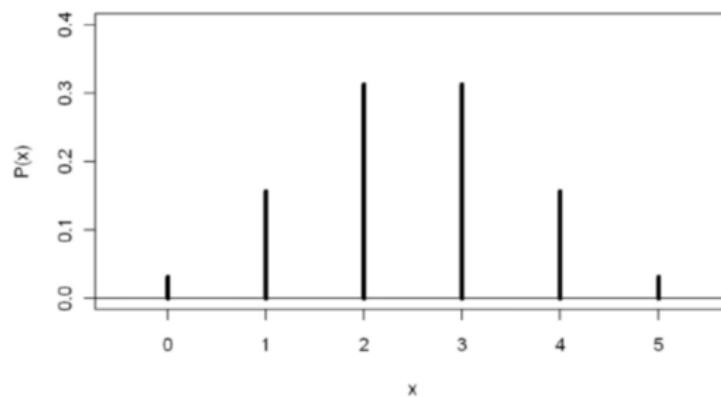
6.0 Zufallsvariablen und deren Verteilung

Verteilung eindimensionaler Zufallsvariablen, diskrete Verteilungsfunktion

Beispiel: Anzahl Kopf beim **5-fachen Münzwurf**

Zähldichte

x	0	1	2	3	4	5
$p(x)=P(X=x)$	1/32	5/32	10/32	10/32	5/32	1/32

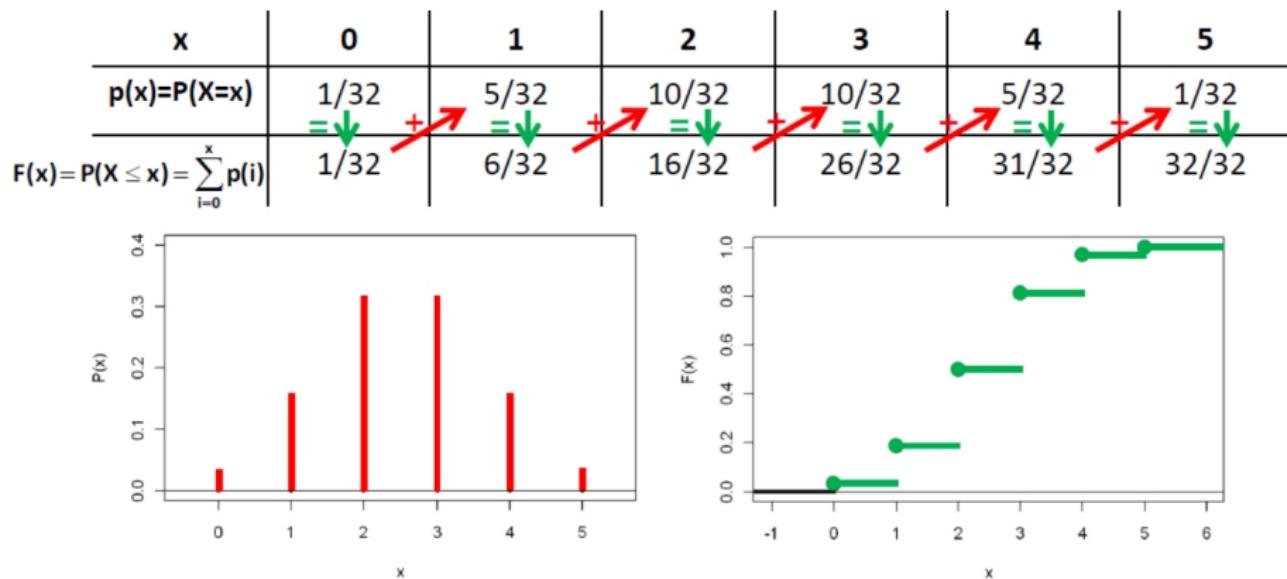


6.0 Zufallsvariablen und deren Verteilung

Verteilung eindimensionaler Zufallsvariablen, diskrete Verteilungsfunktion

Beispiel: Anzahl Kopf beim **5-fachen Münzwurf**

Zähldichte und Verteilungsfunktion



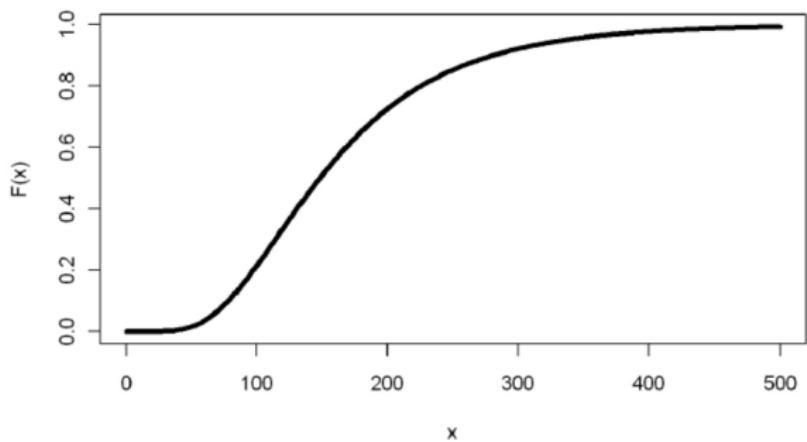
6.0 Zufallsvariablen und deren Verteilung

Verteilung eindimensionaler Zufallsvariablen

Spezialfall stetige Verteilungsfunktion (Ω überabzählbar)

$\omega \in \Omega : X(\omega) \in B, B \subseteq \mathbb{R}$

$F = F^X : \mathbb{R} \rightarrow [0, 1]$ mit $F(x) = P^X((-\infty, x]) = P(X \leq x) = P(\{\omega \in \Omega | X(\omega) \leq x\}), x \in \mathbb{R}$



6.0 Zufallsvariablen und deren Verteilung

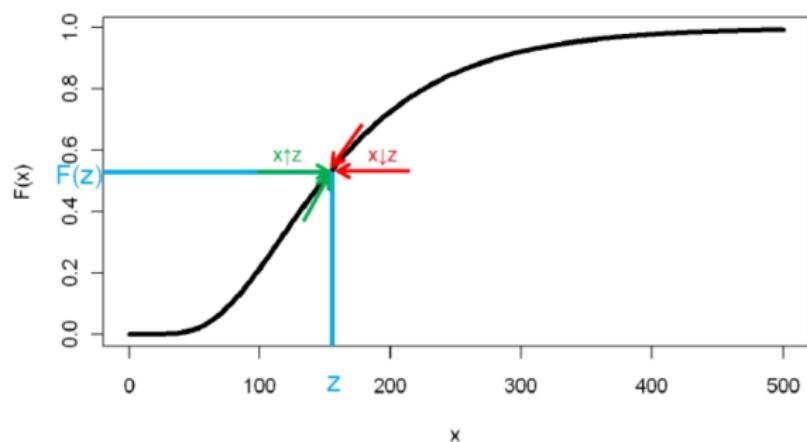
Verteilung eindimensionaler Zufallsvariablen

Spezialfall stetige Verteilungsfunktion (Ω überabzählbar)

$\omega \in \Omega : X(\omega) \in B, B \subseteq \mathbb{R}$

$F = F^X : \mathbb{R} \rightarrow [0, 1]$ mit $F(x) = P^X((-\infty, x]) = P(X \leq x) = P(\{\omega \in \Omega | X(\omega) \leq x\}), x \in \mathbb{R}$

$$(C) \lim_{x \downarrow z} F(x) = F(z) = \lim_{x \uparrow z} F(x)$$



6.0 Zufallsvariablen und deren Verteilung

Verteilung eindimensionaler Zufallsvariablen

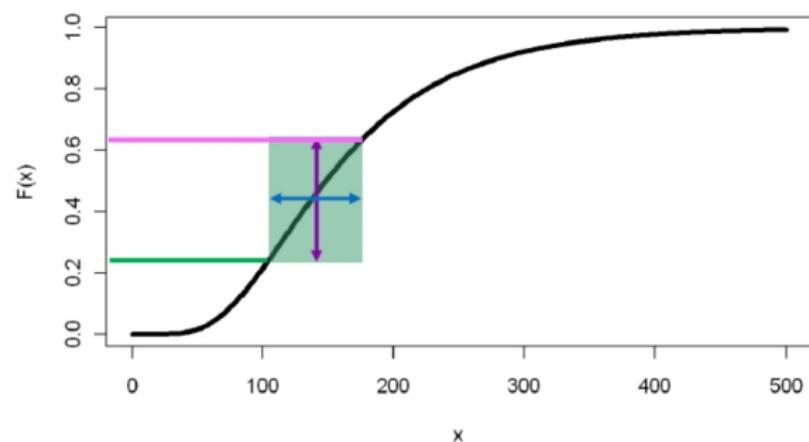
Spezialfall stetige Verteilungsfunktion (Ω überabzählbar)

$$\omega \in \Omega : X(\omega) \in B, B \subseteq \mathbb{R}$$

$$F = F^X : \mathbb{R} \rightarrow [0, 1] \text{ mit } F(x) = P^X((-\infty, x]) = P(X \leq x) = P(\{\omega \in \Omega | X(\omega) \leq x\}), \quad x \in \mathbb{R}$$

$$(C) \lim_{x \rightarrow z} F(x) = F(z) = \lim_{x \uparrow z} F(x)$$

$$(D) P(a < X \leq b) = F(b) - F(a)$$



6.0 Zufallsvariablen und deren Verteilung

Verteilung eindimensionaler Zufallsvariablen

Spezialfall stetige Verteilungsfunktion (Ω überabzählbar)

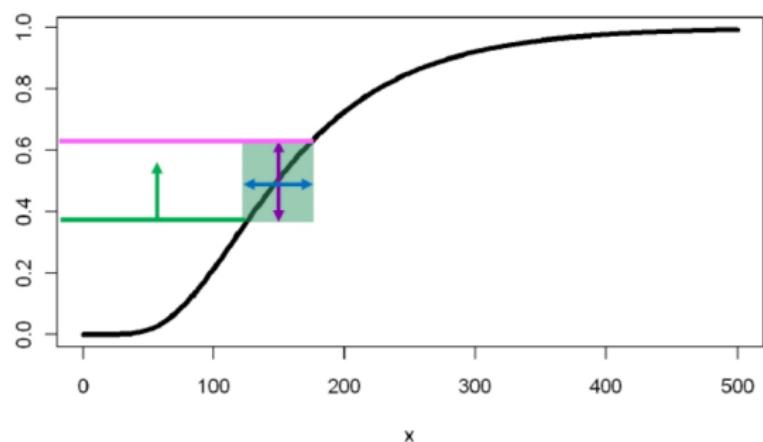
$\omega \in \Omega : X(\omega) \in B, B \subseteq \mathbb{R}$

$F = F^X : \mathbb{R} \rightarrow [0, 1]$ mit $F(x) = P^X((-\infty, x]) = P(X \leq x) = P(\{\omega \in \Omega | X(\omega) \leq x\}), x \in \mathbb{R}$

$$(C) \lim_{x \downarrow z} F(x) = F(z) = \lim_{x \uparrow z} F(x)$$

$$(D) P(a < X \leq b) = F(b) - F(a)$$

$$\begin{aligned} P(X = b) &= \lim_{a \uparrow b} P(a < X \leq b) \\ &= F(b) - \lim_{a \uparrow b} F(a) = F(b) - F(b) = 0 \end{aligned}$$



6.0 Zufallsvariablen und deren Verteilung

Verteilung eindimensionaler Zufallsvariablen

Spezialfall stetige Verteilungsfunktion (Ω überabzählbar)

$\omega \in \Omega : X(\omega) \in B, B \subseteq \mathbb{R}$

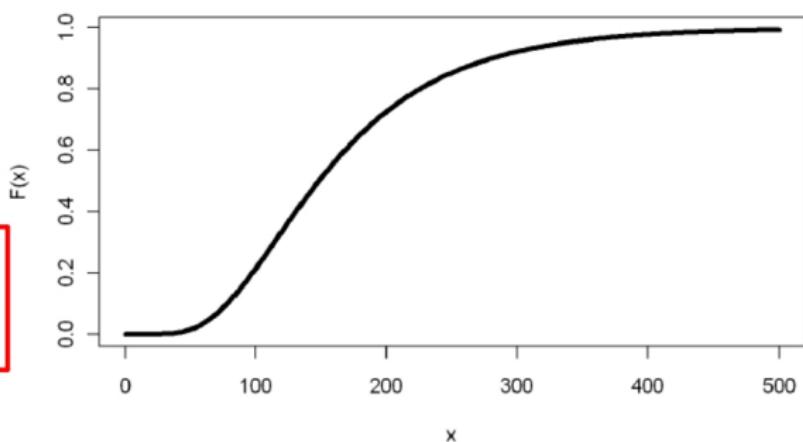
$F = F^X : \mathbb{R} \rightarrow [0, 1]$ mit $F(x) = P^X((-\infty, x]) = P(X \leq x) = P(\{\omega \in \Omega | X(\omega) \leq x\}), x \in \mathbb{R}$

$$(C) \lim_{x \downarrow z} F(x) = F(z) = \lim_{x \uparrow z} F(x)$$

$$(D) P(a < X \leq b) = F(b) - F(a)$$

$$(F) P(X = x) = 0, x \in \mathfrak{N}$$

$$\begin{aligned} (G) P(a < X \leq b) &= P(a \leq X \leq b) \\ &= P(a \leq X < b) = P(a < X < b) \\ &= F(b) - F(a) \end{aligned}$$



6.0 Zufallsvariablen und deren Verteilung

Verteilung eindimensionaler Zufallsvariablen

Spezialfall stetige Verteilungsfunktion (Ω überabzählbar)

$\omega \in \Omega : X(\omega) \in B, B \subseteq \mathbb{R}$

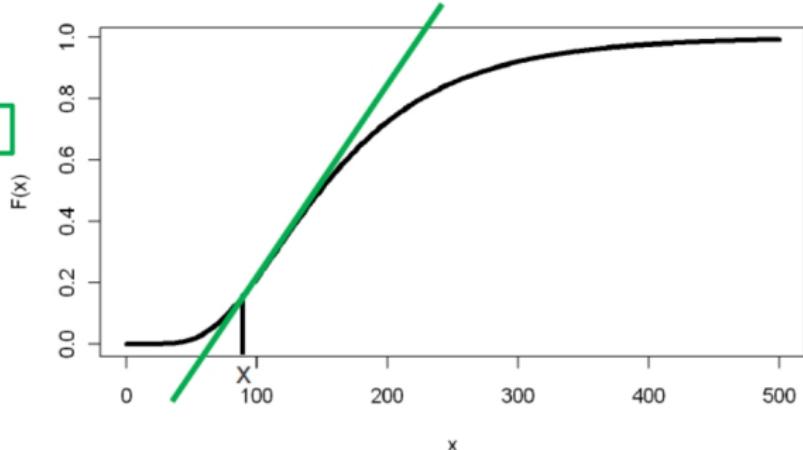
$F = F^X : \mathbb{R} \rightarrow [0, 1]$ mit $F(x) = P^X((-\infty, x]) = P(X \leq x) = P(\{\omega \in \Omega | X(\omega) \leq x\}), x \in \mathbb{R}$

$$\lim_{a \rightarrow b} P(a < X \leq b) = 0$$

$$\lim_{c \downarrow 0} \frac{F(x+c) - F(x)}{c} = F'(x) = f(x)$$

Die Funktion $f(x)$ wird **Dichtefunktion** bzw. **Dichte** von X genannt.

Sie beschreibt die Steigung (Grad der Verdichtung) der Verteilung X



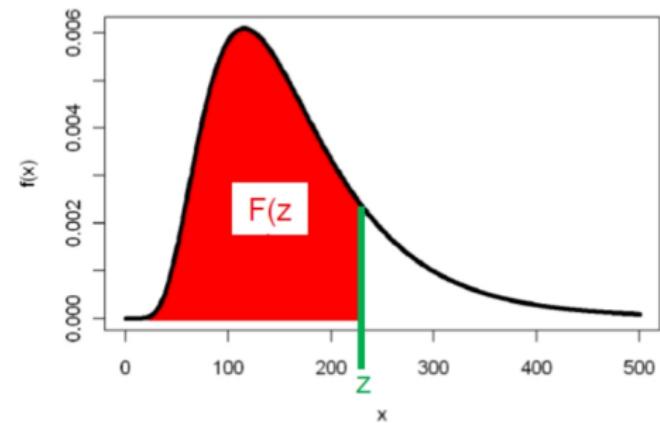
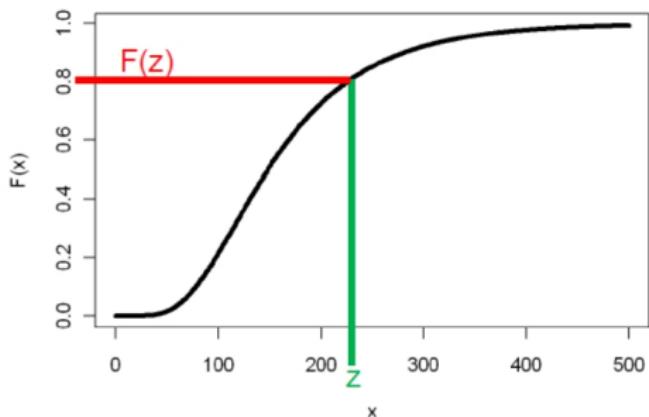
6.0 Zufallsvariablen und deren Verteilung

Verteilung eindimensionaler Zufallsvariablen

Spezialfall stetige Verteilungsfunktion (Ω überabzählbar)

$$F'(x) = f(x), \quad F(x) = \int_{-\infty}^x f(t) dt, \quad x \in \mathfrak{N}, \quad \int_{-\infty}^{\infty} f(t) dt = 1$$

$$P(X \leq z) = F(z) = \int_{-\infty}^z f(t) dt$$



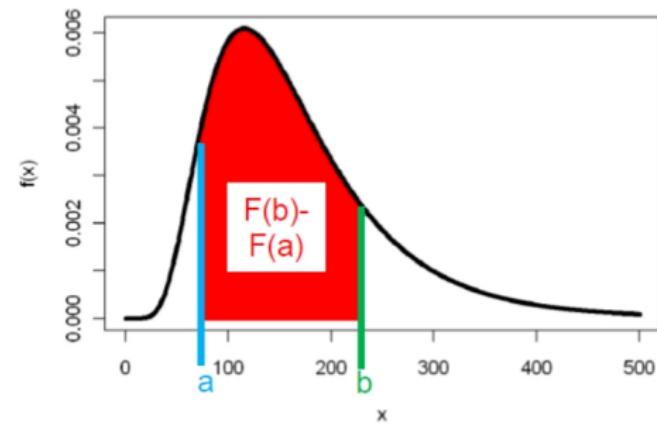
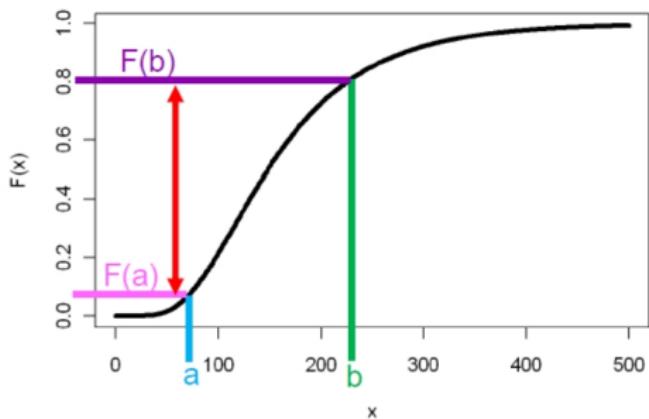
6.0 Zufallsvariablen und deren Verteilung

Verteilung eindimensionaler Zufallsvariablen

Spezialfall stetige Verteilungsfunktion (Ω überabzählbar)

$$F'(x) = f(x), \quad F(x) = \int_{-\infty}^x f(t)dt, \quad x \in \mathfrak{N}, \quad \int_{-\infty}^{\infty} f(t)dt = 1$$

$$P(a < X \leq b) = [F(b) - F(a)] = \int_a^b f(t)dt$$



6.0 Zufallsvariablen und deren Verteilung

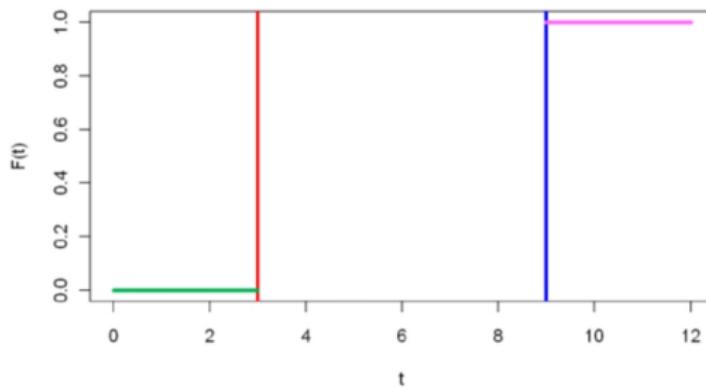
Verteilung eindimensionaler Zufallsvariablen, stetige Verteilungsfunktion

Beispiel: **Mausaktivität, exakter Zeitpunkt T des ersten Mausclicks**

Annahme: T fällt in jedes Intervall gleicher Länge c zwischen t_{\min} und t_{\max} mit derselben Wahrscheinlichkeit

$$P(T < t_{\min}) = 0 = F(t_{\min}) \Rightarrow F(t) = 0, t \leq t_{\min}$$

$$P(T > t_{\max}) = 0 = 1 - F(t_{\max}) \Rightarrow F(t) = 1, t \geq t_{\max}$$



6.0 Zufallsvariablen und deren Verteilung

Verteilung eindimensionaler Zufallsvariablen, stetige Verteilungsfunktion

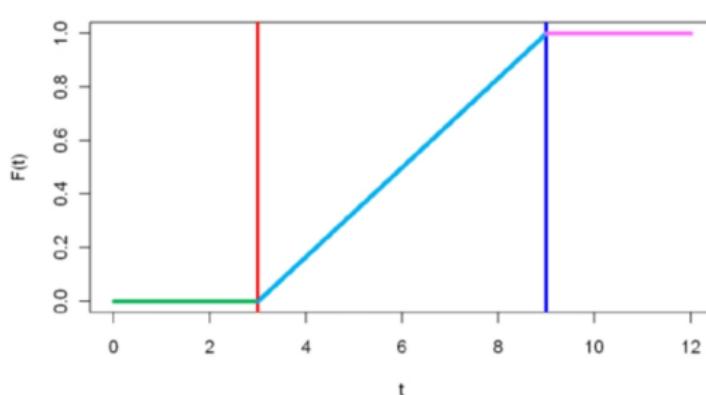
Beispiel: **Mausaktivität, exakter Zeitpunkt T des ersten Mausclicks**

Annahme: T fällt in jedes Intervall gleicher Länge c zwischen t_{\min} und t_{\max} mit derselben Wahrscheinlichkeit

$$F(t) = 0, t \leq t_{\min}$$

$$F(t) = \frac{t - t_{\min}}{t_{\max} - t_{\min}}, t_{\min} < t < t_{\max}$$

$$F(t) = 1, t \geq t_{\max}$$



Wahrscheinlichkeitsdichte

$$t \leq t_{\min} : F'(t) = f(t) = \partial 0 / \partial t = 0$$

$$t_{\min} < t < t_{\max} :$$

$$F'(t) = f(t) = \partial \left(\frac{t - t_{\min}}{t_{\max} - t_{\min}} \right) / \partial t = \frac{1}{t_{\max} - t_{\min}}$$

$$t > t_{\max} : F'(t) = f(t) = \partial 1 / \partial t = 0$$

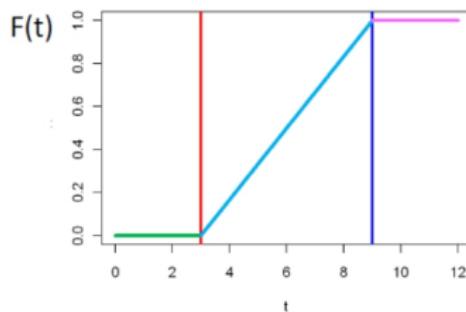
6.0 Zufallsvariablen und deren Verteilung

Verteilung eindimensionaler Zufallsvariablen, stetige Verteilungsfunktion

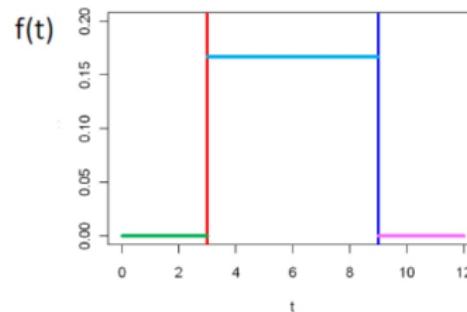
Beispiel: **Mausaktivität, exakter Zeitpunkt T des ersten Mausclicks**

Annahme: T fällt in jedes Intervall gleicher Länge c zwischen t_{\min} und t_{\max} mit derselben Wahrscheinlichkeit

$$\begin{aligned} F(t) &= 0, t \leq t_{\min} & F(t) &= 1, t \geq t_{\max} \\ F(t) &= \frac{t - t_{\min}}{t_{\max} - t_{\min}}, t_{\min} < t < t_{\max} \end{aligned}$$



$$\begin{aligned} f(t) &= 0, t \leq t_{\min} & f(t) &= 0, t \geq t_{\max} \\ f(t) &= \frac{1}{t_{\max} - t_{\min}}, t_{\min} < t < t_{\max} \end{aligned}$$



6.0 Zufallsvariablen und deren Verteilung

Verteilung mehrdimensionaler Zufallsvariablen

Die **Wahrscheinlichkeitsverteilung** oder kurz **Verteilung** einer zweidimensionalen Zufallsvariablen (X, Y) ist definiert durch

$$P^{(X,Y)}(B) = P((X, Y) \in B) = P(\{\omega \in \Omega | (X(\omega), Y(\omega)) \in B\}), B \subseteq \mathbb{R}^2$$

Die Funktion $F = F^{(X,Y)} : \mathbb{R}^2 \rightarrow [0, 1]$ mit

$$\begin{aligned} F(x, y) &= P^{(X,Y)}((-∞, x] \times (-∞, y]) = P(X \leq x, Y \leq y) \\ &= P(\{\omega \in \Omega | X(\omega) \leq x, Y(\omega) \leq y\}), x, y \in \mathbb{R}, \end{aligned}$$

wird **Verteilungsfunktion** von (X, Y) genannt.

6.0 Zufallsvariablen und deren Verteilung

Verteilung mehrdimensionaler Zufallsvariablen

$$P^{(X,Y)}(B) = P((X, Y) \in B) = P(\{\omega \in \Omega | (X(\omega), Y(\omega)) \in B\}), B \subseteq \mathbb{R}^2$$

$$F(x, y) = P(X \leq x, Y \leq y) = P(\{\omega \in \Omega | X(\omega) \leq x, Y(\omega) \leq y\}), x, y \in \mathbb{R}$$

Eigenschaften

$$1. \lim_{x \rightarrow -\infty} F(x, y) = \lim_{y \rightarrow -\infty} F(x, y) = \lim_{x,y \rightarrow -\infty} F(x, y) = 0$$

Beweis:

$$A = \{\omega \in \Omega | X(\omega) \leq x, Y(\omega) \leq y\} = A_x \cap A_y \text{ mit } A_x = \{\omega \in \Omega | X(\omega) \leq x\}$$

$$A_y = \{\omega \in \Omega | Y(\omega) \leq y\}$$

$$F(x, y) = P(A) = P(A_x \cap A_y) = 1 - P(A_x^c \cup A_y^c)$$

$$\boxed{\lim_{x \rightarrow -\infty} F(x, y)} = 1 - (P(A_{-\infty}^c \cup A_y^c)) = 1 - P(\Omega \cup A_y^c)$$

$$= 1 - [P(\Omega) + P(A_y^c) - P(A_y^c)] = 1 - 1 = \boxed{0} \quad \square$$

6.0 Zufallsvariablen und deren Verteilung

Verteilung mehrdimensionaler Zufallsvariablen

$$P^{(X,Y)}(B) = P((X, Y) \in B) = P(\{\omega \in \Omega | (X(\omega), Y(\omega)) \in B\}), B \subseteq \mathbb{R}^2$$

$$F(x, y) = P(X \leq x, Y \leq y) = P(\{\omega \in \Omega | X(\omega) \leq x, Y(\omega) \leq y\}), x, y \in \mathbb{R}$$

Eigenschaften

$$1. \lim_{x \rightarrow -\infty} F(x, y) = \lim_{y \rightarrow -\infty} F(x, y) = \lim_{x, y \rightarrow -\infty} F(x, y) = 0, \quad \boxed{\lim_{x, y \rightarrow \infty} F(x, y) = 1}$$

$$2. \lim_{y \rightarrow \infty} F(x, y) = F^X(x), \quad \lim_{x \rightarrow \infty} F(x, y) = F^Y(y)$$

Beweis:

$$A = \{\omega \in \Omega | X(\omega) \leq x, Y(\omega) \leq y\} = A_x \cap A_y \text{ mit } A_x = \{\omega \in \Omega | X(\omega) \leq x\} \\ A_y = \{\omega \in \Omega | Y(\omega) \leq y\}$$

$$F(x, y) = P(A) = P(A_x \cap A_y) = 1 - P(A_x^c \cup A_y^c)$$

$$\boxed{\lim_{x \rightarrow \infty} F(x, y)} = 1 - P(A_\infty^c \cup A_y^c) = 1 - P(\emptyset \cup A_y^c) = 1 - P(A_y^c) = P(A_y) = \boxed{F^Y(y)}$$

6.0 Zufallsvariablen und deren Verteilung

Verteilung mehrdimensionaler Zufallsvariablen

$$P^{(X,Y)}(B) = P((X, Y) \in B) = P(\{\omega \in \Omega | (X(\omega), Y(\omega)) \in B\}), B \subseteq \mathbb{R}^2$$

$$F(x, y) = P(X \leq x, Y \leq y) = P(\{\omega \in \Omega | X(\omega) \leq x, Y(\omega) \leq y\}), x, y \in \mathbb{R}$$

Eigenschaften

$$1. \lim_{x \rightarrow -\infty} F(x, y) = \lim_{y \rightarrow -\infty} F(x, y) = \lim_{x,y \rightarrow -\infty} F(x, y) = 0, \quad \boxed{\lim_{x,y \rightarrow \infty} F(x, y) = 1}$$

$$2. \lim_{y \rightarrow \infty} F(x, y) = F^X(x), \quad \lim_{x \rightarrow \infty} F(x, y) = F^Y(y)$$

Beweis (Fortsetzung):

$$\boxed{\lim_{x \rightarrow \infty} F(x, y) = F^Y(y)}$$

Beweis für $\lim_{y \rightarrow \infty} F(x, y) = F^X(x)$ analog.

$$\boxed{\lim_{x,y \rightarrow \infty} F(x, y) = \lim_{y \rightarrow \infty} F^Y(y) = 1}$$

$F^X(x)$ und $F^Y(y)$ heißen
Randverteilungen von X und Y

□

6.0 Zufallsvariablen und deren Verteilung

Verteilung mehrdimensionaler Zufallsvariablen

$$P^{(X,Y)}(B) = P((X, Y) \in B) = P(\{\omega \in \Omega | (X(\omega), Y(\omega)) \in B\}), B \subseteq \mathbb{R}^2$$

$$F(x, y) = P(X \leq x, Y \leq y) = P(\{\omega \in \Omega | X(\omega) \leq x, Y(\omega) \leq y\}), x, y \in \mathbb{R}$$

Eigenschaften

$$1. \lim_{x \rightarrow -\infty} F(x, y) = \lim_{y \rightarrow -\infty} F(x, y) = \lim_{x, y \rightarrow -\infty} F(x, y) = 0, \lim_{x, y \rightarrow \infty} F(x, y) = 1$$

$$2. \lim_{y \rightarrow \infty} F(x, y) = F^X(x), \lim_{x \rightarrow \infty} F(x, y) = F^Y(y)$$

$$3. x_1 < x_2 \Rightarrow F(x_1, y) \leq F(x_2, y), y_1 < y_2 \Rightarrow F(x, y_1) \leq F(x, y_2)$$

Beweis

$$F(x_i, y) = P(A_i) \text{ mit } A_i = \{\omega \in \Omega | X(\omega) \leq x_i, Y(\omega) \leq y\}$$

Beweis für
 $F(x, y_1)$ analog

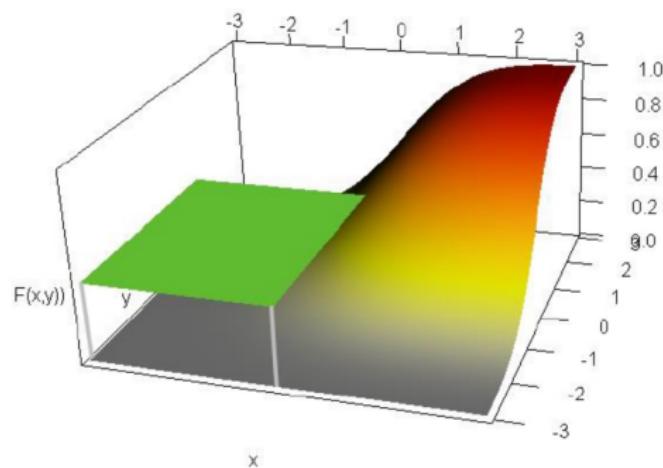
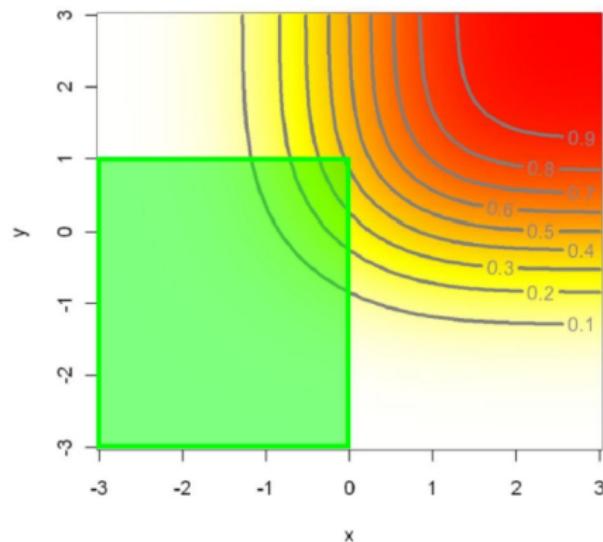
$$x_1 < x_2 \Rightarrow A_1 \subseteq A_2 \Rightarrow P(A_1) \leq P(A_2) \Leftrightarrow F(x_1, y) \leq F(x_2, y)$$

□

6.0 Zufallsvariablen und deren Verteilung

Verteilung mehrdimensionaler Zufallsvariablen

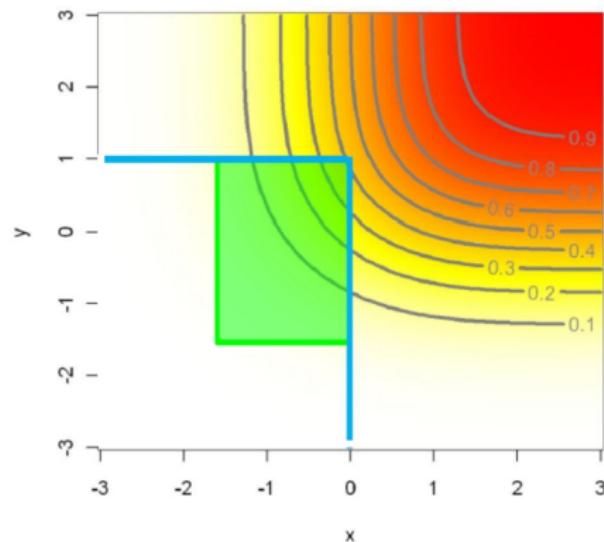
$$F(x,y) = P(X \leq x, Y \leq y), \quad x,y \in \mathbb{R}$$



6.0 Zufallsvariablen und deren Verteilung

Verteilung mehrdimensionaler Zufallsvariablen

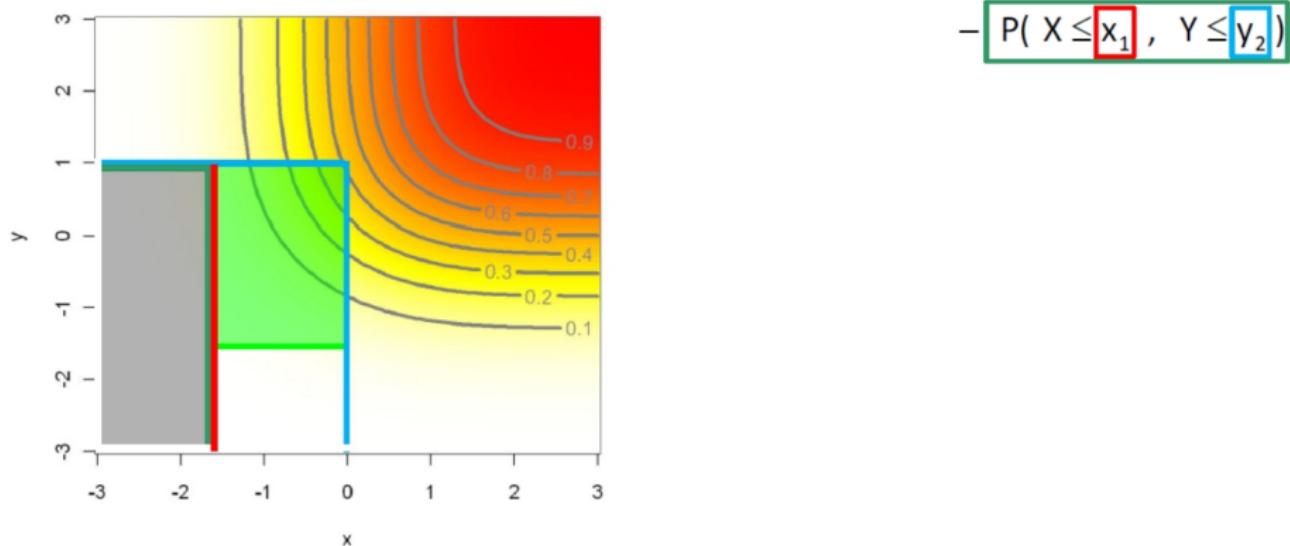
$$P(\boxed{x_1} < X \leq \boxed{x_2}, \boxed{y_1} < Y \leq \boxed{y_2}) = P(X \leq \boxed{x_2}, Y \leq \boxed{y_2})$$



6.0 Zufallsvariablen und deren Verteilung

Verteilung mehrdimensionaler Zufallsvariablen

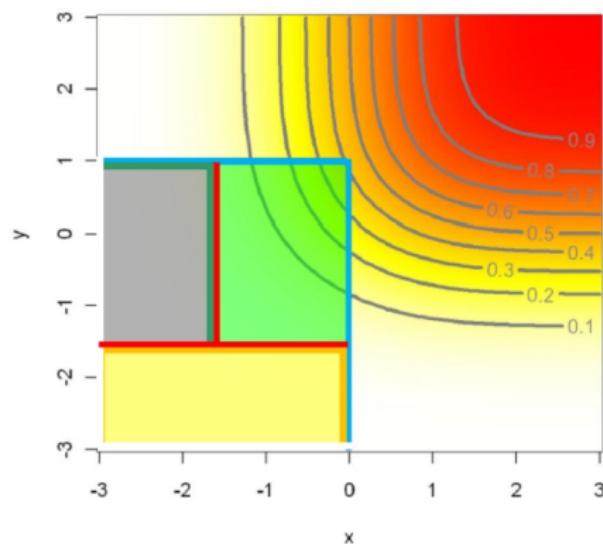
$$P(\boxed{x_1} < X \leq \boxed{x_2}, \boxed{y_1} < Y \leq \boxed{y_2}) = P(X \leq \boxed{x_2}, Y \leq \boxed{y_2}) - P(X \leq \boxed{x_1}, Y \leq \boxed{y_2})$$



6.0 Zufallsvariablen und deren Verteilung

Verteilung mehrdimensionaler Zufallsvariablen

$$P(\boxed{x_1} < X \leq \boxed{x_2}, \quad \boxed{y_1} < Y \leq \boxed{y_2}) = P(X \leq \boxed{x_2}, \quad Y \leq \boxed{y_2})$$



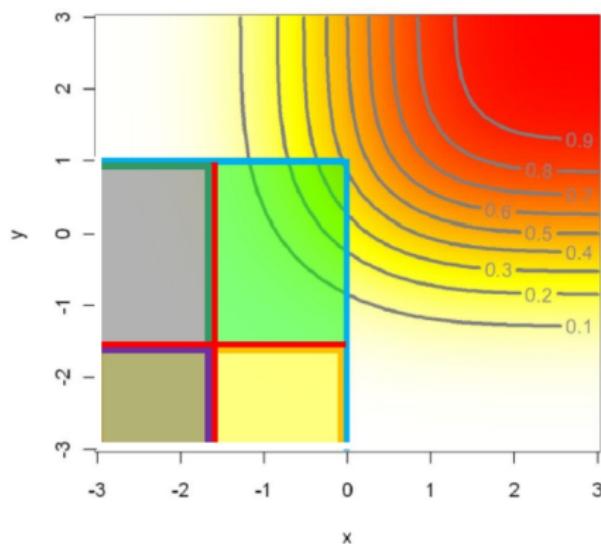
$$- P(X \leq x_1, Y \leq y_2)$$

$$- P(X \leq x_2, Y \leq y_1)$$

6.0 Zufallsvariablen und deren Verteilung

Verteilung mehrdimensionaler Zufallsvariablen

$$P(\boxed{x_1} < X \leq \boxed{x_2}, \boxed{y_1} < Y \leq \boxed{y_2}) = P(\boxed{X \leq x_2}, \boxed{Y \leq y_2})$$



$$\begin{aligned}
 & - P(\boxed{X \leq x_1}, \boxed{Y \leq y_2}) \\
 & - P(\boxed{X \leq x_2}, \boxed{Y \leq y_1}) \\
 & + P(\boxed{X \leq x_1}, \boxed{Y \leq y_1})
 \end{aligned}$$

$$= F(x_2, y_2) - F(x_1, y_2) - F(x_2, y_1) + F(x_1, y_1)$$

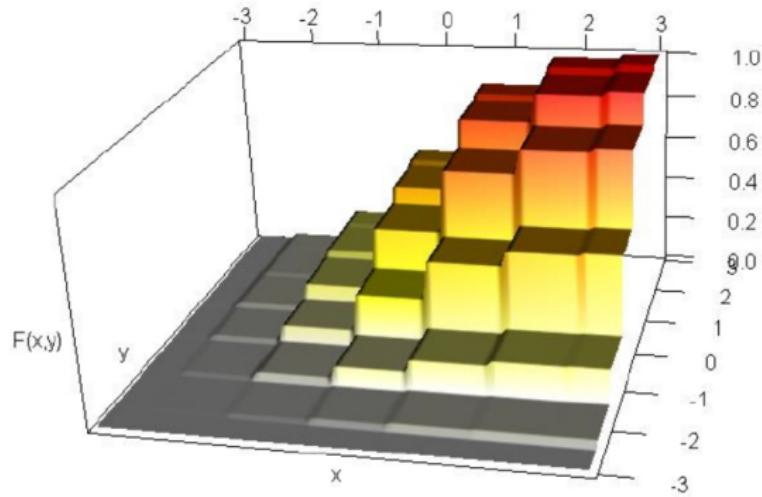
6.0 Zufallsvariablen und deren Verteilung

Verteilung mehrdimensionaler Zufallsvariablen

Spezialfall diskrete Verteilungsfunktion (Ω abzählbar): $\Omega = \{\omega_1, \dots, \omega_n\}$

$\Rightarrow X \in \{X(\omega_1), \dots, X(\omega_n)\} = \{x_1, \dots, x_n\}$ mit $-\infty < x_1 \leq \dots \leq x_n < \infty$

$Y \in \{Y(\omega_1), \dots, Y(\omega_n)\} = \{y_1, \dots, y_n\}$ mit $-\infty < y_1 \leq \dots \leq y_n < \infty$



6.0 Zufallsvariablen und deren Verteilung

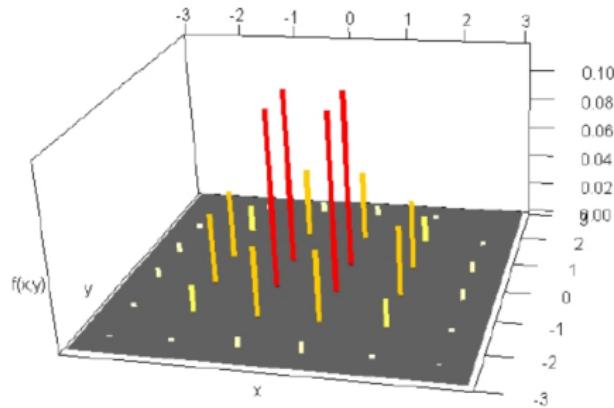
Verteilung mehrdimensionaler Zufallsvariablen

Spezialfall diskrete Verteilungsfunktion (Ω abzählbar): $\Omega = \{\omega_1, \dots, \omega_n\}$

$\Rightarrow X \in \{X(\omega_1), \dots, X(\omega_n)\} = \{x_1, \dots, x_n\}$ mit $-\infty < x_1 \leq \dots \leq x_n < \infty$

$Y \in \{Y(\omega_1), \dots, Y(\omega_n)\} = \{y_1, \dots, y_n\}$ mit $-\infty < y_1 \leq \dots \leq y_n < \infty$

Die Funktion $p : \mathbb{R}^2 \rightarrow [0, 1]$ mit $p(x, y) = P(X = x, Y = y)$ heißt **Zähldichte von (X, Y)**



$$p(x, y) = \begin{cases} F(x_i, y_i) - F(x_{i-1}, y_i) & , x_i \in \{x_1, \dots, x_n\} \\ -F(x_i, y_{i-1}) + F(x_{i-1}, y_{i-1}) & , y_i \in \{y_1, \dots, y_n\} \\ 0 & , \text{sonst} \end{cases}$$

6.0 Zufallsvariablen und deren Verteilung

Verteilung mehrdimensionaler Zufallsvariablen, diskrete Verteilungsfunktion

Beispiel: **4-facher Münzwurf**, X = Anzahl Kopf nach 4 Würfen, Y = Anzahl Kopf nach 2 Würfen

Zähldichte

$\downarrow y \quad x \rightarrow$	0	1	2	3	4
0					
1					
2					

6.0 Zufallsvariablen und deren Verteilung

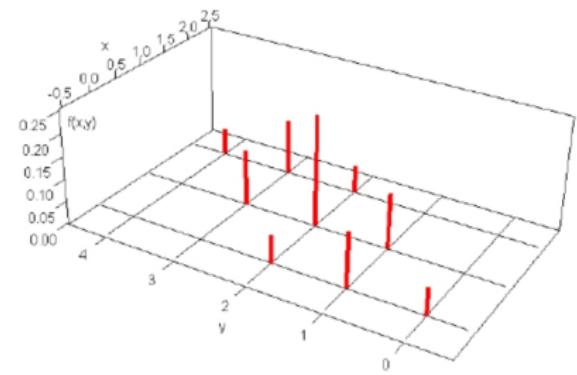
Verteilung mehrdimensionaler Zufallsvariablen, diskrete Verteilungsfunktion

Beispiel: **4-facher Münzwurf**, X = Anzahl Kopf nach 4 Würfen, Y = Anzahl Kopf nach 2 Würfen

Zähldichte

$\downarrow y \rightarrow$	0	1	2	3	4
0	1/16	2/16	1/16		
1		2/16	4/16	2/16	
2			1/16	2/16	1/16

$$p(x,y)$$



6.0 Zufallsvariablen und deren Verteilung

Verteilung mehrdimensionaler Zufallsvariablen, diskrete Verteilungsfunktion

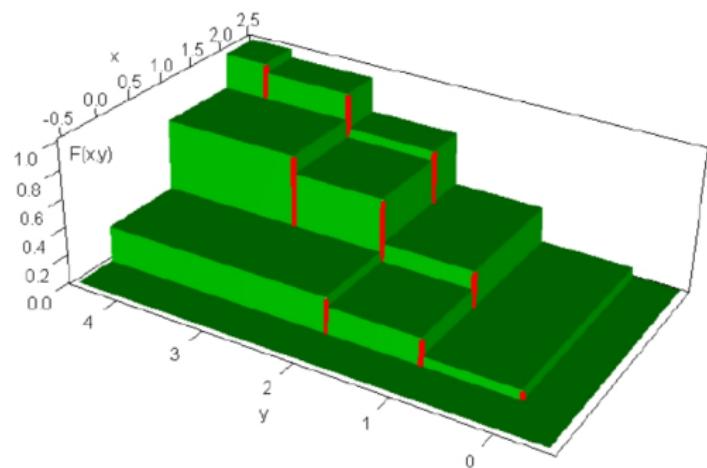
Beispiel: **4-facher Münzwurf**, X = Anzahl Kopf nach 4 Würfen, Y = Anzahl Kopf nach 2 Würfen

Zähldichte

$\downarrow y$	0	1	2	3	4
$\rightarrow x$					
0	$1/16$	$2/16$	$1/16$		
	$\downarrow =$	$\downarrow =$	$\downarrow =$		
	$1/16$	$3/16$	$4/16$		
1		$2/16$	$4/16$	$2/16$	
	$\downarrow =$	$\downarrow =$	$\downarrow =$		
	$5/16$	$10/16$	$12/16$		
2		$1/16$	$2/16$	$1/16$	
	$\downarrow =$	$\downarrow =$	$\downarrow =$		
	$11/16$	$15/16$	$16/16$		

$$p(x,y)$$

$$F(x,y)$$



6.0 Zufallsvariablen und deren Verteilung

Verteilung mehrdimensionaler Zufallsvariablen

Spezialfall stetige Verteilungsfunktion (Ω überabzählbar)

$\omega \in \Omega : (X(\omega), Y(\omega)) \in B, B \subseteq \mathbb{R}^2$

$F = F^{XY} : \mathbb{R}^2 \rightarrow [0, 1]$ mit

$F(x, y) = P(X \leq x, Y \leq y) = P(\{\omega \in \Omega | X(\omega) \leq x, Y(\omega) \leq y\}), x, y \in \mathbb{R}$

Die Funktion $f : \mathbb{R}^2 \rightarrow [0, 1]$ mit $f(x, y) = \frac{\delta^2 F(x, y)}{\delta x \delta y}$

heißt die **gemeinsame Dichtefunktion** von X und Y .

Es gilt:

$$F(x, y) = P(X \leq x, Y \leq y) = \int_{-\infty}^x \int_{-\infty}^y f(s, t) dt ds, \quad \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(s, t) dt ds = 1$$

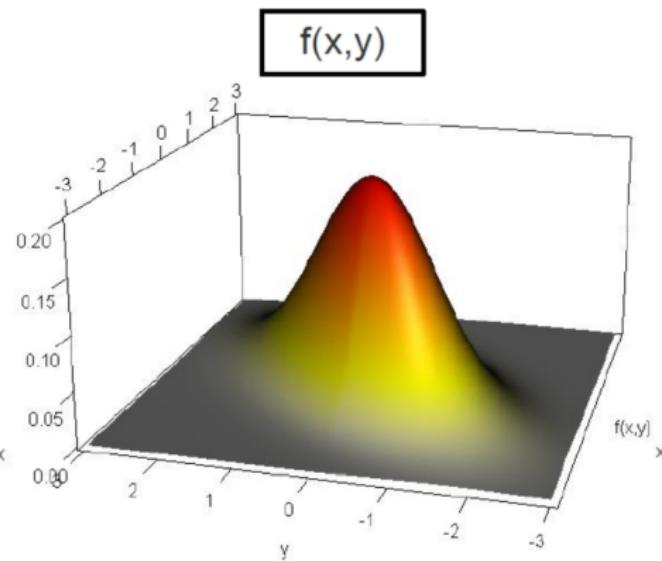
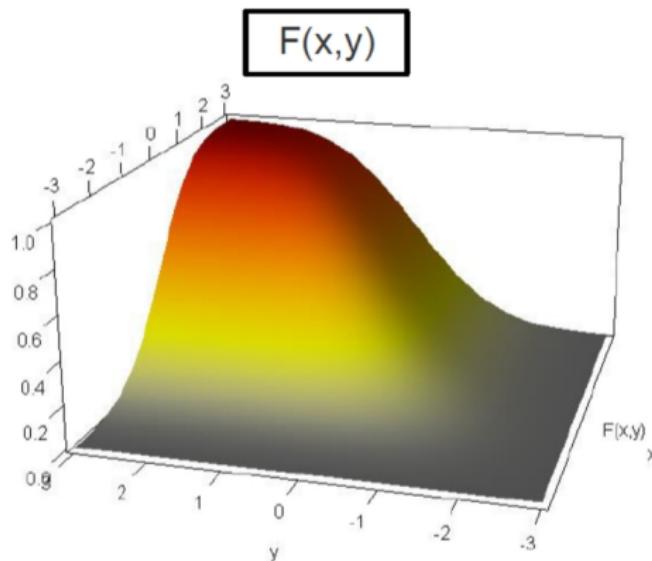
Die **Randdichten** f^X und f^Y von X und Y sind definiert durch

$$f^X(x) = \int_{-\infty}^{\infty} f(x, t) dt \text{ und } f^Y(y) = \int_{-\infty}^{\infty} f(s, y) ds$$

6.0 Zufallsvariablen und deren Verteilung

Verteilung mehrdimensionaler Zufallsvariablen

Spezialfall stetige Verteilungsfunktion (Ω überabzählbar)



Zufallsvariablen und deren Verteilung

7.1 Wichtige Wahrscheinlichkeitsverteilungen

Wahrscheinlichkeitsverteilung einer Zufallsvariablen X :

$$P^X(B) = P(X \in B) = P(\{\omega \in \Omega | X(\omega) \in B\}), B \subseteq \mathbb{R}$$

Verteilungsfunktion von X

$$F = F^X : \mathbb{R} \rightarrow [0, 1]$$

mit $F(x) = P^X((-\infty, x]) = P(X \leq x) = P(\{\omega \in \Omega | X(\omega) \leq x\}), x \in \mathbb{R}$

Träger T_X einer diskreten Wahrscheinlichkeitsverteilung P^X

$$T_X = \{x | P(X = x) > 0\}$$

Träger T_X einer stetigen Wahrscheinlichkeitsverteilung P^X

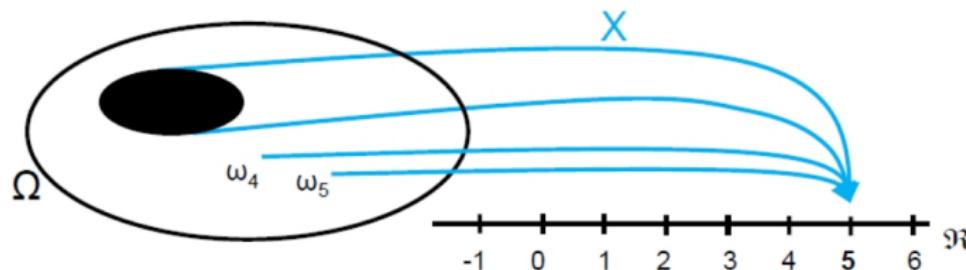
$$T_X = \{x | f(x) > 0\}$$

7.1 Wichtige Wahrscheinlichkeitsverteilungen

Diskrete Wahrscheinlichkeitsverteilungen

Einpunktverteilung ε_a

$$\omega \in \Omega \Rightarrow X(\omega) = a$$



Bestimmung der Dichte über Laplace-Raum

Setze $\Omega' = \{\omega_1\}$, $\omega \in \Omega' \Rightarrow \omega = \omega_1 \Rightarrow X(\omega_1) = a \Rightarrow p(X = a) = 1/|\Omega'| = 1$

7.1 Wichtige Wahrscheinlichkeitsverteilungen

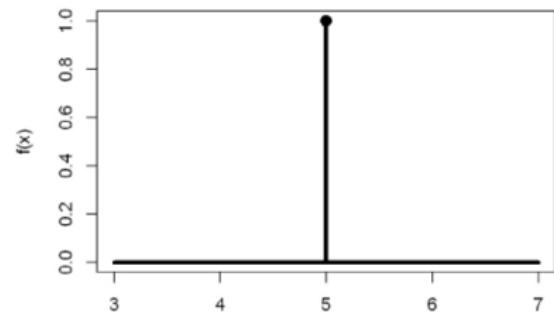
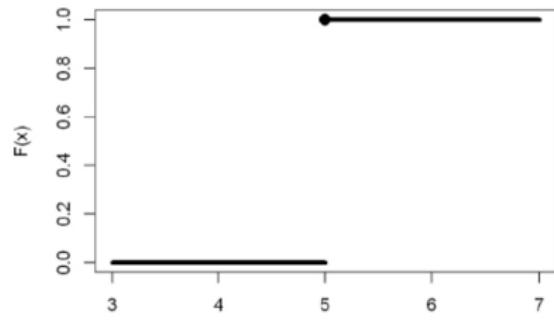
Diskrete Wahrscheinlichkeitsverteilungen

Einpunktverteilung ε_a

Verteilungsfunktion: $F(x) = \mathbb{I}(a \leq x)$

Zähldichte: $p(x) = \mathbb{I}(a = x)$

Träger: $T_X = \{a\}$

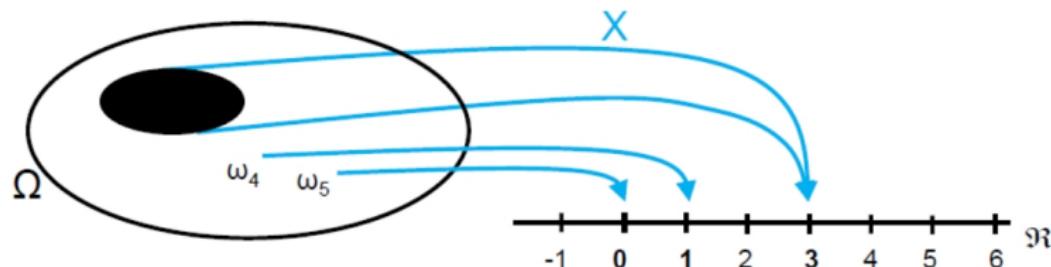


7.1 Wichtige Wahrscheinlichkeitsverteilungen

Diskrete Wahrscheinlichkeitsverteilungen

Diskrete Gleichverteilung $G(x_1, \dots, x_n)$

$$P(\{\omega \in \Omega | X(\omega) = x_1\}) = P(\{\omega \in \Omega | X(\omega) = x_2\}) = \dots = P(\{\omega \in \Omega | X(\omega) = x_n\})$$



Bestimmung der Dichte über Laplace-Raum

Setze $\Omega' = \{\omega_1, \dots, \omega_n\}$, $\omega \in \Omega' \Rightarrow \omega = \omega_i \Rightarrow X(\omega) = x_i \Rightarrow p(X = x_i) = 1/|\Omega'| = 1/n$

7.1 Wichtige Wahrscheinlichkeitsverteilungen

Diskrete Wahrscheinlichkeitsverteilungen

Diskrete Gleichverteilung

$$G(x_1, \dots, x_n)$$

Verteilungsfunktion:

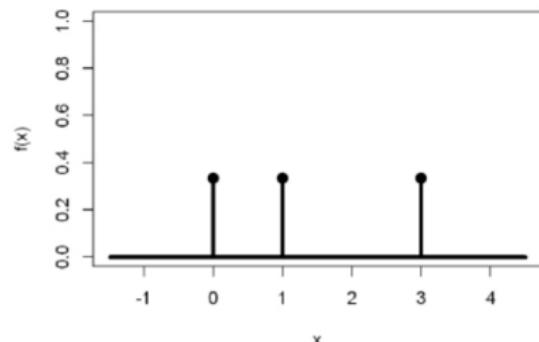
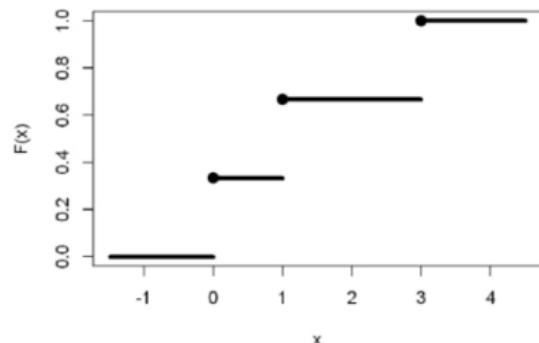
$$F(x) = \frac{1}{n} \sum_{i=1}^n I(x_i \leq x)$$

Zähldichte:

$$p(x) = \frac{1}{n} \cdot I(x \in \{x_1, \dots, x_n\})$$

Träger:

$$T_X = \{x_1, \dots, x_n\}$$

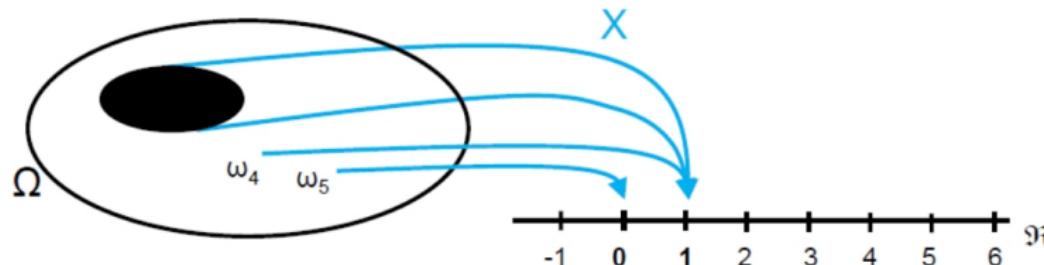


7.1 Wichtige Wahrscheinlichkeitsverteilungen

Diskrete Wahrscheinlichkeitsverteilungen

Bernoulli-Verteilung $B(1, p)$

$$P(\{\omega \in \Omega | X(\omega) = 1\}) = p, \quad P(\{\omega \in \Omega | X(\omega) = 0\}) = 1 - p$$



Der Fall $X(\omega) = 1$ wird Erfolg genannt, entsprechend ist p die Erfolgswahrscheinlichkeit.

7.1 Wichtige Wahrscheinlichkeitsverteilungen

Diskrete Wahrscheinlichkeitsverteilungen

Bernoulli-Verteilung $B(1, p)$

$$P(\{\omega \in \Omega | X(\omega) = 1\}) = p, P(\{\omega \in \Omega | X(\omega) = 0\}) = 1 - p$$

Bestimmung der Dichte über Laplace-Raum

Sei p o.B.d.A. rational,
d.h. es gibt $r, g \in \mathbb{N}, r < g$, mit $p = r/g$

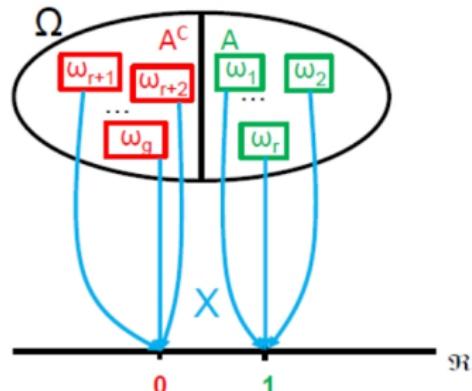
Setze $\Omega' = \{\omega_1, \dots, \omega_g\}$

$$A = \{\omega_1, \dots, \omega_r\}, A^c = \{\omega_{r+1}, \dots, \omega_g\}.$$

$$X(\omega) = I(\omega \in A)$$

$$\Rightarrow p(X = 1) = P(A) = \sum_{i=1}^r 1/|\Omega'| = r/g = p$$

$$p(X = 0) = P(A^c) = 1 - r/g = 1 - p$$



7.1 Wichtige Wahrscheinlichkeitsverteilungen

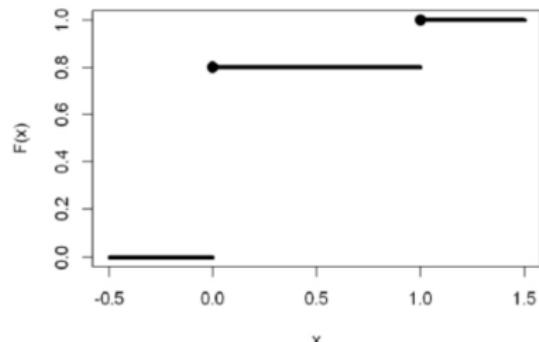
Diskrete Wahrscheinlichkeitsverteilungen

Bernoulli-Verteilung $B(1, p)$,

$$0 < p < 1$$

Verteilungsfunktion:

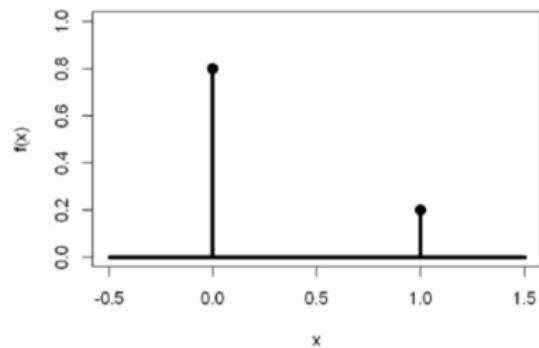
$$F(x) = (1 - p) \cdot \mathbb{I}(0 \leq x) + p \cdot \mathbb{I}(1 \leq x)$$



Zähldichte:

$$p(x) = p \cdot \mathbb{I}(x = 1) + (1 - p) \cdot \mathbb{I}(x = 0)$$

Träger: $T_X = \{0, 1\}$



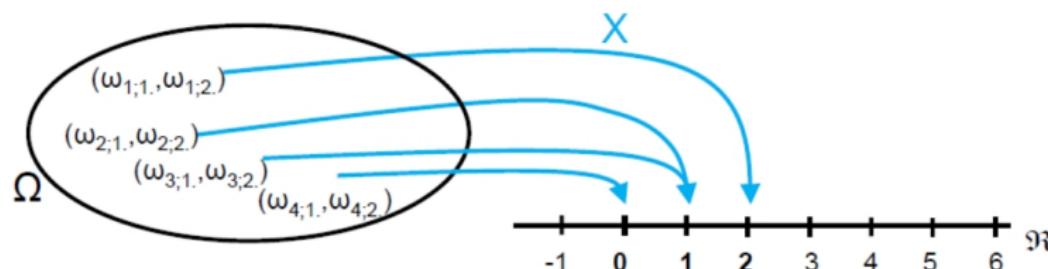
7.1 Wichtige Wahrscheinlichkeitsverteilungen

Diskrete Wahrscheinlichkeitsverteilungen

Binomialverteilung $B(n, p)$

$$P(\{\omega = \{\omega_{1..}, \dots, \omega_{n..}\} \in \Omega = (\Omega')^n | X(\omega) = \sum_{i=1}^n Y(\omega_{i..}) = k\}),$$

wobei $Y \sim B(1, p)$, ist die W'keit für genau k Erfolge in n unabhängigen Zufallsexperimenten mit $B(1, p)$ -verteilter Zufallsvariable



7.1 Wichtige Wahrscheinlichkeitsverteilungen

Diskrete Wahrscheinlichkeitsverteilungen

Binomialverteilung $B(n, p)$

Bestimmung der Dichte über Laplace-Raum

$r, g \in \mathbb{N}$, $p = r/g$, $\Omega' = \{\omega_1, \dots, \omega_g\}$, $A = \{\omega_1, \dots, \omega_r\}$, $A^c = \{\omega_{r+1}, \dots, \omega_g\}$,
 $Y(\omega_i) = \mathbb{I}(\omega_i \in A)$, $i = 1, \dots, n$

Elementarereignisse insgesamt: $|\Omega| = |\Omega'|^n = g^n$

Elementarereignisse mit Erfolg in ersten k Versuchen, danach Misserfolge:
 $|A^k \times (A^c)^{n-k}| = r^k \cdot (g - r)^{n-k}$

Dieselbe Anzahl ergibt sich für jede Verteilung der k Erfolge auf die n Experimente.

Anzahl der Anordnungen der k Erfolge in den n Versuchen: $n! =$ Anzahl der Reihenfolgen-Permutationen

7.1 Wichtige Wahrscheinlichkeitsverteilungen

Diskrete Wahrscheinlichkeitsverteilungen

Binomialverteilung $B(n, p)$

Die Reihenfolge der Erfolge/Misserfolge untereinander spielt dabei keine Rolle; es wird also jedes Elementarereignis $k! \cdot (n - k)!$ mal gezählt.

Binomialkoeffizient:

Anzahl Elementarereignisse mit insgesamt k Erfolgen $\binom{n}{k} = \frac{n!}{k!(n-k)!}$

Wahrscheinlichkeit für k Erfolge:

$$\begin{aligned} P(X = k) &= \frac{r^k \cdot (g - r)^{n-k} \cdot \binom{n}{k}}{g^n} = \frac{r^k \cdot (g - r)^{n-k} \cdot \binom{n}{k}}{g^k g^{n-k}} \\ &= \binom{n}{k} \left(\frac{r}{g}\right)^k \left(\frac{g - r}{g}\right)^{n-k} = \boxed{\binom{n}{k} \cdot p^k \cdot (1 - p)^{n-k}} \end{aligned}$$

Beispiel $n = 3, r = 3, g = 5, k = 2 \Rightarrow P(X = 2) = 54/125$

7.1 Wichtige Wahrscheinlichkeitsverteilungen

Diskrete Wahrscheinlichkeitsverteilungen

Binomialverteilung $B(n, p)$,

$$0 < p < 1, \quad n \in \mathbb{N}$$

Verteilungsfunktion:

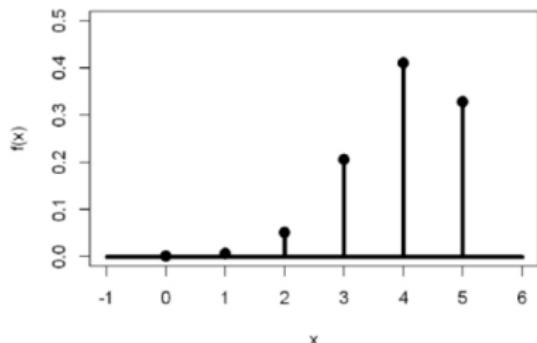
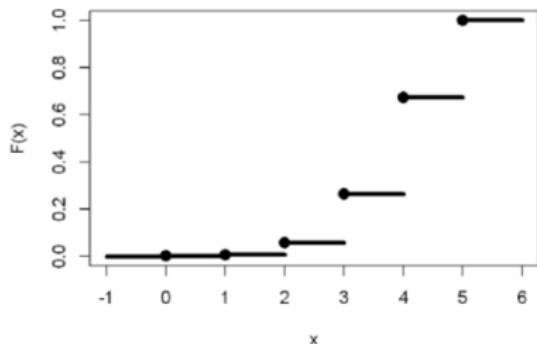
$$F(x) = \sum_{i=0}^n \mathbb{I}(i \leq x) \cdot \binom{n}{i} \cdot p^i \cdot (1-p)^{n-i}$$

Zähldichte:

$$p(x) = \mathbb{I}(x \in \{0, \dots, n\}) \cdot \binom{n}{x} \cdot p^x \cdot (1-p)^{n-x}$$

Träger: $T_X = \{0, \dots, n\}$

Beispiel: X = Anzahl Treffer bei 5 Strafstößen



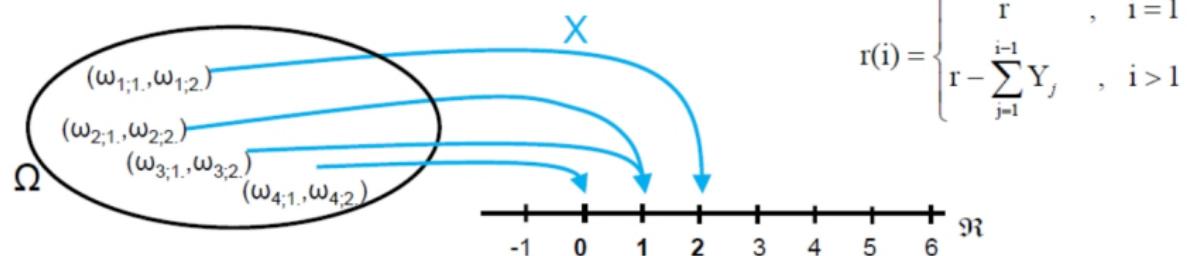
7.1 Wichtige Wahrscheinlichkeitsverteilungen

Diskrete Wahrscheinlichkeitsverteilungen

Hypergeometrische Verteilung $\text{Hyp}(n, r, s)$

$$P(\{\omega = (\omega_{1,.}, \dots, \omega_{n,.}) \in \Omega = \Omega' \times \Omega' \setminus \{\omega_{1,.}\} \times \dots \times \Omega' \setminus \{\omega_{1,.}, \dots, \omega_{n-1,.}\} | X(\omega) = \sum_{i=1}^n Y_i(\omega) = k\}), \quad Y_i \sim B\left(1, \frac{r(i)}{r+s-i+1}\right)$$

ist die W'keit für genau k Erfolge in n Zufallsexperimenten mit jeweils $B\left(1, \frac{r(i)}{r+s-i+1}\right)$ -verteilter Zufallsvariable



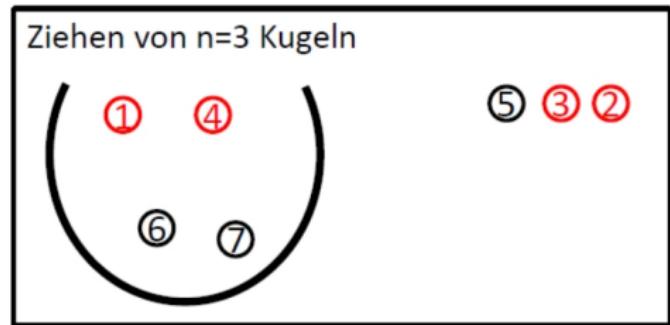
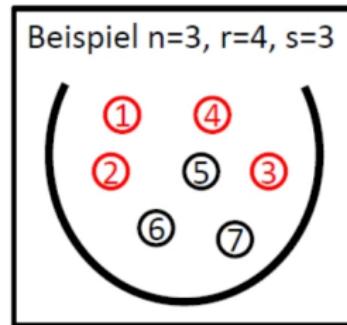
7.1 Wichtige Wahrscheinlichkeitsverteilungen

Diskrete Wahrscheinlichkeitsverteilungen

Hypergeometrische Verteilung Hyp(n, r, s)

Urnensmodell

k = Anzahl rote Kugeln nach n -maligem Ziehen aus einer Urne mit r roten und s schwarzen Kugeln ohne Zurücklegen



7.1 Wichtige Wahrscheinlichkeitsverteilungen

Diskrete Wahrscheinlichkeitsverteilungen

Hypergeometrische Verteilung Hyp(n, r, s)

Urnensmodell

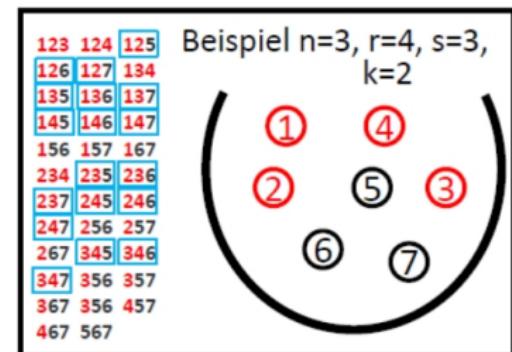
k = Anzahl rote Kugeln nach n -maligem Ziehen aus einer Urne mit r roten und s schwarzen Kugeln ohne Zurücklegen

Ω sind alle Möglichkeiten, die n „Ziehungen“ auf die $r + s$ Kugeln zu verteilen.

Davon gibt es $|\Omega| = \binom{r+s}{n}$.

Die **günstigen Fälle** sind alle, in denen k rote und $n - k$ schwarze Kugeln auf die n gezogenen verteilt werden.

Davon gibt es $|\{\omega \in \Omega | X(\omega) = k\}| = \binom{r}{k} \cdot \binom{s}{n-k}$.



7.1 Wichtige Wahrscheinlichkeitsverteilungen

Diskrete Wahrscheinlichkeitsverteilungen

Hypergeometrische Verteilung Hyp(n, r, s)

Urnensmodell

k = Anzahl rote Kugeln nach n -maligem Ziehen aus einer Urne mit r roten und s schwarzen Kugeln ohne Zurücklegen

Es gibt $|\Omega| = \binom{r+s}{n}$ Möglichkeiten, die n „Ziehungen“ auf die $r + s$ Kugeln zu verteilen.

Davon enthalten $|\{\omega \in \Omega | X(\omega) = k\}| = \binom{r}{k} \cdot \binom{s}{n-k}$ Kombinationen k rote Kugeln.

Die W'keit für k rote Kugeln beträgt also

$$P(X = k) = \frac{\binom{r}{k} \cdot \binom{s}{n-k}}{\binom{r+s}{n}}$$

7.1 Wichtige Wahrscheinlichkeitsverteilungen

Diskrete Wahrscheinlichkeitsverteilungen

Hypergeometrische Verteilung Hyp(n, r, s),

$$0 < n < r + s, \quad n \in \mathbb{N}$$

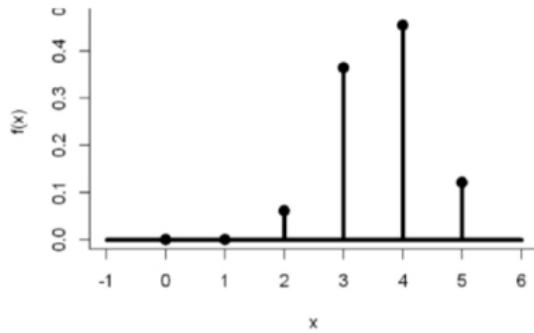
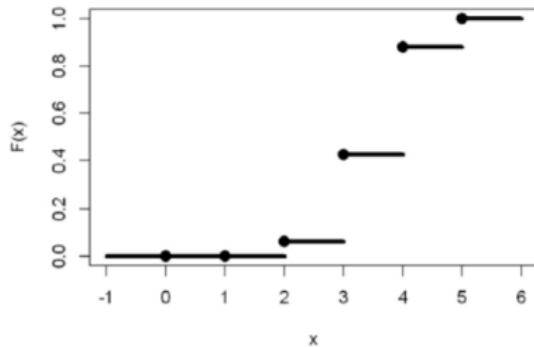
Verteilungsfunktion:

$$F(x) = \sum_{i=0}^n \mathbb{I}(i \leq x) \cdot \frac{\binom{r}{i} \cdot \binom{s}{n-i}}{\binom{r+s}{n}}$$

Zähldichte:

$$p(x) = \mathbb{I}(x \in \{\max(0, n-s), \dots, \min(n, r)\}) \cdot \frac{\binom{r}{x} \cdot \binom{s}{n-x}}{\binom{r+s}{n}}$$

Träger: $T_X = \{\max(0, n-s), \dots, \min(n, r)\}$



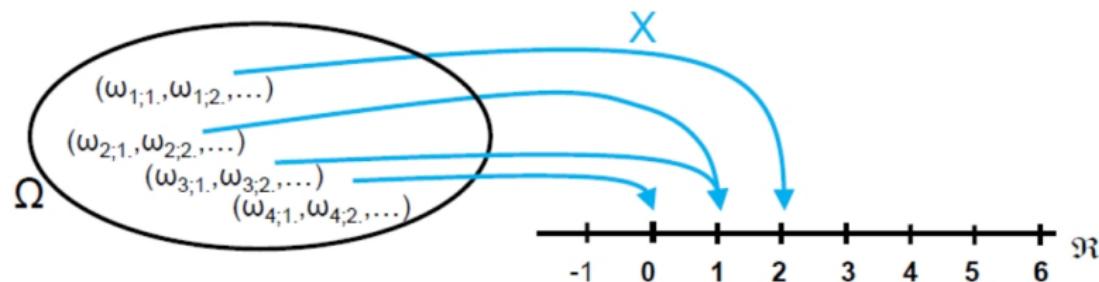
7.1 Wichtige Wahrscheinlichkeitsverteilungen

Diskrete Wahrscheinlichkeitsverteilungen

Geometrische Verteilung $\text{Geo}(p)$

$P(\{\omega = (\omega_{1.}, \omega_{2.}, \dots) \in \Omega = \Omega'^\infty | X(\omega) = \min[i | Y_i(\omega_{i.}) = 1] - 1 = k\}),$
 $Y_i \sim B(1, p)$

ist die W'keit, den ersten Erfolg im $(k + 1)$ -ten Zufallsexperiment mit jeweils $B(1, p)$ -verteilter Zufallsvariable zu erhalten.



7.1 Wichtige Wahrscheinlichkeitsverteilungen

Diskrete Wahrscheinlichkeitsverteilungen

Geometrische Verteilung $\text{Geo}(p)$

$r, g \in \mathbb{N}$, $p = r/g$, $\Omega' = \{\omega_1, \dots, \omega_g\}$, $A = \{\omega_1, \dots, \omega_r\}$, $A^c = \{\omega_{r+1}, \dots, \omega_g\}$,
 $Y(\omega_i) = \mathbb{I}(\omega_i \in A)$, $i = 1, \dots, n$

Für festes k relevanter Grundraum $\Omega'_{k+1} = |\Omega'|^{k+1} \Rightarrow |\Omega'_{k+1}| = g^{k+1}$

Günstige Elementarereignisse sind diejenigen mit ausschließlich Misserfolgen in den ersten k Versuchen, danach ein Erfolg:

$$|(A^c)^k \times A| = r \cdot (g - r)^k$$

$$\Rightarrow P(X = k) = \frac{r \cdot (g - r)^k}{g^{k+1}} = \frac{r \cdot (g - r)^k}{g \cdot g^k} = \left(\frac{r}{g}\right) \cdot \left(\frac{g - r}{g}\right)^k = p \cdot (1 - p)^k$$

7.1 Wichtige Wahrscheinlichkeitsverteilungen

Diskrete Wahrscheinlichkeitsverteilungen

Geometrische Verteilung $\text{Geo}(p)$, $0 < p < 1$

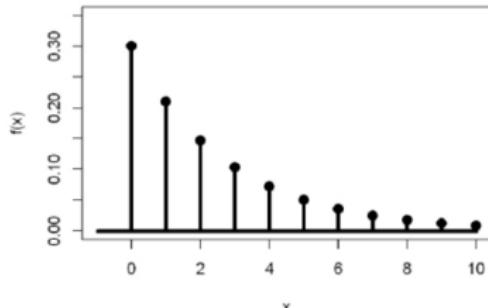
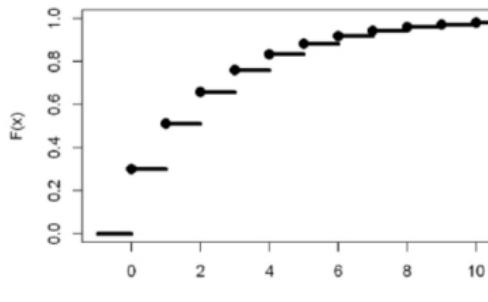
Verteilungsfunktion:

$$F(x) = 1 - (1 - p)^{x+1}$$

Zähldichte:

$$p(x) = \mathbb{I}(x \in \mathbb{N} \cup 0) \cdot p \cdot (1 - p)^x$$

Träger: $T_X = \mathbb{N} \cup 0$



Beispiel: $X = \text{Anzahl verschossener Strafstöße bis zum ersten verwandelten}$

7.1 Wichtige Wahrscheinlichkeitsverteilungen

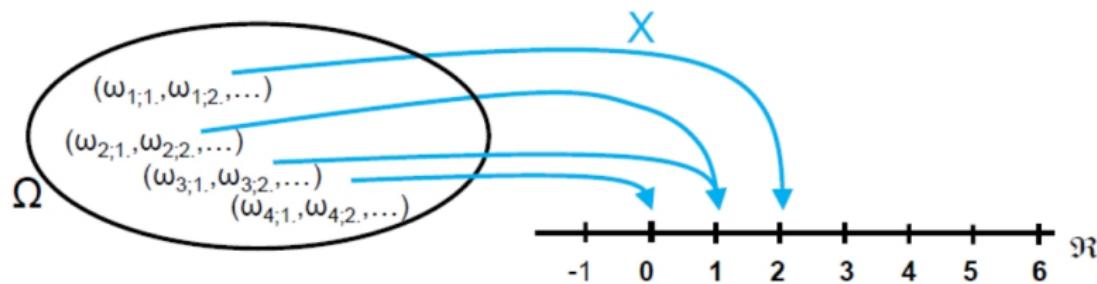
Diskrete Wahrscheinlichkeitsverteilungen

Poisson-Verteilung $\text{Poi}(\lambda)$ $P(\{\omega = (\omega_{1.}, \omega_{2.}, \dots) \in \Omega = \Omega'^{\infty} | X(\omega) = k\})$

$$= \lim_{n \rightarrow \infty} P(\{\omega = (\omega_{1.}, \dots, \omega_{n.}) \in \Omega = \Omega'^n | X(\omega) = \sum_{i=1}^n Y_n(\omega_{i.}) = k\}),$$

$$Y_n \sim B(1, \lambda/n)$$

ist die Wahrscheinlichkeit, in einem festen Zeitraum der Länge t genau k Ereignisse zu beobachten, wenn die mittlere Anzahl an Ereignissen im Zeitraum t durch den Wert von λ gegeben ist und ein Erfolg zu jedem Zeitpunkt im betrachteten Zeitraum gleichwahrscheinlich ist.



7.1 Wichtige Wahrscheinlichkeitsverteilungen

Diskrete Wahrscheinlichkeitsverteilungen

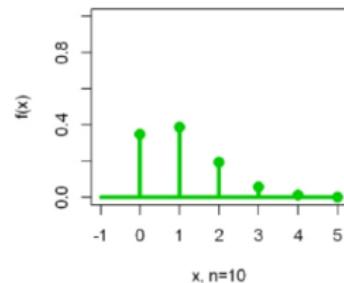
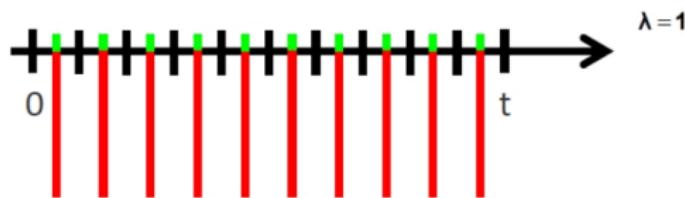
Poisson-Verteilung $\text{Poi}(\lambda)$ $P(\{\omega = (\omega_{1.}, \omega_{2.}, \dots) \in \Omega = \Omega'^\infty | X(\omega) = k\})$

$$= \lim_{n \rightarrow \infty} P(\{\omega = (\omega_{1.}, \dots, \omega_{n.}) \in \Omega = \Omega'^n | X(\omega) = \sum_{i=1}^n Y_n(\omega_{i.}) = k\}), Y_n \sim B(1, \lambda/n)$$

ist die Wahrscheinlichkeit, in einem festen Zeitraum der Länge t genau k Ereignisse zu beobachten, wenn die mittlere Anzahl an Ereignissen im Zeitraum t durch den Wert von λ gegeben ist und ein Erfolg zu jedem Zeitpunkt im betrachteten Zeitraum gleichwahrscheinlich ist.

Durchführung von n Bernoulli-Experimenten im Zeitraum t :

$$p(x) = I(x \in \{0, \dots, n\}) \cdot \binom{n}{x} \cdot \left(\frac{\lambda}{n}\right)^x \cdot \left(1 - \frac{\lambda}{n}\right)^{n-x}$$



7.1 Wichtige Wahrscheinlichkeitsverteilungen

Diskrete Wahrscheinlichkeitsverteilungen

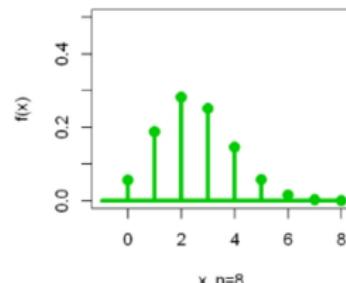
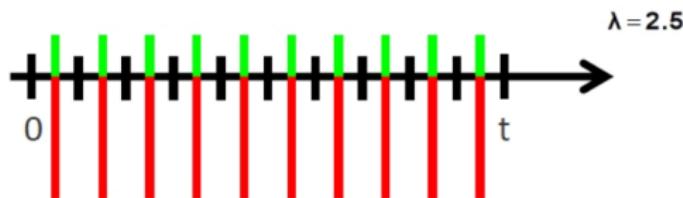
Poisson-Verteilung $\text{Poi}(\lambda)$ $P(\{\omega = (\omega_{1.}, \omega_{2.}, \dots) \in \Omega = \Omega'^\infty | X(\omega) = k\})$

$$= \lim_{n \rightarrow \infty} P(\{\omega = (\omega_{1.}, \dots, \omega_{n.}) \in \Omega = \Omega'^n | X(\omega) = \sum_{i=1}^n Y_n(\omega_{i.}) = k\}), Y_n \sim B(1, \lambda/n)$$

ist die Wahrscheinlichkeit, in einem festen Zeitraum der Länge t genau k Ereignisse zu beobachten, wenn die mittlere Anzahl an Ereignissen im Zeitraum t durch den Wert von λ gegeben ist und ein Erfolg zu jedem Zeitpunkt im betrachteten Zeitraum gleichwahrscheinlich ist.

Durchführung von n Bernoulli-Experimenten im Zeitraum t :

$$p(x) = I(x \in \{0, \dots, n\}) \cdot \binom{n}{x} \cdot \left(\frac{\lambda}{n}\right)^x \cdot \left(1 - \frac{\lambda}{n}\right)^{n-x}$$



7.1 Wichtige Wahrscheinlichkeitsverteilungen

Diskrete Wahrscheinlichkeitsverteilungen

Poisson-Verteilung $\text{Poi}(\lambda)$

$$\begin{aligned}
 p(x) &= \lim_{n \rightarrow \infty} \left[\mathbb{I}(x \in \{0, \dots, n\}) \cdot \binom{n}{x} \cdot \left(\frac{\lambda}{n}\right)^x \cdot \left(1 - \frac{\lambda}{n}\right)^{n-x} \right] \\
 &= \mathbb{I}(x \in \mathbb{N} \cup 0) \cdot \lim_{n \rightarrow \infty} \left[\frac{n!}{x!(n-x)!} \cdot \left(\frac{\lambda}{n}\right)^x \cdot \left(1 - \frac{\lambda}{n}\right)^{n-x} \right] \\
 &= \mathbb{I}(x \in \mathbb{N} \cup 0) \cdot \lim_{n \rightarrow \infty} \left[\frac{n \cdot (n-1) \cdot (n-2) \cdot \dots \cdot (n-x+1)}{x!} \cdot \frac{\lambda^x}{n^x} \right. \\
 &\quad \left. \cdot \left(1 - \frac{\lambda}{n}\right)^n \cdot \left(1 - \frac{\lambda}{n}\right)^{-x} \right] \\
 &= \mathbb{I}(x \in \mathbb{N} \cup 0) \cdot \left(\frac{\lambda^x}{x!} \right) \cdot \lim_{n \rightarrow \infty} \left(\frac{n}{n} \cdot \frac{n-1}{n} \cdot \frac{n-2}{n} \cdot \dots \cdot \frac{n-x+1}{n} \right) \\
 &\quad \cdot \lim_{n \rightarrow \infty} \left(1 - \frac{\lambda}{n}\right)^n \cdot \lim_{n \rightarrow \infty} \left(1 - \frac{\lambda}{n}\right)^{-x} \\
 &= \mathbb{I}(x \in \mathbb{N} \cup 0) \cdot \left(\frac{\lambda^x}{x!} \right) \cdot 1 \cdot e^{-\lambda} \cdot 1 = \boxed{\frac{\lambda^x e^{-\lambda}}{x!}}
 \end{aligned}$$

7.1 Wichtige Wahrscheinlichkeitsverteilungen

Diskrete Wahrscheinlichkeitsverteilungen

Poisson-Verteilung $\text{Poi}(\lambda)$, $\lambda > 0$

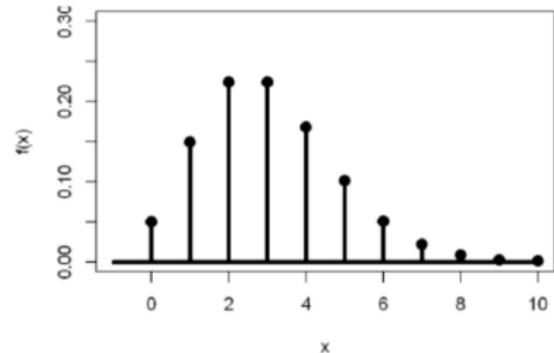
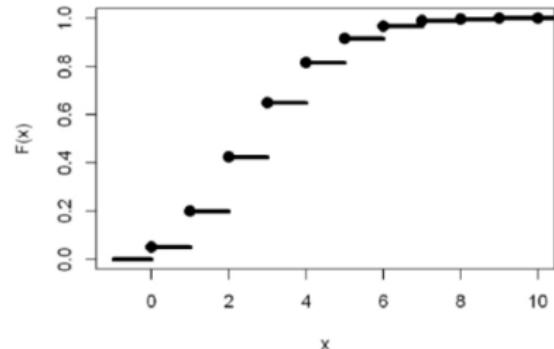
Verteilungsfunktion:

$$F(x) = e^{-\lambda} \cdot \sum_{i=0}^n \mathbb{I}(i \leq x) \cdot \frac{\lambda^x}{x!}$$

Zähldichte: $p(x) = \frac{\lambda^x e^{-\lambda}}{x!}$

Träger: $T_X = \mathbb{N} \cup 0$

Beispiel: X = Anzahl Tore pro Bundesliga-Spieltag



7.1 Wichtige Wahrscheinlichkeitsverteilungen

Stetige Wahrscheinlichkeitsverteilungen

Rechteckverteilung $R(a, b)$, $a < b$

Verteilungsfunktion:

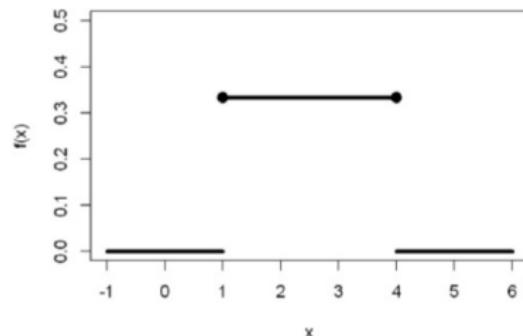
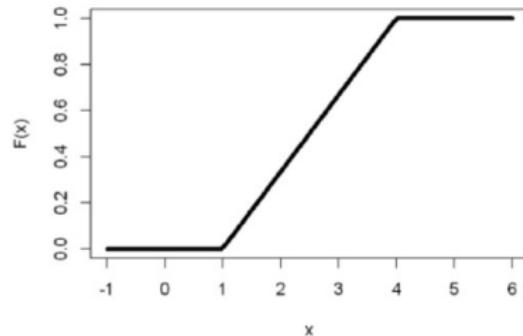
$$F(x) = \mathbb{I}(a \leq x) \cdot \frac{\min(x, b) - a}{b - a}$$

Dichtefunktion:

$$f(x) = \frac{\mathbb{I}(a \leq x \leq b)}{b - a}$$

Träger: $T_X = [a, b]$

Beispiel: X = Zeitpunkt beliebiger Spielunterbrechung zwischen 10. und 20. Spielminute



7.1 Wichtige Wahrscheinlichkeitsverteilungen

Stetige Wahrscheinlichkeitsverteilungen

Exponentialverteilung $\text{Exp}(\lambda)$, $\lambda > 0$

Verteilungsfunktion:

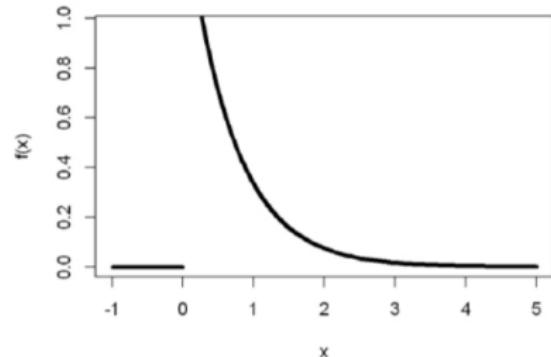
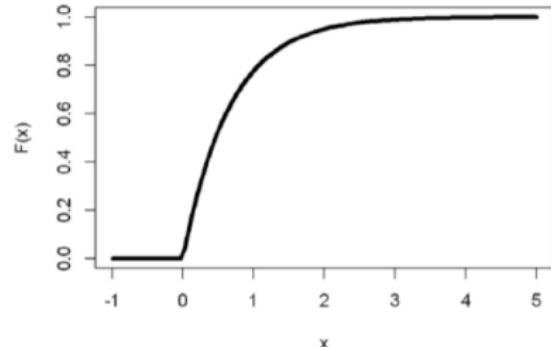
$$F(x) = \mathbb{I}(0 \leq x) \cdot (1 - e^{-(\lambda \cdot x)})$$

Dichtefunktion:

$$f(x) = \mathbb{I}(0 \leq x) \cdot \lambda e^{-(\lambda \cdot x)}$$

Träger: $T_X = [0, \infty)$

Beispiel: X = Zeit zwischen zwei Spielunterbrechungen



7.1 Wichtige Wahrscheinlichkeitsverteilungen

Stetige Wahrscheinlichkeitsverteilungen

Weibull-Verteilung $W(\alpha, \beta)$

$$P(\{\omega \in \Omega | X(\omega) \leq x\})$$

ist die Wahrscheinlichkeit, höchstens x Zeiteinheiten auf das erste Ereignis zu warten, wenn die Hazardrate

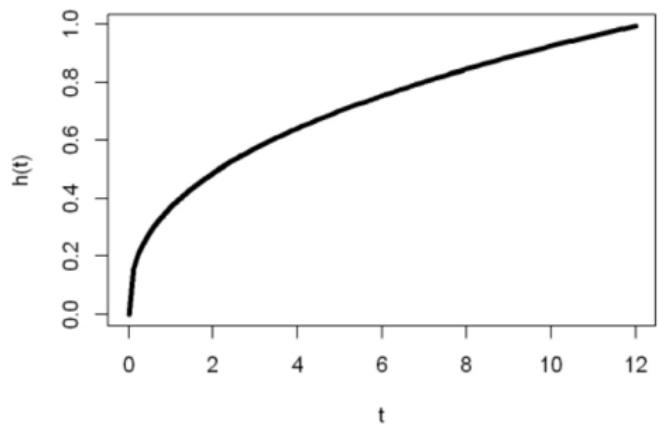
$$h(t) = \lim_{\delta \rightarrow \infty} \frac{P(t \leq T \leq t + \delta t)}{\delta t}$$

durch die Funktion

$$h(t) = e^{(\nu + \rho \cdot \ln(t))}$$

mit $\nu = \ln(\alpha) - \alpha \cdot \ln(\beta)$ und $\rho = \alpha - 1$

beschrieben wird.



7.1 Wichtige Wahrscheinlichkeitsverteilungen

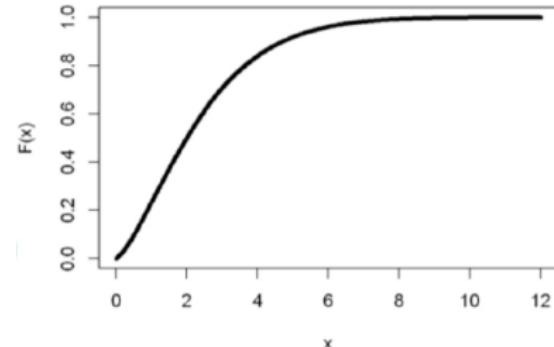
Stetige Wahrscheinlichkeitsverteilungen

Weibull-Verteilung $W(\alpha, \beta)$,

$$\alpha > 0, \beta > 0$$

Verteilungsfunktion:

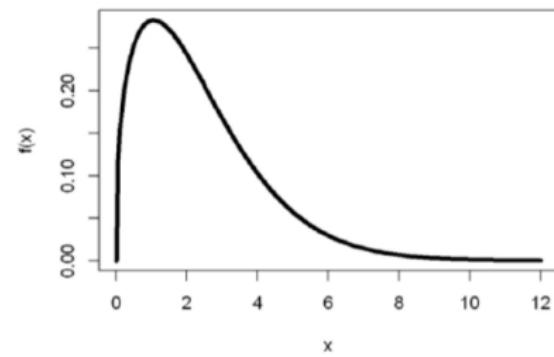
$$F(x) = I(0 \leq x) \cdot (1 - e^{-(x/\beta)^\alpha})$$



Dichtefunktion:

$$f(x) = I(0 \leq x) \cdot \left(\frac{\alpha}{\beta} \cdot \left(\frac{x}{\beta} \right)^{\alpha-1} e^{-(x/\beta)^\alpha} \right)$$

Träger: $T_X = [0, \infty)$



Beispiel: X = Zeitpunkt des Tors zum 1:0,
wenn das Hinspiel 0:1 verloren wurde

7.1 Wichtige Wahrscheinlichkeitsverteilungen

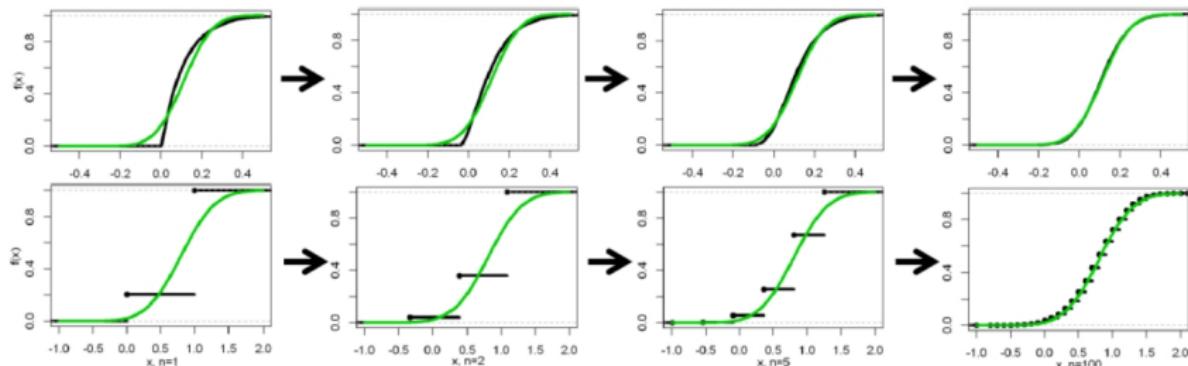
Stetige Wahrscheinlichkeitsverteilungen

Normalverteilung $N(\mu, \sigma^2)$ $P(\{\omega \in \Omega | X(\omega) \leq x\})$

$$= \lim_{n \rightarrow \infty} P\left(\{\omega \in \Omega'^n | \left(\frac{1}{n} \sum_{i=1}^n \left[\frac{Y(\omega_i) - E(X)}{\sqrt{\text{Var}(X)}} \right] \right) \cdot \sqrt{\text{Var}(X) \cdot n} + E(X) \leq x\}\right),$$

$$Y \sim F_0(E(X) = \mu, \text{Var}(X) = \sigma^2)$$

ist die Grenzw'keit für unendliches n , dass der Mittelwert aus n standardisierten Zufallsvariablen, die aus der selben Verteilung stammen, den Wert $[x - E(X)] / [\text{Var}(X) \cdot n]^{0.5}$ nicht übersteigt.



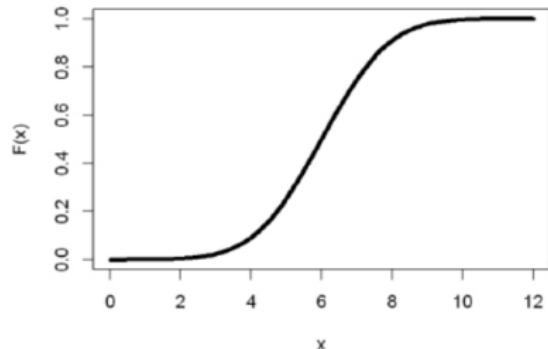
7.1 Wichtige Wahrscheinlichkeitsverteilungen

Stetige Wahrscheinlichkeitsverteilungen

Normalverteilung $N(\mu, \sigma^2)$, $\sigma > 0$

Verteilungsfunktion:

$$F(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{t-\mu}{\sigma}\right)^2} dt$$

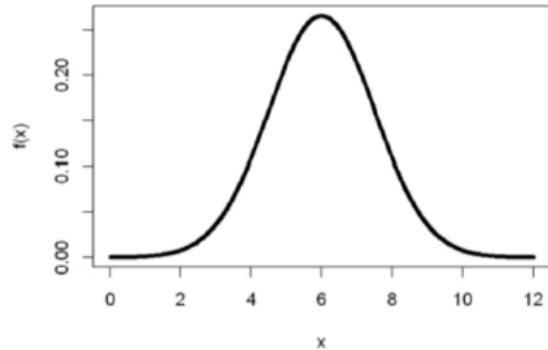


Dichtefunktion:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

Träger: $T_X = \mathbb{R}$

Beispiel: X = Nettospielzeit pro Bundesligaspielzeit



7.1 Wichtige Wahrscheinlichkeitsverteilungen

Stetige Wahrscheinlichkeitsverteilungen

χ^2 -Verteilung χ_f^2 mit f Freiheitsgraden

$$P(\{\omega \in \Omega | X(\omega) \leq x\}) = P\left(\{\omega \in \Omega^f | \sum_{i=1}^f Y_i^2 \leq x\}\right), \quad Y_i \sim N(0, 1)$$

ist die Wahrscheinlichkeit, dass die Summe von f quadrierten, standardnormalverteilten Zufallsvariablen den Wert x nicht übersteigt.

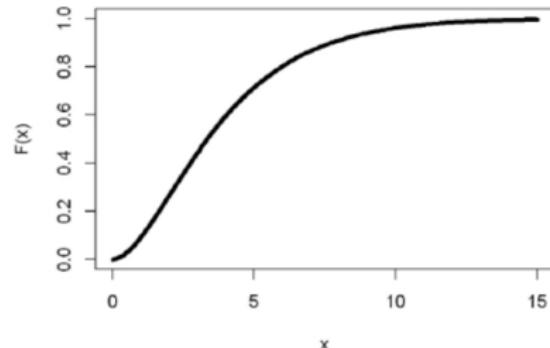
7.1 Wichtige Wahrscheinlichkeitsverteilungen

Stetige Wahrscheinlichkeitsverteilungen

χ^2 -Verteilung, $f \in \mathbb{N}$ ($= \Gamma[0.5, f/2]$)

Verteilungsfunktion:

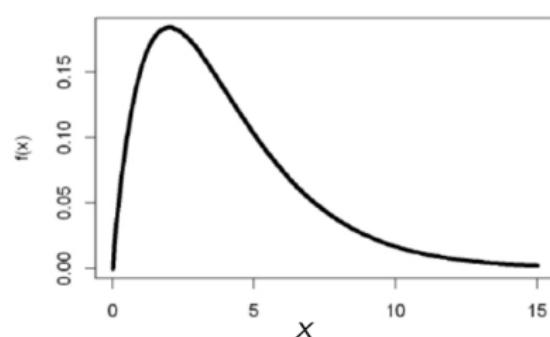
$$F(x) = \int_0^x \frac{1}{2^{f/2}\Gamma(f/2)} t^{f/2-1} e^{-t/2} dt$$



Dichtefunktion:

$$f(x) = I(0 < x) \cdot \frac{1}{2^{f/2}\Gamma(f/2)} t^{f/2-1} e^{-x/2}$$

Träger: $T_X = [0, \infty)$



Beispiel: $X = \chi^2$ -Statistik zwischen Anzahl gelber Karten pro Spiel in Hin- und Rückrunde

7.1 Wichtige Wahrscheinlichkeitsverteilungen

Stetige Wahrscheinlichkeitsverteilungen

F-Verteilung F_{f_1, f_2} mit f_1 und f_2 Freiheitsgraden

$$P(\{\omega \in \Omega | X(\omega) \leq x\}) = P\left(\{\omega \in \Omega' | [Y \cdot f_2]/[Z \cdot f_1] \leq x\}\right), \quad Y \sim \chi^2_{f_1}, \quad Z \sim \chi^2_{f_2}$$

ist die Wahrscheinlichkeit, dass der Quotient zweier durch ihre Anzahl an Freiheitsgraden dividierte χ^2 -verteilter Zufallsvariablen den Wert x nicht übersteigt.

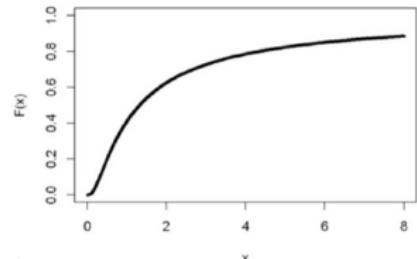
7.1 Wichtige Wahrscheinlichkeitsverteilungen

Stetige Wahrscheinlichkeitsverteilungen

F-Verteilung F_{f_1, f_2} $f_1 \in \mathbb{N}, f_2 \in \mathbb{N}$

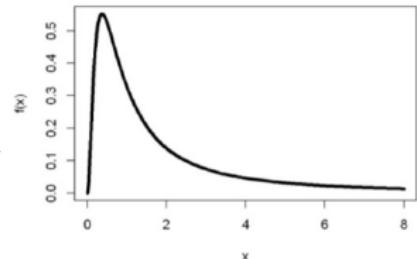
Verteilungsfunktion:

$$F(x) = \int_0^x \frac{\Gamma\left(\frac{f_1+f_2}{2}\right)}{\Gamma\left(\frac{f_1}{2}\right) \cdot \Gamma\left(\frac{f_2}{2}\right)} \cdot \left(\frac{f_1}{f_2}\right)^{f_1/2} \frac{t^{f_2/2-1}}{(1 + f_1 t/f_2)^{(f_1+f_2)/2}} dt$$



Dichtefunktion:

$$f(x) = I(0 < x) \cdot \frac{\Gamma\left(\frac{f_1+f_2}{2}\right)}{\Gamma\left(\frac{f_1}{2}\right) \cdot \Gamma\left(\frac{f_2}{2}\right)} \cdot \left(\frac{f_1}{f_2}\right)^{f_1/2} \frac{x^{f_2/2-1}}{(1 + f_1 x/f_2)^{(f_1+f_2)/2}}$$



Träger: $T_X = [0, \infty)$

Beispiel: $X = \text{Verhältnis der mittleren Varianz der Zuschauerzahlen pro Spiel an jeweils einem Spieltag zur Varianz der mittleren Zuschauerzahlen pro Spieltag}$

7.1 Wichtige Wahrscheinlichkeitsverteilungen

Stetige Wahrscheinlichkeitsverteilungen

t -Verteilung t_f mit f Freiheitsgraden

$$P(\{\omega \in \Omega | X(\omega) \leq x\}) = P\left(\{\omega \in \Omega'^{f+1} | \frac{Z}{\sqrt{Y/f}} \leq x\}\right), \quad Z \sim N(0, 1), \quad Y \sim \chi_f^2$$

ist die Wahrscheinlichkeit, dass der Quotient einer standardnormalverteilten Zufallsvariable und der Wurzel aus einer durch die Anzahl ihrer Freiheitsgrade dividierte χ^2 -verteilter Zufallsvariablen den Wert x nicht übersteigt.

7.1 Wichtige Wahrscheinlichkeitsverteilungen

Stetige Wahrscheinlichkeitsverteilungen

t -Verteilung $t_f \quad f \in \mathbb{N}$

Verteilungsfunktion:

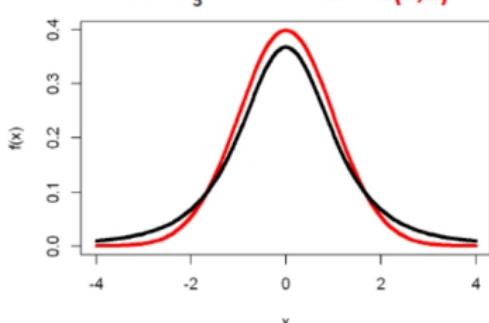
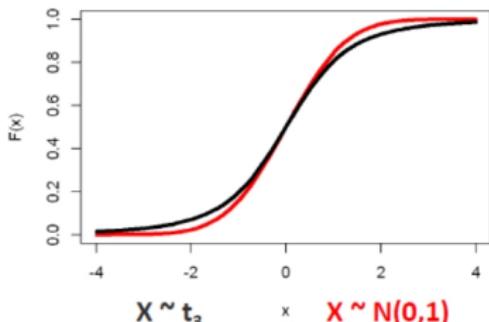
$$F(x) = \int_0^x \frac{\Gamma\left(\frac{f+1}{2}\right)}{\sqrt{f\pi} \cdot \Gamma\left(\frac{f}{2}\right)} \cdot \left(1 + \frac{t^2}{f}\right)^{-(f+1)/2} dt$$

Dichtefunktion:

$$f(x) = \frac{\Gamma\left(\frac{f+1}{2}\right)}{\sqrt{f\pi} \cdot \Gamma\left(\frac{f}{2}\right)} \cdot \left(1 + \frac{x^2}{f}\right)^{-(f+1)/2}$$

Träger: $T_X = \mathbb{R}$

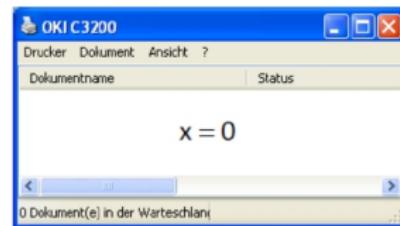
Beispiel: X = Geeignete skalierte Differenz aus mittlerer Nettospielzeit an geraden und ungeraden Spieltagen



7.1 Wichtige Wahrscheinlichkeitsverteilungen

Kombinationen aus diskreten und stetigen Wahrscheinlichkeitsverteilungen

Beispiel **Wartezeit bis zum Start eines Druckauftrags**

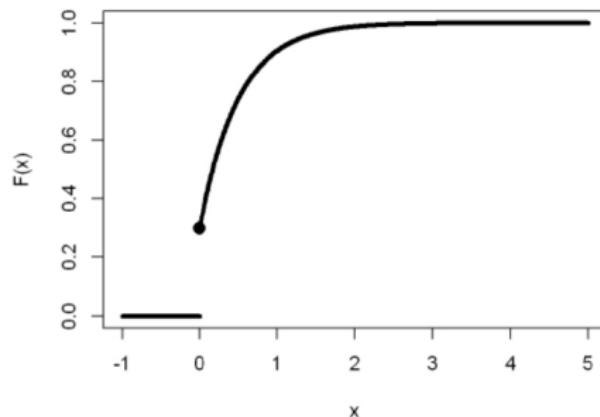


$$P(X = 0) = 1 - p$$



$$P(0 < X < x) = p - pe^{-\lambda x}$$

Verteilungsfunktion: $F(x) = I(0 \leq x) \cdot (1 - e^{-\lambda x})$



7.2 Zwei- und Mehrdimensionale Wahrscheinlichkeitsverteilungen

Diskrete Wahrscheinlichkeitsverteilungen

Multinomialverteilung $\text{Mult}(n, p_1, \dots, p_r)$

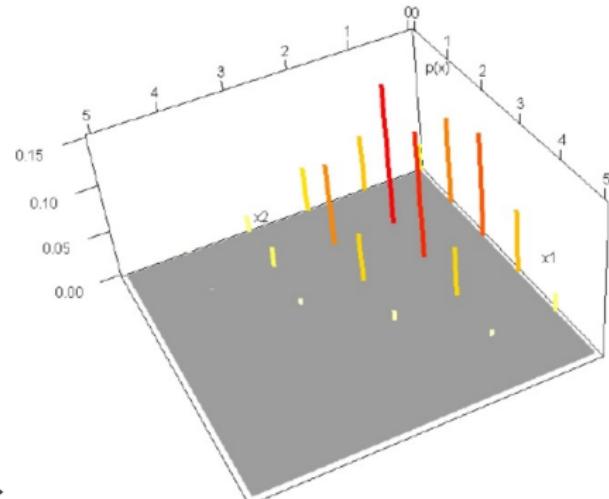
$$n \in \mathbb{N}, 0 \leq p_i \leq 1, i = 1, \dots, r, \sum_{i=1}^r p_i = 1$$

Zähldichte:

$$p(x_1, \dots, x_r) = I(x \in T_X) \cdot \frac{n!}{\prod_{i=1}^r x_i!} \cdot \prod_{i=1}^r p_i^{x_i}$$

Träger:

$$T_X = \left\{ x = (x_1, \dots, x_r) \in (\mathbb{N} \cup \{0\})^r \mid \sum_{i=1}^r x_i = n \right\}$$



Beispiel: X = Vektor mit Anzahlen geschossener Tore in einer Saison für alle Spieler im Kader

7.2 Zwei- und Mehrdimensionale Wahrscheinlichkeitsverteilungen

Stetige Wahrscheinlichkeitsverteilungen

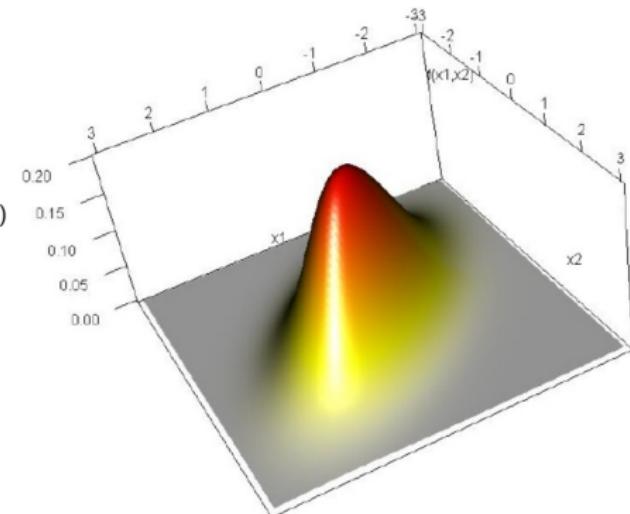
Multivariate Normalverteilung $N(\mu, \Sigma)$

$\mu \in \mathbb{R}^r$, $\Sigma \in \mathbb{R}^{r \times r}$, Σ p.s.d

Dichtefunktion:

$$f(x_1, \dots, x_r) = \frac{1}{(2\pi)^{k/2} \sqrt{|\Sigma|}} e^{-\frac{1}{2}(x-\mu)^\top \Sigma^{-1}(x-\mu)}$$

Träger: $T_X = \mathbb{R}^r$



Beispiel: $X =$ Zuschauerzahl, Etat und Summe der Spielergehälter

Wahrscheinlichkeits- theoretische Kennzahlen

8.1 Erwartungswert und Varianz

Zuletzt: Abbildung von Ereignissen auf reelle Zahlen durch Zufallsvariablen;
mathematische Formulierung ihrer W'keiten durch Verteilungsfunktionen

$$\begin{array}{ll} X : \Omega \rightarrow \mathbb{R} & F^X \in \mathcal{F} \\ \omega \mapsto X(\omega) & F^X : \mathbb{R} \rightarrow [0, 1] \\ & x \mapsto F^X(x) \end{array}$$

Jetzt: **Charakterisierung der Verteilungen durch einzelne Parameter**

$$\begin{aligned} \theta : \mathcal{F} &\rightarrow \mathbb{R} \\ F^X &\mapsto \theta(F^X) \end{aligned}$$

8.1 Erwartungswert und Varianz

Diskrete Wahrscheinlichkeitsverteilungen

Der **Erwartungswert** einer diskret verteilten Zufallsvariable X mit Zähldichte $p(x)$ und Träger $T_X = \{x_1, x_2, \dots\}$ ist definiert durch

$$\mathbb{E}[X] = \sum_{j=1}^J p(x_j) \cdot x_j, \quad J \in \mathbb{N} \cup \{\infty\}$$

Die **Varianz** von X ist definiert durch

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \sum_{j=1}^J p(x_j) \cdot (x_j - \mathbb{E}[X])^2, \quad J \in \mathbb{N} \cup \{\infty\}$$

Die **Standardabweichung** von X ist definiert durch

$$\sqrt{\text{Var}(X)}$$

8.1 Erwartungswert und Varianz

Diskrete Wahrscheinlichkeitsverteilungen

Der **Erwartungswert** ist der Wert, den man „im Mittel“ annimmt.

Beispiel einmaliger Würfelwurf:

$$\begin{aligned} E[X] &= P(X = 1) \cdot 1 + P(X = 2) \cdot 2 + P(X = 3) \cdot 3 \\ &\quad + P(X = 4) \cdot 4 + P(X = 5) \cdot 5 + P(X = 6) \cdot 6 \\ &= \frac{1}{6}(1 + 2 + 3 + 4 + 5 + 6) = 3.5 \end{aligned}$$

Die **Varianz** ist die erwartete quadratische Abweichung vom Erwartungswert, die „Streuung“ um den Erwartungswert.

Beispiel einmaliger Würfelwurf:

$$\begin{aligned} \text{Var}(X) &= E[(X - E[X])^2] = E[(X - 3.5)^2] \\ &= P(X = 1) \cdot (1 - 3.5)^2 + P(X = 2) \cdot (2 - 3.5)^2 + P(X = 3) \cdot (3 - 3.5)^2 \\ &\quad + P(X = 4) \cdot (4 - 3.5)^2 + P(X = 5) \cdot (5 - 3.5)^2 + P(X = 6) \cdot (6 - 3.5)^2 \\ &= \frac{1}{6}((-2.5)^2 + (-1.5)^2 + (-0.5)^2 + 0.5^2 + 1.5^2 + 2.5^2) = \frac{17.5}{6} = \frac{35}{12} \end{aligned}$$

8.1 Erwartungswert und Varianz

Diskrete Wahrscheinlichkeitsverteilungen

Ist $h : \mathbb{R} \rightarrow \mathbb{R}$ eine Funktion, so gilt für den Erwartungswert der transformierten Zufallsvariable $h(X)$:

$$E[h(X)] = \sum_{j=1}^J h(x_j) \cdot p(x_j), \quad J \in \mathbb{N} \cup \{\infty\}$$

Für $h : x \mapsto x$ ergibt sich für $E[h(X)]$ damit der Erwartungswert von X und für $h : x \mapsto (x - E[X])^2$ die Varianz von X .

Der Wert, der sich für $h : x \mapsto x^k$ ergibt, wird k -tes **Moment** von X genannt:

$$m_k(X) = E[X^k] = \sum_{j=1}^J x_j^k \cdot p(x_j), \quad J \in \mathbb{N} \cup \{\infty\}.$$

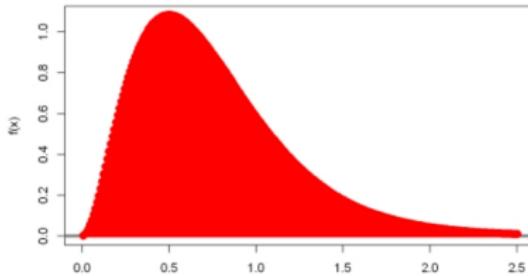
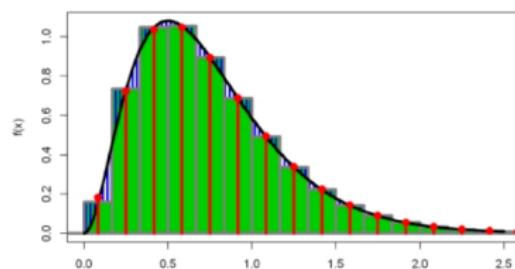
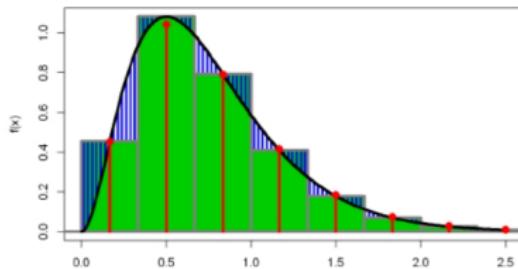
Das k -te Moment der um den Erwartungswert zentrierten Zufallsvariable $X - E[X]$ heißt k -tes **zentrales Moment**:

$$\mu_k(X) = E[(X - E[X])^k] = \sum_{j=1}^J (x_j - E[X])^k \cdot p(x_j), \quad J \in \mathbb{N} \cup \{\infty\}$$

8.1 Erwartungswert und Varianz

Stetige Wahrscheinlichkeitsverteilungen

Approximation stetiger Dichtefunktionen von X durch Zähldichte diskreter Zufallsvariable



Integral ist die Fläche unter der Kurve und kann als Grenzwert von immer dünneren Rechtecken berechnet werden

8.1 Erwartungswert und Varianz

Stetige Wahrscheinlichkeitsverteilungen

Der **Erwartungswert** einer stetig verteilten Zufallsvariable X mit Dichtefunktion $f(\cdot)$ ist definiert durch

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} t \cdot f(t) dt$$

Die **Varianz** von X ist definiert durch

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \int_{-\infty}^{\infty} (t - \mathbb{E}[X])^2 \cdot f(t) dt$$

Die **Standardabweichung** von X ist definiert durch

$$\sqrt{\text{Var}(X)}$$

8.1 Erwartungswert und Varianz

Eigenschaften von Erwartungswerten

Falls die folgenden Erwartungswerte von stetig oder diskret verteilten Zufallsvariablen existieren, so gelten folgende Eigenschaften:

$$(1) \quad E[X + Y] = E[X] + E[Y]$$

$$(2) \quad E[aX + b] = aE[X] + b, \quad a, b \in \mathbb{R}$$

$$(3) \quad E\left[\sum_{i=1}^n a_i X_i + b\right] = \sum_{i=1}^n a_i E[X_i] + b, \quad a_1, \dots, a_n, b \in \mathbb{R}$$

$$(4) \quad X \text{ und } Y \text{ st.u.} \Rightarrow E[XY] = E[X] \cdot E[Y]$$

8.1 Erwartungswert und Varianz

Eigenschaften von Erwartungswerten

Falls die folgenden Erwartungswerte von stetig oder diskret verteilten Zufallsvariablen existieren, so gelten folgende Eigenschaften:

$$(1) \quad E[X + Y] = E[X] + E[Y]$$

Beweis:

$$\begin{aligned} E[X + Y] &= \sum_{x+y \in T_{X+Y}} [x + y] \cdot P(X + Y = x + y) = \sum_{\omega \in \Omega} [X(\omega) + Y(\omega)] \cdot P(\{\omega\}) \\ &= \sum_{\omega \in \Omega} X(\omega) \cdot P(\{\omega\}) + \sum_{\omega \in \Omega} Y(\omega) \cdot P(\{\omega\}) \\ &= \sum_{x \in T_X} x \cdot P(X = x) + \sum_{y \in T_Y} P(Y = y) = \boxed{E[X] + E[Y]} \quad \square \end{aligned}$$

8.1 Erwartungswert und Varianz

Eigenschaften von Erwartungswerten

Falls die folgenden Erwartungswerte von stetig oder diskret verteilten Zufallsvariablen existieren, so gelten folgende Eigenschaften:

$$(2) \quad E[aX + b] = aE[X] + b, \quad a, b \in \mathbb{R}$$

Beweis:

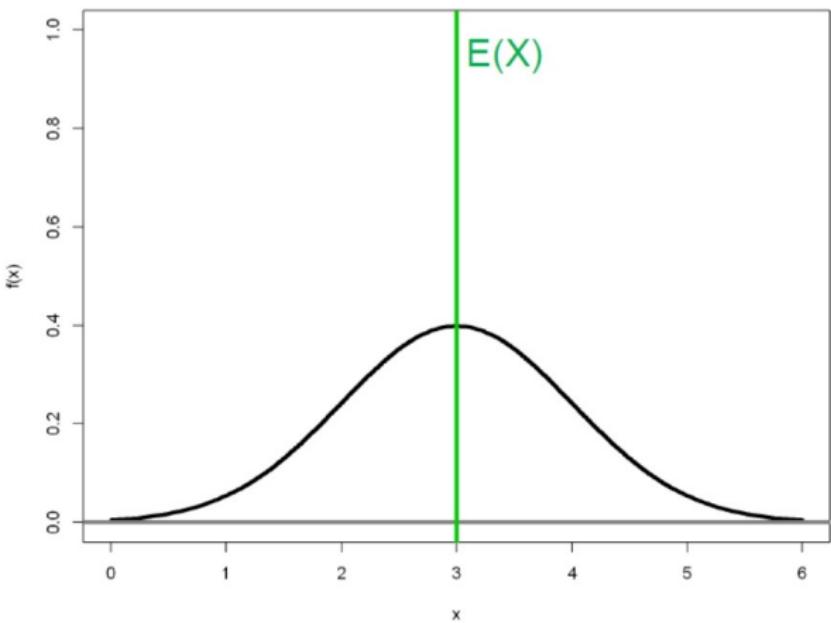
$$\begin{aligned} E[aX + b] &= \int_{-\infty}^{\infty} (at + b) \cdot f(t) dt = \int_{-\infty}^{\infty} at \cdot f(t) dt + \int_{-\infty}^{\infty} b \cdot f(t) dt \\ &= a \cdot \int_{-\infty}^{\infty} t \cdot f(t) dt + b \cdot \int_{-\infty}^{\infty} f(t) dt = a \cdot E[X] + b \cdot 1 \\ &= aE[X] + b \end{aligned}$$

8.1 Erwartungswert und Varianz

Eigenschaften von Erwartungswerten

$$E[aX + b] = a E[X] + b,$$
$$a, b \in \mathbb{R}$$

Beispiel mit $a=0.5$ und $b=2$

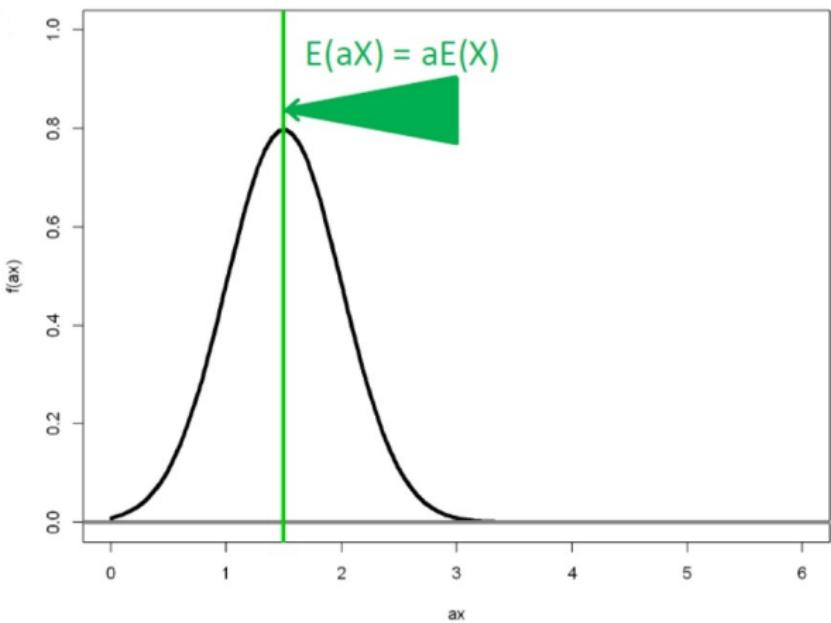


8.1 Erwartungswert und Varianz

Eigenschaften von Erwartungswerten

$$E[aX + b] = a E[X] + b,$$
$$a, b \in \mathbb{R}$$

Beispiel mit $a=0.5$ und $b=2$

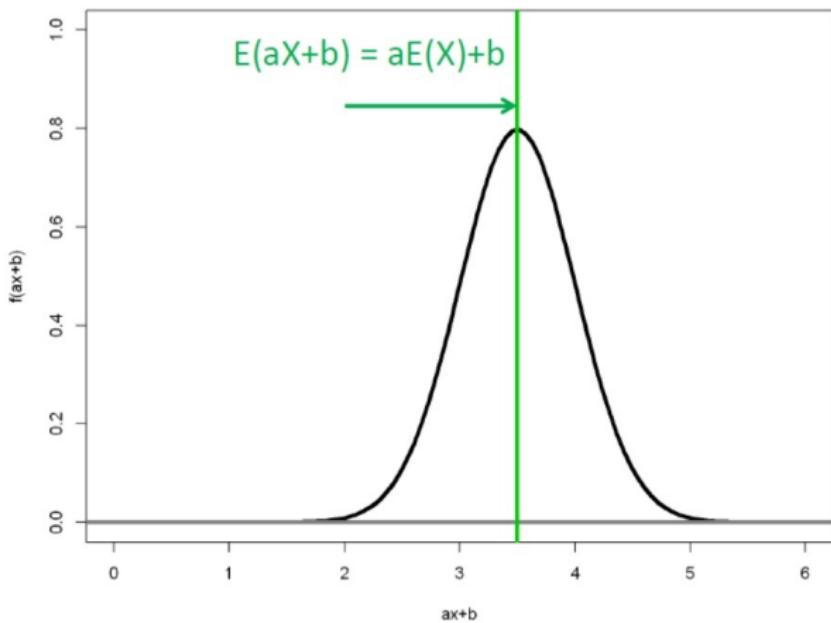


8.1 Erwartungswert und Varianz

Eigenschaften von Erwartungswerten

$$E[aX + b] = a E[X] + b, \\ a, b \in \mathbb{R}$$

Beispiel mit $a=0.5$ und $b=2$



8.1 Erwartungswert und Varianz

Eigenschaften von Erwartungswerten

Falls die folgenden Erwartungswerte von stetig oder diskret verteilten Zufallsvariablen existieren, so gelten folgende Eigenschaften:

$$(3) \quad E\left[\sum_{i=1}^n a_i X_i + b\right] = \sum_{i=1}^n a_i E[X_i] + b, \quad a_1, \dots, a_n, b \in \mathbb{R}$$

Beweis:

$$\begin{aligned} E\left[\sum_{i=1}^n a_i X_i + b\right] &\stackrel{(2)}{=} E\left[\sum_{i=1}^n a_i X_i\right] + b \stackrel{(1)}{=} \sum_{i=1}^n E[a_i X_i] + b \\ &\stackrel{(2)}{=} \sum_{i=1}^n a_i E[X_i] + b \quad \square \end{aligned}$$

8.1 Erwartungswert und Varianz

Eigenschaften von Erwartungswerten

Falls die folgenden Erwartungswerte von stetig oder diskret verteilten Zufallsvariablen existieren, so gelten folgende Eigenschaften:

$$(4) \quad X \text{ und } Y \text{ st.u.} \Rightarrow E[XY] = E[X] \cdot E[Y]$$

Beweis:

$$X \text{ und } Y \text{ st.u.} \Rightarrow f_{XY}(x, y) = f_X(x) \cdot f_Y(y)$$

$$\begin{aligned} \Rightarrow E[XY] &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} u \cdot v \cdot f_{XY}(u, v) du dv = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} u \cdot v \cdot f_X(u) \cdot f_Y(v) du dv \\ &= \int_{-\infty}^{\infty} u \cdot f_X(u) du \int_{-\infty}^{\infty} v \cdot f_Y(v) dv = \boxed{E[X] \cdot E[Y]} \end{aligned}$$

8.1 Erwartungswert und Varianz

Eigenschaften von Varianzen

Falls die folgenden Varianzen von stetig oder diskret verteilten Zufallsvariablen existieren, so gelten folgende Eigenschaften:

- (A) $\text{Var}(X) \geq 0$
- (B) $\text{Var}(X) = 0 \Leftrightarrow X \sim \varepsilon_a, a \in \mathbb{R}$
- (C) $\text{Var}(aX + b) = a^2 \text{Var}(X)$
- (D) X und Y st.u. $\Rightarrow \text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$
- (E) X_1, \dots, X_n st.u., $a_1, \dots, a_n \in \mathbb{R}$

$$\Rightarrow \text{Var}\left(\sum_{i=1}^n a_i X_i + b\right) = \sum_{i=1}^n a_i^2 \text{Var}(X)$$

- (A) $\boxed{\text{Var}(X) \geq 0}$ ist klar, da Quadrat und Dichte immer größer 0

8.1 Erwartungswert und Varianz

Eigenschaften von Varianzen

Falls die folgenden Varianzen von stetig oder diskret verteilten Zufallsvariablen existieren, so gelten folgende Eigenschaften:

$$(B) \quad \text{Var}(X) = 0 \Leftrightarrow X \sim \varepsilon_a, a \in \mathbb{R}$$

Beweis:

$$\text{„} \Leftarrow \text{“ : } X \sim \varepsilon_a \Rightarrow E[X] = a \Rightarrow X - E[X] = 0 \Rightarrow \boxed{\text{Var}(X) = 0}$$

$$\text{„} \Rightarrow \text{“ : } \text{Var}(X) = 0 \Leftrightarrow \int_{-\infty}^{\infty} (t - E[X])^2 \cdot f(t) dt = 0$$

$$\Rightarrow \text{ für alle } t \in \mathbb{R} : (t - E[X])^2 = 0 \text{ oder } f(t) = 0$$

$$(t - E[X])^2 = 0 \Leftrightarrow t = E[X] \Rightarrow \text{ für alle } t \neq E[X] \text{ muss gelten : } f(t) = 0$$

$$\int_{-\infty}^{\infty} f(t) dt = 1 \Rightarrow \boxed{X \sim \varepsilon_{E[X]}} \quad \square$$

8.1 Erwartungswert und Varianz

Eigenschaften von Varianzen

Falls die folgenden Varianzen von stetig oder diskret verteilten Zufallsvariablen existieren, so gelten folgende Eigenschaften:

$$(C) \quad \text{Var}(aX + b) = a^2 \text{Var}(X)$$

Beweis:

$$\begin{aligned} \boxed{\text{Var}(aX + b)} &= E[(aX + b - E[aX + b])^2] \\ &\stackrel{E[aX+b]=aE[X]+b}{=} E[(aX + b - aE[X] - b)^2] = E[(a \cdot (X - E[X]))^2] \\ &= E[a^2 \cdot (X - E[X])^2] = a^2 \cdot E[(X - E[X])^2] = \boxed{a^2 \text{Var}(X)} \quad \square \end{aligned}$$

8.1 Erwartungswert und Varianz

Eigenschaften von Varianzen

Falls die folgenden Varianzen von stetig oder diskret verteilten Zufallsvariablen existieren, so gelten folgende Eigenschaften:

(D) X und Y st.u. $\Rightarrow \text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$

Beweis: X und Y st.u. $\Rightarrow E[XY] = E[X]E[Y]$ (*)

$$\begin{aligned}\text{Var}(X + Y) &= E[(X + Y - E[X + Y])^2] = E[(X + Y - E[X] - E[Y])^2] \\ &= E[((X - E[X]) + (Y - E[Y]))^2] \\ &= E[(X - E[X])^2 + (Y - E[Y])^2 + 2(X - E[X]) \cdot (Y - E[Y])] \\ &= \text{Var}(X) + \text{Var}(Y) + 2R\end{aligned}$$

8.1 Erwartungswert und Varianz

Eigenschaften von Varianzen

Falls die folgenden Varianzen von stetig oder diskret verteilten Zufallsvariablen existieren, so gelten folgende Eigenschaften:

(D) X und Y st.u. $\Rightarrow \text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$

Beweis: (Fortsetzung)

$$\begin{aligned} R &= E[(X - E[X]) \cdot (Y - E[Y])] = E[XY - E[X]Y - X E[Y] + E[X] E[Y]] \\ &= E[XY] - E[X] E[Y] - E[X] E[Y] + E[X] E[Y] \stackrel{(*)}{=} 0 \end{aligned}$$

$$\Rightarrow \boxed{\text{Var}(X + Y)} = \text{Var}(X) + \text{Var}(Y) + 2R \underset{R=0}{=} \boxed{\text{Var}(X) + \text{Var}(Y)} \quad \square$$

8.1 Erwartungswert und Varianz

Eigenschaften von Varianzen

Falls die folgenden Varianzen von stetig oder diskret verteilten Zufallsvariablen existieren, so gelten folgende Eigenschaften:

(F) Verschiebungssatz von Steiner:

$$a \in \mathbb{R} \Rightarrow \text{Var}(X) = E[(X - a)^2] - (E[X] - a)^2,$$

speziell für $a = 0 \Rightarrow \text{Var}(X) = E[X^2] - E[X]^2$

(G) Tschebyscheff-Ungleichung:

$$P(|X - E[X]| > \varepsilon) \leq \frac{\text{Var}(X)}{\varepsilon^2}, \quad \varepsilon \in (0, \infty)$$

8.1 Erwartungswert und Varianz

Eigenschaften von Varianzen

Falls die folgenden Varianzen von stetig oder diskret verteilten Zufallsvariablen existieren, so gelten folgende Eigenschaften:

(F) Verschiebungssatz von Steiner:

$$a \in \mathbb{R} \Rightarrow \text{Var}(X) = E[(X - a)^2] - (E[X] - a)^2,$$

$$\text{speziell f\"ur } a = 0 \Rightarrow \text{Var}(X) = E[X^2] - E[X]^2$$

Beweis:

$$\begin{aligned}\text{Var}(X) &= E[(X - E[X])^2] = E[((X - a) + (a - E[X]))^2] \\&= E[(X - a)^2 + 2(a - E[X])(X - a) + (a - E[X])^2] \\&= E[(X - a)^2] + 2(a - E[X])(E[X] - a) + (a - E[X])^2 \\&= E[(X - a)^2] - 2(a - E[X])^2 + (a - E[X])^2 \\&= \boxed{E[(X - a)^2] - (a - E[X])^2}\end{aligned}$$

8.1 Erwartungswert und Varianz

Eigenschaften von Varianzen

(G) **Tschebyscheff-Ungleichung:**

$$P(|X - E[X]| > \varepsilon) \leq \frac{Var(X)}{\varepsilon^2}, \quad \varepsilon \in (0, \infty)$$

Beweis:

$$\begin{aligned} Var(X) &= \int_{-\infty}^{\infty} (t - E[X])^2 f_X(t) dt \\ &\geq \int_{(t-E[X])^2 f_X(t) \geq 0} (t - E[X])^2 f_X(t) dt \\ &\geq \int_{t:(t-E[X])^2 > \varepsilon^2} \varepsilon^2 f_X(t) dt = \varepsilon^2 \int_{t:(t-E[X])^2 > \varepsilon^2} f_X(t) dt \\ &= \varepsilon^2 \cdot P[(X > E[X] + \varepsilon) \cup (X < E[X] - \varepsilon)] \\ &\stackrel{(*)}{=} \varepsilon^2 \cdot P[|X - E[X]| > \varepsilon] \quad \square \end{aligned}$$

$$(*) (t - E[X])^2 > \varepsilon^2 \Leftrightarrow t > E[X] + \varepsilon \cup t < E[X] - \varepsilon$$

8.1 Erwartungswert und Varianz

Eigenschaften von Varianzen

Anwendung der Tschebyscheff-Ungleichung: Abschätzung verteilungsunabhängiger Unsicherheitsbereiche

$$P(|X - E[X]| > \varepsilon) \leq \frac{Var(X)}{\varepsilon^2}, \quad \varepsilon \in (0, \infty)$$

$$\text{Setze } \varepsilon := r\sqrt{Var(X)} \Rightarrow P(|X - E[X]| > r\sqrt{Var(X)}) \leq \frac{1}{r^2}$$

$$\Leftrightarrow P(E[X] - r\sqrt{Var(X)} \leq X \leq E[X] + r\sqrt{Var(X)}) \geq 1 - \frac{1}{r^2}$$

Die Wahrscheinlichkeit, dass eine Realisation von X in einem symmetrischen Intervall der Breite von r Standardabweichungen fällt, beträgt also unabhängig von der Verteilung von X mindestens $1 - 1/r^2$.

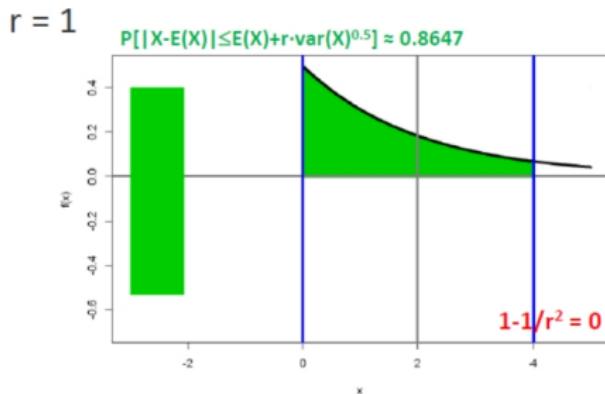
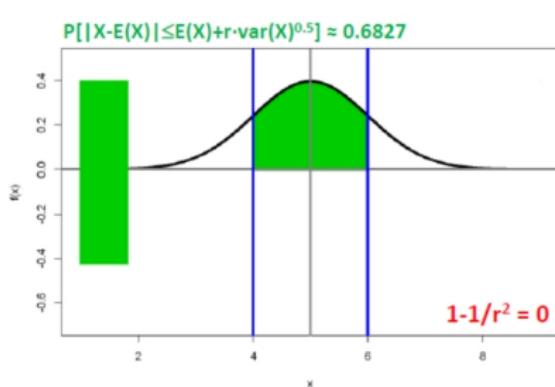
8.1 Erwartungswert und Varianz

Eigenschaften von Varianzen Anwendung der Tschebyscheff-Ungleichung:

Abschätzung verteilungsunabhängiger Unsicherheitsbereiche

$$P\left(E[X] - r\sqrt{\text{Var}(X)} \leq X \leq E[X] + r\sqrt{\text{Var}(X)}\right) \geq 1 - \frac{1}{r^2}$$

Die Wahrscheinlichkeit, dass eine Realisation von X in einem symmetrischen Intervall der Breite von r Standardabweichungen fällt, beträgt also unabhängig von der Verteilung von X mindestens $1 - 1/r^2$.



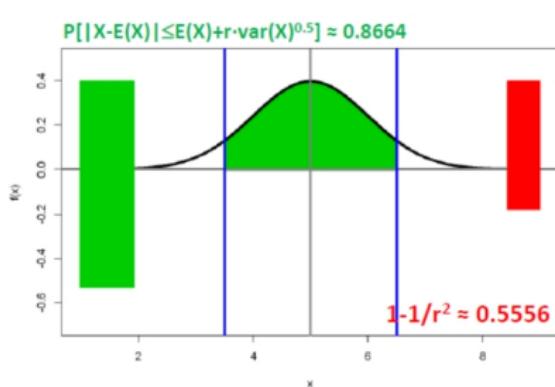
8.1 Erwartungswert und Varianz

Eigenschaften von Varianzen Anwendung der Tschebyscheff-Ungleichung:

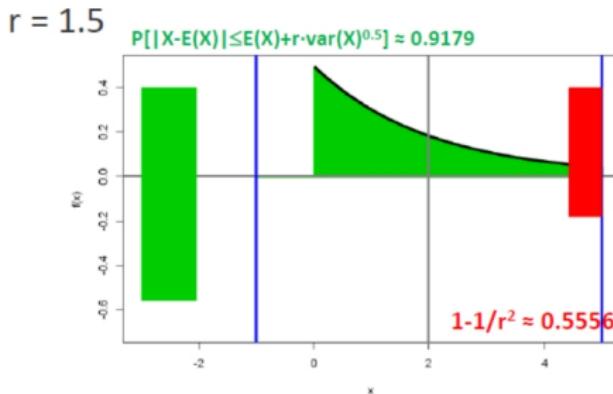
Abschätzung verteilungsunabhängiger Unsicherheitsbereiche

$$P\left(E[X] - r\sqrt{\text{Var}(X)} \leq X \leq E[X] + r\sqrt{\text{Var}(X)}\right) \geq 1 - \frac{1}{r^2}$$

Die Wahrscheinlichkeit, dass eine Realisation von X in einem symmetrischen Intervall der Breite von r Standardabweichungen fällt, beträgt also unabhängig von der Verteilung von X mindestens $1 - 1/r^2$.



$N(5, 1)$



$\text{Exp}(0.5)$

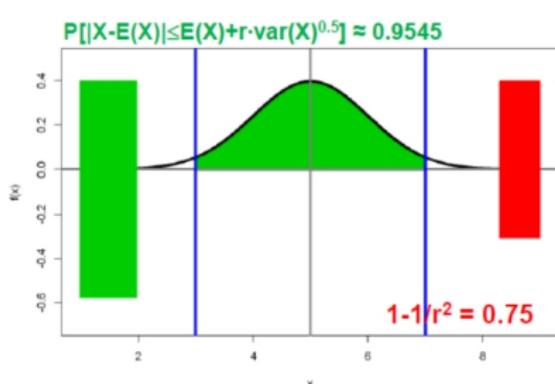
8.1 Erwartungswert und Varianz

Eigenschaften von Varianzen Anwendung der Tschebyscheff-Ungleichung:

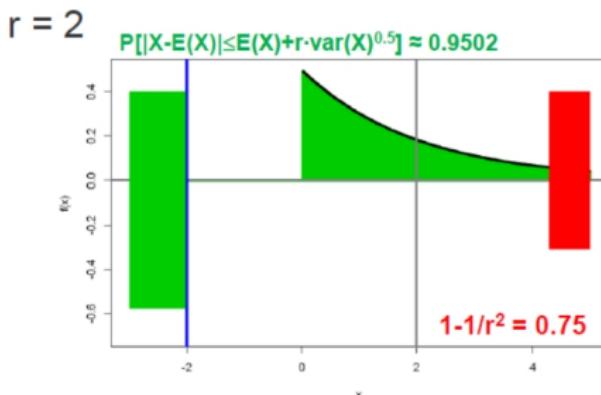
Abschätzung verteilungsunabhängiger Unsicherheitsbereiche

$$P\left(E[X] - r\sqrt{\text{Var}(X)} \leq X \leq E[X] + r\sqrt{\text{Var}(X)}\right) \geq 1 - \frac{1}{r^2}$$

Die Wahrscheinlichkeit, dass eine Realisation von X in einem symmetrischen Intervall der Breite von r Standardabweichungen fällt, beträgt also unabhängig von der Verteilung von X mindestens $1 - 1/r^2$.



$N(5, 1)$



$\text{Exp}(0.5)$

8.1 Erwartungswert und Varianz

Diskrete Wahrscheinlichkeitsverteilungen

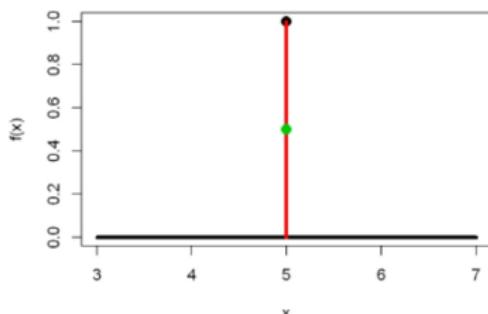
$$\mathbb{E}[X] = \sum_{j=1}^J p(x_j) \cdot x_j \quad \text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2]$$

Beispiel **Einpunktverteilung** ε_a

Zähldichte: $p(x) = \mathbb{I}(a = x)$

$$\mathbb{E}[X] = a$$

$$\sqrt{\text{Var}(X)} = 0$$

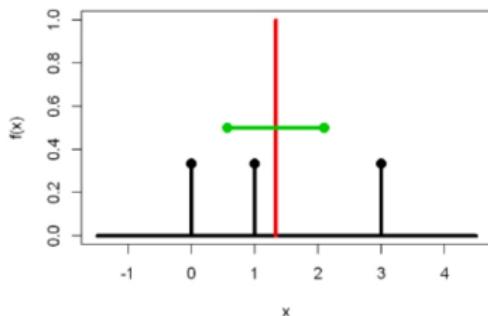


Bsp. **Diskrete Gleichverteilung** $G(x_1, \dots, x_n)$

Zähldichte: $p(x) = \frac{1}{n} \cdot \mathbb{I}(x \in \{x_1, \dots, x_n\})$

$$\mathbb{E}[X] = \bar{x}$$

$$\sqrt{\text{Var}(X)} = \sqrt{s_X^2}$$



8.1 Erwartungswert und Varianz

Diskrete Wahrscheinlichkeitsverteilungen

$$\mathbb{E}[X] = \sum_{j=1}^J p(x_j) \cdot x_j \quad \text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2]$$

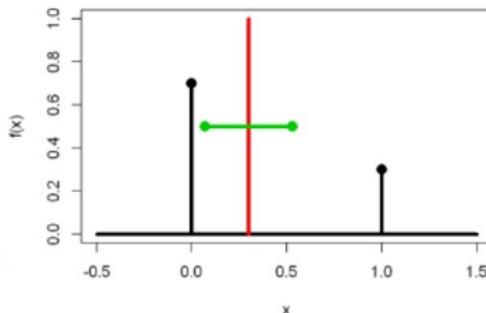
Bsp. **Bernoulli-Verteilung** $\text{Ber}(p)$

Zähldichte:

$$p(x) = p \cdot \mathbb{I}(x = 1) + (1 - p) \cdot \mathbb{I}(x = 0)$$

$$\mathbb{E}[X] = p$$

$$\sqrt{\text{Var}(X)} = \sqrt{p(1-p)}$$



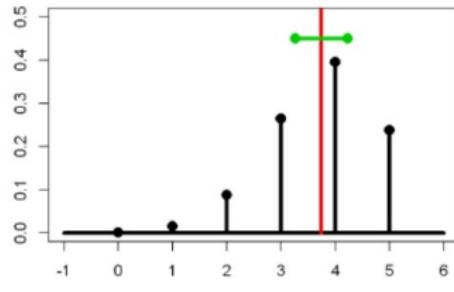
Bsp. **Binomialverteilung** $\text{Bin}(n, p)$

Zähldichte:

$$p(x) = \mathbb{I}(x \in \{0, \dots, n\}) \cdot \binom{n}{x} \cdot p^x \cdot (1-p)^{n-x}$$

$$\mathbb{E}[X] = np$$

$$\sqrt{\text{Var}(X)} = \sqrt{np(1-p)}$$



8.1 Erwartungswert und Varianz

Diskrete Wahrscheinlichkeitsverteilungen

$$E[X] = \sum_{j=1}^J p(x_j) \cdot x_j \quad \text{Var}(X) = E[(X - E[X])^2]$$

Bsp. **Hypergeometrische Verteilung** Hyp(n, r, s)

Zähldichte:

$$p(x) = I(x \in \{\max(0, n-1), \dots, \min(n, r)\}) \cdot \frac{\binom{r}{x} \cdot \binom{s}{n-x}}{\binom{r+s}{n}}$$

$$E[X] = n \frac{r}{r+s}$$

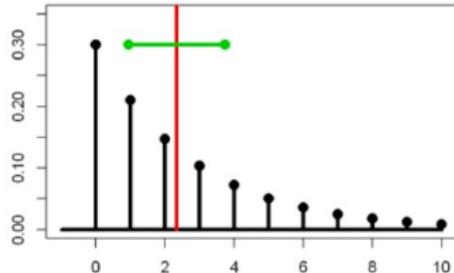
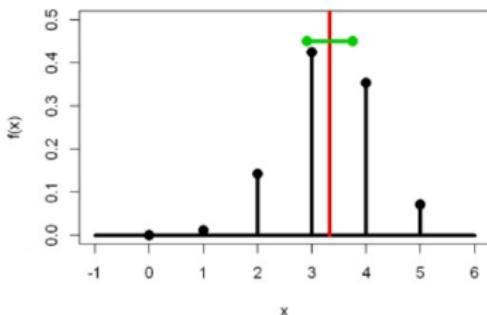
$$\sqrt{\text{Var}(X)} = \sqrt{n \frac{r}{r+s} \frac{s}{r+s} \frac{r+s-n}{r+s-1}}$$

Bsp. **Geometrische Verteilung** Geo(p)

Zähldichte: $p(x) = I(x \in \mathbb{N} \cup 0) \cdot p \cdot (1-p)^x$

$$E[X] = \frac{1-p}{p}$$

$$\sqrt{\text{Var}(X)} = \sqrt{\frac{1-p}{p^2}}$$



8.1 Erwartungswert und Varianz

Diskrete Wahrscheinlichkeitsverteilungen

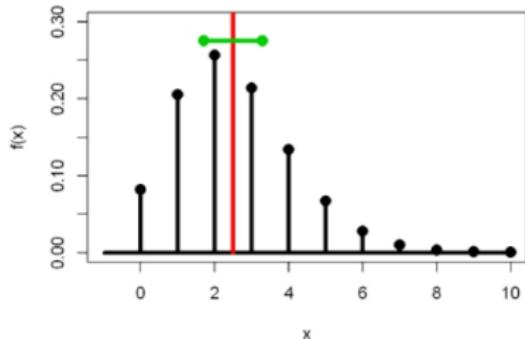
$$\mathbb{E}[X] = \sum_{j=1}^J p(x_j) \cdot x_j \quad \text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2]$$

Bsp. **Poisson-Verteilung** $\text{Poi}(\lambda)$

Zähldichte: $p(x) = \frac{\lambda^x e^{-\lambda}}{x!}$

$$\mathbb{E}[X] = \lambda$$

$$\sqrt{\text{Var}(X)} = \sqrt{\lambda}$$



8.1 Erwartungswert und Varianz

Stetige Wahrscheinlichkeitsverteilungen

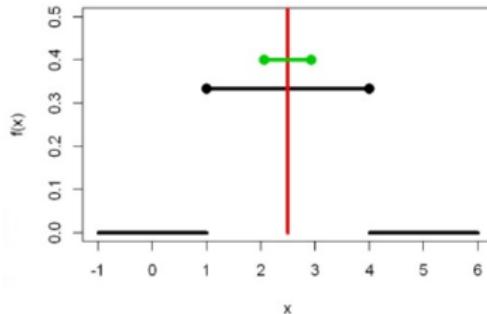
$$E[X] = \int_{-\infty}^{\infty} t \cdot f(t) dt \quad \text{Var}(X) = E[(X - E[X])^2]$$

Bsp. **Rechteckverteilung** $R(a, b)$

Dichtefunktion: $f(x) = \frac{I(a \leq x \leq b)}{b-a}$

$$E[X] = \frac{a+b}{2}$$

$$\sqrt{\text{Var}(X)} = \sqrt{\frac{(b-a)^2}{12}}$$

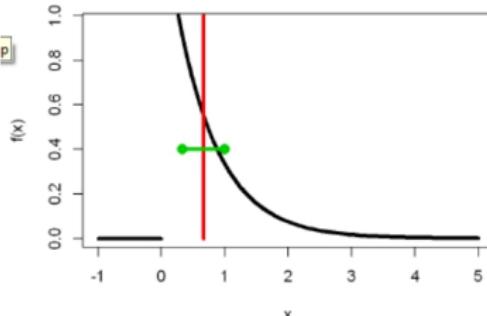


Bsp. **Exponentialverteilung** $\text{Exp}(\lambda)$

Dichtefunktion: $f(x) = I(0 \leq x) \cdot \lambda e^{-(\lambda \cdot x)}$

$$E[X] = \frac{1}{\lambda}$$

$$\sqrt{\text{Var}(X)} = \sqrt{\frac{1}{\lambda^2}}$$



8.1 Erwartungswert und Varianz

Stetige Wahrscheinlichkeitsverteilungen

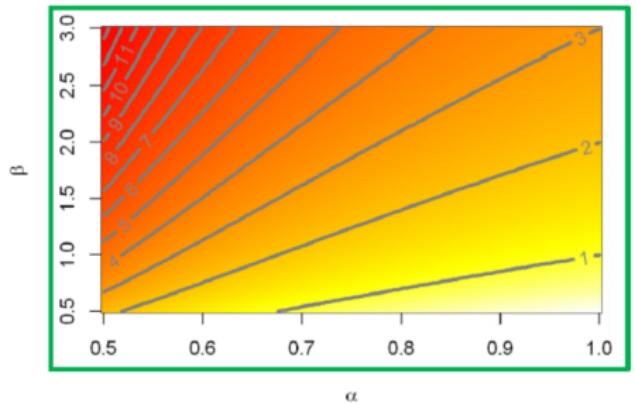
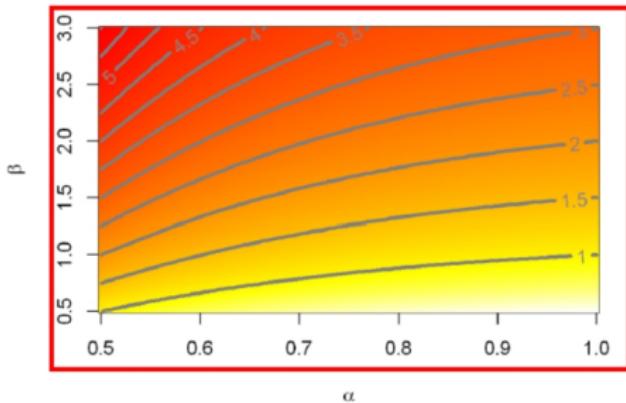
Bsp. **Weibull-Verteilung** $W(\alpha, \beta)$

Dichtefunktion:

$$f(x) = I(0 \leq x) \cdot \left(\frac{\alpha}{\beta} \left(\frac{x}{\beta} \right)^{\alpha-1} e^{-(x/\beta)^\alpha} \right)$$

$$E[X] = \frac{\beta}{\alpha} \Gamma\left(\frac{1}{\alpha}\right)$$

$$\sqrt{\text{Var}(X)} = \sqrt{\beta^2 \left(\frac{2}{\alpha} \Gamma\left[\frac{2}{\alpha}\right] - \left[\frac{1}{\alpha} \Gamma\left(\frac{1}{\alpha}\right) \right]^2 \right)}$$



8.1 Erwartungswert und Varianz

Stetige Wahrscheinlichkeitsverteilungen

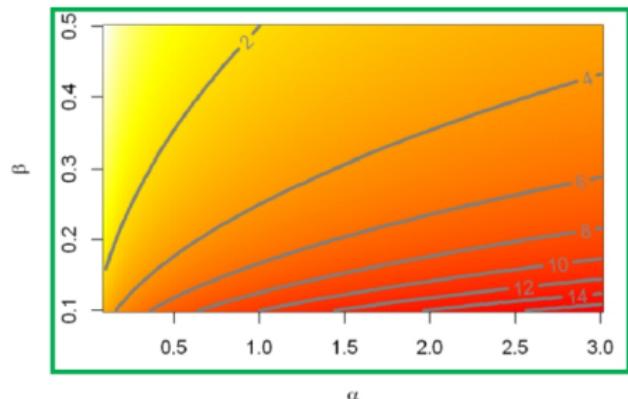
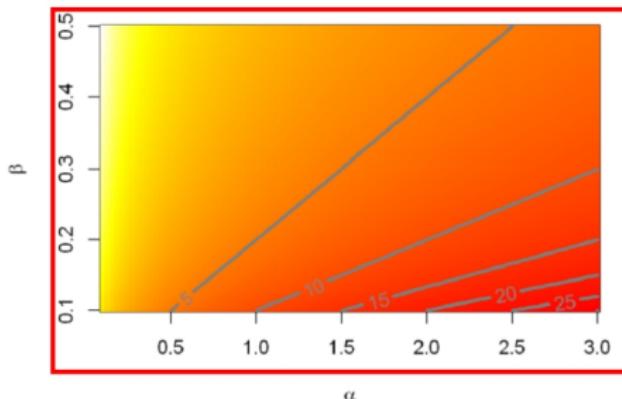
Bsp. **Gamma-Verteilung** $\Gamma(\alpha, \beta)$

$$E[X] = \frac{\alpha}{\beta}$$

Dichtefunktion:

$$f(x) = I(0 \leq x) \cdot \frac{\alpha^\beta}{\Gamma(\beta)} x^{\beta-1} e^{-\alpha x}$$

$$\sqrt{\text{Var}(X)} = \sqrt{\frac{\alpha}{\beta^2}}$$



8.1 Erwartungswert und Varianz

Stetige Wahrscheinlichkeitsverteilungen

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} t \cdot f(t) dt \quad \text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2]$$

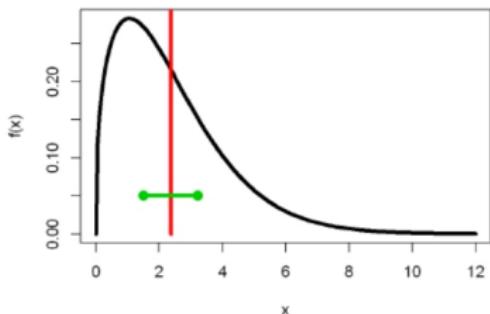
Bsp. **Weibull-Verteilung** $W(\alpha, \beta)$

Dichtefunktion:

$$f(x) = \mathbb{I}(0 \leq x) \cdot \left(\frac{\alpha}{\beta} \left(\frac{x}{\beta} \right)^{\alpha-1} e^{-(x/\beta)^\alpha} \right)$$

$$\mathbb{E}[X] = \frac{\beta}{\alpha} \Gamma\left(\frac{1}{\alpha}\right)$$

$$\sqrt{\text{Var}(X)} = \sqrt{\beta^2 \left(\frac{2}{\alpha} \Gamma\left[\frac{2}{\alpha}\right] - \left[\frac{1}{\alpha} \Gamma\left(\frac{1}{\alpha}\right) \right]^2 \right)}$$

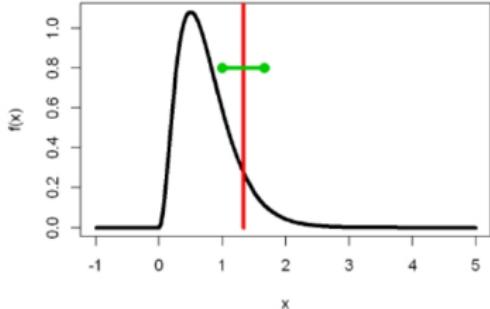


Bsp. **Gamma-Verteilung** $\Gamma(\alpha, \beta)$

Dichtefunktion: $f(x) = \mathbb{I}(0 \leq x) \cdot \frac{\alpha^\beta}{\Gamma(\beta)} x^{\beta-1} e^{-\alpha x}$

$$\mathbb{E}[X] = \frac{\alpha}{\beta}$$

$$\sqrt{\text{Var}(X)} = \sqrt{\frac{\alpha}{\beta^2}}$$



8.1 Erwartungswert und Varianz

Stetige Wahrscheinlichkeitsverteilungen

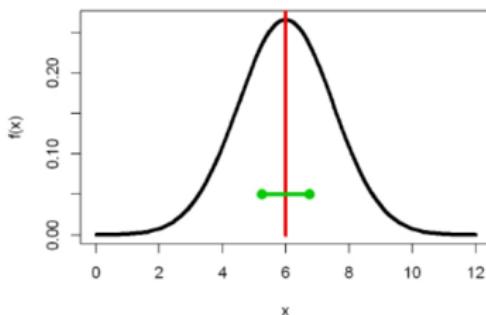
$$E[X] = \int_{-\infty}^{\infty} t \cdot f(t) dt \quad \text{Var}(X) = E[(X - E[X])^2]$$

Bsp. **Normalverteilung** $N(\mu, \sigma^2)$

Dichtefunktion: $f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$

$$E[X] = \mu$$

$$\sqrt{\text{Var}(X)} = \sqrt{\sigma^2}$$



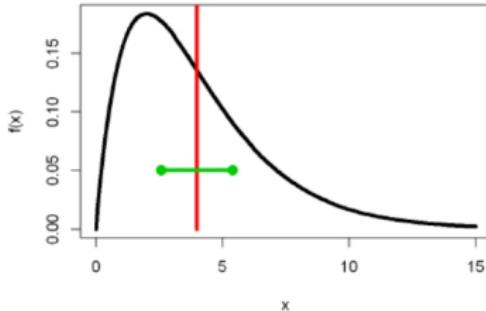
Bsp. χ^2 -Verteilung χ_f^2

Dichtefunktion:

$$f(x) = I(0 < x) \cdot \frac{1}{2^{f/2}\Gamma(f/2)} x^{f/2-1} e^{-x/2}$$

$$E[X] = f$$

$$\sqrt{\text{Var}(X)} = \sqrt{2f}$$



8.1 Erwartungswert und Varianz

Stetige Wahrscheinlichkeitsverteilungen

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} t \cdot f(t) dt \quad \text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2]$$

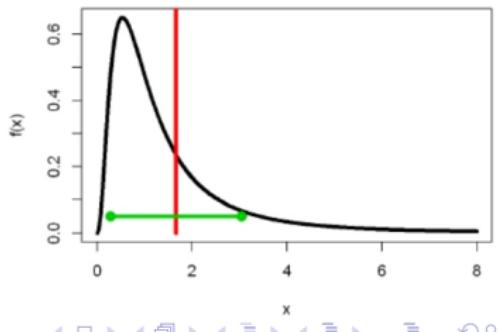
Bsp. **F-Verteilung** F_{f_1, f_2}

Dichtefunktion:

$$f(x) = I(0 < x) \cdot \frac{\Gamma\left(\frac{f_1+f_2}{2}\right)}{\Gamma\left(\frac{f_1}{2}\right)\Gamma\left(\frac{f_2}{2}\right)} \left(\frac{f_1}{f_2}\right)^{f_1/2} \frac{x^{f_1/2-1}}{(1+f_1x/f_2)^{(f_1+f_2)/2}}$$

$$\boxed{\mathbb{E}[X] = \frac{f_2}{f_2-2}, f_2 > 2}$$

$$\boxed{\sqrt{\text{Var}(X)} = \sqrt{\frac{2f_2^2(f_1+f_2-2)}{f_1(f_2-2)^2(f_2-4)}}, f_2 > 4}$$



8.1 Erwartungswert und Varianz

Stetige Wahrscheinlichkeitsverteilungen

$$E[X] = \int_{-\infty}^{\infty} t \cdot f(t) dt \quad \text{Var}(X) = E[(X - E[X])^2]$$

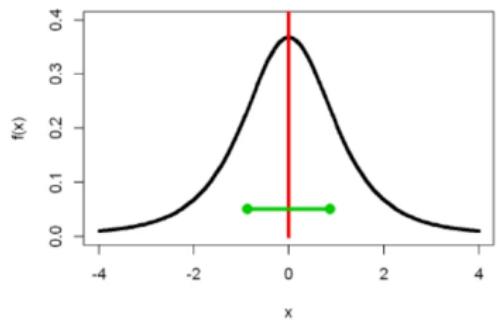
Bsp. **t-Verteilung** t_f

Dichtefunktion:

$$f(x) = \frac{\Gamma\left(\frac{f+1}{2}\right)}{\sqrt{f\pi} \cdot \Gamma\left(\frac{f}{2}\right)} \cdot \left(1 + \frac{x^2}{f}\right)^{-(f+1)/2 - x/2}$$

$$E[X] = 0$$

$$\sqrt{\text{Var}(X)} = \sqrt{\frac{f}{f-2}}, \quad f > 2$$



8.1 Erwartungswert und Varianz

Schwaches Gesetz der großen Zahlen

Es gelte: $X = (X_1, \dots, X_N)$, $X_i \sim F^X$ u.i.v.,

$$\mathbb{E}[X_i] = \mu, \text{Var}(X_i) = \sigma^2, i = 1, \dots, N, \bar{X} = \frac{1}{N} \sum_{i=1}^N X_i$$

Dann gilt:

$$\lim_{N \rightarrow \infty} [\mathbb{P}(|\bar{X} - \mu| > \varepsilon)] = 0$$

Beweis:

$$1. \mathbb{E}[\bar{X}] = \mathbb{E}\left[\frac{1}{N} \sum_{i=1}^N X_i\right] = \frac{1}{N} \mathbb{E}\left[\sum_{i=1}^N X_i\right] = \frac{1}{N} \sum_{i=1}^N \mathbb{E}[X_i] = \frac{1}{N} \sum_{i=1}^N \mu = \frac{1}{N} N \mu = \mu$$

$$2. \text{Var}(\bar{X}) = \text{Var}\left(\frac{1}{N} \sum_{i=1}^N X_i\right) = \frac{1}{N^2} \text{Var}\left(\sum_{i=1}^N X_i\right) \underset{X_1, \dots, X_N \text{ st.u.}}{=} \frac{1}{N^2} \sum_{i=1}^N \text{Var}(X_i)$$

$$= \frac{1}{N^2} \sum_{i=1}^N \sigma^2 = \frac{1}{N^2} N \sigma^2 = \frac{\sigma^2}{N}$$

8.1 Erwartungswert und Varianz

Schwaches Gesetz der großen Zahlen

Beweis: (Fortsetzung)

Einsetzen in Tschebyscheff-Ungleichung:

$$P(|\bar{X} - E[\bar{X}]| > \varepsilon) \leq \frac{\text{Var}(\bar{X})}{\varepsilon^2} \Rightarrow P(|\bar{X} - \mu| > \varepsilon) \leq \frac{\sigma^2}{N\varepsilon^2} \xrightarrow[N \rightarrow \infty]{} 0$$
$$\Rightarrow \lim_{N \rightarrow \infty} P(|\bar{X} - \mu| > \varepsilon) = 0 \quad \square$$

8.1 Erwartungswert und Varianz

Nicht existente Erwartungswerte oder Varianzen

Erwartungswert, Varianz und höhere Momente müssen nicht existieren.

Beispiel:

Sei X stetig verteilte Zufallsvariable mit Dichtefunktion $f_X(x) = I(x \geq 1) \cdot \frac{1}{x^2}$

Dann ist f_X tatsächlich Dichte, denn es gilt:

$$F_X(x) = \int_{-\infty}^x f_X(t) dt = \int_1^x f_X(t) dt = -\frac{1}{x} + 1 = 1 - \frac{1}{x} \text{ und damit}$$

$$\int_{-\infty}^{\infty} f_X(t) dt = \lim_{x \rightarrow \infty} (1 - 1/x) = 1$$

Allerdings gilt auch: $E[X] = \int_{-\infty}^{\infty} t f_X(t) dt = \int_1^{\infty} t \frac{1}{t^2} dt = \lim_{b \rightarrow \infty} (\log(b)) = \infty$

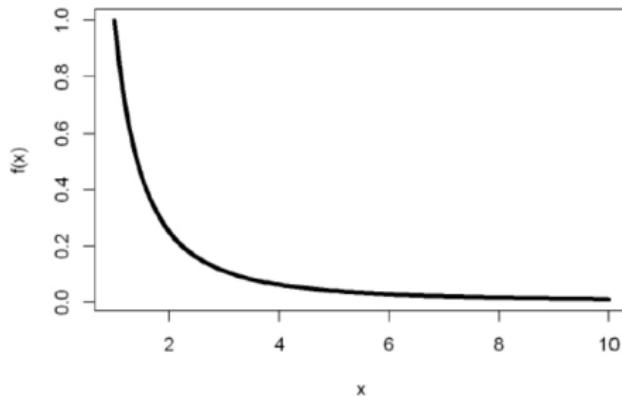
8.1 Erwartungswert und Varianz

Nicht existente Erwartungswerte oder Varianzen

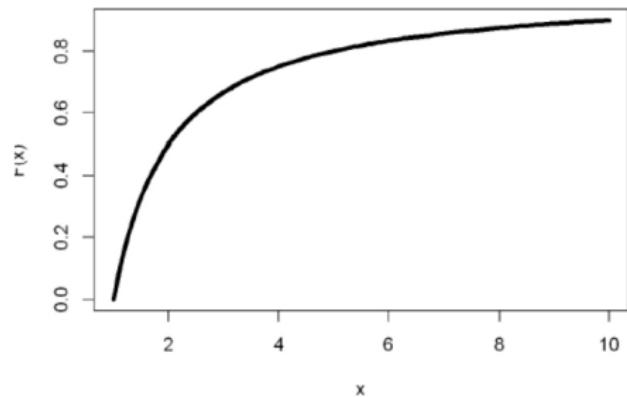
Erwartungswert, Varianz und höhere Momente müssen nicht existieren.

Beispiel:

$$f_x(x) = \frac{1}{x^2}$$



$$F_x(x) = 1 - \frac{1}{x}$$



8.2 Weitere wahrscheinlichkeitstheoretische Kennzahlen

p-Quantile

Sei X eine Zufallsvariable mit Verteilungsfunktion F .

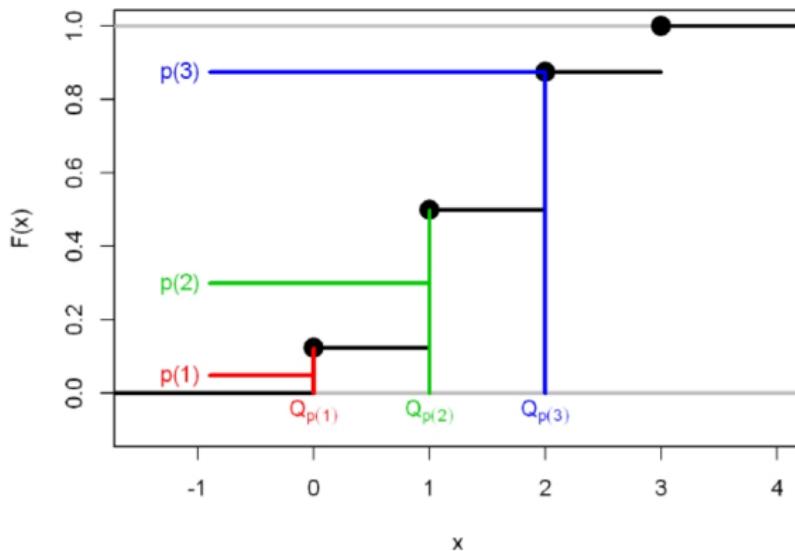
Für eine Zahl $p \in (0, 1)$ wird das **p -Quantil** $Q_p = Q_p(X)$ der durch die Verteilungsfunktion $F = F^X$ festgelegten Verteilung P^X definiert durch den kleinsten Wert $x \in \mathbb{R}$, für den gilt:

$$F(x) \geq p$$

Das 0.5-Quantil heißt **Median**, das 0.25-Quantil **unteres Quartil** und das 0.75-Quantil **oberes Quartil**.

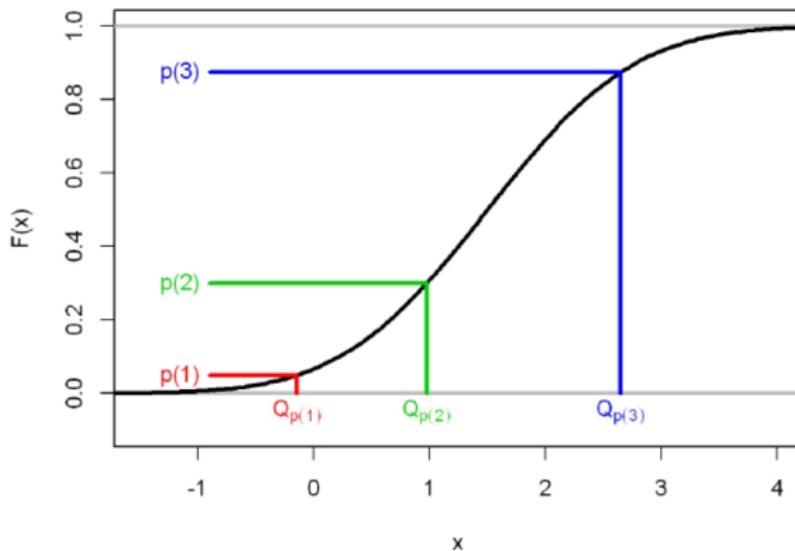
8.2 Weitere wahrscheinlichkeitstheoretische Kennzahlen

Quantilsbestimmung über Verteilungsfunktion (diskreter Fall)



8.2 Weitere wahrscheinlichkeitstheoretische Kennzahlen

Quantilsbestimmung über Verteilungsfunktion (stetiger Fall)



8.2 Weitere wahrscheinlichkeitstheoretische Kennzahlen

Abhangigkeitsmae

Erinnerung: X und Y stochastisch unabhangig $\Rightarrow E[XY] = E[X] \cdot E[Y]$

Umgekehrt gilt somit: $E[XY] \neq E[X] \cdot E[Y] \Rightarrow X$ und Y stochastisch abhangig

Seien X und Y Zufallsvariablen. Dann heit

$$\text{Cov}(X, Y) = E[(X - E[X]) \cdot (Y - E[Y])]$$

Kovarianz von X und Y . Die Groe

$$\text{Cor}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \cdot \text{Var}(Y)}}$$

heit **Korrelation** von X und Y .

8.2 Weitere wahrscheinlichkeitstheoretische Kennzahlen

Abhangigkeitsmae

$$\text{Cov}(X, Y) = E[(X - E[X]) \cdot (Y - E[Y])] \quad \text{Cor}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \cdot \text{Var}(Y)}}$$

Eigenschaften

- (i) $\text{Cov}(X, Y) = \text{Cov}(Y, X)$, $\text{Cor}(X, Y) = \text{Cor}(Y, X)$
- (ii) $\text{Cov}(X, Y) = E[XY] - E[X]E[Y]$
- (iii) $-1 \leq \text{Cor}(X, Y) \leq 1$
- (iv) $\text{Cor}(X, Y) < 0 \Leftrightarrow X \text{ und } Y \text{ sind negativ korreliert}$
 $\text{Cor}(X, Y) > 0 \Leftrightarrow X \text{ und } Y \text{ sind positiv korreliert}$
 $\text{Cor}(X, Y) = 0 \Leftrightarrow X \text{ und } Y \text{ sind unkorreliert}$

8.2 Weitere wahrscheinlichkeitstheoretische Kennzahlen

Abhangigkeitsmae

$$\text{Cov}(X, Y) = E[(X - E[X]) \cdot (Y - E(Y))] \quad \text{Cor}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \cdot \text{Var}(Y)}}$$

Eigenschaften

- (v) X und Y stoch. unabh. $\Rightarrow X$ und Y unkorreliert
 X und Y unkorreliert $\not\Rightarrow X$ und Y stoch. unabh.
- (vi) $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) - 2 \cdot \text{Cov}(X, Y)$
- (vii) $\text{Cov}(aX + b, cY + d) = ac \cdot \text{Cov}(X, Y)$
- (viii) $\text{Cov}(X, X) = \text{Var}(X)$

Beweise der Eigenschaften analog zu den Beweisen der gleichen Eigenschaften fur die empirische Kovarianz und empirische Korrelation.

Bedingte Wahrscheinlichkeiten und stochastische Unabhängigkeit

9.1 Bedingte Wahrscheinlichkeiten

Bisher: Wahrscheinlichkeitsraum (Ω, \mathcal{A}, P)

Grundraum Ω , Menge aller Ereignisse \mathcal{A} auf Ω , Wahrscheinlichkeitsmaß P auf Ω

$$P : \mathcal{A} \rightarrow [0, 1], A \mapsto P(A)$$

- ① $0 \leq P(A) \leq 1$ für jedes Ereignis $A \in \mathcal{A}$
- ② $P(\Omega) = 1$
- ③ $P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$ für alle paarweise disjunkten Ereignisse $A_i \in \mathcal{A}$

9.1 Bedingte Wahrscheinlichkeiten

Jetzt: Wahrscheinlichkeitsraum (B, \mathcal{B}, P_B)

Einschränkung des Grundraums auf Ereignis $B \subset \Omega$, Wahrscheinlichkeitsmaß P_B auf B

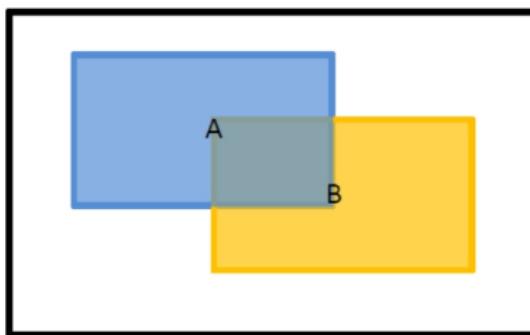
$$P : \mathcal{B} \rightarrow [0, 1], A \mapsto P_B(A)$$

- ① $0 \leq P(A) \leq 1$ für jedes Ereignis $A \in \mathcal{B}$
- ② $P(\Omega) = 1$
- ③ $P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$ für alle paarweise disjunkten Ereignisse $A_i \in \mathcal{B}$

9.1 Bedingte Wahrscheinlichkeiten

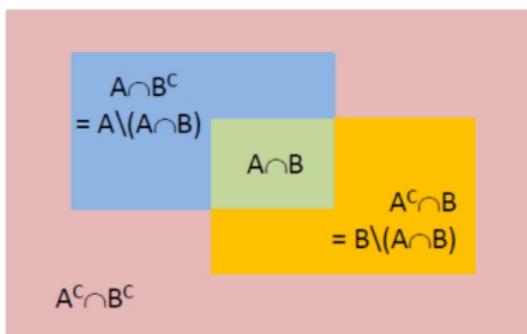
Wahrscheinlichkeitsraum (Ω, \mathcal{A}, P)

Ω



9.1 Bedingte Wahrscheinlichkeiten

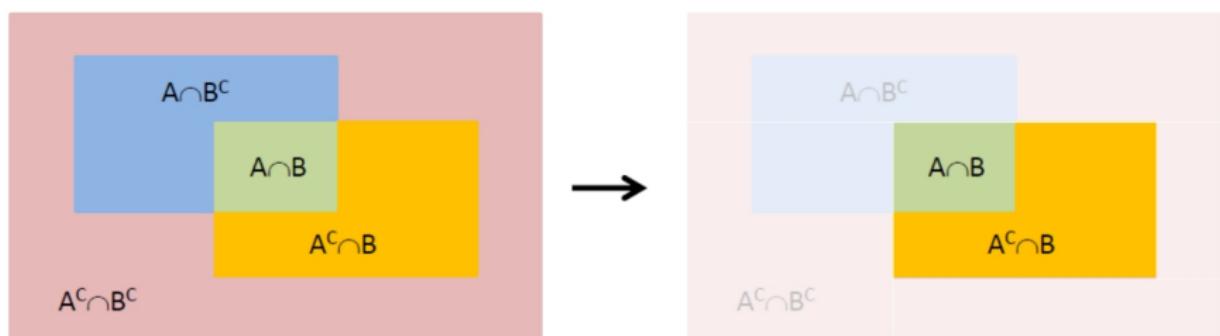
Wahrscheinlichkeitsraum (Ω, \mathcal{A}, P)



9.1 Bedingte Wahrscheinlichkeiten

Wahrscheinlichkeitsraum (Ω, \mathcal{A}, P)

Wahrscheinlichkeitsraum (B, \mathcal{B}, P_B)

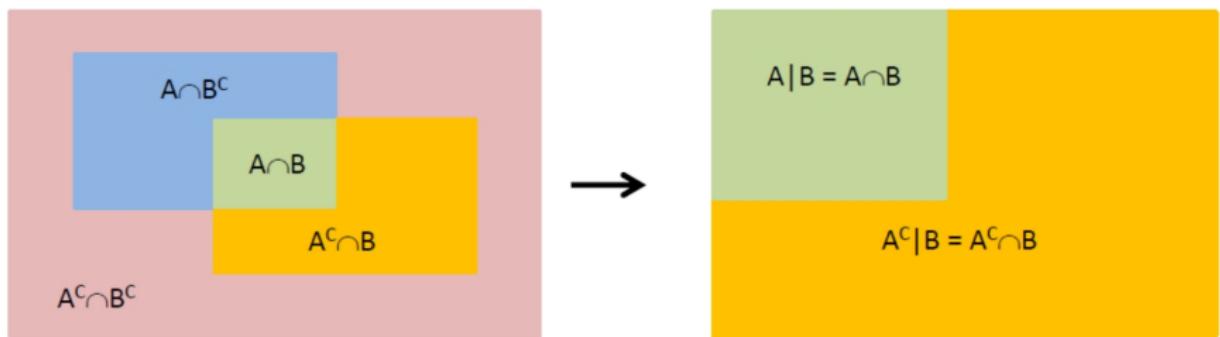


$$\begin{aligned} A \cap B^C &\subset B^C \\ A^C \cap B^C &\subset B^C \end{aligned}$$

9.1 Bedingte Wahrscheinlichkeiten

Wahrscheinlichkeitsraum (Ω, \mathcal{A}, P)

Wahrscheinlichkeitsraum (B, \mathcal{B}, P_B)



$$A \cap B^c \subset B^c$$

$$A^c \cap B^c \subset B^c$$

$$A|B = A \cap B$$

$$A^c|B = A^c \cap B$$

9.1 Bedingte Wahrscheinlichkeiten

Wahrscheinlichkeitsraum (Ω, \mathcal{A}, P)

Wahrscheinlichkeitsraum (B, \mathcal{B}, P_B)



$$1 = P(\Omega) = P_{\Omega}(\Omega) = P(\Omega | \Omega)$$

$$= P[A \cap B^c] + P[A^c \cap B^c]$$

$$+ P[A \cap B] + P[A^c \cap B]$$

$$= P(C_1) + P(C_2) + P(C_3) + P(C_4)$$

$$1 = P_B(B) = P(B | B)$$

$$= P[A|B] + P[A^c|B]$$

$$= P_B[A \cap B] + P_B[A^c \cap B]$$

$$= P_B(C_3) + P_B(C_4)$$

9.1 Bedingte Wahrscheinlichkeiten

Wahrscheinlichkeitsraum (Ω, \mathcal{A}, P)

Wahrscheinlichkeitsraum (B, \mathcal{B}, P_B)



Die Wahrscheinlichkeit

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

heißt **bedingte Wahrscheinlichkeit** von A gegeben B .

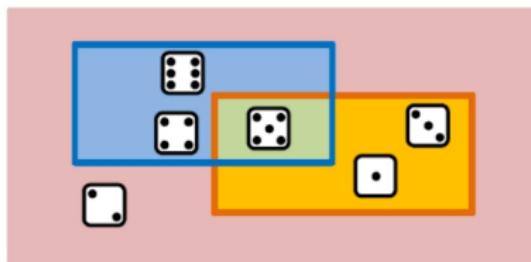
9.1 Bedingte Wahrscheinlichkeiten

Beispiel: **einfacher Würfelwurf**

$A = \text{Zahl größer } 3$

$B = \text{Zahl ungerade}$

Wahrscheinlichkeitsraum (Ω, \mathcal{A}, P)

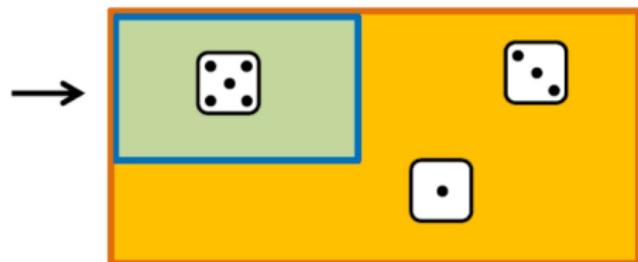


$$P_{(1,\dots,6)}(A) = 3/6$$

$$P_{(1,\dots,6)}(B) = 3/6$$

$$P_{(1,\dots,6)}(A \cap B) = 1/6$$

Wahrscheinlichkeitsraum (B, \mathcal{B}, P_B)



$$P_{(1,3,5)}(B) = P_{(1,\dots,6)}(B \cap A) / P_{(1,\dots,6)}(A) = 1$$

$$P_{(1,3,5)}(A) = P_{(1,\dots,6)}(A \cap B) / P_{(1,\dots,6)}(B)$$

$$= (1/6) / (3/6) = 1/3$$

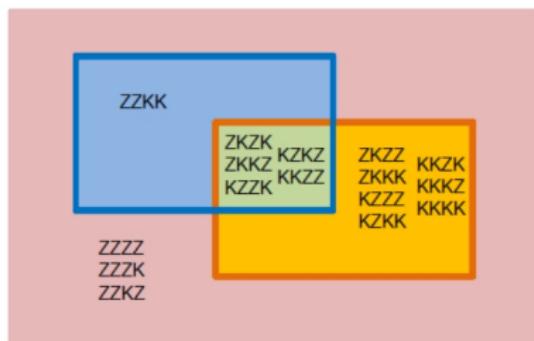
9.1 Bedingte Wahrscheinlichkeiten

Beispiel: **vierfacher Münzwurf**

$A = \text{genau zweimal Kopf nach vier Würfen}$

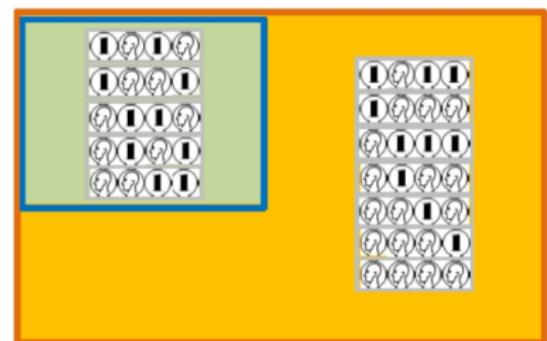
$B = \text{mindestens einmal Kopf nach zwei Würfen}$

Wahrscheinlichkeitsraum (Ω, \mathcal{A}, P)



$$\begin{aligned} P_{\Omega}(A) &= 6/16 = 0.375 & P_{\Omega}(B) &= 12/16 \\ P_{\Omega}(A \cap B) &= 5/16 \end{aligned}$$

Wahrscheinlichkeitsraum (B, \mathcal{B}, P_B)



$$\begin{aligned} P_B(A) &= P_{\Omega}(A \cap B) / P_{\Omega}(B) \\ &= (5/16) / (12/16) = 5/12 \approx 0.417 \end{aligned}$$

9.1 Bedingte Wahrscheinlichkeiten

Umformung der Definitionsformel

$$P(A|B) = \frac{P(A \cap B)}{P(B)} \Rightarrow P(A \cap B) = P(A|B) \cdot P(B)$$

$$P(A \cap B) = P(A|B) \cdot P(B)$$

$$P(A^c \cap B) = P(A^c|B) \cdot P(B)$$

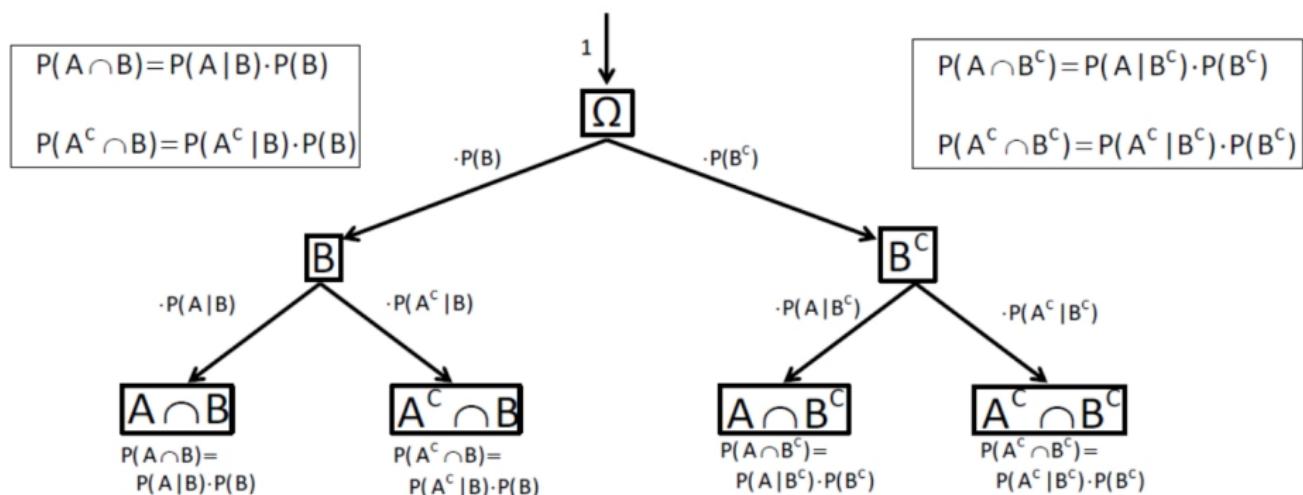
$$P(A \cap B^c) = P(A|B^c) \cdot P(B^c)$$

$$P(A^c \cap B^c) = P(A^c|B^c) \cdot P(B^c)$$

9.1 Bedingte Wahrscheinlichkeiten

Umformung der Definitionsformel

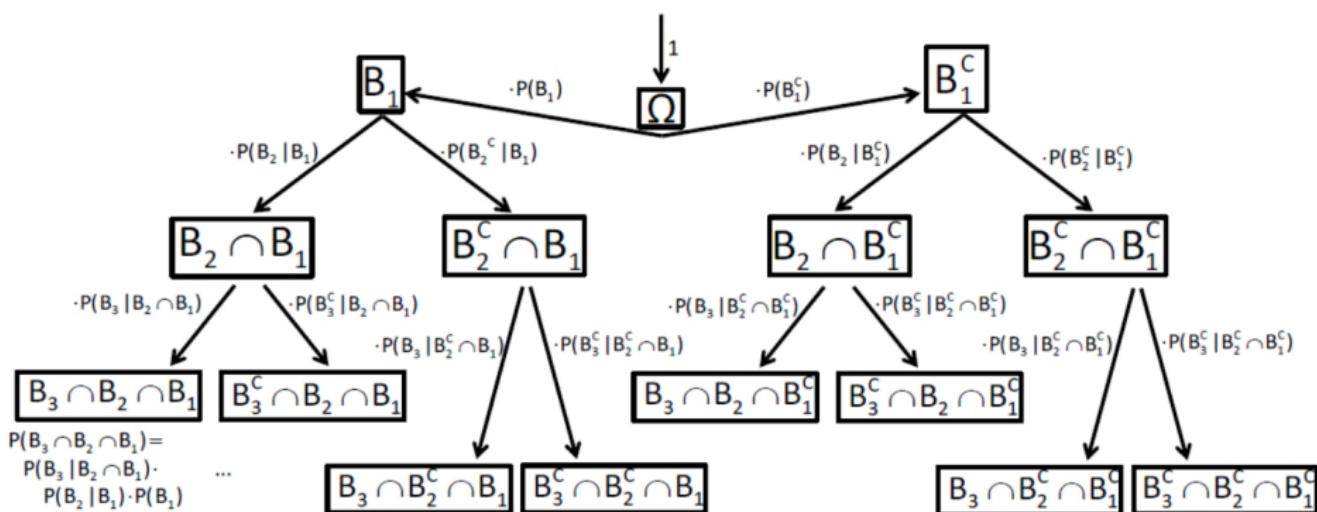
Darstellung der Wahrscheinlichkeit für Schnittereignisse in Ereignisbaum



9.1 Bedingte Wahrscheinlichkeiten

Umformung der Definitionsformel

Darstellung der Wahrscheinlichkeit für Schnittereignisse in Ereignisbaum



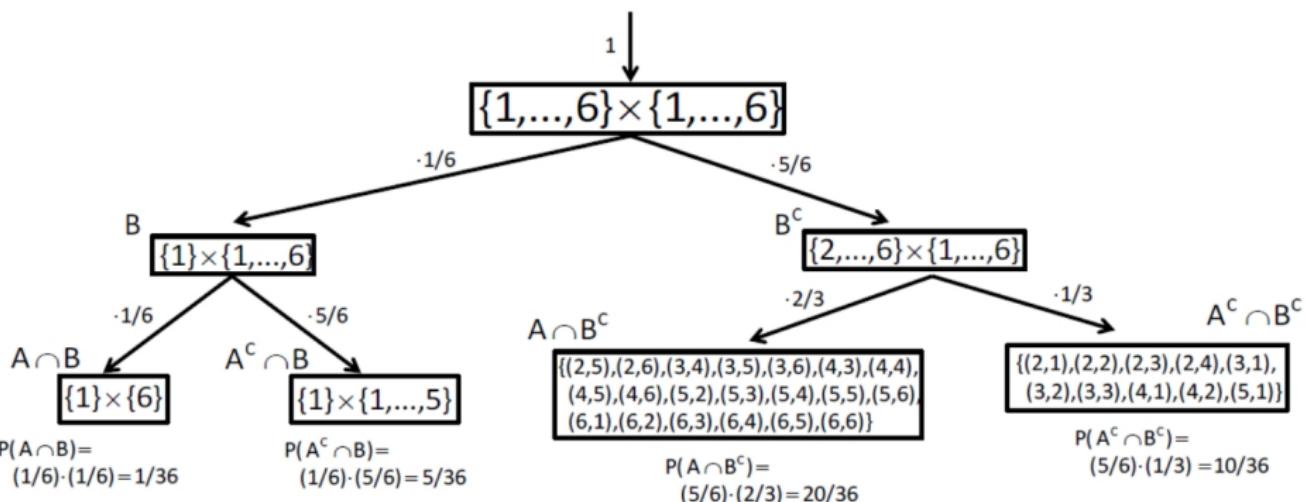
$$\begin{aligned} P(B_3 \cap B_2 \cap B_1) &= \\ P(B_3 | B_2 \cap B_1) \cdot & P(B_2 \cap B_1) \end{aligned}$$

9.1 Bedingte Wahrscheinlichkeiten

Ereignisbaum: Beispiel **zweifacher Würfelwurf**

A = Gesamtaugenzahl ist größer als 6

B = erster Wurf ergibt Augenzahl 1



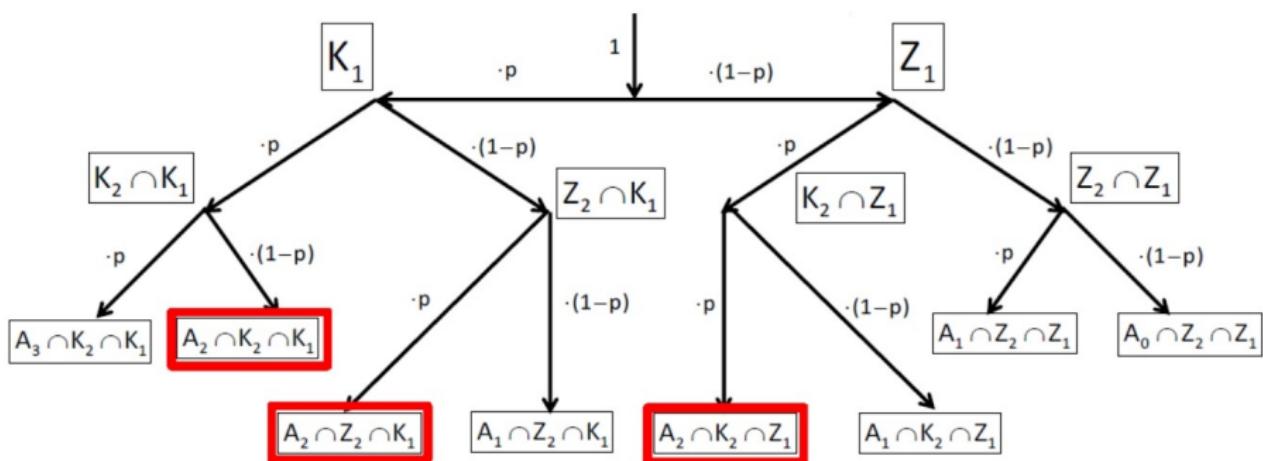
9.1 Bedingte Wahrscheinlichkeiten

Ergebnisbaum: Beispiel **dreifacher Münzwurf mit unfairer Münze**

P : W'keit für Kopf

K_i : i -ter Wurf Kopf, $i = 1, \dots, 4$

A_n : Gesamtzahl Kopf = n , $n = 0, \dots, 3$



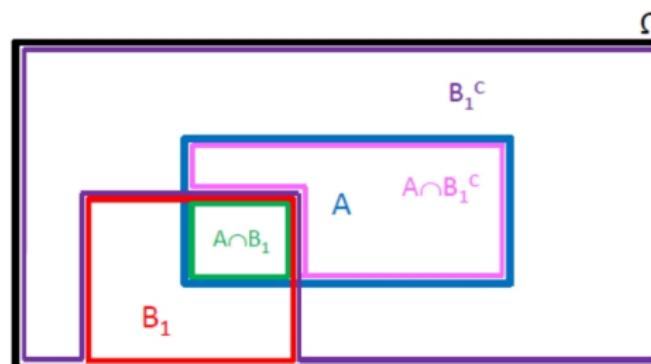
$$P(A_2) = p \cdot p \cdot (1-p) + p \cdot (1-p) \cdot p + (1-p) \cdot p \cdot p = \binom{3}{2} \cdot p^2 (1-p)^{3-2}$$

9.1 Bedingte Wahrscheinlichkeiten

Umformung der Definitionsformel

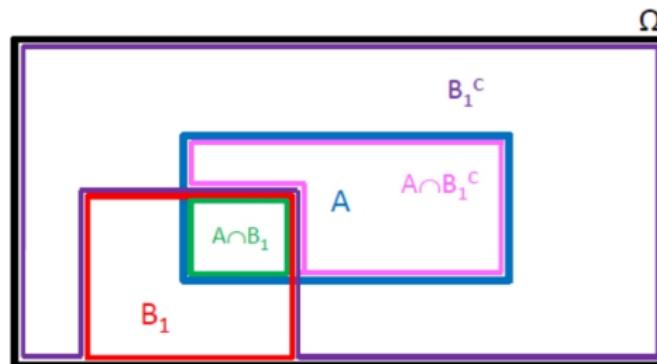
$$P(A|B_1) = \frac{P(A \cap B_1)}{P(B_1)} \Rightarrow P(A \cap B_1) = P(A|B_1) \cdot P(B_1)$$

$$P(A|B_1^c) = \frac{P(A \cap B_1^c)}{P(B_1^c)} \Rightarrow P(A \cap B_1^c) = P(A|B_1^c) \cdot P(B_1^c)$$



9.1 Bedingte Wahrscheinlichkeiten

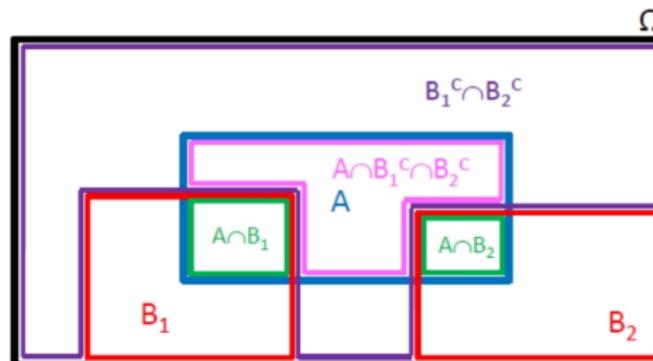
$$P(A) = P(A \cap B_1) + P(A \cap B_1^c) = P(A | B_1) \cdot P(B_1) + P(A | B_1^c) \cdot P(B_1^c)$$



9.1 Bedingte Wahrscheinlichkeiten

$$B_1 \cap B_2 = \emptyset \Rightarrow P(A) = P(A \cap B_1) + P(A \cap B_2) + P(A \cap B_1^c \cap B_2^c)$$

$$= P(A | B_1) \cdot P(B_1) + P(A | B_2) \cdot P(B_2) + P(A | B_1^c \cap B_2^c) \cdot P(B_1^c \cap B_2^c)$$

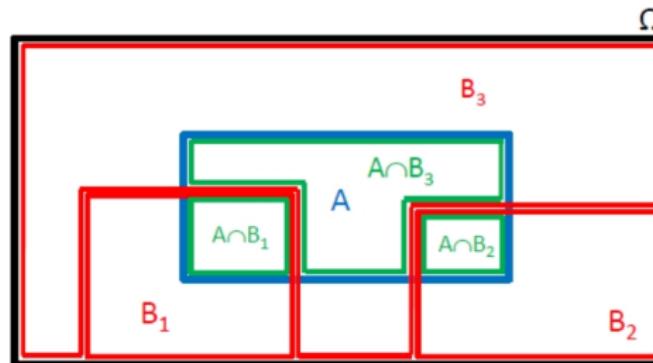


9.1 Bedingte Wahrscheinlichkeiten

$$B_3 = B_1^c \cap B_2^c \Rightarrow B_1 \cap B_2 = \emptyset, B_1 \cap B_3 = \emptyset, B_2 \cap B_3 = \emptyset, B_1 \cup B_2 \cup B_3 = \Omega$$

$$\Rightarrow P(A) = P(A \cap B_1) + P(A \cap B_2) + P(A \cap B_3)$$

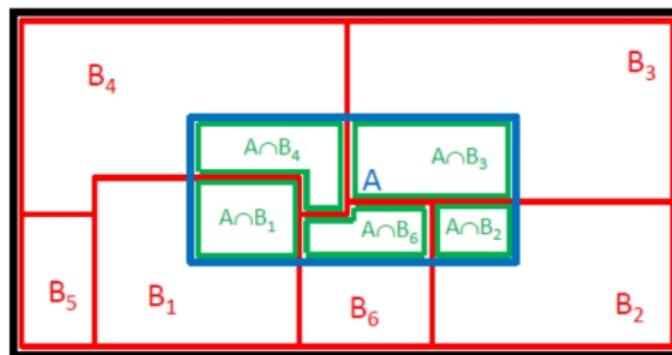
$$= P(A|B_1) \cdot P(B_1) + P(A|B_2) \cdot P(B_2) + P(A|B_3) \cdot P(B_3)$$



9.1 Bedingte Wahrscheinlichkeiten

Satz von der totalen Wahrscheinlichkeit

$$i \neq j \Rightarrow B_i \cap B_j = \emptyset, \quad \bigcup_{i=1}^n B_i = \Omega \Rightarrow P(A) = \sum_{i=1}^n P(A | B_i) \cdot P(B_i)$$



9.1 Bedingte Wahrscheinlichkeiten

Satz von der totalen Wahrscheinlichkeit

Beispiel: Ausfall einer Internetverbindung

A = Internetverbindung fällt aus

B_1 = Verbindung mit Knoten 1

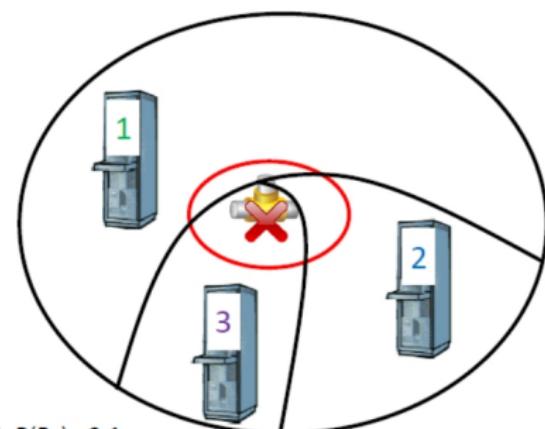
B_2 = Verbindung mit Knoten 2

B_3 = Verbindung mit Knoten 3

W'keiten für Einwahl in Knoten 1, 2 oder 3: $P(B_1) = 0.7$, $P(B_2) = 0.2$, $P(B_3) = 0.1$

W'keiten für Verbindungsausfall für Knoten 1, 2 oder 3 : $P(A|B_1) = 0.02$, $P(A|B_2) = 0.04$, $P(A|B_3) = 0.06$

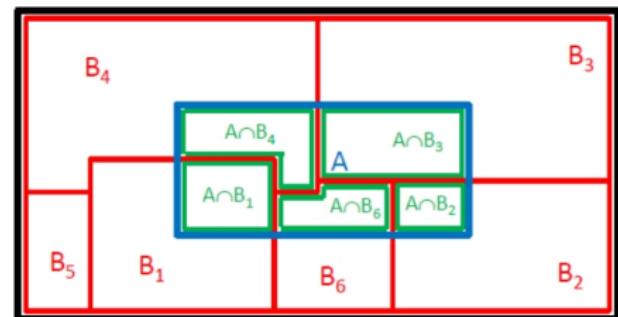
\Rightarrow W'keit für Verbindungsausfall: $P(A) = 0.02 \cdot 0.7 + 0.04 \cdot 0.2 + 0.06 \cdot 0.1 = 0.028$



9.1 Bedingte Wahrscheinlichkeiten

Satz von der totalen Wahrscheinlichkeit $i \neq j \Rightarrow B_i \cap B_j = \emptyset, \bigcup_{i=1}^n B_i = \Omega$

$$P(A) = \sum_{i=1}^n P(A|B_i) \cdot P(B_i)$$

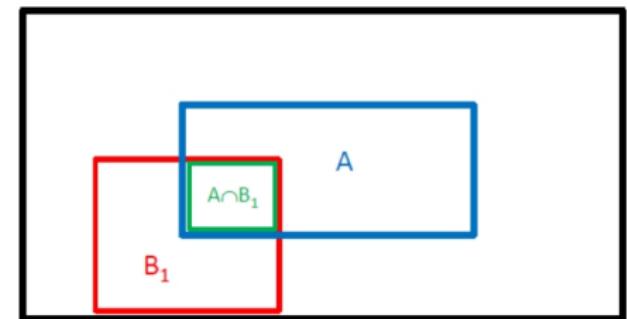


9.1 Bedingte Wahrscheinlichkeiten

Satz von der totalen Wahrscheinlichkeit $i \neq j \Rightarrow B_i \cap B_j = \emptyset, \bigcup_{i=1}^n B_i = \Omega$

$$P(A) = \sum_{i=1}^n P(A|B_i) \cdot P(B_i)$$

$$\begin{aligned} P(A \cap B_i) &= P(A|B_i) \cdot P(B_i) \\ &= P(B_i|A) \cdot P(A) \end{aligned}$$



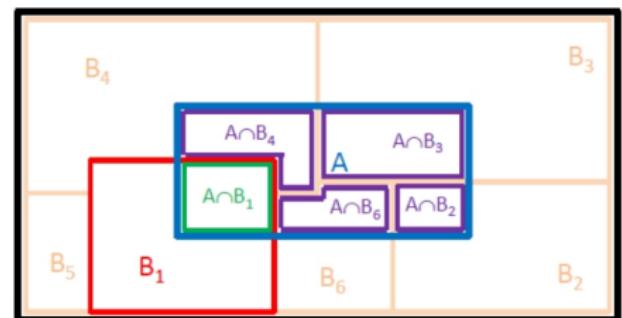
9.1 Bedingte Wahrscheinlichkeiten

Satz von der totalen Wahrscheinlichkeit $i \neq j \Rightarrow B_i \cap B_j = \emptyset, \bigcup_{i=1}^n B_i = \Omega$

$$P(A) = \sum_{i=1}^n P(A|B_i) \cdot P(B_i)$$

$$\begin{aligned} P(A \cap B_i) &= P(A|B_i) \cdot P(B_i) \\ &= P(B_i|A) \cdot P(A) \end{aligned}$$

$$\begin{aligned} \Rightarrow P(B_i|A) &= \frac{P(A \cap B_i)}{P(A)} \\ &= \frac{P(A|B_i) \cdot P(B_i)}{\sum_{j=1}^n P(A|B_j) \cdot P(B_j)} \end{aligned}$$



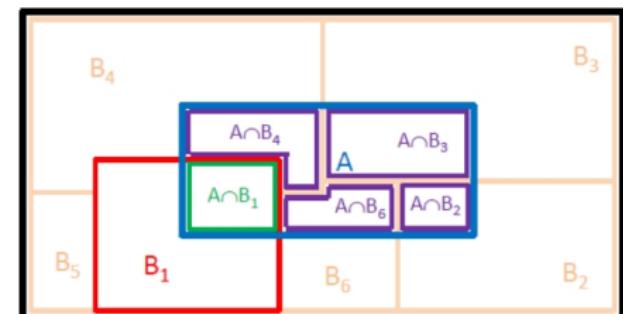
9.1 Bedingte Wahrscheinlichkeiten

Satz von Bayes $i \neq j \Rightarrow B_i \cap B_j = \emptyset, \bigcup_{i=1}^n B_i = \Omega$

$$P(B_i|A) = \frac{P(A|B_i) \cdot P(B_i)}{\sum_{j=1}^n P(A|B_j) \cdot P(B_j)}$$

$P(B_1), \dots, P(B_n)$ heißen
a-priori-Wahrscheinlichkeiten,

$P(B_1|A), \dots, P(B_n|A)$ heißen
a-posteriori-Wahrscheinlichkeiten



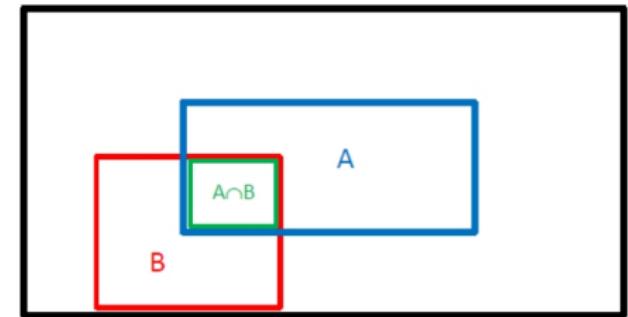
9.1 Bedingte Wahrscheinlichkeiten

Satz von Bayes $i \neq j \Rightarrow B_i \cap B_j = \emptyset, \bigcup_{i=1}^n B_i = \Omega$

$$\Rightarrow P(B_i|A) = \frac{P(A|B_i) \cdot P(B_i)}{\sum_{j=1}^n P(A|B_j) \cdot P(B_j)}$$

Insbesondere

$$A, B \in \Omega \Rightarrow P(B|A) = \frac{P(A|B) \cdot P(B)}{P(A)}$$



9.1 Bedingte Wahrscheinlichkeiten

Satz von Bayes, Beispiel **Spam-Filter**

$$P(B|A) = \frac{P(A|B) \cdot P(B)}{P(A)}$$

Ereignis A: „Mail enthält das Wort *Maximalgewinn*“ \Rightarrow Klassifizierte Mail als Spam

Ereignis B: „Mail ist Spam“

$P(A|B)$ = **Sensitivität** = W'keit, Spam als solchen zu klassifizieren

$P(A^c|B^c)$ = **Spezifität** = W'keit, normale Mails nicht als Spam zu klassifizieren

	B : Mail ist Spam	B^c : Mail ist kein Spam
A : <i>Maximalgewinn</i> in Mail	$P(A B)$	$P(A B^c) = 1 - P(A^c B^c)$
A^c : <i>Maximalgewinn</i> nicht in Mail	$P(A^c B) = 1 - P(A B)$	$P(A^c B^c)$

9.1 Bedingte Wahrscheinlichkeiten

Satz von Bayes, Beispiel **Spam-Filter**

$$P(B|A) = \frac{P(A|B) \cdot P(B)}{P(A)}$$

$P(A|B)$ = **Sensitivität** = W'keit, Spam als solchen zu klassifizieren

$P(A^c|B^c)$ = **Spezifität** = W'keit, normale Mails nicht als Spam zu klassifizieren

Gesucht:

$P(B|A)$ = W'keit, dass klassifizierte Mail Spam ist

Im Satz von Bayes werden $P(A)$ und $P(B)$ benötigt.

$$P(A) = P(A|B) \cdot P(B) + P(A|B^c) \cdot (1 - P(B))$$

Für die Berechnung von $P(B|A)$ ist also die Angabe der **Prävalenz $P(B)$** ausreichend.

9.1 Bedingte Wahrscheinlichkeiten

Satz von Bayes, Beispiel **Spam-Filter**

$$P(B|A) = \frac{P(A|B) \cdot P(B)}{P(A)}$$

Gegeben:

$P(A|B)$ = Sensitivität

$P(A^c|B^c)$ = Spezifität

$P(B)$ = Prävalenz

	B : Mail ist Spam	B^c : Mail ist kein Spam
A : Maximalgewinn in Mail	$P(A B)$	$P(A B^c)$
A^c : Maximalgewinn nicht in Mail	$P(A^c B)$	$P(A^c B^c)$

$$\Rightarrow P(B|A) = \frac{P(A|B) \cdot P(B)}{P(A|B) \cdot P(B) + [1 - P(A^c|B^c)] \cdot [1 - P(B)]}$$

9.1 Bedingte Wahrscheinlichkeiten

Satz von Bayes, Beispiel **Spam-Filter**

$$P(B|A) = \frac{P(A|B) \cdot P(B)}{P(A)}$$

Gegeben:

$$P(A|B) = \text{Sensitivität} = 0.95$$

$$P(A^c|B^c) = \text{Spezifität} = 0.98$$

$$P(B) = \text{Prävalenz} = 0.3$$

	$B : \text{Mail ist Spam}$	$B^c : \text{Mail ist kein Spam}$
$A : \text{Maximalgewinn in Mail}$	0.95	0.02
$A^c : \text{Maximalgewinn nicht in Mail}$	0.05	0.98

$$\begin{aligned} P(B|A) &= \frac{P(A|B) \cdot P(B)}{P(A|B) \cdot P(B) + [1 - P(A^c|B^c)] \cdot [1 - P(B)]} \\ &= \frac{0.95 \cdot 0.3}{0.95 \cdot 0.3 + (1 - 0.98) \cdot (1 - 0.3)} = \frac{0.285}{0.299} \approx 0.9532 \end{aligned}$$

⇒ Wenn 30% der Mails Spam sind, sind bei einer Sensitivität von 95% und bei einer Spezifität von 98% ca. 95.3% der als Spam klassifizierten Mails tatsächlich Spam

9.1 Bedingte Wahrscheinlichkeiten

Satz von Bayes, Beispiel Spam-Filter

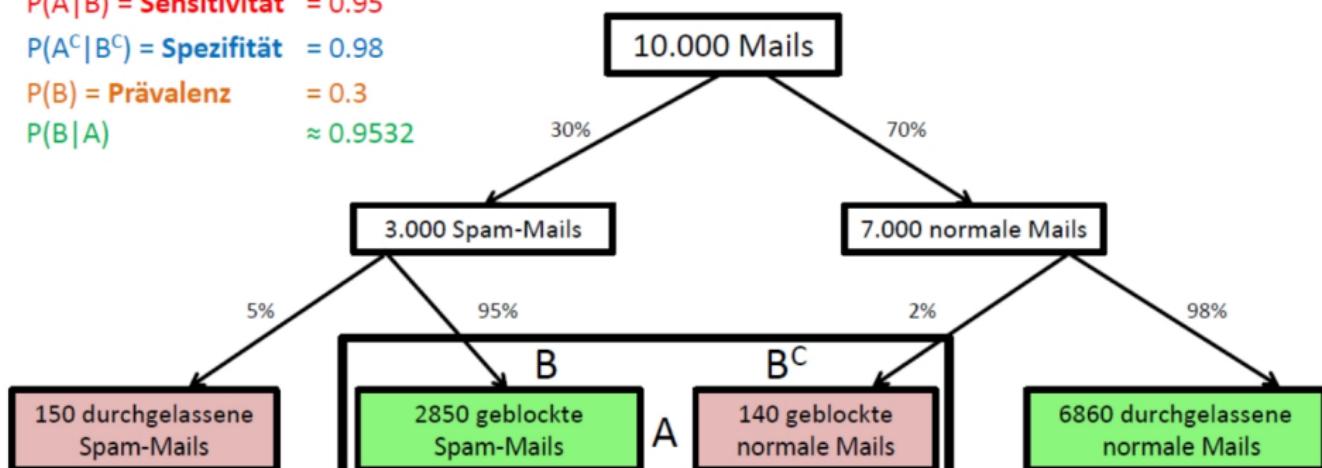
$$P(B|A) = \frac{P(A|B) \cdot P(B)}{P(A)}$$

$$P(A|B) = \text{Sensitivität} = 0.95$$

$$P(A^C|B^C) = \text{Spezifität} = 0.98$$

$$P(B) = \text{Prävalenz} = 0.3$$

$$P(B|A) \approx 0.9532$$



$$P(B|A) = 2850 / (2850 + 140) \approx 95.3\%$$

9.1 Bedingte Wahrscheinlichkeiten

Satz von Bayes, Beispiel **Spam-Filter**

$$P(B|A) = \frac{P(A|B) \cdot P(B)}{P(A)}$$

Gegeben:

$$P(A|B) = \text{Sensitivität} = 0.95$$

$$P(A^c|B^c) = \text{Spezifität} = 0.98$$

$$P(B) = \text{Prävalenz} = 0.005$$

	$B : \text{Mail ist Spam}$	$B^c : \text{Mail ist kein Spam}$
$A : \text{Maximalgewinn in Mail}$	0.95	0.02
$A^c : \text{Maximalgewinn nicht in Mail}$	0.05	0.98

$$\begin{aligned} P(B|A) &= \frac{P(A|B) \cdot P_\Omega(B)}{P(A|B) \cdot P_\Omega(B) + [1 - P(A^c|B^c)] \cdot [1 - P_\Omega(B)]} \\ &= \frac{0.95 \cdot 0.005}{0.95 \cdot 0.005 + (1 - 0.98) \cdot (1 - 0.005)} = \frac{0.00475}{0.02465} \approx 0.1927 \end{aligned}$$

⇒ Wenn 0.5% der Mails Spam sind, sind bei einer Sensitivität von 95% und bei einer Spezifität von 98% ca. 19.3% der als Spam klassifizierten Mails tatsächlich Spam

9.1 Bedingte Wahrscheinlichkeiten

Satz von Bayes, Beispiel Spam-Filter

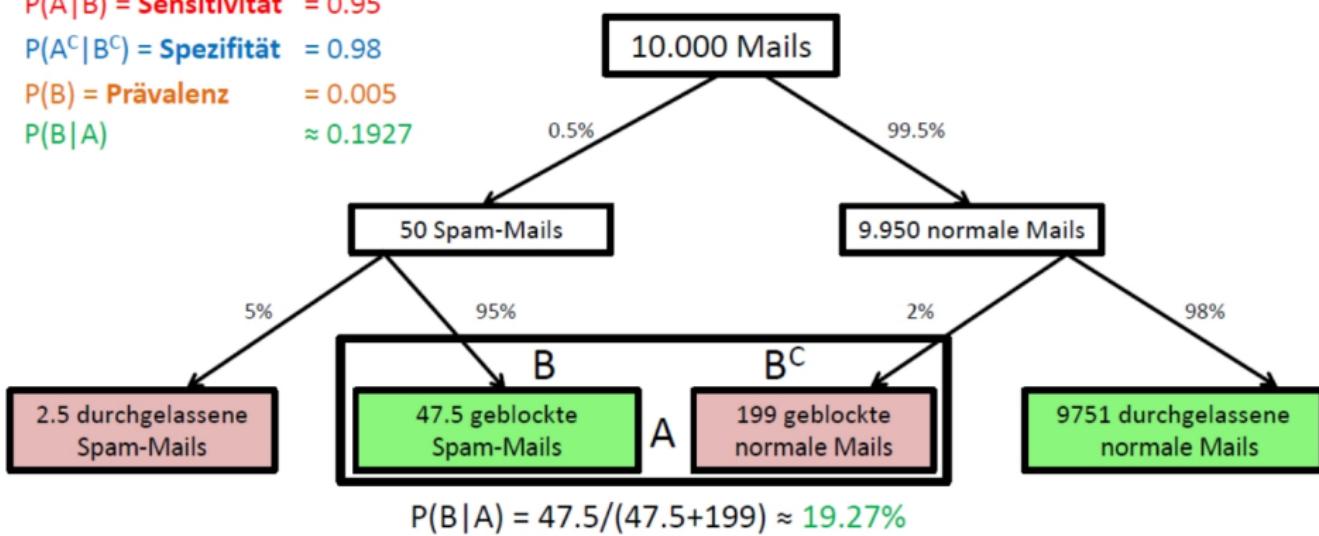
$$P(B|A) = \frac{P(A|B) \cdot P(B)}{P(A)}$$

$P(A|B)$ = Sensitivität = 0.95

$P(A^C|B^C)$ = Spezifität = 0.98

$P(B)$ = Prävalenz = 0.005

$P(B|A)$ ≈ 0.1927



9.2 Stochastische Unabhängigkeit von Ereignissen

Zwei Ereignisse A und B aus (Ω, \mathcal{A}, P) heißen **stochastisch unabhängig**, wenn gilt:

$$P(A \cap B) = P(A) \cdot P(B)$$

Sind $P(B) > 0$ und $P(A)$ stochastisch unabhängig, so sind bedingte und unbedingte Wahrscheinlichkeit von A gleich:

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{P(A) \cdot P(B)}{P(B)} = P(A)$$

9.2 Stochastische Unabhängigkeit von Ereignissen

Eine Menge von n Ereignissen A_1, \dots, A_n aus (Ω, \mathcal{A}, P) heißt **paarweise stochastisch unabhängig**, wenn gilt:

$$P(A_i \cap A_j) = P(A_i) \cdot P(A_j), \quad j \neq i, \quad j = 1, \dots, n, \quad i = 1, \dots, n$$

Eine Menge von n Ereignissen aus (Ω, \mathcal{A}, P) heißt **gemeinsam stochastisch unabhängig**, wenn gilt:

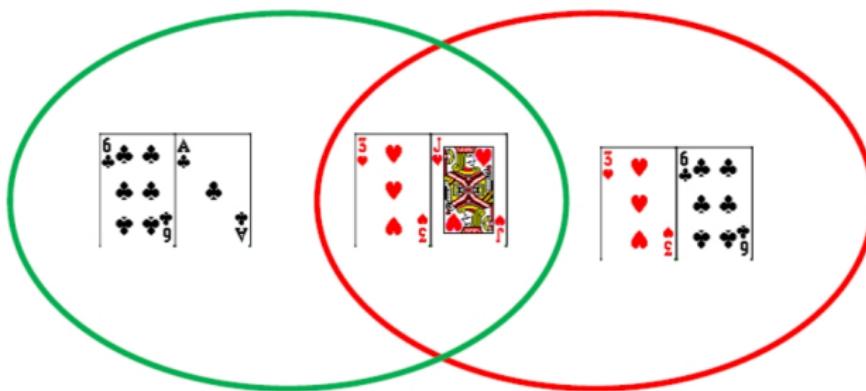
$$P\left(\bigcap_{j=1}^s A_{i_j}\right) = \prod_{j=1}^s P(A_{i_j}), \quad \{i_1, \dots, i_s\} \subseteq \{1, \dots, n\}$$

9.2 Stochastische Unabhängigkeit von Ereignissen

Beispiel: **wiederholtes Ziehen aus gemischem Skatspiel**

A: zweite Karte hat gleiche Symbolfarbe wie erste Karte

B: erste Karte ist rot



9.2 Stochastische Unabhängigkeit von Ereignissen

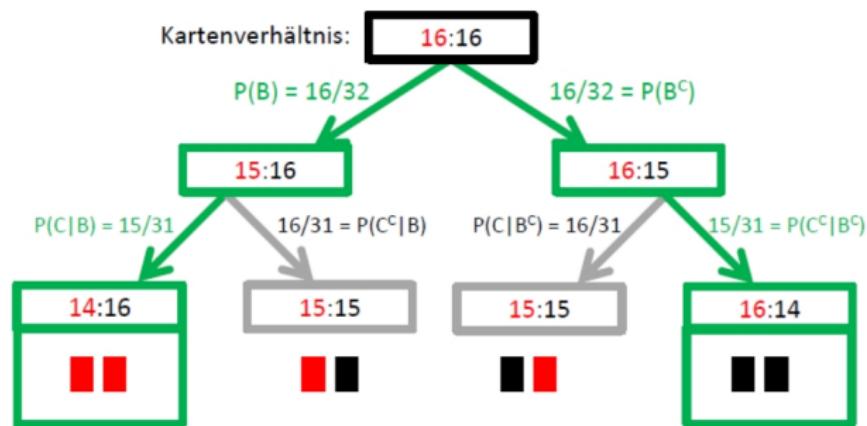
Beispiel: **wiederholtes Ziehen aus gemischem Skatspiel**

A: zweite Karte hat gleiche Symbolfarbe wie erste Karte

B: erste Karte ist rot

C: zweite Karte ist rot

$$P(A) = \frac{16 \cdot 15}{32 \cdot 31} + \frac{16 \cdot 15}{32 \cdot 31} = \frac{15}{31}$$



9.2 Stochastische Unabhängigkeit von Ereignissen

Beispiel: wiederholtes Ziehen aus gemischem Skatspiel

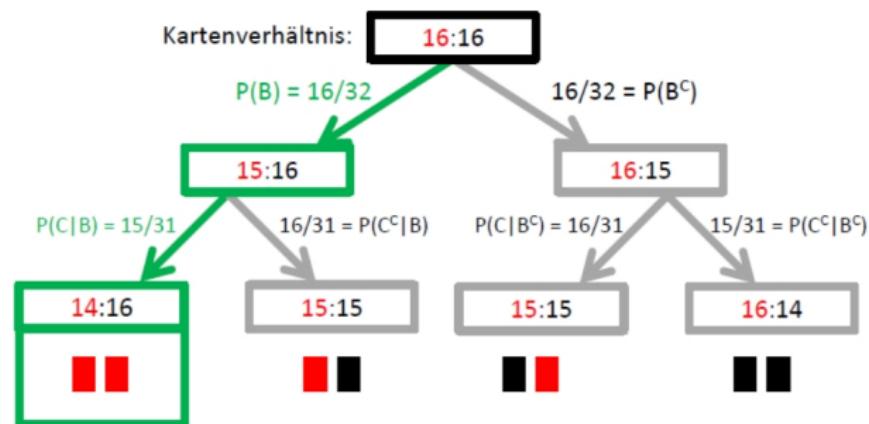
A: zweite Karte hat gleiche Symbolfarbe wie erste Karte

B: erste Karte ist rot

C: zweite Karte ist rot

$$P(A) = \frac{15}{31}$$

$$P(A|B) = \left(\frac{16 \cdot 15}{32 \cdot 31} \right) \Bigg/ \left(\frac{16}{32} \right) = \frac{15}{31}$$



9.2 Stochastische Unabhängigkeit von Ereignissen

Beispiel: **wiederholtes Ziehen aus gemischem Skatspiel**

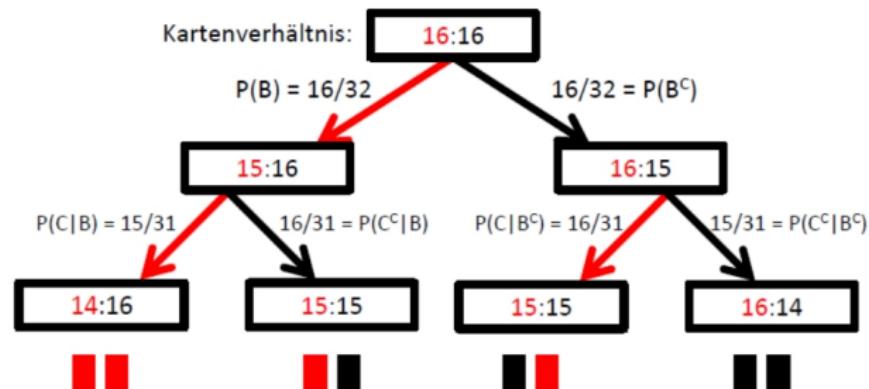
A: zweite Karte hat gleiche Symbolfarbe wie erste Karte

B: erste Karte ist rot

C: zweite Karte ist rot

$$P(A) = \frac{15}{31} = P(A | B)$$

$\Rightarrow A$ und B sind stochastisch unabhängig



9.2 Stochastische Unabhängigkeit von Ereignissen

Beispiel: wiederholtes Ziehen aus gemischem Skatspiel

A: dritte Karte hat gleiche Symbolfarbe wie erste Karte

B: erste zwei Karten sind rot

16:16

16:32

16:32

16:16

15:16

16:15

15:31

16:31

16:31

14:16

15:15

15:31

16:14

13:16

14:15

15:15

15:14

16:13

■ ■ ■

■ ■ ■

■ ■ ■

■ ■ ■

■ ■ ■

14/30

15/30

15/30

16/30

16/30

15/30

15/30

14/30

16/32

16/32

$$\begin{aligned} P(A) = & \frac{16 \cdot 15 \cdot 14 + 16 \cdot 16 \cdot 15}{32 \cdot 31 \cdot 30} + \\ & \frac{16 \cdot 15 \cdot 14 + 16 \cdot 16 \cdot 15}{32 \cdot 31 \cdot 30} \end{aligned}$$

≈ 0.4839

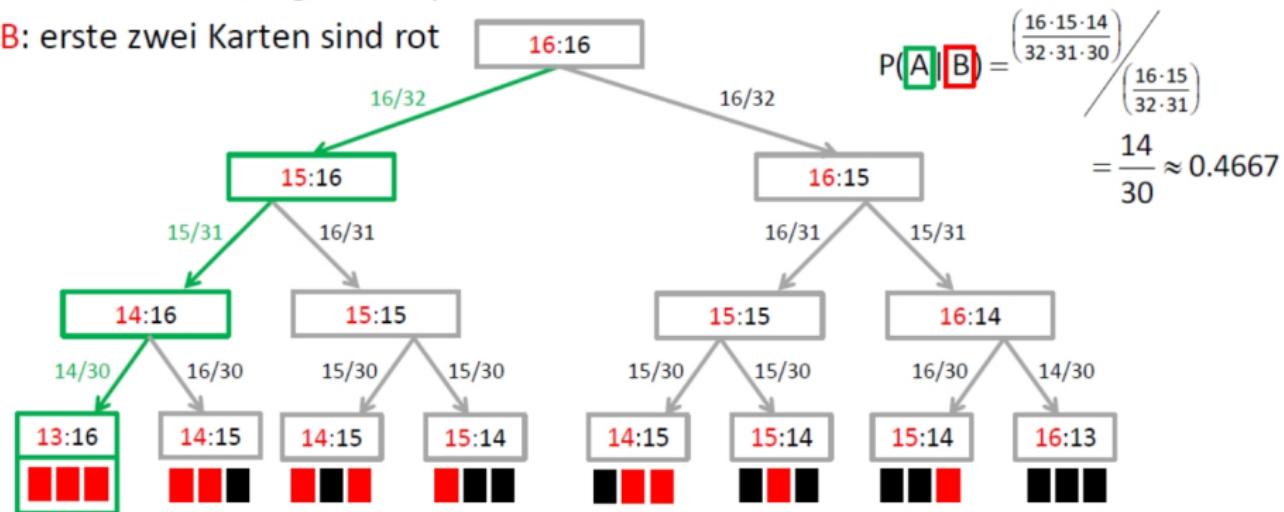
9.2 Stochastische Unabhängigkeit von Ereignissen

Beispiel: wiederholtes Ziehen aus gemischem Skatspiel

$$P(A) \approx 0.4839$$

A: dritte Karte hat gleiche Symbolfarbe wie erste Karte

B: erste zwei Karten sind rot



$$\begin{aligned} P(A|B) &= \frac{\left(\frac{16 \cdot 15 \cdot 14}{32 \cdot 31 \cdot 30}\right)}{\left(\frac{16 \cdot 15}{32 \cdot 31}\right)} \\ &= \frac{14}{30} \approx 0.4667 \end{aligned}$$

9.2 Stochastische Unabhängigkeit von Ereignissen

Beispiel: **wiederholtes Ziehen aus gemischem Skatspiel**

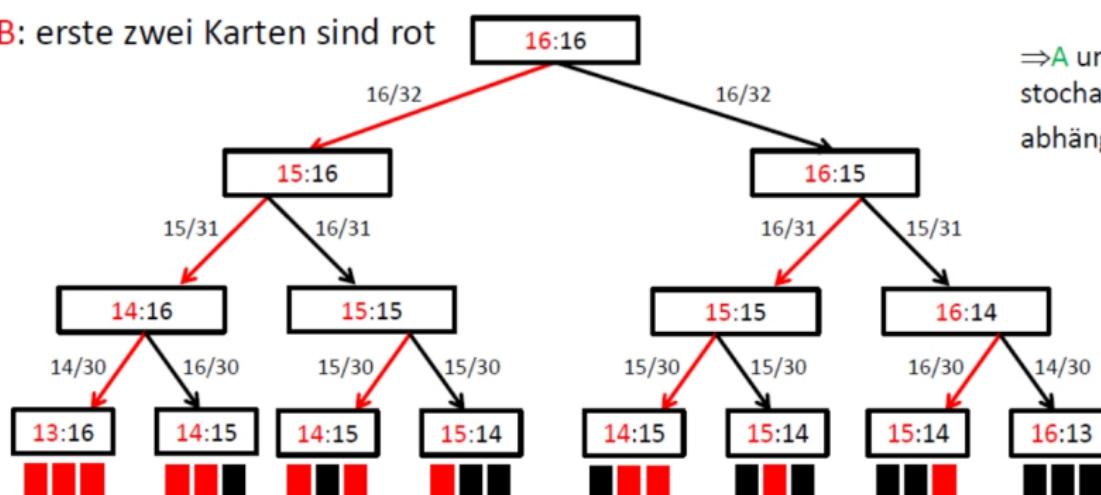
$$P(A) \approx 0.4839$$

A: dritte Karte hat gleiche Symbolfarbe wie erste Karte

$$\neq 0.4667 = P(A | B)$$

B: erste zwei Karten sind rot

$\Rightarrow A$ und B sind
stochastisch
abhängig



9.2 Stochastische Unabhängigkeit von Ereignissen

Seien X und Y Zufallsvariablen mit Verteilungsfunktionen F^X , F^Y und $F^{(X,Y)}$.

Dann heißen X und Y stochastisch unabhängig, falls

$$F^{(X,Y)} = F^X(x) \cdot F^Y(y) \text{ für alle } x, y \in \mathbb{R}$$

Die Zufallsvariablen X_1, \dots, X_n heißen stochastisch unabhängig, falls

$$F^{(X_1, \dots, X_n)}(x_1, \dots, x_n) = \prod_{i=1}^n F^{X_i}(x_i) \text{ für alle } x_1, \dots, x_n \in \mathbb{R}$$

9.2 Stochastische Unabhängigkeit von Ereignissen

Seien X und Y Zufallsvariablen mit Verteilungsfunktionen F^X , F^Y und $F^{(X,Y)}$.

Dann heißen X und Y stochastisch unabhängig, falls

$$F^{(X,Y)}(x,y) = F^X(x) \cdot F^Y(y) \text{ für alle } x, y \in \mathbb{R}$$

$$\Rightarrow F^{(X,Y)}(x,y) = \boxed{P(A \cap B)} = \boxed{P(A) \cdot P(B)} = F^X(x) \cdot F^Y(y)$$

mit $A = \{\omega \in \Omega | X(\omega) \leq x\}$, $B = \{\omega \in \Omega | Y(\omega) \leq y\}$

9.2 Stochastische Unabhängigkeit von Ereignissen

Seien X und Y Zufallsvariablen mit Verteilungsfunktionen F^X , F^Y und $F^{(X,Y)}$.

Dann heißen X und Y stochastisch unabhängig, falls

$$F^{(X,Y)} = F^X(x) \cdot F^Y(y) \text{ für alle } x, y \in \mathbb{R}$$

$F^{(X,Y)}$ diskret

$$\begin{aligned} \Rightarrow p(x_i, y_j) &= P(A \cap B) \\ &= F^{(X,Y)}(x_i, y_j) - F^{(X,Y)}(x_{i-1}, y_j) - F^{(X,Y)}(x_i, y_{j-1}) \\ &\quad + F^{(X,Y)}(x_{i-1}, y_{j-1}) \\ &= F^X(x_i)F^Y(y_j) - F^X(x_{i-1})F^Y(y_j) - F^X(x_i)F^Y(y_{j-1}) \\ &\quad + F^X(x_{i-1})F^Y(y_{j-1}) \\ &= [F^X(x_i) - F^X(x_{i-1})] \cdot [F^Y(y_j) - F^Y(y_{j-1})] = p(x_i) \cdot p(y_j) \end{aligned}$$

mit $A = \{\omega \in \Omega | X(\omega) \leq x_i\}$, $B = \{\omega \in \Omega | Y(\omega) \leq y_j\}$

9.2 Stochastische Unabhängigkeit von Ereignissen

Seien X und Y Zufallsvariablen mit Verteilungsfunktionen F^X , F^Y und $F^{(X,Y)}$.

Dann heißen X und Y stochastisch unabhängig, falls

$$F^{(X,Y)} = F^X(x) \cdot F^Y(y) \text{ für alle } x, y \in \mathbb{R}$$

Seien X und Y Zufallsvariablen mit Verteilungsfunktionen F^X , F^Y und $F^{(X,Y)}$.

Dann heißen X und Y stochastisch unabhängig, falls $F^{(X,Y)}$ stetig

$$\begin{aligned} \Rightarrow f^{(X,Y)}(x, y) &= \frac{\delta F^{(X,Y)}(x, y)}{\delta x \delta y} = \frac{\delta [F^X(x) \cdot F^Y(y)]}{\delta x \delta y} = \frac{\delta F^X(x) \cdot \delta F^Y(y)}{\delta x \delta y} \\ &= f^X(x) \cdot f^Y(y) \end{aligned}$$

9.2 Stochastische Unabhängigkeit von Ereignissen

Beispiel: **Multinomialverteilung**

$$(X, Y) \sim \text{Mult}(2, 0.5, 0.5)$$

$$\Rightarrow p^{XY}(0, 2) = \frac{2}{0! \cdot 2!} \cdot 0.5^2 = \frac{2}{1 \cdot 2} \cdot \frac{1}{4} = \frac{1}{4}$$

$$p^{XY}(1, 1) = \frac{2}{1! \cdot 1!} \cdot 0.5^2 = \frac{2}{1 \cdot 1} \cdot \frac{1}{4} = \frac{1}{2}$$

$$p^{XY}(2, 0) = \frac{2}{2! \cdot 0!} \cdot 0.5^2 = \frac{2}{2 \cdot 1} \cdot \frac{1}{4} = \frac{1}{4}$$

9.2 Stochastische Unabhängigkeit von Ereignissen

Beispiel: **Multinomialverteilung**

$$(X, Y) \sim \text{Mult}(2, 0.5, 0.5)$$

$$p^{XY}(0, 2) = \frac{1}{4} \quad p^X(0) = p^Y(2) = \frac{1}{4} \quad p^X(0) \cdot p^Y(2) = \frac{1}{4} \cdot \frac{1}{4} = \frac{1}{16} \neq \frac{1}{4} = p^{XY}(0, 2)$$

$$p^{XY}(1, 1) = \frac{1}{2} \quad p^X(1) = p^Y(1) = \frac{1}{2} \quad p^X(1) \cdot p^Y(1) = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4} \neq \frac{1}{2} = p^{XY}(1, 1)$$

$$p^{XY}(2, 0) = \frac{1}{4} \quad p^X(2) = p^Y(0) = \frac{1}{4} \quad p^X(2) \cdot p^Y(0) = \frac{1}{4} \cdot \frac{1}{4} = \frac{1}{16} \neq \frac{1}{4} = p^{XY}(2, 0)$$

$\Rightarrow X$ und Y sind stochastisch abhängig